

UNIVERSIDAD DE INGENIERÍA Y TECNOLOGÍA

CARRERA DE BIOINGENIERÍA



Diseño de un modelo predictivo de riesgo de deterioro de la Estela de Raimondi basado en genómica comparativa y potencial metabólico

PROYECTO FINAL DE CARRERA

AUTOR(ES)

Eduardo Esteban Tello Osorio 

Ana Sofía Barrientos Uriarte 

ASESOR(ES)

Pablo Tsukayama Cisneros 

Monica Cecilia Santa María Fuster 

Harry Gustavo Saavedra Espinoza 

Lima - Perú

2026

TABLA DE CONTENIDO

	Pág.
RESUMEN	1
ABSTRACT	2
 CAPÍTULO I INTRODUCCIÓN	 3
Presentación del proyecto	3
Descripción de la situación problemática	3
Formulación del problema	4
Objetivos del proyecto	5
Objetivo general	5
Objetivos específicos	5
Justificación	6
Alcance y limitaciones	7
 CAPÍTULO II ESTADO DEL ARTE	 8
2.1 Soluciones precedentes	8
2.1.1 Protocolos basados en cultivo microbiológico (método tradicional)	8
2.1.2 Tratamientos y limpieza con biocidas químicos	10
2.2 Análisis comparativo de tecnologías actuales	10
2.3 Insuficiencia tecnológica	12
 CAPÍTULO III MARCO TEÓRICO	 14
3.1 Biodeterioro microbiano en sustratos graníticos	14

3.2	Biopelículas subaéreas en patrimonio pétreo	15
3.3	Metagenómica <i>shotgun</i> y ensamblaje de genomas metagenómicos (MAGs)	16
3.4	Evaluación de calidad genómica	17
3.5	Posicionamiento filogenómico y ANI	18
3.5.1	La jerarquía taxonómica	21
3.6	Análisis pangenómico comparativo	22
3.7	Anotación funcional y predicción del potencial metabólico	23
3.8	Limitaciones de la inferencia funcional basada en datos genómicos	25
CAPÍTULO IV MARCO REFERENCIAL		26
4.1	Estándares bioinformáticos	26
4.2	Restricciones realistas del proyecto	27
CAPÍTULO V MARCO METODOLÓGICO		30
5.1	Metodología	30
5.1.1	Diseño general y criterios de decisión metodológica	30
5.1.2	Origen de los datos y unidad de análisis	30
5.1.3	Fase 1. Control de calidad y selección de genomas (OE1)	32
5.1.3.1	Filtrado por dominio	32
5.1.3.2	Evaluación de la calidad genómica	34
5.1.4	Fase 2. Asignación taxonómica y definición de linajes (OE2)	35
5.1.4.1	Clasificación taxonómica genómica	35
5.1.4.2	Confirmación de especie por ANI	35
5.1.4.3	Desreplicación y definición de linajes	36
5.1.4.4	Confirmación filogenómica	37
5.1.4.5	Selección de linajes para el análisis comparativo . . .	38
5.1.5	Fase 3. Análisis pangenómico comparativo (OE3)	39
5.1.5.1	Recopilación de genomas de referencia	39
5.1.5.2	Anotación estructural y funcional consistente	39

5.1.5.3	Reconstrucción del pangenoma	40
5.1.5.4	Identificación de genes candidatos exclusivos de la Estela	42
5.1.6	Fase 4. Caracterización del potencial metabólico y del riesgo (OE4) . . .	42
5.1.6.1	Anotación funcional del potencial metabólico	42
5.1.6.2	Definición de marcadores de riesgo y supervivencia .	43
5.1.6.3	Integración del potencial funcional con la estructura del pangenoma	43
5.1.7	Reproducibilidad	44

CAPÍTULO VI DISEÑO TECNOLÓGICO **47**

6.1	Cálculo de los parámetros y dimensionamiento de los componentes	47
6.1.1	Bases de diseño: el conjunto de datos de entrada	47
6.1.2	Parámetros operativos del diseño	48
6.1.3	Dimensionamiento del cómputo	49
6.1.4	Dimensionamiento del almacenamiento	51
6.2	Selección de materiales, componentes y equipos de la solución	52
6.2.1	Versiones de software y compatibilidad	52
6.2.2	Bases de datos como insumo de referencia	53
6.2.3	Entorno de ejecución	54
6.2.4	Plataforma de cómputo	55
6.3	Integración e implementación de los componentes en la solución final . . .	56
6.3.1	Organización del sistema en programas	56
6.3.2	Normalización de la entrada y trazabilidad	57
6.3.3	Encadenamiento entre etapas	58
6.3.4	Implementación de los script de ejecuciones	60
6.3.5	Control de versiones	61
6.4	Representación gráfica de la solución y su verificación	62
6.4.1	Diagrama de flujo del sistema	62

6.4.2	Arquitectura de cómputo	64
6.4.3	Verificación de la correspondencia entre el diagrama y la implementación	64
CAPÍTULO VI PRUEBAS Y RESULTADOS		66
7.1	Plan de pruebas de la solución	66
7.1.1	Caso base	66
7.1.2	Variables medidas	67
7.1.3	Escenarios de sensibilidad	68
7.2	Análisis de los resultados de las pruebas	69
7.2.1	Resultados de la Fase 1: control de calidad y selección de genomas (OE1)	69
7.2.1.1	Depuración secuencial del conjunto de bins	70
7.2.1.2	Calidad y estructura de los 21 genomas seleccionados	72
7.2.1.3	Implicancia para el OE1	75
7.2.2	Resultados de la Fase 2: asignación taxonómica y definición de linajes (OE2)	76
7.2.2.1	Composición taxonómica de la fracción viable	76
7.2.2.2	Confirmación filogenómica	78
7.2.2.3	Confirmación de especie y candidatos a novedad taxonómica	79
7.2.2.4	Desreplicación y definición de linajes	81
7.2.2.5	Prevalencia espacial de los linajes	83
7.2.2.6	Implicancia para el OE2	85
7.2.3	Sensibilidad de los resultados a los umbrales elegidos	86
7.2.3.1	Umbrales de calidad genómica	87
7.2.3.2	Criterio de discriminación por dominio	88
7.2.3.3	Umbral de ANI para la definición de linaje	89
7.2.3.4	Continuidad del ensamblaje	90
7.2.4	Iteraciones de diseño derivadas de los resultados	90
7.2.4.1	Primera iteración: alcance del árbol filogenómico	91

7.2.4.2	Segunda iteración: criterio de selección de linajes para el pangenoma	91
7.3	Verificación del cumplimiento de las especificaciones técnicas	92
7.4	Verificación del cumplimiento de restricciones	93
ANEXOS		104
	Resolución de problemas	104
	Trabajo en equipo	106
	Experimentación	107
	Aprendizaje continuo	108
7.5	Anexo: Repositorio de GitHub	110
7.6	Anexo: Reporte completo de calidad y selección de bins (Fase 1)	110

ÍNDICE DE TABLAS

Tabla 3.1	Categorías de calidad MIMAG para MAGs bacterianos y arqueales [30].	18
Tabla 4.1	Matriz de restricciones realistas del proyecto y su impacto en las decisiones de diseño metodológico.	28
Tabla 5.1	Bins genómicos recuperados por muestra (previos al filtrado por dominio y calidad).	33
Tabla 5.2	Matriz de selección de software para la clasificación de contigs.	34
Tabla 5.3	Matriz de selección de software para la confirmación filogenómica.	37
Tabla 5.4	Matriz de selección de software para la anotación estructural y funcional.	40
Tabla 5.5	Matriz de selección de software para la reconstrucción del pan-genoma.	41
Tabla 5.6	Marcadores genómicos <i>a priori</i> de biodeterioro y supervivencia.	45
Tabla 6.1	Bases de diseño del conjunto de entrada	48
Tabla 6.2	Parámetros operativos implementados	49
Tabla 6.3	Dimensionamiento de cómputo por etapa	50
Tabla 6.4	Dimensionamiento del almacenamiento	51
Tabla 6.5	Versiones de software seleccionadas	53
Tabla 6.6	Insumos de referencia del sistema	54
Tabla 6.7	Programas que componen el sistema	56
Tabla 6.8	Archivos que encadenan las etapas	58

Tabla 7.1	Parámetros del caso base	67
Tabla 7.2	Variables medidas en cada etapa	68
Tabla 7.3	Escenarios de sensibilidad	69
Tabla 7.4	Métricas de los 21 MAGs seleccionados	75
Tabla 7.5	Linajes definidos en la Fase 2	86
Tabla 7.6	Sensibilidad a los umbrales de calidad	87
Tabla 7.7	Sensibilidad del criterio de dominio	88
Tabla 7.8	Matriz de verificación de especificaciones técnicas	93
Tabla 7.9	Matriz de verificación de restricciones	94
Tabla 7.10	Aprendizaje continuo: fuentes consultadas, contenido aprendi- do y su aplicación en el documento.	108
Tabla 7.11	Reporte completo de evaluación y filtrado de bins genómicos (Fase 1).	110

ÍNDICE DE FIGURAS

Figura 5.1	Esquema de muestreo de la Estela de Raimondi. Se señalan los 20 puntos de hisopado distribuidos sobre las cinco regiones del monumento (base superior, cara frontal, laterales izquierda y derecha, y sección inferior). En cada punto se recolectaron dos hisopados independientes: el hisopo A, destinado a la extracción directa de ADN para secuenciación de amplicones, y el hisopo B, destinado al cultivo de la fracción viable, posteriormente secuenciado por metagenómica <i>shotgun</i> . Tomado del informe técnico de la UPCH [10].	31
Figura 6.1	Diagrama de flujo del sistema	63
Figura 6.2	Arquitectura de cómputo del sistema	64
Figura 7.1	Embudo de selección de genomas	71
Figura 7.2	Calidad y métricas de ensamblaje	73
Figura 7.3	Composición taxonómica	77
Figura 7.4	Árbol filogenómico de los 21 genomas	78
Figura 7.5	Evaluación de novedad taxonómica	80
Figura 7.6	Matriz de similitud genómica	82
Figura 7.7	Prevalencia espacial de los linajes	83
Figura 7.8	Diagrama de Gantt del trabajo en equipo durante el desarrollo del proyecto.	106

Figura 7.9 Flujograma del marco metodológico: cuatro fases consecutivas
(OE1 a OE4) desde el origen de los datos metagenómicos hasta la
caracterización del potencial metabólico y de riesgo. 107

RESUMEN

El patrimonio pétreo está expuesto al biodeterioro microbiano, proceso mediante el cual las comunidades que colonizan la roca disuelven su matriz mineral y alteran su superficie. La Estela de Raimondi, litoescultura de granito de la cultura Chavín bajo custodia museística, presenta biopelículas y alteraciones cromáticas cuya evaluación previa se limitó a la identificación taxonómica, sin esclarecer la capacidad de deterioro de los organismos vivos que la habitan. El objetivo de este proyecto fue diseñar un flujo de análisis computacional para caracterizar el potencial de biodeterioro y las señales de adaptación genómica de los linajes bacterianos dominantes de la fracción viable del monumento, con el fin de sustentar la evaluación del riesgo y una conservación preventiva basada en evidencia genómica. Se partió de datos de secuenciación metagenómica masiva obtenidos de la fracción cultivable de la superficie, sobre los que se estructuró un flujo reproducible que integró el control de calidad genómica, la clasificación taxonómica basada en el genoma completo, la agrupación de genomas redundantes en linajes, la reconstrucción pangenómica comparativa frente a referencias globales y la anotación funcional del potencial metabólico.

Palabras clave:

Biodeterioro; Patrimonio pétreo; Metagenómica; Pangenoma; Potencial metabólico; Conservación preventiva; Estela de Raimondi

ABSTRACT

Stone heritage is exposed to microbial biodeterioration, a process by which the communities colonizing the rock dissolve its mineral matrix and alter its surface. The Raimondi Stela, a granite lithosculpture of the Chavín culture held in a national museum, exhibits biofilms and chromatic alterations whose prior assessment was limited to taxonomic identification, without clarifying the deterioration capacity of the living organisms inhabiting it. The objective of this project was to design a computational analysis workflow to characterize the biodeterioration potential and the genomic adaptation signals of the dominant bacterial lineages of the monument's viable fraction, in order to support risk assessment and genomics-based preventive conservation. High-throughput metagenomic sequencing data obtained from the cultivable surface fraction were used as the starting point, upon which a reproducible workflow was structured, integrating genomic quality control, whole-genome-based taxonomic classification, the grouping of redundant genomes into lineages, comparative pangenomic reconstruction against global references, and functional annotation of metabolic potential.

Keywords:

Biodeterioration; Stone heritage; Metagenomics; Pangenome; Metabolic potential; Preventive conservation; Raimondi Stela

CAPÍTULO I

INTRODUCCIÓN

Presentación del proyecto

La Estela de Raimondi es una de las piezas más importantes de la cultura Chavín (Horizonte Temprano, 1200 a.C. - 400 a.C.) y un pilar de la arqueología andina. Elaborada en granito pulido, esta litoescultura de casi dos metros de altura representa a una divinidad antropomorfa, el “Dios de los Báculos”, caracterizada por una compleja iconografía que integra rasgos de felinos, aves de rapiña y serpientes [1]. Tras su hallazgo a mediados del siglo XIX, inicialmente por el agricultor Timoteo Espinoza en 1840 y su posterior reconocimiento valórico por Antonio Raimondi en 1860 en el Templo Nuevo de Chavín de Huántar, la Estela ha sido objeto de múltiples traslados y, por consiguiente, daños, desde su uso doméstico en Áncash hasta su actual custodia en el Museo Nacional de Arqueología, Antropología e Historia del Perú (MNAAHP) [2].

El presente proyecto de tesis surge de la necesidad de aplicar herramientas de genómica avanzada y bioinformática para entender la ecología microbiana que habita este monumento, integrando el análisis del pangenoma de linajes bacterianos para identificar poblaciones propias de la región, así como para predecir riesgos de deterioro en elementos arqueológicos.

Descripción de la situación problemática

A pesar de encontrarse en un ambiente controlado de museo, la Estela de

Raimondi no es inmune al paso del tiempo ni a la interacción con agentes biológicos. Históricamente, la pieza ha sufrido daños físicos, incluyendo fracturas por el terremoto de 1940 [3]. Sin embargo, informes técnicos recientes han identificado la presencia de biopelículas y alteraciones cromáticas en la superficie del granito.

Las piedras arqueológicas, como la caliza, el granito o la toba volcánica, son altamente susceptibles al daño causado por comunidades microbianas, incluyendo bacterias, cianobacterias, algas y hongos. Los microorganismos penetran los poros y fisuras de la piedra mediante hifas fúngicas o forman biopelículas [4]. Estas comunidades pueden inducir biocorrosión mediante la secreción de ácidos orgánicos que disuelven la matriz mineral o generar pigmentos que alteran irreparablemente la estética del monumento [4, 5]. Sin embargo, se ha demostrado que las biopelículas subaéreas tienen un rol dual, pues mientras algunas causan deterioro, otras pueden actuar como una capa bioprotectora que regula la humedad térmica, consolida la superficie y protege a la piedra de los contaminantes atmosféricos [5, 6].

El problema reside en que las estrategias tradicionales de conservación suelen ser reactivas y basadas en identificación taxonómica básica, ignorando el potencial metabólico real, las poblaciones favorables y las capacidades adaptativas de las bacterias que dominan la biopelícula.

Formulación del problema

Si bien estudios previos sobre la Estela de Raimondi permitieron caracterizar la diversidad taxonómica de su microbioma mediante secuenciación de amplicones (16S rRNA e ITS2) a partir de ADN ambiental, esta aproximación presenta limitaciones importantes para evaluar su papel en el biodeterioro del monumento. Por un lado, el ADN ambiental no permite distinguir entre microorganismos metabólicamente activos, latentes o muertos, ni diferenciar a los verdaderos colonizadores

del sustrato de aquellos microorganismos depositados pasivamente desde el ambiente [7, 8]. Por otro lado, la secuenciación de amplicones ofrece información sobre la identidad taxonómica de la comunidad microbiana, pero no permite determinar su potencial metabólico ni las capacidades adaptativas de las poblaciones presentes [9].

Frente a ello, la presente tesis se concentra en la fracción viable del microbioma, es decir, en aquellos microorganismos capaces de crecer en cultivo y, por tanto, confirmados como vivos. A partir de esta fracción se realizó secuenciación metagenómica *shotgun* [10]. Mediante el ensamblaje de genomas metagenómicos (MAGs) y el análisis comparativo de sus genes accesorios frente a referencias globales, se busca caracterizar el potencial metabólico y las señales de adaptación evolutiva de los linajes bacterianos dominantes en el sustrato lítico. Esta aproximación permite identificar biomarcadores genómicos asociados a la producción de ácidos y a la formación de biopelículas, aportando parámetros técnicos para la evaluación del riesgo de biodeterioro y el diseño de protocolos de conservación preventiva basados en evidencia genómica.

Objetivos del proyecto

Objetivo general

Diseñar un modelo predictivo para determinar el potencial metabólico y la evolución genómica de los linajes bacterianos dominantes en la Estela de Raimondi mediante análisis de pangenoma y potencial metabólico.

Objetivos específicos

1. Seleccionar los MAGs con mayor integridad ($> 70\%$) y baja contaminación ($< 5\%$).

2. Determinar la posición filogenómica de los MAGs seleccionados mediante el cálculo de ANI (Identidad Nucleotídica Promedio) y filogenia frente a bases de datos internacionales como NCBI y GTDB.
3. Definir el genoma core y el genoma accesorio de los linajes dominantes de la fracción viable de la Estela frente a genomas de referencia globales, identificando genes exclusivos, es decir, específicos de la Estela.
4. Mapear las rutas metabólicas de supervivencia, como la esporulación, y de deterioro, como la formación de biopelículas y la producción de ácidos, analizando si los genes responsables se encuentran en el genoma accesorio, es decir, si fueron adquiridos por adaptación al monumento.

Justificación

El presente trabajo surge de la necesidad de transitar de una caracterización taxonómica convencional hacia un análisis de resolución genómica. En el contexto de la conservación del patrimonio en Latinoamérica, los estudios microbiológicos suelen detenerse en la descripción de géneros, dejando sin respuesta la interrogante sobre qué mecanismos biológicos específicos están siendo ejecutados activamente en la superficie del monumento [5, 6]. El uso de bioinformática avanzada para la reconstrucción de MAGs y el análisis pangenómico permitirá identificar si los determinantes de biodeterioro, como la síntesis de ácidos orgánicos o la formación de biopelículas, son rasgos intrínsecos de los linajes o adaptaciones adquiridas para la supervivencia en el monumento [7, 11]. Este estudio no solo posiciona el análisis del patrimonio cultural peruano a la vanguardia tecnológica regional, sino que provee una base científica para predecir riesgos y optimizar estrategias de conservación preventiva menos invasivas.

Alcance y limitaciones

El alcance de esta tesis es de naturaleza estrictamente computacional y descriptiva, basándose en el análisis de datos metagenómicos previamente secuenciados de la Estela de Raimondi por la Universidad Peruana Cayetano Heredia (Laboratorio de Genómica Microbiana). El estudio se centrará exclusivamente en los linajes bacterianos dominantes que presenten métricas de calidad genómica adecuadas para un análisis pangenómico robusto.

Entre las limitaciones, se debe precisar que la caracterización describe la fracción del microbioma recuperable mediante cultivo, que corresponde a un subconjunto de la comunidad viable y no necesariamente a la totalidad de las poblaciones dominantes *in situ* [8, 12]. A cambio, garantiza que los genomas analizados provienen de organismos vivos, condición necesaria para atribuirles un rol activo en el biodeterioro. Asimismo, al no contar con datos de metatranscriptómica (RNA-seq), la caracterización funcional representa el potencial metabólico y no la actividad biológica real en el momento de la toma de muestra [13]. Además, la integridad y el grado de contaminación de los MAGs están intrínsecamente ligados a la profundidad de la secuenciación original y a la complejidad de la biopelícula colonizadora [5, 14]. Por otro lado, la potencia del análisis pangenómico está sujeta a la disponibilidad y representatividad de genomas de referencia de alta calidad en bases de datos globales como NCBI o GTDB [15]. Finalmente, factores abióticos externos, como las fluctuaciones de humedad y temperatura en el museo, solo se utilizarán como marco contextual para interpretar las estrategias de supervivencia microbiana.

CAPÍTULO II

ESTADO DEL ARTE

A lo largo del tiempo, la evaluación del biodeterioro en monumentos arqueológicos e históricos ha pasado por distintas etapas tecnológicas, donde cada método presentó limitaciones operativas y alcances técnicos que influyeron en la evolución del área. En este contexto, el propósito de este capítulo es revisar de manera crítica las soluciones analíticas y de intervención desarrolladas tanto en el ámbito académico como industrial, estableciendo un marco comparativo basado en parámetros de rendimiento, cobertura y viabilidad técnica. Esto permitirá comprender las fortalezas y limitaciones de los enfoques previos, así como justificar el desarrollo y la adopción de aproximaciones diagnósticas contemporáneas.

2.1 Soluciones precedentes

2.1.1 Protocolos basados en cultivo microbiológico (método tradicional)

Durante décadas, el estudio de los ecosistemas microbianos en el patrimonio pétreo dependió casi exclusivamente de técnicas dependientes de cultivo. Las muestras extraídas del sustrato se sembraban en medios de laboratorio generales, como Agar Nutritivo, MEA o PDA, frecuentemente suplementados con antibióticos o cicloheximida para la selección de grupos específicos [8]. Este enfoque permitió aislar e identificar morfológicamente a numerosos taxa bacterianos y fúngicos asociados al biodeterioro.

No obstante, esta metodología introduce sesgos selectivos, siendo su principal limitación la estructural: se estima que aproximadamente el 99 % de los microorganismos ambientales son "viables pero no cultivables"(VBNC) en condiciones de laboratorio estándar, dado que los medios artificiales no replican las condiciones oligotróficas, de estrés hídrico y radiación UV características de las superficies pétreas [8, 12, 16]. En contraste con las tecnologías moleculares modernas, los métodos de cultivo solo logran detectar entre el 1 % y el 5 % de la comunidad microbiana total [17]. Un estudio ilustrativo realizado en el campo de concentración de Auschwitz demostró que el cultivo detectó apenas 8 géneros bacterianos, mientras que la secuenciación NGS reveló 99 géneros en el mismo material [18]. Adicionalmente, los medios de cultivo imponen concentraciones artificialmente elevadas de nutrientes, lo que favorece a microorganismos heterótrofos de rápido crecimiento que pueden no ser los colonizadores dominantes ni los principales agentes de deterioro in situ [8, 19].

Ahora bien, esta misma selectividad adquiere valor metodológico cuando el objetivo no es inventariar la comunidad total, sino identificar a los organismos con capacidad real de deterioro. A diferencia del ADN ambiental, que persiste en el sustrato tras la muerte celular y no distingue entre células activas y muertas [8], el crecimiento en cultivo constituye una prueba directa de viabilidad: todo microorganismo aislado está, por definición, vivo. Por ello, la secuenciación metagenómica aplicada sobre la fracción cultivada permite acoplar la certeza de viabilidad con la resolución genómica, estrategia adoptada en la presente tesis [10]. La contrapartida, que se mantiene explícita, es que dicha fracción representa únicamente el subconjunto cultivable de la comunidad viable, por lo que sus conclusiones no se extienden a los linajes que no crecen en los medios empleados.

2.1.2 Tratamientos y limpieza con biocidas químicos

Para el control del biodeterioro, la práctica conservativa tradicional recurrió históricamente a sustancias antimicrobianas de síntesis química: alcoholes, fenoles, aldehídos, compuestos de amonio cuaternario (como el cloruro de benzalconio), sales de estaño, derivados de isotiazolinonas y tratamientos de fumigación con óxido de etileno [12, 13]. Estas estrategias presentan ventajas a corto plazo en términos de reducción de biomasa visible, pero exhiben graves inconvenientes a mediano y largo plazo.

En primer lugar, la eficacia del biocida es frecuentemente transitoria y requiere reaplicaciones periódicas [13]. En segundo lugar, generan toxicidad tanto para los operadores humanos como para el ecosistema circundante [13]. Desde el punto de vista material, los biocidas oxidantes pueden inducir manchas por herrumbre y eflorescencias sobre la piedra, mientras que las soluciones de limpieza ácida o alcalina comprometen la integridad mineralógica del sustrato [13]. Finalmente, y de mayor relevancia para la gestión del biodeterioro a largo plazo, los biocidas eliminan el microbioma natural sin remover la biomasa celular residual, la cual actúa como sustrato nutritivo que acelera la recolonización. Bajo la presión selectiva del biocida, las comunidades que recolonizan son frecuentemente resistentes al tratamiento y presentan perfiles metabólicos más agresivos, involucrando tanto a cepas bacterianas resistentes como a una mayor presencia de hongos altamente melanizados [13, 20]. Este efecto fue documentado de forma notable tras los tratamientos masivos realizados en las cuevas de Lascaux y en la tumba de San Pablo en Éfeso [12].

2.2 Análisis comparativo de tecnologías actuales

La introducción de las tecnologías de secuenciación de próxima generación (NGS) como Illumina MiSeq, NovaSeq, PacBio y Oxford Nanopore, redefinió los

estándares del análisis del microbioma del patrimonio pétreo. En la práctica contemporánea, coexisten diversos enfoques que compiten en términos de rendimiento de datos, costos operativos y viabilidad de estandarización.

La secuenciación de amplicones de genes marcadores evolutivamente conservados, como las regiones hipervariables V3-V6 del gen 16S rRNA (para bacterias y arqueas) y las regiones ITS1/ITS2 (para hongos), permite la identificación filogenética de alta resolución sin necesidad de cultivo previo [16, 21].

La metagenómica de escopeta (shotgun metagenomics) secuencia la totalidad del material genético presente en la muestra, superando el sesgo de la amplificación específica por PCR y revelando no solo qué organismos están presentes, sino que permite determinar potencialmente qué rutas metabólicas y genes funcionales contiene la comunidad [16, 22]. Estudios previos demostraron que la secuenciación de amplicones permite detectar una diversidad microbiana significativamente superior a la obtenida mediante métodos clásicos y, en combinación con herramientas bioinformáticas predictivas, inferir el potencial funcional del microbioma en monumentos pétreos [17, 21].

Cabe precisar que la metagenómica *shotgun* puede aplicarse tanto sobre ADN extraído directamente del ambiente como sobre material previamente enriquecido por cultivo; en el segundo caso, la comunidad se acota a su fracción viable a cambio de un ADN de mayor calidad y trazabilidad, un compromiso relevante en muestras de baja biomasa como las superficies pétreas [10, 23].

En términos comparativos con los métodos tradicionales, la NGS supera significativamente al cultivo en cobertura taxonómica, sensibilidad y representatividad de la comunidad real [12, 16, 18]. No obstante, su coste por muestra es considerablemente más elevado, requiere equipamiento especializado, genera grandes volúmenes de datos que demandan análisis bioinformáticos complejos, y presenta limitaciones

propias: artefactos genéticos generados durante la amplificación por PCR (secuencias quiméricas), resolución taxonómica que frecuentemente no alcanza el nivel de especie, y dificultades de extracción de ADN en estructuras resistentes como las endosporas de *Bacillus* spp. [7, 8, 17].

En la frontera tecnológica se ubican la metatranscriptómica y la metabolómica ambiental, diseñadas para resolver el perfil funcional dinámico del microbioma in situ [13, 18]. La metatranscriptómica ofrece la medición directa de los transcritos de ARN activos al momento del muestreo, discriminando con precisión entre células muertas, en estado viable pero no cultivable (VBNC) o metabólicamente activas [8]. Sin embargo, la secuenciación de ARN ambiental en el patrimonio pétreo se encuentra aún en una etapa inicial y carece de estandarización operativa; esto se debe en gran medida a la inestabilidad de la molécula y a que los costos de este análisis molecular siguen siendo demasiado altos en relación con los recursos habituales disponibles para los laboratorios de restauración [12, 16]. Por su parte, la metabolómica acoplada a espectrometría de masas (UPLC/HRMS) permite identificar los productos reales del catabolismo (como los ácidos orgánicos implicados en la disolución mineral), pero se enfrenta a la limitación de utilizar bases de datos de referencia ambiental incompletas que generan un volumen considerable de falsos positivos, situando los resultados en un nivel de identificación que requiere precaución y validación adicional [18].

2.3 Insuficiencia tecnológica

A pesar de los importantes avances moleculares, las soluciones actuales presentan vacíos estructurales al ser incapaces de confirmar si el potencial genético detectado se traduce en una actividad de deterioro real in situ, ya que el ADN perdura tras la muerte celular y disocia el inventario microbiano del daño activo [8, 13, 22]. Además, existe una carencia crítica de metodologías estandarizadas y

cuantitativas que permitan relacionar el perfil metabólico con el riesgo material [13], lo que impide diferenciar empíricamente si una biopelícula ejerce un rol de degradación o de bioprotección sobre la piedra [13]. En este contexto, se ha subrayado la necesidad de transitar desde diagnósticos descriptivos y centrados en el material hacia marcos predictivos basados en la función microbiana [24]; sin embargo, estas propuestas permanecen mayoritariamente en un plano conceptual, con énfasis en sustratos calcáreos y sin una implementación operativa que permita particionar el repertorio génico de los linajes colonizadores ni distinguir los rasgos de deterioro intrínsecos de aquellos adquiridos por adaptación al nicho. Por consiguiente, establecer una causalidad directa entre microorganismos específicos y el daño observado sigue siendo un reto profundo debido a las barreras económicas, logísticas y metodológicas para integrar datos multiómicos y petrofísicos [8, 18], lo que evidencia la necesidad urgente de desarrollar plataformas diagnósticas integrales que vinculen la taxonomía con la actividad metabólica activa y el impacto real sobre el sustrato [13].

CAPÍTULO III

MARCO TEÓRICO

3.1 Biodeterioro microbiano en sustratos graníticos

El granito es una roca ígnea intrusiva de textura fanerítica compuesta principalmente por cuarzo (SiO_2), feldespatos potásicos (KAlSi_3O_8), plagioclasas ($\text{NaAlSi}_3\text{O}_8$ – $\text{CaAl}_2\text{Si}_2\text{O}_8$) y micas (biotita, moscovita) [3]. Esta composición lo hace susceptible a la biocorrosión química mediada por el microbioma colonizador, que actúa a través de dos mecanismos principales: la acidólisis y la quelatación iónica [4, 25]. En el primer mecanismo, bacterias heterótrofas y hongos secretan ácidos orgánicos de bajo peso molecular, incluyendo ácido oxálico, cítrico, glucónico, láctico y 2-cetoglucónico, que reducen el pH local del microambiente de la biopelícula y disuelven activamente los feldespatos y silicatos de la matriz mineral [18, 25]. En el segundo, estos mismos ácidos actúan como agentes quelantes que secuestran cationes estructurales esenciales (Fe^{2+} , Al^{3+} , Mg^{2+} , Ca^{2+}) de la red cristalina, debilitando la cohesión mineral [25]. Géneros bacterianos como *Bacillus*, *Arthrobacter* y *Streptomyces* han sido identificados como productores de ácido 2-cetoglucónico, un quelante altamente eficiente de la sílice presente en monumentos graníticos [18].

Adicionalmente, bacterias quimiolitotróficas del ciclo del nitrógeno (*Nitrosomonas*, *Nitrospira*) y del azufre (*Thiobacillus*, *Sulfurimonas*) producen ácido nítrico y sulfúrico como subproductos metabólicos, que corroen directamente los minerales carbonatados y silicatados de la roca [4, 16, 23]. A nivel físico, las hifas fúngicas ejercen presión mecánica de turgencia que les permite penetrar microporos

y fisuras en proceso casmolítico y criptoendolítico, ampliando progresivamente el sistema de poros del granito y facilitando la entrada de agua [20, 25].

3.2 Biopelículas subaéreas en patrimonio pétreo

Las biopelículas subaéreas (SABs, *Subaerial Biofilms*) constituyen la forma dominante de vida microbiana en superficies líticas expuestas a la atmósfera [5]. Su formación sigue un proceso secuencial regulado molecularmente: (1) adhesión reversible mediada por fuerzas de Van der Waals y electrostáticas; (2) adhesión irreversible mediante proteínas de adhesión de superficie, pili tipo IV y fimbrias; (3) maduración con producción de sustancias poliméricas extracelulares (EPS); y (4) dispersión de células al entorno [26]. La matriz de EPS, que puede representar más del 90 % del volumen de la biopelícula madura, es producida por operones específicos como *epsA-O* en *Bacillus subtilis*, los clusters *pel* y *psl* en *Pseudomonas aeruginosa*, y el operón *csgA* responsable de la síntesis de fibras de curli en enterobacterias [26]. Esta matriz actúa como una esponja biológica que retiene agua, captura nutrientes orgánicos del aire y protege a las células de la desecación y los biocidas [13, 26].

En el contexto del patrimonio pétreo, Villa et al. [5] proponen un marco ecológico fundamental para este proyecto: las biopelículas subaéreas tienen un rol dual. Por un lado, pueden inducir biodeterioro activo mediante la producción de ácidos, pigmentos y presión mecánica; por el otro, pueden actuar como capa de bioprotección que amortigua las fluctuaciones térmicas e hídricas, consolida la superficie y limita la disolución química al entrar en contacto con agua de lluvia o condensación [5, 13]. Esta dualidad funcional implica que la sola identificación taxonómica de microorganismos es insuficiente para determinar el riesgo real de deterioro; es necesaria la caracterización del repertorio funcional, específicamente de los genes accesorios, para discernir qué mecanismos se encuentran genómicamente codificados en cada linaje [7, 13].

Las estrategias de supervivencia en el nicho oligotrófico del granito incluyen la esporulación (operón *spo0A/spoIIA/spoIIE* en Firmicutes, altamente prevalentes en ambientes líticos), la melanización en hongos meristemáticos negros (*Ochroconis*, *Coniosporium*) como escudo contra estrés oxidativo y radiación UV, y la síntesis de carotenoides en arqueas y bacterias halotolerantes como *Rubrobacter* spp. [6–8, 12, 19, 27]. Estos rasgos de supervivencia constituyen los biomarcadores genómicos de mayor relevancia para el modelo predictivo de riesgo.

3.3 Metagenómica *shotgun* y ensamblaje de genomas metagenómicos (MAGs)

La metagenómica *shotgun* permite el acceso directo al material genómico total de una comunidad microbiana sin necesidad de cultivo previo, superando el sesgo de cultivabilidad que limita los estudios clásicos al 1–5 % de la diversidad real [7, 9, 17]. En este enfoque, el ADN extraído de la muestra ambiental se fragmenta y secuencía masivamente, generando millones de lecturas cortas (*reads*) que representan fragmentos aleatorios de todos los genomas presentes en la comunidad [8, 9].

El proceso de reconstrucción de MAGs sigue tres etapas principales: ensamblaje, binning y refinamiento. En la etapa de ensamblaje, los *reads* se ensamblan *de novo* en contigs mediante ensambladores basados en grafos de De Bruijn, como MEGAHIT [28] o SPAdes [29], que fragmentan las lecturas en *k-mers* y reconstruyen las secuencias por solapamiento. En la etapa de *binning*, los contigs se agrupan en MAGs candidatos mediante dos señales complementarias: la composición nucleotídica (frecuencia de tetra-nucleótidos, un vector de 256 dimensiones) y el perfil de cobertura diferencial (razón de *reads* alineados sobre longitud del contig a lo largo de múltiples muestras) [9, 30]. La premisa biológica es que contigs del mismo organismo tendrán firmas de composición y coberturas similares. MetaBAT 2 [31] modela esta relación con una distribución de probabilidad Gaussiana, mientras que DAS Tool [32]

integra las predicciones de múltiples *binners* para maximizar el número de MAGs de alta calidad por muestra. El refinamiento manual mediante Anvi'o [30, 33] permite inspeccionar visualmente la coherencia de cada *bin* y eliminar contaminantes.

Esta aproximación supera directamente la limitación del 16S rRNA *amplicon* identificada en la formulación del problema de la tesis: mientras la secuenciación de amplicones provee información taxonómica a nivel de género o especie, los MAGs reconstruyen el genoma completo potencial de cada linaje, habilitando el análisis pangenómico y la predicción del potencial metabólico [9, 34, 35].

3.4 Evaluación de calidad genómica

La calidad de un MAG se define por dos métricas fundamentales: completitud y contaminación [30]. La completitud refleja qué fracción del genoma real ha sido capturada en el MAG; la contaminación indica la proporción de contigs provenientes de organismos distintos al organismo *target*.

Ambas métricas se estiman contando los genes marcadores de copia única (SCGs, *Single-Copy Genes*): genes que evolucionaron para existir exactamente en copia única en >97 % de todos los procariotas. Un SCG ausente sugiere incompletitud; un SCG presente en múltiples copias sugiere contaminación por contigs de otro organismo [30, 36].

$$\text{Completitud} = \frac{\text{SCGs detectados}}{\text{SCGs esperados para el linaje}} \times 100 \% \quad (\text{III.1})$$

$$\text{Contaminación} = \frac{\text{SCGs redundantes}}{\text{SCGs esperados}} \times 100 \% \quad (\text{III.2})$$

CheckM2 [14] moderniza este cálculo mediante modelos de *machine learning* (*gradient boosting* y redes neuronales) entrenados sobre cientos de miles de genomas sintéticos simulados a partir de referencias de alta calidad. A diferencia de su predecesor, no requiere asignación taxonómica previa y es más preciso en linajes divergentes como Patescibacteria o el superphylum CPR [14].

El estándar internacional MIMAG [30] establece tres categorías, resumidas en la tabla 3.1: (a) alta calidad (HQ): completitud ≥ 90 %, contaminación < 5 %, ARNr 16S completo; (b) calidad media (MQ): 50–90 % completitud, < 10 % contaminación; (c) baja calidad: < 50 %. El criterio del OE1 (> 70 %, < 5 %) se posiciona como un umbral intermedio conservador, apropiado para análisis pangenómicos que requieren representación mínima del *core genome* [14, 30].

TABLA 3.1: Categorías de calidad MIMAG para MAGs bacterianos y arqueales [30].

Categoría	Completitud (%)	Contaminación (%)	Criterios adicionales
Alta calidad (HQ)	≥ 90	< 5	ARNr + ≥ 18 ARNt
Media calidad (MQ)	≥ 50	< 10	—
Baja calidad (LQ)	< 50	Cualquiera	Solo referencial

3.5 Posicionamiento filogenómico y ANI

La identidad nucleotídica promedio (ANI, *Average Nucleotide Identity*) es la métrica estándar actual para la delimitación de especies procarióticas a nivel genómico, sustituyendo empíricamente a la hibridación ADN-ADN (DDH) con mayor reproducibilidad y escala computacional [37]. El ANI se calcula como el promedio ponderado de identidad de secuencia de todos los fragmentos ortólogos entre dos genomas:

$$\text{ANI}(A, B) = \frac{\sum_i \text{identity}(f_i^A, f_i^B) \times |f_i|}{\sum_i |f_i|} \quad (\text{III.3})$$

donde f_i^A y f_i^B son fragmentos ortólogos de 3 kb. Un ANI ≥ 95 % (con fracción de alineamiento, AF ≥ 65 %) equivale a un DDH ≥ 70 %, el umbral convencional de especie [15, 37]. FastANI [37] implementa este cálculo mediante *locality-sensitive hashing* sobre *k-mers* (*sketching* de MinHash), permitiendo comparaciones a escala masiva.

El clasificador GTDB-Tk [15] ubica los MAGs en un árbol filogenómico de referencia usando 120 genes marcadores bacterianos (*bac120*) o 122 arqueales (*arc122*), colocando cada genoma en la taxonomía del *Genome Taxonomy Database* (GTDB) [38]. GTDB corrige las inconsistencias del NCBI normalizando los rangos taxonómicos por divergencia evolutiva relativa (RED, por sus siglas en inglés), siendo especialmente relevante para MAGs ambientales que con frecuencia representan linajes sin cultivos de referencia [15, 38].

Un problema adicional al de la sola delimitación taxonómica surge cuando se aplica el ANI a colecciones completas de MAGs recuperados por metagenómica *shotgun*: dado que el ensamblaje y el *binning* se realizan de forma independiente por muestra, un mismo linaje presente en varios puntos de muestreo puede recuperarse varias veces como genomas ligeramente distintos entre sí, debido a diferencias en la profundidad de secuenciación o en el proceso de ensamblaje de cada muestra. A este proceso de identificar y colapsar genomas redundantes se le conoce como *desreplicación*, y la herramienta estándar para realizarlo es dRep [39], que agrupa los genomas de una colección en clústeres según su ANI y selecciona, dentro de cada clúster, un único genoma representativo.

Internamente, dRep realiza esta comparación en dos pasos. Primero ejecuta una comparación rápida entre todos los genomas mediante *MinHash* (Mash), que agrupa genomas claramente similares en clústeres preliminares de forma poco costosa computacionalmente. Luego, dentro de cada clúster preliminar, calcula el ANI de forma precisa mediante ANIm o FastANI para confirmar la agrupación final. El genoma representativo de cada clúster se escoge según un *score* de calidad que pondera completitud, contaminación y contigüidad (N50), con criterios análogos a los de calidad descritos en la sección 2.4.

El umbral de ANI usado en el segundo paso define qué tan estricta es la agrupación: un umbral cercano al 95 % agrupa genomas de la misma especie, de forma consistente con el umbral de DDH descrito previamente, mientras que un umbral cercano al 99 % agrupa solo genomas de la misma cepa. Este último valor representa además el límite práctico de detección del método, ya que dos copias idénticas de un mismo genoma comparadas entre sí suelen rendir valores de ANI de aproximadamente 99.99 %, por lo que exigir una identidad mayor ya no aporta resolución real [37, 39]. De este modo, la desreplicación cumple dos funciones: elimina la redundancia técnica generada por el ensamblaje independiente de cada muestra, y define operativamente la unidad de análisis, el linaje, sobre la cual se construye posteriormente el pangenoma comparativo descrito en la siguiente sección.

IQ-TREE [40] es un programa de inferencia filogenética que reconstruye árboles mediante el criterio de máxima verosimilitud. Su algoritmo de búsqueda combina perturbaciones de tipo *nearest neighbor interchange* estocástico con una estrategia de hill-climbing eficiente, lo que le permite explorar un espacio amplio de topologías sin caer prematuramente en óptimos locales, un problema frecuente en métodos de búsqueda heurística más simples. Antes de la búsqueda del árbol, IQ-TREE incorpora ModelFinder [41], un procedimiento que evalúa de forma automática el ajuste estadístico de distintos modelos de sustitución de aminoácidos o nucleótidos sobre

el alineamiento de entrada y selecciona el más adecuado según criterios de información (AIC, BIC), evitando que el usuario deba fijar el modelo de forma arbitraria. El soporte estadístico de cada rama del árbol resultante se estima mediante el ultrafast bootstrap (UFBoot) [42], una aproximación computacionalmente eficiente al remuestreo bootstrap tradicional que aproxima de forma no sesgada los valores de soporte con un costo varios órdenes de magnitud menor, permitiendo ejecutar miles de réplicas en una fracción del tiempo que requeriría el bootstrap clásico de Felsenstein. Por estas características, IQ-TREE es ampliamente utilizado en filogenómica bacteriana para construir árboles focalizados a partir de alineamientos concatenados de genes marcadores, como los conjuntos bac120 y ar122 empleados por el GTDB [15], en escenarios donde se requiere no solo inferir la topología del árbol, sino cuantificar la confianza estadística de cada agrupamiento, como la monofilia de un linaje frente a sus genomas de referencia.

3.5.1 La jerarquía taxonómica

La clasificación taxonómica organiza a los organismos en diferentes niveles jerárquicos según sus características y relaciones evolutivas. El **filo** agrupa organismos que comparten características estructurales y evolutivas generales, mientras que la **clase** reúne grupos más específicos dentro de un mismo filo. El **orden** subdivide las clases de acuerdo con características adicionales compartidas entre los organismos, y la **familia** agrupa géneros que presentan una relación evolutiva cercana. El **género** reúne especies estrechamente relacionadas y constituye la primera parte del nombre científico de un organismo. Finalmente, la **especie** representa el nivel taxonómico más específico y permite identificar grupos de organismos con características genéticas y biológicas altamente similares. En conjunto, estos niveles siguen una jerarquía de mayor a menor amplitud: **filo** → **clase** → **orden** → **familia** → **género** → **especie**.

3.6 Análisis pangenómico comparativo

El pangenoma de una especie o linaje bacteriano representa el conjunto total de genes presentes en todos los miembros del grupo [43]. Introducido formalmente por Tettelin et al. [43] con una división inicial entre genes núcleo y accesorios, la genómica computacional moderna lo estructura algorítmicamente en tres compartimentos principales [35, 44]: (a) el **core genome** (G_c): genes presentes en ≥ 95 % de los genomas; codifican funciones esenciales conservadas (metabolismo central, replicación, traducción); (b) el **shell genome**: genes en el 15–95 % de los genomas; representan adaptaciones frecuentes en el nicho; y (c) el **cloud genome** (o *dispensable*): genes presentes en < 15 %; incluyen genes singulares (*singletons*) posiblemente adquiridos por HGT para nichos específicos.

Los genes accesorios son el producto directo de la transferencia horizontal de genes (HGT, *Horizontal Gene Transfer*): el mecanismo por el cual las bacterias adquieren genes de organismos filogenéticamente distantes mediante conjugación, transformación o transducción [45]. Este proceso permite la rápida adquisición de rasgos fenotípicos, incluyendo la capacidad de producir ácidos orgánicos o *biopelículas*, sin necesidad de mutaciones secuenciales, lo que lo convierte en el principal motor de adaptación ecológica en procariotas [45]. En este microambiente, la propia matriz de la *biopelícula* actúa como un reservorio de ADN extracelular que facilita y potencia estos eventos de transferencia génica [26]. Herramientas recientes como PPanGGOLiN [46] han introducido modelos estadísticos basados en grafos para particionar el pangenoma en sus componentes de manera probabilística. Sin embargo, en colecciones de MAGs, la fragmentación intrínseca de los ensamblajes sigue provocando una sobreestimación de genes accesorios. Para superar esta limitación, Panaroo [35] emplea una representación gráfica del pangenoma que corrige activamente los errores de anotación y ensamblaje mediante la propagación del contexto

genómico vecino, lo que reduce de manera drástica la inflación artificial del genoma accesorio debida a la fragmentación.

3.7 Anotación funcional y predicción del potencial metabólico

La anotación funcional de MAGs sigue un proceso jerárquico descrito en la metagenómica computacional [9], el cual inicia con la predicción de ORFs (*Open Reading Frames*) mediante algoritmos como Prodigal [47] (frecuentemente integrado en *pipelines* como Prokka [48]).

Bakta [49] constituye una evolución de este enfoque de anotación estructural y funcional. A diferencia de *pipelines* anteriores como Prokka, que dependen de alineamientos de secuencias contra bases de datos de referencia limitadas, Bakta incorpora un módulo de identificación de secuencias sin alineamiento (*alignment-free sequence identification*, AFSI), el cual calcula *hashes* MD5 a partir de secuencias proteicas completas para acelerar la asignación de homología. Al emplear una base de datos taxonómicamente independiente, esta característica resulta especialmente relevante para MAGs ambientales, donde la especie o el género del organismo colonizador con frecuencia pertenece a linajes raros o carece de representación cercana en las bases de datos curadas. Para las secuencias no identificadas por AFSI, Bakta integra fuentes complementarias como RefSeq y PSC (*Protein Sequence Clusters* derivados de UniRef90), así como modelos de covarianza de Rfam para ARN no codificante.

A continuación, se realiza una búsqueda de homología contra bases de datos de referencia y la posterior asignación a categorías funcionales, para culminar finalmente con la reconstrucción de rutas metabólicas [34].

Las principales bases de datos funcionales utilizadas en este tipo de análisis son:

- **KEGG Orthology (KO)** [50]: organiza genes en módulos metabólicos y rutas de señalización; la completitud de una ruta se calcula como la fracción de KOs esenciales detectados en el genoma.
- **COG** (*Clusters of Orthologous Groups*) [27]: categorías funcionales de alto nivel (metabolismo, transporte, regulación de transcripción).
- **dbCAN/CAZy** [51, 52]: enzimas activas sobre carbohidratos, relevantes para la degradación de EPS y polisacáridos de la biopelícula.
- **CARD** (*Comprehensive Antibiotic Resistance Database*) [53]: genes de resistencia antimicrobiana, útil para evaluar persistencia bajo tratamientos biocidas.

DRAM (*Distilled and Refined Annotation of Metabolism*) [34] integra estas bases de datos en un sistema de anotación que produce tablas de completitud por módulo metabólico y resúmenes de los principales ciclos biogeoquímicos (nitrógeno, azufre y carbono), así como del inventario de enzimas activas sobre carbohidratos (CAZymes) [34]. Esta herramienta es especialmente apropiada para el presente estudio dado que el mapeo de estas rutas metabólicas permite inferir el potencial de biodeterioro de la comunidad: los ciclos inorgánicos (N y S) están directamente vinculados a la disolución de minerales por acidólisis y biocorrosión [4, 19], mientras que la síntesis de polisacáridos se relaciona con la producción de EPS para la biopelícula. De este modo, la destilación metabólica se alinea perfectamente con la identificación de factores de riesgo exigida en los objetivos del OE4.

La completitud de una vía metabólica se expresa formalmente en la metodología de DRAM [34] como:

$$\text{Completitud}_{\text{vía}} = \frac{\text{módulos KO detectados}}{\text{módulos KO totales en la vía}} \times 100 \% \quad (\text{III.4})$$

Los biomarcadores genómicos de mayor relevancia para el modelo predictivo de riesgo ecológico incluyen: genes del ciclo TCA (*acnA*, *sdhA*, *fumA*) asociados a la producción de ácidos orgánicos biocorrosivos [13, 19]; la gluconato deshidrogenasa (*gcd*) responsable de la síntesis del ácido 2-cetoglucónico, un potente quelante de silicatos [18]; genes de biosíntesis de EPS (como el operón *pel*) cruciales para la arquitectura de la *biopelícula* [26]; y los operones de esporulación (con reguladores maestros como *spo0A*) como marcadores de persistencia y resistencia extrema [27].

3.8 Limitaciones de la inferencia funcional basada en datos genómicos

La caracterización del potencial metabólico mediante análisis genómico de MAGs representa una aproximación de alto poder inferencial, pero con una limitación intrínseca en ausencia de datos de metatranscriptómica. Dado que los MAGs analizados en esta tesis se recuperaron a partir de la fracción cultivable (hisopo B), los organismos representados demostraron ser metabólicamente viables al proliferar bajo las condiciones de cultivo empleadas; sin embargo, el propio cultivo constituye un filtro selectivo cuyas condiciones (medio, temperatura, tiempo de incubación) no reproducen el ambiente real del monumento (radiación UV, desecación, escasez de nutrientes). Por ello, la detección de un gen no garantiza que su función se exprese de la misma forma *in situ*, y los resultados de este proyecto describen el potencial metabólico codificado en los linajes colonizadores, no la actividad biológica real sobre la piedra, tal como se declara en el alcance de la tesis.

CAPÍTULO IV

MARCO REFERENCIAL

El presente marco referencial contextualiza el entorno operativo para el análisis genómico de la Estela de Raimondi, estableciendo las directrices, limitaciones y consideraciones éticas que fundamentan las decisiones metodológicas del proyecto. Para transitar de un simple inventario taxonómico a la caracterización del potencial metabólico mediante genomas metagenómicos (MAGs), el diseño del estudio asume compromisos técnicos (*trade-offs*) justificados a través de tres componentes críticos: los estándares de ingeniería bioinformática, las restricciones del entorno real y el análisis ético de la conservación patrimonial.

4.1 Estándares bioinformáticos

El flujo de trabajo para el ensamblaje, control de calidad y análisis comparativo de linajes bacterianos se rige por métricas consensuadas internacionalmente en genómica ambiental, las cuales garantizan la viabilidad técnica de las conclusiones:

- **Estándares MIMAG para la calidad de genomas:** De acuerdo a lo mencionado en el marco teórico, este umbral ($>70\%$ completitud, $<5\%$ contaminación) representa un *trade-off* de diseño, pues flexibiliza el rigor de completitud para maximizar la recuperación de genomas ambientales fragmentados, pero adopta la máxima restricción de contaminación ($< 5\%$) para asegurar que el análisis del genoma accesorio no se vea sesgado por la inclusión de ADN foráneo [30].

- **Estandarización taxonómica y genómica:** Para evitar ambigüedades en la clasificación de los MAGs, el diseño requiere el uso de bases de datos curadas y de alta resolución, como la base de datos GTDB (*Genome Taxonomy Database*) a través de herramientas como GTDB-Tk, la cual provee una asignación taxonómica objetiva basada en la divergencia evolutiva relativa y la Identidad Nucleotídica Promedio (ANI) [15]. Asimismo, el mapeo de rutas de esporulación y biodeterioro se enmarca en la capacidad de herramientas de destilación metabólica como DRAM, diseñadas para decodificar las contribuciones microbianas a los ciclos geoquímicos a partir de datos genómicos [34].
- **Requerimientos para el pangenoma:** La comparación genómica a nivel poblacional debe mitigar los errores inherentes a la anotación automatizada, como la fragmentación de ensamblajes que infla artificialmente el tamaño del genoma accesorio [35]. Por ello, se asume el requerimiento de utilizar algoritmos basados en grafos (como la topología de red de Panaroo) que permiten corregir errores de traducción y colapsar familias de genes diversos, asegurando que los genes exclusivos de la Estela correspondan a verdaderas adaptaciones evolutivas (xenólogos o parálogos) y no a artefactos del ensamblaje [35].

4.2 Restricciones realistas del proyecto

Las decisiones de diseño del estudio no solo responden a la teoría bioinformática, sino que están fuertemente moldeadas por las limitaciones del objeto de estudio y su entorno:

- **Restricciones físicas y normativas:** La Estela de Raimondi es una pieza única, inscrita en el Registro Nacional Informatizado del Perú (Pieza L-8741) y de incalculable valor para la nación [3]. Normativamente, cualquier muestreo debe ser estrictamente no destructivo e *in situ*, prohibiendo la alteración física

del soporte [8]. Esto obliga a utilizar técnicas de hisopado superficial en seco que generan cantidades de ADN extremadamente limitadas (baja biomasa) [10]. Esta restricción justifica directamente la decisión de priorizar en los objetivos únicamente a los linajes bacterianos dominantes, pues la secuenciación profunda del microbioma “raro” resulta computacionalmente inviable y estadísticamente ruidosa frente a la baja cantidad de material genético extraíble.

- **Restricciones económicas:** Las tecnologías de secuenciación de próxima generación (NGS) y la evaluación bioinformática profunda presentan altos costos financieros y computacionales. Esta barrera económica justifica el compromiso de emplear metodologías metagenómicas basadas en ADN en lugar de aproximaciones dinámicas más costosas como la metatranscriptómica (ARN) [8].

Las restricciones materiales, operativas y éticas del proyecto se resumen en la tabla 4.1. Cada restricción se asocia a la decisión metodológica concreta que originó.

TABLA 4.1: Matriz de restricciones realistas del proyecto y su impacto en las decisiones de diseño metodológico.

Categoría	Restricción	Consecuencia metodológica
Ético-patrimonial	Prohibición de muestreo destructivo (raspado, corte, extracción de fragmentos).	Adopción de hisopado seco estéril sobre área $<10\text{ cm}^2$; no es viable la metaproteómica directa.
Computacional	Capacidad del clúster institucional (memoria RAM, núcleos disponibles).	Selección de MEGAHIT sobre metaSPAdes por menor huella de memoria; binning con MetaBAT 2 en lugar de ensamble de herramientas.
Histórica	Ausencia de muestras previas conservadas de la Estela.	No es posible comparar el estado actual con líneas de base históricas; la inferencia de cambios temporales se limita a hipótesis ecológicas.

El conjunto de restricciones de la tabla 4.1 no constituye una limitación accesorio del trabajo, sino el marco que define qué preguntas pueden responderse con

rigor y cuáles permanecen fuera del alcance metodológico de esta tesis. En particular, la caracterización del potencial metabólico (OE4) es alcanzable bajo estas restricciones; la verificación de su actividad real *in situ*, en cambio, exigiría intervenciones (metatranscriptómica directa o metaproteómica) que el marco ético-patrimonial vigente no permite y que se proponen como continuidad de la investigación en el capítulo final.

CAPÍTULO V

MARCO METODOLÓGICO

5.1 Metodología

5.1.1 Diseño general y criterios de decisión metodológica

El estudio es de naturaleza estrictamente computacional y descriptiva. Parte de datos metagenómicos shotgun previamente secuenciados y ensamblados en el marco del informe técnico microbiológico de la Estela de Raimondi, realizado por UPCH [10], sobre los cuales se construye un flujo bioinformático que va desde el control de calidad de los genomas hasta la inferencia del potencial metabólico de los linajes dominantes. El flujo se organiza en cuatro fases consecutivas, cada una asociada a un objetivo específico (OE1 a OE4), y se ejecuta en el orden presentado a continuación.

5.1.2 Origen de los datos y unidad de análisis

El microbioma de la Estela de Raimondi fue muestreado mediante hisopado en seco sobre la superficie del monumento. En cada punto de muestreo se recolectaron dos hisopados independientes: el hisopo A, destinado a la extracción directa de ADN ambiental para secuenciación de amplicones (16S rRNA e ITS2), y el hisopo B, destinado al cultivo microbiológico de la fracción viable [10]. La secuenciación metagenómica shotgun analizada en esta tesis se realizó sobre el material proveniente del cultivo (hisopo B).




FIGURA 5.1: Esquema de muestreo de la Estela de Raimondi. Se señalan los 20 puntos de hisopado distribuidos sobre las cinco regiones del monumento (base superior, cara frontal, laterales izquierda y derecha, y sección inferior). En cada punto se recolectaron dos hisopados independientes: el hisopo A, destinado a la extracción directa de ADN para secuenciación de amplicones, y el hisopo B, destinado al cultivo de la fracción viable, posteriormente secuenciado por metagenómica *shotgun*. Tomado del informe técnico de la UPCH [10].

Si bien la metagenómica suele aplicarse de forma independiente de cultivo, en el estudio del patrimonio pétreo se han documentado también aproximaciones dependientes de cultivo acopladas a la identificación molecular por secuenciación [16].

En consecuencia, los genomas reconstruidos representan la fracción microbiana recuperable mediante cultivo y no necesariamente las poblaciones dominantes *in situ*. Esta condición se trata de forma explícita como limitación en la Fase 3.

Las lecturas crudas (archivos FASTQ) no estuvieron disponibles para este trabajo. Por ello, todo el flujo se ejecuta sobre los genomas ensamblados (bins) y no sobre lecturas. En consecuencia, la importancia de cada linaje no se mide por abundancia, sino por prevalencia espacial: el número de puntos de muestreo distintos en los que se recuperó ese linaje. Esta métrica no depende de las lecturas crudas y es más robusta frente al sesgo del cultivo.

5.1.3 Fase 1. Control de calidad y selección de genomas (OE1)

5.1.3.1. Filtrado por dominio

Los bins se filtraron primero por dominio para descartar contigs de origen eucariota u organelar antes de cualquier métrica basada en genes procariotas. Se utilizó Tiara [54], un clasificador de secuencias metagenómicas basado en aprendizaje profundo que opera sobre la composición de los contigs en un esquema de dos etapas. La elección de Tiara frente a Whokaryote [55] y EukRep [56] se sustentó en la matriz de selección ponderada (Tabla 5.2), en la que Tiara obtuvo la mayor puntuación total gracias a su facilidad de instalación, su menor costo computacional y su capacidad adicional de identificar ADN organelar; la descripción detallada de cada herramienta evaluada se presenta en el Anexo 1.

TABLA 5.1: Bins genómicos recuperados por muestra (previos al filtrado por dominio y calidad).

Muestra	N.º bins	Long. total (Mb)	Rango bin (Mb)	N50 prom. (kb)	%GC prom.
49	2	28.1	0.55–27.6	173	36.2
50	6	67.3	0.61–53.4	47	59.5
51	1	4.7	4.73	189	52.6
52	5	18.2	0.42–5.3	37	61.6
53	3	36.9	2.48–29.2	264	40.5
54	2	11.6	4.31–7.3	167	38.7
55	1	34.2	34.24	404	51.1
56	6	88.4	0.23–49.6	95	45.6
57	6	74.7	0.22–39.1	164	46.9
58	3	46.5	4.77–29.6	418	48.5
59	2	29.1	5.91–23.2	283	40.9
60	5	49.6	2.32–25.7	52	43.5
61	6	73.1	0.61–40.1	207	47.7
62	5	45.7	0.23–27.9	128	39.4
63	6	88.8	0.37–56.5	40	45.7
64	7	75.5	0.24–29.7	33	43.4
65	5	94.8	0.22–29.6	89	47.0
66	0	—	—	—	—
67	0	—	—	—	—
68	2	2.7	0.25–2.5	43	49.2
69	2	2.7	0.25–2.5	40	49.1
70	6	109.2	0.28–94.3	3	44.0
71	12	126.9	0.26–101.9	6	47.2
72	4	9.7	0.25–6.6	4	38.9
Total	97				

Nota. Se dispuso de 24 librerías de secuenciación Illumina, identificadas con los códigos 49 a 72. El procesamiento previo, documentado por el centro de secuenciación, comprendió el ensamblaje por muestra mediante MEGAHIT, la segmentación del ensamblaje en bins genómicos mediante MetaBAT2, la evaluación de métricas de ensamblaje con QUAST y la anotación preliminar de cada bin con Bakta, junto con una asignación taxonómica preliminar basada en Kraken2. Un bin corresponde, en este punto del flujo, a un subconjunto de contigs del ensamblaje agrupados según su perfil de cobertura y composición de tetranucleótidos, bajo el supuesto de que los contigs pertenecientes a un mismo organismo comparten estas señales. Por tanto, cada bin constituye una reconstrucción parcial o completa de un genoma individual, cuya pureza taxonómica y calidad genómica se evalúan posteriormente. De las 24 librerías, 22 produjeron bins, con un total de 97 bins; las muestras 66 y 67 no recuperaron bins y fueron excluidas del análisis genómico. Las cifras mostradas corresponden a bins crudos entregados por el centro de secuenciación y preceden al filtrado por dominio y al control de calidad genómica descritos en la Fase 1; por ello, no implican que la totalidad de los bins listados sean genomas procariotas completos o libres de contaminación.

TABLA 5.2: Matriz de selección de software para la clasificación de contigs.

Criterio	Peso (%)	Tiara		Whokaryote		EukRep	
		Pts	Peso×Pts	Pts	Peso×Pts	Pts	Peso×Pts
Facilidad de instalación	10	4	40	3	30	2	20
Acceso a dependencias	15	4	60	2	30	2	30
Costo computacional	10	3	30	2	20	3	30
Integración en pipeline	15	4	60	3	45	2	30
Calidad de resultado	30	4	120	3	90	2	60
Alcance funcional	10	4	40	2	20	2	20
Interpretabilidad	10	3	30	4	40	2	20
Total	100		380		275		210

Se aplicó una longitud mínima de contig de 3000 pares de bases, valor por debajo del cual los clasificadores basados en composición de secuencia pierden exactitud, y se descartaron los bins cuya fracción mayoritaria de longitud se clasificó como eucariota u organelar. Dado que Tiara discrimina entre procariotas y eucariotas pero no separa bacterias de arqueas, esta última distinción se resolvió en las fases posteriores mediante CheckM2 y GTDB-Tk.

5.1.3.2. Evaluación de la calidad genómica

La completitud y la contaminación de los bins procariotas se estimaron con CheckM2 [14], que predice ambas métricas mediante modelos de aprendizaje automático entrenados sobre genomas de referencia y no requiere asignación taxonómica previa, lo que mejora su desempeño en linajes divergentes [14]. Se conservaron únicamente los genomas con completitud superior al 70 % y contaminación inferior al 5 %.

El umbral no corresponde a ninguna categoría MIMAG estándar. Se adoptó un valor intermedio que flexibiliza la exigencia de completitud, con el fin de recuperar genomas ambientales fragmentados, pero mantiene la restricción más estricta de contaminación (inferior al 5 %) para evitar que la posterior reconstrucción del genoma accesorio se sesgue por la inclusión de ADN foráneo [30]. Este compromiso se documenta como criterio propio del proyecto y no como un estándar MIMAG de alta calidad.

5.1.4 Fase 2. Asignación taxonómica y definición de linajes (OE2)

5.1.4.1. Clasificación taxonómica genómica

Los genomas que superaron el control de calidad se clasificaron taxonómicamente con GTDB-Tk [15], empleando los conjuntos de marcadores bac120 para bacterias y arc122 para arqueas. GTDB-Tk ubica cada genoma en el árbol de referencia del GTDB, que normaliza los rangos taxonómicos según la divergencia evolutiva relativa [15, 38]. Este enfoque basado en el genoma completo reemplaza a la asignación preliminar por Kraken2, de naturaleza basada en lecturas, por una clasificación de mayor resolución y consistencia filogenética.

5.1.4.2. Confirmación de especie por ANI

La clasificación de GTDB-Tk asigna taxonomía comparando características genómicas globales, pero no compara directamente el genoma completo contra una cepa de referencia. Para confirmar la identidad a nivel de especie, se calculó la Identidad Nucleotídica Promedio (ANI) entre cada genoma ensamblado y el genoma de referencia oficial de su taxón asignado. Este genoma de referencia corresponde a la cepa tipo de la especie (el organismo depositado en bases de datos públicas cuando

esa especie fue descrita por primera vez, y que actualmente actúa como estándar de comparación).

El ANI mide qué tan parecidas son dos secuencias de ADN a lo largo del genoma completo. Dos genomas se consideran de la misma especie cuando el ANI es igual o superior al 95 % y al menos el 65 % del genoma puede alinearse [15, 37].

5.1.4.3. Desreplicación y definición de linajes

Dado que el ensamblaje y el binning se realizaron por muestra de forma independiente, un mismo organismo presente en varias muestras pudo recuperarse como bins redundantes. Para colapsar esta redundancia se aplicó dRep [39], que agrupa los genomas en clústeres según su Identidad Nucleotídica Promedio (ANI). Se utilizó un umbral primario del 95 % de ANI para delimitar clústeres a nivel de especie, congruente con el radio de circunscripción taxonómica estándar empleado por la base de datos GTDB [15]. De forma complementaria, el agrupamiento secundario se definió a un umbral estricto del 99 % de ANI para lograr una resolución de cepa. Este último umbral permite agrupar genomas casi idénticos [39], asegurando la desreplicación de poblaciones clonales sin colapsar cepas de la misma especie que pudieran albergar variaciones intraespecíficas relevantes. Cada clúster resultante se define operativamente como un linaje.

La desreplicación cumple dos funciones determinantes. Primero, provee varios genomas de la Estela por linaje, lo que habilita la construcción de un pangenoma interno con réplicas reales en la Fase 4. Segundo, permite definir una métrica de prevalencia objetiva, calculada como el número de muestras, sobre el total de 24, que aportan al menos un genoma a cada clúster. Esta métrica no depende de las lecturas crudas y por ello constituye el criterio primario de importancia de un linaje.

5.1.4.4. Confirmación filogenómica

La ubicación de cada linaje se visualizó mediante un árbol filogenómico focalizado que incluyó los genomas de la Estela y los genomas de referencia, inferido de novo por GTDB-Tk [15] a partir de los mismos marcadores bac120 empleados en la clasificación taxonómica. Esta elección, frente a la alternativa de inferir el árbol externamente con IQ-TREE [40], se sustentó en la matriz de selección ponderada (Tabla 5.3), en la que GTDB-Tk obtuvo la mayor puntuación gracias a su integración directa en el flujo ya ejecutado y a su menor costo computacional, criterio priorizado dada la restricción de cómputo propia de un proyecto de pregrado. Como contrapartida, el árbol de novo de GTDB-Tk no provee selección de modelo de sustitución ni soporte de rama mediante bootstrap, por lo que la topología resultante se interpreta como una verificación visual de la monofilia de cada linaje frente a las referencias, y no como una confirmación con soporte estadístico cuantificado.

TABLA 5.3: Matriz de selección de software para la confirmación filogenómica.

Criterio	Peso (%)	GTDB-Tk (árbol de novo)		IQ-TREE	
		Pts	Peso×Pts	Pts	Peso×Pts
Facilidad de instalación	20	4	80	3	60
Acceso a dependencias	20	4	80	3	60
Costo computacional	15	4	60	2	30
Integración en pipeline	20	4	80	3	60
Calidad de resultado	10	2	20	4	40
Alcance funcional	5	2	10	4	20
Interpretabilidad	10	2	20	4	40
Total	100		350		310

5.1.4.5. Selección de linajes para el análisis comparativo

A partir de los linajes definidos, entendidos como los clústeres de especie obtenidos al 95 % de ANI, se priorizaron los de mayor prevalencia. Por restricciones de cómputo, el análisis comparativo se concentró en los tres linajes de mayor prevalencia. Para esta selección, no se utilizó la abundancia de secuencias, ya que los cultivos previos en laboratorio sesgan estos números. En su lugar, se utilizó el criterio de **prevalencia espacial** [39]. Esto consistió en seleccionar a las especies que lograron ser ensambladas en la mayor cantidad de puntos físicos distintos de la Estela Raimondi. La detección repetida de un mismo genoma a través de múltiples muestras independientes demuestra que se trata de microorganismos residentes y estables, y no de simple polvo o contaminación ambiental

Esta elección de la especie como unidad primaria de análisis resulta indispensable para el correcto funcionamiento de Panaroo, dado que el algoritmo requiere comparar un conjunto de genomas estrechamente emparentados para diferenciar con precisión los genes esenciales y conservados (genoma core) de aquellos genes ganados o perdidos como producto de la adaptación evolutiva al nicho específico (genoma accesorio). Cuando la comparación se realiza entre genomas filogenéticamente distantes, esta distinción pierde fiabilidad, pues la divergencia de secuencia entre especies no relacionadas introduce una subestimación artificial del genoma core, atribuible a limitaciones del método de detección de ortólogos y no a una reducción real del repertorio génico compartido [35].

5.1.5 Fase 3. Análisis pangenómico comparativo (OE3)

5.1.5.1. Recopilación de genomas de referencia

Para cada uno de los tres linajes seleccionados se recopilamos genomas de referencia desde NCBI RefSeq y GTDB. Se incluyeron genomas de la especie asignada por GTDB-Tk y, cuando el número de referencias a nivel de especie fue insuficiente, se amplió al género correspondiente. Se priorizaron los ensamblajes designados como completos o representativos en RefSeq, que ya han pasado por el proceso de curación de NCBI. Cuando un linaje no contó con referencias de especie en RefSeq, se recurrió a los genomas tipo de GTDB como alternativa.

El conjunto de referencias se desreplicó con dRep a un umbral del 99 % de ANI, con el fin de evitar que genomas casi clonales, frecuentes en taxones muy secuenciados, inflaran artificialmente el genoma núcleo. El número de genomas de referencia no se fijó de forma arbitraria, sino que se determinó mediante la curva de acumulación del pangenoma: se añadieron genomas secuencialmente hasta observar la estabilización del genoma núcleo [43]. Cuando un taxón presentó menos de aproximadamente diez genomas de referencia de calidad suficiente en bases de datos públicas, el conjunto se amplió siguiendo el mismo criterio. En el caso de los linajes arqueales, para los que la disponibilidad de referencias de calidad fue menor, el linaje se incluyó en el análisis comparativo solo si reunió genomas suficientes para estabilizar la curva; en caso contrario, se describió de forma individual sin pangenoma comparativo.

5.1.5.2. Anotación estructural y funcional consistente

La totalidad de los genomas, tanto los MAGs de la Estela como las referencias, se anotó con la misma herramienta y versión para garantizar la homogeneidad

requerida por el análisis pangenómico [35]. Se empleó Bakta [49], que realiza la predicción de marcos abiertos de lectura y la anotación mediante identificación de secuencias sin alineamiento, y que ya se había aplicado a los bins originales. Esta elección, frente a la alternativa de Prokka [48] (heredero directo de Prodigal [47]), se sustentó en la matriz de selección ponderada (Tabla 5.4), en la que Bakta obtuvo la mayor puntuación gracias a su continuidad con la anotación ya aplicada a los bins originales, su mayor resolución en linajes ambientales divergentes y su alcance funcional más amplio; Prokka resultó más liviano de instalar, pero con menor calidad de resultado en MAGs poco representados en bases de datos curadas. La anotación consistente evita que diferencias en la predicción génica se confundan con diferencias biológicas.

TABLA 5.4: Matriz de selección de software para la anotación estructural y funcional.

Criterio	Peso (%)	Bakta		Prokka	
		Pts	Peso×Pts	Pts	Peso×Pts
Facilidad de instalación	10	3	30	4	40
Acceso a dependencias	10	3	30	4	40
Costo computacional	5	3	15	4	20
Integración en pipeline	25	4	100	2	50
Calidad de resultado	25	4	100	2	50
Alcance funcional	15	4	60	3	45
Interpretabilidad	10	4	40	3	30
Total	100		375		275

5.1.5.3. Reconstrucción del pangenoma

El pangenoma de cada linaje se reconstruyó con Panaroo [35] en su modo estricto (clean-mode strict). Esta elección, frente a la alternativa de PPanGGOLiN

[46], se sustentó en la matriz de selección ponderada (Tabla 5.5), en la que Panaroo obtuvo la mayor puntuación gracias a su representación gráfica del pangenoma, que corrige errores de anotación y de ensamblaje mediante la propagación del contexto genómico vecino y reduce de forma marcada la inflación artificial del genoma accesorio asociada a la fragmentación de los MAGs; PPanGGOLiN, pese a ofrecer un modelo probabilístico de partición con módulos adicionales (regiones de plasticidad genómica), no corrige esta inflación con la misma eficacia en colecciones de MAGs fragmentados.

TABLA 5.5: Matriz de selección de software para la reconstrucción del pangenoma.

Criterio	Peso (%)	Panaroo		PPanGGOLiN	
		Pts	Peso×Pts	Pts	Peso×Pts
Facilidad de instalación	10	3	30	3	30
Acceso a dependencias	10	3	30	3	30
Costo computacional	5	3	15	4	20
Integración en pipeline	15	3	45	3	45
Calidad de resultado	35	4	140	2	70
Alcance funcional	15	3	45	4	60
Interpretabilidad	10	4	40	3	30
Total	100		345		285

El pangenoma se particionó en tres compartimentos siguiendo la convención de la genómica comparativa [35, 43, 44]: genoma nuclear (genes presentes en al menos el 95 % de los genomas), genoma de cubierta o shell (genes en el 15 a 95 %) y genoma accesorio o cloud (genes en menos del 15 %).

5.1.5.4. Identificación de genes candidatos exclusivos de la Estela

Los genes candidatos a ser exclusivos de la Estela se definieron como aquellos presentes en uno o más MAGs del monumento y ausentes en todos los genomas de referencia. Para reducir la probabilidad de errores, se exigió que el gen estuviera completo y no truncado en el borde de un contig. Los candidatos se contrastaron mediante búsqueda de homología frente a las bases de datos nr (non-redundant) y nt (nucleotide) para descartar contaminación. Estos genes se interpretan en el marco de la transferencia horizontal de genes como principal motor de adaptación ecológica en procariotas [45]. Dado que la incompletitud de los MAGs implica que la ausencia observada de un gen no equivale a su ausencia real [30], los resultados se reportan como candidatos a exclusivos y como adquisición probable, sin afirmar certeza.

5.1.6 Fase 4. Caracterización del potencial metabólico y del riesgo (OE4)

5.1.6.1. Anotación funcional del potencial metabólico

El potencial metabólico de los linajes seleccionados se caracterizó con la herramienta DRAM [34], la cual integra la asignación de ortólogos KEGG (KO) y produce resúmenes de los ciclos biogeoquímicos del nitrógeno, el azufre y el carbono, así como el inventario de enzimas activas sobre carbohidratos (CAZymes) basado en las bases dbCAN y CAZy. Para la evaluación de los módulos de KEGG, DRAM modela las vías como redes dirigidas y calcula la completitud como el porcentaje de cobertura de la ruta que presenta la mayor proporción de genes (nodos) detectados [34]. Sobre esta base, en el presente estudio se estableció un umbral operativo estricto: un marcador individual se consideró detectado cuando el KO estuvo presente, mientras que un módulo metabólico completo se consideró funcionalmente "presente" solo cuando su porcentaje de completitud alcanzó o superó el 66 %.

5.1.6.2. Definición de marcadores de riesgo y supervivencia

La interpretación funcional se ancló en una tabla de marcadores genómicos definida *a priori*, es decir, fijada antes de observar los resultados, con el fin de evitar el sesgo de confirmación. Esta tabla clasifica genes y ortólogos KO en dos categorías: marcadores de riesgo de biodeterioro, que incluyen la producción de ácidos orgánicos por el ciclo de los ácidos tricarboxílicos [19], la síntesis de ácido 2-cetoglucónico como quelante de silicatos [18], la biosíntesis de sustancias poliméricas extracelulares de la biopelícula [26], la nitrificación y la oxidación del azufre como fuentes de ácidos inorgánicos [4, 19] y las CAZymes [51, 52]; y marcadores de supervivencia o persistencia, que incluyen la esporulación [27] y la respuesta a estrés oxidativo y desecación. La Tabla 5.6 detalla los marcadores organizados por categoría. Para cada función se consignan los genes representativos, el identificador KEGG Orthology (KO) y, cuando corresponde, el módulo metabólico KEGG. Los identificadores KO y los módulos se asignaron consultando directamente la base de datos KEGG [50] a partir del nombre del gen. Los operones de exopolisacáridos (EPS) y las enzimas activas sobre carbohidratos (CAZymes) no poseen un identificador KO único; su detección se realiza mediante la base de datos dbCAN, integrada en DRAM. La detección efectiva de cada marcador en los genomas se obtiene de DRAM durante la fase de anotación funcional.

5.1.6.3. Integración del potencial funcional con la estructura del pangenoma

En el paso final, cada marcador de la tabla *a priori* se mapeó sobre la partición del pangenoma para determinar si reside en el genoma nuclear o en el accesorio. Para evaluar de forma cuantitativa si los marcadores de riesgo se concentran en el

genoma accesorio, se aplicó una prueba exacta de Fisher sobre una tabla de contingencia de dos por dos que cruza la condición de gen de riesgo o no de riesgo con su pertenencia al genoma accesorio o nuclear, reportando tanto el valor de probabilidad como la razón de momios (odds ratio) como medida del tamaño del efecto. Cuando se evaluaron varias categorías funcionales de forma simultánea, los valores de probabilidad se ajustaron por comparaciones múltiples mediante el procedimiento de Benjamini y Hochberg. Esta prueba se interpreta con cautela por dos razones: las familias génicas no constituyen observaciones estadísticamente independientes, debido a la no independencia filogenética, y el número reducido de marcadores de riesgo limita la potencia estadística. Por ello, el resultado se presenta como evidencia de apoyo y no como prueba concluyente. De forma complementaria, se caracterizó la apertura del pangenoma estimando el parámetro de la ley de Heaps [46].

La lógica interpretativa es la siguiente. Si los genes de biodeterioro se enriquecen de forma significativa en el genoma accesorio, en particular si son compartidos por varios MAGs del mismo linaje, ello aporta soporte cuantitativo a la hipótesis de que dichas funciones fueron adquiridas como adaptación al nicho del monumento. Si, por el contrario, residen en el genoma nuclear, se interpretan como rasgos intrínsecos y conservados del linaje. En coherencia con el alcance del estudio, estas conclusiones describen el potencial metabólico codificado y no la actividad biológica real en el momento del muestreo.

5.1.7 Reproducibilidad

Se registró la versión exacta de cada herramienta bioinformática y la versión de cada base de datos empleada, y cada identificador KO se verificó contra la versión vigente de KEGG. El conjunto de software comprende, en orden de ejecución, Tiara [54], CheckM2 [14], GTDB-Tk [15], FastANI [37], dRep [39], Bakta [49], Panaroo

TABLA 5.6: Marcadores genómicos *a priori* de biodeterioro y supervivencia.

Categoría	Función / mecanismo	Genes	KO	MóduloFuente
Riesgo	Ácidos orgánicos del ciclo TCA (acidólisis)	gltA, acnA, icd, sdhA, fumA	K01647, K01681, K00031, K00239, K01676	M00009 [18, 19]
Riesgo	Ácido 2-cetoglucónico (quelación de silicatos)	gcd	K00117	— [18]
Riesgo	Biosíntesis de EPS de biopelícula	pel, psl, epsA-O	sin KO único (dbCAN)	— [26]
Riesgo	Adhesión y curli	csgA, csgB	K04334, K04335	— [26]
Riesgo	Nitrificación (ácido nítrico)	amoA, hao, nxrA	K10944, K10535, K00370	M00528 [19, 34]
Riesgo	Oxidación de azufre (ácido sulfúrico)	soxB, dsrA, dsrB	K17224, K11180, K11181	M00595 [19]
Riesgo	CAZymes (polisacáridos y EPS)	familias GH, GT	sin KO único (dbCAN)	— [51, 52]
Supervivencia	Esporulación (latencia y resistencia)	spo0A, spoIIAA, spoIIIE	K07699, K06378, K06382	— [27]
Supervivencia	Carotenoides (protección UV)	crtB, crtI	K02291, K10027	M00915 [57]
Supervivencia	Estrés oxidativo y desecación	katA, sodA, dps	K03781, K04564, K04047	— [6, 57]

[35] y DRAM [34]. Las pruebas estadísticas se ejecutaron en un entorno de R con las bibliotecas correspondientes.

Los análisis computacionalmente intensivos se ejecutaron en el clúster de cómputo de alto rendimiento Khipu de la Universidad de Ingeniería y Tecnología (UTECH), modalidad Tesis. Este tipo de acceso permite el uso de las particiones `debug`, `debug-gpu`, `standard`, `gpu` y `big-mem`, con una asignación máxima por usuario de 32 núcleos de CPU, 98 GB de memoria RAM y 40 *GPU shards*, además de un

tiempo máximo de ejecución de 24 horas por trabajo computacional. La disponibilidad de esta infraestructura permitió ejecutar de manera controlada y reproducible las etapas de filtrado, evaluación de calidad, clasificación taxonómica, comparación genómica, anotación funcional y análisis pangenómico.

Para asegurar la trazabilidad del flujo de trabajo, se conservaron los comandos utilizados, los parámetros de ejecución, los archivos de entrada y salida, y los registros generados por cada herramienta. Asimismo, los resultados intermedios relevantes fueron organizados por etapa del análisis. Esta estructura permite auditar cada paso del procesamiento, repetir los análisis bajo las mismas condiciones computacionales y vincular los resultados finales con los archivos originales.

CAPÍTULO VI

DISEÑO TECNOLÓGICO

Este capítulo documenta la construcción del flujo bioinformático con el que se ejecutaron las Fases 1 y 2. El Capítulo IV estableció qué herramientas se emplean, por qué se eligieron frente a sus alternativas y qué valor toma cada umbral. Este capítulo parte de esas decisiones y no las repite. Frente a ello, el objetivo de este capítulo es determinar el tamaño de los recursos que el flujo necesita, seleccionar las versiones y los entornos que lo hacen ejecutable sobre la infraestructura disponible, implementarlo en código y describir la arquitectura que resulta de integrar todas sus piezas.

6.1 Cálculo de los parámetros y dimensionamiento de los componentes

El dimensionamiento del flujo bioinformático no consiste en calcular el volumen de un equipo, sino en determinar cuántos recursos de cómputo, almacenamiento y tiempo consume cada etapa, y comprobar que esos consumos caben en la infraestructura disponible. Esta sección establece primero las bases de diseño, que son el volumen de datos de entrada y los parámetros operativos heredados del marco metodológico, y a partir de ellas dimensiona cada etapa.

6.1.1 Bases de diseño: el conjunto de datos de entrada

El sistema opera sobre genomas ya ensamblados y agrupados. No procesa lecturas crudas. Esta condición fija las características de la entrada y, con ella, el

orden de magnitud de todo el dimensionamiento posterior. La Tabla 6.1 resume las características del conjunto.

TABLA 6.1: Características del conjunto de bins de entrada, medidas sobre los archivos FASTA de origen.

Característica	Valor
Bins de entrada	97
Librerías de origen	22
Volumen total de secuencia	1.12 Gpb
Contigs totales	151 180
Tamaño mediano por bin	4.28 Mpb
Tamaño mínimo por bin	0.22 Mpb
Tamaño máximo por bin	101.9 Mpb
Contigs en el bin más fragmentado	41 610

Dos cifras de esta tabla condicionan el diseño. La primera es el tamaño máximo de 101.9 Mpb, que corresponde a **bin-11-71**. Un bin de ese tamaño no es un genoma bacteriano sino una mezcla, y su presencia en la entrada obliga a que la primera etapa del flujo sea capaz de procesar archivos un orden de magnitud mayores que el caso típico. La segunda es el volumen total de 1.12 Gpb, que es modesto para los estándares de la metagenómica. El cuello de botella del sistema no está, por tanto, en el tamaño de los datos propios, sino en el tamaño de las bases de datos de referencia que el flujo debe consultar.

6.1.2 Parámetros operativos del diseño

Los parámetros que gobiernan cada etapa se establecieron en el Capítulo IV junto con su fundamento. La Tabla 6.2 los reúne en la forma en que quedan codificados en el sistema, que es como variables de configuración al inicio de cada

script de ejecución. El propósito de esta tabla no es justificarlos de nuevo, sino dejar constancia de la correspondencia exacta entre el valor definido en la metodología y el valor implementado.

TABLA 6.2: Parámetros operativos del diseño y variable con que se implementan. La justificación de cada valor se encuentra en el Capítulo IV.

Fase	Parámetro	Variable en el código	Valor
1	Longitud mínima de contig	MIN_CONTIG_LEN	3000
1	Compleitud mínima	MIN_COMPLETENESS	70
1	Contaminación máxima	MAX_CONTAMINATION	5
2	Umbral primario de dRep (MASH)	DREP_PA	0.90
2	Umbral secundario de dRep (ANI)	DREP_SA	0.95
2	ANI de confirmación de especie	ANI_ESPECIE	95
2	Fracción alineada mínima	AF_ESPECIE	65

Los parámetros se declaran como variables al principio del script y no aparecen escritos dentro de las llamadas a las herramientas. Esta decisión de implementación tiene una consecuencia práctica: cambiar un umbral exige editar una sola línea, y el valor efectivo queda registrado de forma automática en el archivo de versiones que el propio script ejecutado escribe. El análisis de sensibilidad del Capítulo VII se apoya en esa propiedad.

6.1.3 Dimensionamiento del cómputo

La cuenta de usuario en el clúster Khipu admite como máximo 32 núcleos, 98 GB de memoria y 24 horas de ejecución por trabajo. Ese límite es la restricción dura del dimensionamiento. La Tabla 6.3 indica, para cada etapa, cuál es el recurso crítico y qué decisión de diseño se tomó para que el consumo quepa dentro de la cuota.

TABLA 6.3: Recurso crítico de cada etapa y decisión de dimensionamiento adoptada.

Etapa	Recurso crítico	Decisión de dimensionamiento
Tiara	Procesador	Se ejecuta un bin por vez en un bucle, con los 32 núcleos asignados a cada llamada. El procesamiento secuencial evita que el bin de 101.9 Mpb coincida en memoria con otros bins grandes
CheckM2	Memoria y disco	Se ejecuta una sola llamada sobre el conjunto completo de bins procariotas, lo que carga la base de DIAMOND una vez en lugar de una por genoma
GTDB-Tk	Memoria	La etapa de colocación filogenética es la de mayor consumo de todo el flujo. Se fija <code>--placer_cpus 1</code> , con lo que el consumo de esa etapa se acota a unos 55 GB para el conjunto de marcadores bac120. Con más hilos el consumo crece por encima de la cuota
GTDB-Tk	Tiempo y disco	Se fija <code>--skip_anl_screen</code> , que omite el prefiltrado por MASH y elimina la necesidad de una base de datos adicional. La confirmación de especie se obtiene igualmente del cálculo interno de ANI
dRep	Tiempo	Se reutiliza la evaluación de calidad ya producida por CheckM2 en la Fase 1 mediante <code>--genomeInfo</code> , de modo que dRep no vuelve a estimar completitud ni contaminación

La asignación final de recursos se declara en la cabecera de cada script de ejecución. Ambas fases solicitan 32 núcleos y 90 GB de memoria, es decir, ocho gigabytes por debajo del límite máximo de la cuenta. Ese margen es deliberado: el planificador rechaza el trabajo si la solicitud excede la cuota, y algunas herramientas

reservan memoria adicional fuera del proceso principal. La Fase 1 solicita 24 horas y la Fase 2, doce.

La etapa de GTDB-Tk merece un comentario aparte porque es la que determina el dimensionamiento de todo el sistema. La colocación filogenética de los genomas sobre el árbol de referencia es un procedimiento cuyo consumo de memoria crece con el número de hilos, no con el número de genomas de consulta. Por ese motivo la única variable de ajuste disponible es el número de hilos de esa subetapa, y por ese motivo se fija en uno aunque el resto del flujo disponga de 32. Esta restricción es también la que impidió construir el árbol *de novo* con el conjunto completo de referencias del dominio bacteriano, como se documenta en el Capítulo VII.

6.1.4 Dimensionamiento del almacenamiento

El volumen de datos propios es pequeño frente al de las bases de referencia. La Tabla 6.4 lo detalla.

TABLA 6.4: Requerimiento de almacenamiento por componente.

Componente	Tipo	Tamaño
Bins de entrada	Datos propios	1.12 Gpb
Base de datos de CheckM2 (DIAMOND)	Insumo de referencia	~3 GB
Base de datos de GTDB R220	Insumo de referencia	~110 GB
Resultados completos de la Fase 2	Salida	406 MB
Alineamiento concatenado bac120	Salida intermedia	230 MB

La base de GTDB determina por sí sola el requerimiento de disco del proyecto. Su descompresión desde el archivo comprimido es una operación de larga duración que debe ejecutarse en el nodo de login, único con acceso a internet, y que excede la tolerancia de una sesión interactiva. Por ese motivo el script de preparación de la

Fase 2 verifica el espacio disponible antes de iniciar la descompresión y está diseñado para ejecutarse en un segundo plano.

6.2 Selección de materiales, componentes y equipos de la solución

En un diseño de esta naturaleza los materiales son de tres clases: las versiones concretas del software, las bases de datos que actúan como insumo de referencia y el entorno de ejecución que hace reproducible el conjunto. La elección de cada herramienta ya se justificó en el Capítulo IV. Lo que se selecciona aquí es la versión, el insumo y el entorno, decisiones que no son metodológicas sino de implementación, y que en este proyecto resultaron determinantes para que el flujo funcionara.

6.2.1 Versiones de software y compatibilidad

La Tabla 6.5 indica la versión empleada de cada herramienta y el criterio con que se fijó.

TABLA 6.5: Versiones de software empleadas y criterio de selección de cada una.

Componente	Versión	Criterio de selección de la versión
GTDB-Tk	2.6.1	Fijada de forma explícita por compatibilidad con el release R220 de la base de datos. La tabla de compatibilidad oficial de la herramienta vincula cada versión del programa con un release de datos determinado, y una combinación incorrecta produce clasificaciones erróneas sin emitir error
Python	3.11	Fijada de forma explícita en todos los entornos. Sin esta restricción el resolutor instala Python 3.14, con el que GTDB-Tk no arranca porque la versión de su biblioteca de validación de datos no es compatible con esa versión
Tiara, CheckM2	última estable	Sin restricción de versión. Ninguna de las dos depende de un release externo de datos versionado
dRep, fastANI, MASH	última estable, Python 3.11	Instaladas en un entorno propio con la misma versión de Python, para evitar la misma clase de incompatibilidad

La fijación de la versión de Python es la decisión de selección más importante del capítulo, por la siguiente razón: el error que produce su ausencia no se manifiesta durante la instalación sino en la primera ejecución, cuando ya se han descargado 110 GB de base de datos y se ha encolado un trabajo. Fijarla convierte un fallo tardío en una condición verificable en el momento de crear el entorno.

6.2.2 Bases de datos como insumo de referencia

Las bases de datos cumplen en este diseño la función que los insumos cumplen en un proceso físico: son material externo que el sistema consume y del que depende

la validez del resultado. La Tabla 6.6 las especifica.

TABLA 6.6: Bases de datos empleadas como insumo de referencia.

Insumo	Versión	Etapa que lo consume
Base de datos de CheckM2	la que distribuye la herramienta	Calidad genómica
Base de datos de GTDB	R220	Clasificación taxonómica y ANI

La versión del insumo forma parte del resultado. Un genoma clasificado contra R220 puede recibir un nombre distinto contra un release posterior, porque la taxonomía del GTDB se reorganiza entre versiones. Por ese motivo el release se registra en el archivo de versiones de cada ejecución y se declara junto a los resultados.

6.2.3 Entorno de ejecución

El sistema se ejecuta sobre entornos conda independientes, uno por herramienta. La separación responde a un conflicto real de dependencias: Tiara, CheckM2 y GTDB-Tk requieren versiones incompatibles de las mismas bibliotecas, y un entorno único no resuelve.

La selección de canales de paquetes también fue objeto de una decisión. El canal `defaults` de la distribución no compila desde el clúster, lo que produce un fallo de red durante la creación del entorno. El diseño emplea únicamente los canales `conda-forge` y `bioconda`, y los declara de forma explícita en cada llamada de creación. El Código VI.1 muestra la forma en que se implementa esta decisión junto con la fijación de versiones.

LISTING VI.1: Creación del entorno de GTDB-Tk con versión de herramienta y de Python fijadas, y canales declarados de forma explícita (extracto de `02_setup_fase2_khipu.sh`).

```
# Versiones fijadas: GTDB-Tk al release de los datos y Python a
# una serie compatible. --override-channels evita 'defaults'.
$SOLVER create -y -n gtdbtk --override-channels \
    -c conda-forge -c bioconda \
    "gtdbtk=$GTDBTK_VERSION" "python=$PYTHON_VERSION"
```

Para dejar constancia del entorno efectivamente utilizado, el guion de preparación exporta al final un archivo de bloqueo por cada entorno creado, con la lista completa de paquetes y sus versiones exactas. Esos archivos se versionan junto con el código.

6.2.4 Plataforma de cómputo

El sistema se ejecuta en el clúster Khipu de la UTEC, bajo el planificador SLURM. Se emplea la partición **standard**, que agrupa los nodos de propósito general con 32 núcleos y 224 GB de memoria. No se emplean las particiones de GPU, porque ninguna de las herramientas del flujo aprovecha aceleración gráfica, ni la partición de memoria ampliada, a la que la cuenta no tiene acceso.

La arquitectura del clúster impone una separación que el diseño debe respetar: solo el nodo de login tiene acceso a internet, y los nodos de cómputo trabajan sin conexión. Esto obliga a repartir el sistema en dos clases de programas. Los guiones de preparación descargan bases de datos y crean entornos, y se ejecutan de forma interactiva en el login. Los scripts de ejecución ejecutan el análisis y se envían a la cola, sin requerir conexión alguna.

6.3 Integración e implementación de los componentes en la solución final

Las etapas descritas no funcionan de forma aislada. Esta sección documenta cómo se encadenan, qué resultado produce cada una, qué resultado de la etapa anterior consume la siguiente y qué mecanismos garantizan que el encadenamiento no se rompa.

6.3.1 Organización del sistema en programas

El sistema se implementa en seis programas, que se agrupan en tres clases según dónde y cuándo se ejecutan. La Tabla 6.7 los describe.

TABLA 6.7: Programas del sistema, clase a la que pertenecen y función que cumplen.

Programa	Clase	Función
00_setup_khipu.sh	Preparación (login)	Crea los entornos de Tiara y CheckM2 y descarga la base de datos de CheckM2
01_prep_bins.sh	Preparación (local)	Normaliza el conjunto de bins de entrada y genera la tabla de trazabilidad
02_setup_fase2_khipu.sh	Preparación (login)	Crea los entornos de GTDB-Tk y dRep con versiones fijadas y descomprime la base de GTDB R220
run_fase1.slurm	script de ejecución (cola)	Ejecuta el filtrado por dominio, la evaluación de calidad y la selección
run_fase2.slurm	script de ejecución (cola)	Ejecuta la clasificación taxonómica, la replicación y el cálculo de prevalencia
summarize_phase1.py, summarize_phase2.py	Procesamiento	Convierten las salidas de cada herramienta en las tablas de decisión del flujo y en los reportes legibles

La separación entre script de ejecución y procesamiento es deliberada. El script de ejecución se ocupa de activar entornos, invocar herramientas y verificar condiciones. Los programas de procesamiento contienen la lógica de decisión del flujo, escrita en Python y empleando únicamente la biblioteca estándar. Esta última restricción permite ejecutarlos con el intérprete de cualquiera de los entornos, sin instalar dependencias adicionales.

6.3.2 Normalización de la entrada y trazabilidad

La trazabilidad entre cada genoma y su muestra de origen es un requisito del diseño, porque la prevalencia espacial de la Fase 2 se calcula sobre esos resultados. El programa de preparación la establece antes de que empiece el análisis.

Los archivos de origen llevan nombres de la forma `bin-<N>-<muestra>`, que ya codifican la muestra. El programa los copia a una carpeta limpia, descarta los ensamblajes por muestra que no son bins y construye una tabla de correspondencia con la muestra, el número de bin, el número de contigs y la longitud de cada genoma. El Código VI.2 muestra el núcleo de esa operación.

LISTING VI.2: Extracción de la muestra de origen a partir del nombre de archivo y registro en la tabla de trazabilidad (extracto de `01_prep_bins.sh`).

```
# Parseo del nombre: bin-<N>-<muestra>.fasta
core="${bn%.fasta}"           # bin-1-49
sample="${core##*-}"          # 49
rest="${core%*-}"             # bin-1
binn="${rest##*-}"            # 1
nctg=$(grep -c '^>' "$DEST/$bn" || echo 0)
len=$(grep -v '^>' "$DEST/$bn" | tr -d '\n' | wc -c)
printf "%s\t%s\t%s\t%s\t%s\n" \
    "$bn" "$sample" "$binn" "$nctg" "$len" >> "$MAP"
```

El programa verifica al final que el número de genomas procesados sea 97 y emite una advertencia en caso contrario. Esta comprobación protege contra el error más probable de esta etapa, que es tomar como origen una carpeta equivocada.

6.3.3 Encadenamiento entre etapas

Las etapas se comunican mediante archivos, no mediante memoria compartida. Cada etapa escribe un archivo en disco y la siguiente lo lee. La Tabla 6.8 documenta esa cadena, que es la descripción precisa de cómo la salida de un componente alimenta al siguiente.

TABLA 6.8: Archivos de datos que conectan las etapas del sistema.

Archivo	Lo produce	Lo consume
<code>bin_rename_map.tsv</code>	Preparación	La Fase 2, para asignar cada genoma a su muestra y calcular prevalencia
<code>tiara_bin_summary.tsv</code>	Tiara y su resumen	La copia selectiva de bins procariotas hacia la entrada de CheckM2
<code>quality_report.tsv</code>	CheckM2	La selección de la Fase 1 y, más adelante, dRep en la Fase 2
<code>phase1_selection.tsv</code>	Resumen de la Fase 1	El reporte de la Fase 1. Documenta el motivo de descarte de cada bin
<code>phase1_selected_genomes/</code>	Resumen de la Fase 1	La Fase 2 completa. Es su única entrada de secuencias
<code>genomeInfo.csv</code>	Resumen de la Fase 2	dRep, para evitar que recalcule la calidad de los genomas
<code>Cdb.csv</code> , <code>Wdb.csv</code>	dRep	El cálculo de linajes, representantes y prevalencia

Dos elementos de esta cadena resuelven problemas de integración concretos.

El primero es la carpeta de genomas seleccionados. La Fase 2 no recibe una lista de nombres ni un filtro que deba volver a aplicar, sino una carpeta que contiene exactamente los genomas que superaron la Fase 1. De ese modo el criterio de selección se aplica una sola vez, en el lugar donde está definido, y no puede divergir entre fases.

El segundo es el archivo de información de genomas. La herramienta de desreplicación evalúa por omisión la calidad de cada genoma con su propio procedimiento, lo que duplicaría un cálculo ya realizado y podría además descartar genomas que la Fase 1 había aceptado. El diseño evita ambos problemas convirtiendo el reporte de CheckM2 al formato que la herramienta espera y desactivando sus filtros propios, como muestra el Código VI.3.

LISTING VI.3: Reutilización de la evaluación de calidad de la Fase 1 y desactivación de los filtros propios de dRep (extracto de `run_fase2.slurm`).

```
# genomeInfo.csv a partir de CheckM2 (Fase 1): evita que dRep
# vuelva a estimar completitud y contaminacion.
python "$SCRIPTS_DIR/summarize_phase2.py" genomeinfo \
    --genomes-dir "$DREP_INPUT" --bin-ext "$BIN_EXT" \
    --checkm2 "$CHECKM2_REPORT" \
    --out "$RESULTS/genomeInfo.csv"

# -comp 0 -con 100: desactiva el filtro propio de dRep, ya
# aplicado en la Fase 1 (>70 % compl., <5 % contaminacion).
dRep dereplicate "$DREP_OUT" \
    -g "$DREP_INPUT"/*. "$BIN_EXT" \
    -p "$THREADS" \
    -pa "$DREP_PA" -sa "$DREP_SA" \
    --S_algorithm fastANI \
    -comp 0 -con 100 \
    --genomeInfo "$RESULTS/genomeInfo.csv"
```

6.3.4 Implementación de los script de ejecuciones

Cada script de ejecución declara primero los recursos que solicita al planificador del clúster y después la configuración del análisis. El Código VI.4 reproduce la cabecera de la Fase 1, que materializa el dimensionamiento de la Sección 6.1.3.

LISTING VI.4: Cabecera de solicitud de recursos al planificador (extracto de `run_fase1.slurm`).

```
# Limites de la cuenta: 32 cores, 98 GB RAM, 24 h por trabajo.
#SBATCH --job-name=fase1_estela
#SBATCH --partition=standard
#SBATCH --nodes=1
#SBATCH --ntasks=1
#SBATCH --cpus-per-task=32
#SBATCH --mem=90G
#SBATCH --time=24:00:00
#SBATCH --output=fase1_%j.out
#SBATCH --error=fase1_%j.err
```

La implementación incorpora tres mecanismos de robustez que conviene documentar porque responden a condiciones propias de esta plataforma.

El primero es el modo de terminación ante error. Los scripts se ejecutan con interrupción ante el primer fallo y con propagación del error a través del *pipeline*, pero sin la opción que aborta ante variables no definidas. Esa opción, que sería deseable, resulta incompatible con el sistema de módulos del clúster, que referencia una variable de entorno sin definirla previamente. El Código VI.5 muestra la solución adoptada y el comentario que la documenta en el propio archivo.

LISTING VI.5: Configuración de terminación ante error, compatible con el sistema de módulos del clúster (extracto de `run_fase1.slurm`).

```

# NO usar 'set -u' (nounset): Lmod referencia LD_PRELOAD sin
# definir y aborta la carga de modulos en Khipu.
set -eo pipefail
export LD_PRELOAD="${LD_PRELOAD:-}"

```

El segundo es un bloque de comprobaciones previas que se ejecuta antes de cualquier cálculo. Verifica que exista la carpeta de bins, que contenga archivos, que la base de datos esté descargada y que el entorno conda haya quedado disponible tras cargar el módulo. Cada comprobación fallida termina el trabajo con un mensaje que indica qué hacer. La finalidad es que un error de configuración se manifieste en los primeros segundos y no después de horas de cola y cómputo.

El tercero es el registro automático de versiones. Antes de empezar, cada script de ejecución escribe un archivo con la fecha, el identificador del trabajo, el nodo asignado, los umbrales efectivos y la versión de cada herramienta consultada al propio programa. Ese archivo acompaña a los resultados y es la evidencia de reproducibilidad que se reporta en el Capítulo VII.

6.3.5 Control de versiones

El código, las tablas de resultados y los archivos de bloqueo de los entornos se mantienen en un repositorio de control de versiones. Los archivos de gran tamaño que no aportan a la reproducibilidad, como el alineamiento concatenado de 230 MB, quedan excluidos de forma explícita y se conservan solo en el almacenamiento local. Esta separación mantiene el repositorio manejable sin perder la capacidad de reconstruir el análisis.

6.4 Representación gráfica de la solución y su verificación

Esta sección traduce las decisiones de las secciones anteriores a dos representaciones. La primera describe el flujo de datos, es decir, qué transformación sufre la información en cada etapa. La segunda describe la arquitectura de cómputo, es decir, dónde se ejecuta cada pieza y por qué.

6.4.1 Diagrama de flujo del sistema

La Figura 6.1 representa el sistema como una secuencia de operaciones unitarias conectadas por corrientes de datos. Cada bloque corresponde a una etapa de transformación, cada flecha representa un archivo de los declarados en la Tabla 6.8 y las cifras indican el número de genomas que atraviesa cada punto del flujo.





FIGURA 6.1: Diagrama de flujo del sistema implementado. Los bloques continuos representan etapas de transformación y los bloques discontinuos, las corrientes de entrada y salida. Las etiquetas sobre las flechas indican los archivos de datos que conectan las etapas. La flecha discontinua lateral representa la reutilización de la evaluación de calidad de la Fase 1 por parte de la desreplicación de la Fase 2, descrita en la Sección 6.3.3.

El diagrama muestra que el flujo es secuencial, con una única conexión entre fases: la reutilización de la evaluación de calidad. Esta conexión evita repetir el cálculo de calidad antes de la desreplicación.

6.4.2 Arquitectura de cómputo

La Figura 6.2 representa dónde se ejecuta cada pieza. La división entre el nodo de login y los nodos de cómputo no es un detalle de operación sino una restricción de diseño, porque determina qué programas pueden descargar insumos y cuáles deben encontrarlos ya disponibles.



La descarga de insumos y la ejecución del análisis ocurren en nodos distintos y en momentos distintos.

FIGURA 6.2: Arquitectura de cómputo del sistema sobre el clúster Khipu. Los programas de preparación se ejecutan de forma interactiva en el nodo de login, único con acceso a internet, y dejan los entornos y las bases de datos en el almacenamiento compartido. Los scripts de ejecución se envían a la cola con **sbatch** y se ejecutan en un nodo de cómputo sin conexión, que solo lee lo que la etapa de preparación dejó disponible.

6.4.3 Verificación de la correspondencia entre el diagrama y la implementación

Las dos figuras anteriores describen un sistema que existe y que se ejecutó. La correspondencia entre ambas y el código puede comprobarse de forma directa. Cada bloque de la Figura 6.1 corresponde a una invocación identificable dentro de uno de los dos scripts de ejecución, y cada archivo rotulado sobre las flechas corresponde a

un archivo que el sistema escribe en disco y que se conserva en el repositorio junto con los resultados. Las cifras de genomas que atraviesan cada etapa provienen de la ejecución real y coinciden con las que se reportan en el Capítulo VII.

Los guiones completos, con todas sus comprobaciones y mensajes, se presentan en el Anexo correspondiente. Los extractos incluidos en este capítulo recogen las decisiones de diseño relevantes y omiten el código de verificación y de reporte, que no aporta información ingenieril adicional.

CAPÍTULO VII

PRUEBAS Y RESULTADOS

Este capítulo presenta el desempeño del flujo bioinformático diseñado en el Capítulo VI. Primero se define bajo qué condiciones se probó el flujo. Luego se exponen los resultados obtenidos en las Fases, junto con los ajustes de diseño que esos resultados obligaron a realizar. Por último se verifica si la solución cumple las especificaciones técnicas y las restricciones del proyecto.

7.1 Plan de pruebas de la solución

El flujo diseñado no es un cálculo cerrado. Sus resultados dependen de umbrales numéricos que el equipo eligió. Por ese motivo la validación no consiste solo en ejecutar el flujo una vez. Consiste en ejecutarlo con una configuración de referencia y luego comprobar cuánto cambian los resultados si esos umbrales se mueven.

Esta sección define tres cosas. Primero, la configuración de referencia o caso base. Segundo, las variables que se midieron en cada etapa. Tercero, los escenarios alternativos con los que se evaluó la sensibilidad del diseño.

7.1.1 Caso base

El caso base es la configuración con la que se ejecutaron las dos fases en el clúster Khipu. Corresponde a los trabajos SLURM 49286 (Fase 1) y 49316 (Fase 2). Todos los resultados de la Sección 7.2 provienen de esta configuración, salvo los del

análisis de sensibilidad, que se identifican de forma explícita. La Tabla 7.1 resume sus parámetros.

TABLA 7.1: Parámetros operativos del caso base con el que se ejecutaron las Fases 1 y 2.

Etapas	Parámetro	Valor	Herramienta
Entrada	Bins de partida	97 (22 librerías)	—
Filtrado de dominio	Longitud mínima de contig	3000 bp	Tiara
Filtrado de dominio	Criterio de decisión	dominio mayoritario	Tiara
Calidad genómica	Complejidad	> 70 %	CheckM2
Calidad genómica	Contaminación	< 5 %	CheckM2
Clasificación	Base de datos	GTDB R220	GTDB-Tk 2.6.1
Confirmación de especie	ANI	≥ 95 %	FastANI
Confirmación de especie	Fracción alineada (AF)	≥ 65 %	FastANI
Definición de linaje	Umbral primario / secundario	0.90 / 0.95	dRep
Cómputo	Núcleos, memoria, tiempo	32, 98 GB, 24 h	SLURM

7.1.2 Variables medidas

En cada etapa del flujo se registró un conjunto de variables de respuesta. Estas variables son las que permiten juzgar si la etapa funcionó. La Tabla 7.2 las organiza por etapa.

TABLA 7.2: Variables de respuesta registradas en cada etapa del flujo.

Etapa	Variables medidas
Filtrado de dominio	Número de bins retenidos; porcentaje de longitud asignada a cada dominio en cada bin
Calidad genómica	Número de genomas retenidos; completitud y contaminación; motivo de rechazo; número de contigs, N50, tamaño y GC
Clasificación	Número de filos, órdenes y géneros; número de genomas con especie confirmada; ANI y AF frente a la referencia más próxima
Desreplicación	Número de linajes; ANI y cobertura dentro de cada clúster
Prevalencia	Número de muestras distintas en que aparece cada linaje

7.1.3 Escenarios de sensibilidad

Los umbrales del caso base son decisiones de diseño y no constantes físicas. Un umbral distinto habría producido un conjunto de genomas distinto. Para medir esa dependencia se repitió la selección con otros valores y se contó cuántos genomas y cuántos linajes quedaban en cada caso.

Estos escenarios no requirieron volver a ejecutar el flujo en el clúster. Las herramientas del caso base ya entregan, para cada genoma, el valor numérico sobre el que actúa cada filtro. La selección se recalculó sobre esas tablas de salida. El procedimiento es equivalente porque los filtros son comparaciones directas sobre valores ya calculados. La Tabla 7.3 detalla los cinco escenarios evaluados.

TABLA 7.3: Escenarios de sensibilidad evaluados sobre los resultados del caso base.

Escenario	Variable manipulada	Valores	Variable medida
E1	Umbral de completitud	50, 60, 70, 80, 90, 95 %	Genomas retenidos
E2	Umbral de contaminación	1, 3, 5, 10 %	Genomas retenidos
E3	Criterio de dominio	mayoría simple; 25 a 90 % de longitud procariota	Bins retenidos
E4	Umbral de ANI de linaje	95, 98, 99, 99.5 %	Linajes definidos
E5	Continuidad del ensamblaje	sin filtro; ≤ 300 contigs	Genomas retenidos

7.2 Análisis de los resultados de las pruebas

Esta sección presenta los resultados de las dos fases ejecutadas. Las Secciones 7.2.1 y 7.2.2 exponen los resultados del caso base. La Sección 7.2.3 evalúa cuánto dependen esos resultados de los umbrales elegidos. La Sección 7.2.4 documenta los dos ajustes de diseño que los resultados obligaron a realizar.

7.2.1 Resultados de la Fase 1: control de calidad y selección de genomas (OE1)

La Fase 1 se ejecutó en el clúster Khipu mediante el controlador `run_fase1.slurm` (trabajo SLURM 49286), sobre los 97 bins genómicos crudos procedentes de las 22 librerías Illumina que recuperaron material ensamblable (Tabla 5.1). El flujo aplicó dos filtros secuenciales e independientes: primero una discriminación por dominio con Tiara y después una estimación de calidad genómica con CheckM2. El orden no es intercambiable, ya que las métricas de completitud y contaminación de CheckM2 se calculan sobre marcadores procariotas y carecen de sentido en un ensamblaje mayoritariamente eucariota.

7.2.1.1. Depuración secuencial del conjunto de bins

El filtrado por dominio descartó 31 de los 97 bins, cuya mayoría se clasificó como eucariota u organelar. Este resultado era esperable dado el origen de las muestras: una superficie pétrea expuesta a la intemperie acumula material fúngico, algal y vegetal que el ensamblaje por muestra no separa del componente procariota. Casos como **bin-1-55**, con 34.2 Mb repartidos en 247 contigs, corresponden con claridad a un genoma eucariota parcialmente reconstruido y no a un genoma bacteriano contaminado.

Los 66 bins restantes pasaron al control de calidad genómica, donde se aplicó el criterio definido para el OE1: completitud superior al 70 % y contaminación inferior al 5 %. De ellos, 45 fueron rechazados y 21 seleccionados, lo que representa una tasa de retención del 21.65 % sobre el total crudo inicial. El motivo de los rechazos resulta informativo porque expone dos problemas de naturaleza distinta:

- **18 bins** incumplieron únicamente el criterio de completitud ($\leq 70\%$). Se trata de reconstrucciones parciales, atribuibles a baja profundidad de secuenciación o a fragmentación del ensamblaje. Los valores cubren todo el rango, desde reconstrucciones cercanas al umbral, como **bin-1-50** con 62.29 %, hasta fragmentos residuales sin utilidad analítica, como **bin-1-52** con 6.05 %.
- **20 bins** incumplieron únicamente el criterio de contaminación ($\geq 5\%$), lo que indica quimerismo: contigs de linajes distintos coagrupados por MetaBAT2 durante el *binning*. La magnitud es en ocasiones considerable, como en **bin-1-60**, con 24.87 %.
- **7 bins** incumplieron ambos criterios de forma simultánea. El caso extremo es **bin-1-58**, con 0.00 % de completitud y 17.71 % de contaminación, un agrupamiento sin correspondencia con ningún genoma real.

Esta diferencia es importante para entender qué se perdió en cada caso. Los 18 bins incompletos corresponden a información que estaba presente en la muestra, pero que no pudo reconstruirse completamente durante el ensamblaje. En cambio, los 20 bins contaminados contienen fragmentos de distintos organismos que fueron agrupados incorrectamente. Este segundo problema es más crítico, porque podría afectar la reconstrucción del genoma accesorio en los análisis posteriores. Por ello, se mantuvo un límite estricto de contaminación del 5 %, mientras que el umbral de completitud se fijó en 70 %.




FIGURA 7.1: Embudo de selección de genomas desde los bins crudos hasta los linajes. **(a)** Número de genomas que sobrevive a cada etapa del flujo: 97 bins crudos procedentes de 22 librerías Illumina, 66 con dominio mayoritariamente procariota según Tiara, 21 que superan los umbrales de calidad de CheckM2 (completitud superior al 70 %, contaminación inferior al 5 %) y 19 linajes tras la desreplicación con dRep al 95 % de ANI. Las cifras en blanco indican las pérdidas en cada paso. **(b)** Motivos de descarte de los 76 bins eliminados. **(c)** Composición por dominio de cada uno de los 97 bins según Tiara, expresada como porcentaje de la longitud del bin clasificada en cada categoría; los bins se separan según su dominio mayoritario y se ordenan por la fracción procariota.

La Figura 7.1(c) muestra que la clasificación por dominio no es ambigua en la mayoría de los casos: los bins se concentran en los extremos de la escala, con una fracción procariota cercana al 0 % o al 100 %, y son pocos los que ocupan posiciones intermedias. Esto respalda la decisión de aplicar un criterio de mayoría simple sobre la longitud clasificada en lugar de un umbral más elaborado.

7.2.1.2. Calidad y estructura de los 21 genomas seleccionados

Los 21 genomas retenidos presentan una calidad marcadamente asimétrica respecto del umbral. La mediana de la completitud alcanza el 99.86 %, con 13 genomas por encima del 99 % y 5 con completitud estimada del 100.00 %; solo cuatro quedan por debajo del 80 %. La mediana de la contaminación es del 0.44 %, valor muy por debajo del límite fijado.




FIGURA 7.2: Calidad y métricas de ensamblaje de los genomas. **(a)** Completitud frente a contaminación (CheckM2) de los 66 bins procariotas. El eje de contaminación usa escala logarítmica ($\log(1+x)$) porque unos pocos bins superan el 60 % y comprimirían la región de interés. Las líneas discontinuas marcan los umbrales del estudio (completitud igual o superior al 70 %, contaminación inferior al 5 %) y la región sombreada, los 21 genomas seleccionados. **(b)** Tamaño del genoma frente a contenido GC de los 21 genomas seleccionados; el tamaño del punto es proporcional al N50 de los contigs y el color indica el filo. **(c)** Distribución de N50, número de contigs, densidad codificante y completitud por filo. Cada punto es un genoma; las cajas muestran mediana y cuartiles.

La Figura 7.2(a) muestra los criterios de contaminación y completitud sobre las distintas poblaciones de bins.

La completitud y la contaminación no describen por completo la utilidad de un genoma para el análisis pangenómico. La continuidad del ensamblaje sí importa, y en esa dimensión el conjunto es heterogéneo: el número de contigs va de 17 a 1041,

con mediana de 90. Cuatro genomas superan los 300 contigs (**bin-5-50** con 1041, **bin-6-50** con 591, **bin-3-64** con 459 y **bin-9-71** con 346).

El caso de **bin-5-50** muestra que la calidad y la fragmentación de un genoma son aspectos distintos. Este bin tiene una completitud del 76.56 % y una contaminación del 0.44 %, por lo que cumple los criterios del OE1. Sin embargo, sus 3.47 Mb están divididos en más de mil contigs, con una longitud media de solo 3.3 kb.

CheckM2 le asigna una buena calidad porque evalúa principalmente la presencia de genes marcadores, muchos de los cuales pueden encontrarse completos incluso en contigs pequeños. Por tanto, esta métrica no refleja directamente qué tan continuo está el ensamblaje.

El problema aparece en la Fase 3. Cuando un gen queda cortado entre contigs, puede no coincidir correctamente con su versión completa en los genomas de referencia. Como resultado, el análisis pangenómico puede interpretarlo como un gen diferente y clasificarlo como accesorio o incluso exclusivo de la Estela. Así, una alta fragmentación puede generar falsos genes exclusivos, afectando directamente al OE3. Por esta razón, la Fase 3 incluye controles para identificar y descartar estos casos.

Los tamaños genómicos oscilan entre 1.83 y 5.91 Mb, con mediana de 4.03 Mb, valores compatibles con genomas bacterianos. El extremo inferior corresponde a **bin-9-71** (1.83 Mb), cuya completitud del 85.09 %.

TABLA 7.4: Métricas de ensamblaje y calidad genómica de los 21 MAGs seleccionados (completitud superior al 70 % y contaminación inferior al 5 %).

Bin	Contigs	Longitud (bp)	Dominio	Completitud (%)	Contaminación (%)
bin-1-51	51	4.727.435	prok	100.00	0.00
bin-1-53	30	2.476.631	prok	99.84	0.12
bin-1-54	49	4.312.038	prok	92.25	0.01
bin-1-57	22	4.032.412	prok	99.99	3.23
bin-1-59	98	5.907.869	prok	99.97	3.07
bin-1-64	163	3.944.265	prok	99.84	0.59
bin-1-68	50	2.465.224	prok	100.00	1.79
bin-2-53	39	5.164.804	prok	99.99	0.57
bin-2-57	28	5.172.263	prok	99.96	1.01
bin-2-58	17	4.771.531	prok	100.00	0.06
bin-2-63	150	4.282.638	prok	92.39	0.34
bin-2-69	61	2.481.071	prok	99.99	0.18
bin-3-52	204	5.184.467	prok	98.97	0.58
bin-3-64	459	2.352.198	prok	70.14	0.64
bin-4-52	96	3.497.259	prok	99.86	0.25
bin-5-50	1041	3.472.002	prok	76.56	0.44
bin-5-60	97	2.849.856	prok	77.53	0.10
bin-5-63	90	2.758.939	prok	72.46	0.05
bin-6-50	591	5.543.214	prok	100.00	0.65
bin-6-61	30	4.792.746	prok	100.00	0.74
bin-9-71	346	1.832.072	prok	85.09	2.13

7.2.1.3. Implicancia para el OE1

El OE1 se cumple. Obtenemos un conjunto de 21 genomas procariotas cuya completitud y pureza permiten la asignación taxonómica y la comparación genómica

posteriores. Por ese motivo descartamos 78.35 % del material de partida. La depuración descarta organismos que estuvieran presentes en la estela pero que no alcanzan la calidad necesaria para los posteriores análisis. Por lo tanto, la diversidad real de la fracción viable es mayor que la que estos 21 genomas representan.

El detalle de todos los 97 bins evaluados, con los motivos específicos para su exclusión, se presenta en el Anexo 7.11.

7.2.2 Resultados de la Fase 2: asignación taxonómica y definición de linajes (OE2)

La Fase 2 se ejecutó en Khipu mediante `run_fase2.slurm` (trabajo SLURM 49316) sobre los 21 genomas seleccionados en la fase anterior. El flujo comprendió la clasificación taxonómica con GTDB-Tk sobre los datos de la versión R220, la confirmación de especie por ANI, la desreplicación en linajes con dRep y el cálculo de la prevalencia espacial de cada linaje.

7.2.2.1. Composición taxonómica de la fracción viable

GTDB-Tk clasificó los 21 genomas dentro de tres filos bacterianos. No se detectó ningún genoma arqueal, lo que resuelve la ambigüedad que Tiara había dejado abierta en la Fase 1 entre bacterias y arqueas. La distribución está dominada por Bacillota, con 13 genomas (62 %), seguido de Pseudomonadota con 5 (24 %) y Actinomycetota con 3 (14 %). Por debajo del filo, la diversidad es alta en relación con el tamaño de la muestra: los 21 genomas se reparten en 11 órdenes y 17 géneros distintos, y solo cuatro géneros aportan más de un genoma.




FIGURA 7.3: Composición taxonómica del conjunto de genomas seleccionados. **(a)** Número de genomas por género, agrupados por filo. **(b)** Número de genomas por orden. **(c)** Reparto de los 21 genomas entre los tres filos detectados.

El predominio de Bacillota (Figura 7.3) es coherente con el sustrato y con el método de obtención de la muestra. Buena parte de los géneros recuperados dentro de este filo (*Bacillus*, *Peribacillus*, *Priestia*, *Cytobacillus*, *Metabacillus*, *Rosellomorea*, *Mesobacillus*, *Sporosarcina*, *Paenibacillus*) forma endosporas, una estrategia de resistencia que favorece la supervivencia sobre una superficie pétrea expuesta a desecación, radiación ultravioleta y oscilación térmica [11].

7.2.2.2. Confirmación filogenómica




FIGURA 7.4: Árbol filogenómico de los 21 genomas seleccionados con sus metadatos. Árbol de Neighbor-Joining calculado sobre distancias-p a partir del alineamiento concatenado de los 120 marcadores bacterianos de copia única (bac120, 5035 posiciones) generado por GTDB-Tk (datos R220), enraizado en el filo Pseudomonadota. Los números sobre las ramas son valores de soporte de *bootstrap* (500 réplicas); solo se muestran los iguales o superiores al 70 %. Las columnas de la derecha indican, para cada genoma, la muestra de origen, el linaje asignado por dRep (el asterisco marca el genoma representante del linaje) y los valores de completitud y contaminación de CheckM2.

La topología del árbol (Figura 7.4) es congruente con la asignación taxonómica: los tres filos se recuperan como grupos separados y los genomas del mismo género quedan en ramas adyacentes. Los valores de soporte son altos en los nodos que definen la estructura principal, con *bootstrap* del 100 % en la separación de los filos y en los pares congénéricos.

El alcance de este resultado es limitado. El árbol es de distancias y se calculó únicamente sobre los genomas de consulta, sin incorporar genomas de referencia de GTDB, de modo que verifica la coherencia interna del conjunto pero no constituye

una prueba filogenética independiente de la asignación taxonómica. Tal como se justificó en el Capítulo IV, el árbol de novo focalizado por linaje, con referencias del taxón asignado y grupo externo, queda previsto para la Fase 4.

7.2.2.3. Confirmación de especie y candidatos a novedad taxonómica

Se calculó la Identidad Nucleotídica Promedio de cada genoma frente a su referencia GTDB más próxima, aplicando los criterios de confirmación de especie definidos en el Capítulo IV ($ANI \geq 95\%$ y fracción alineada $\geq 65\%$). Dieciséis de los 21 genomas satisfacen ambos criterios, con valores de ANI entre 95.61 % y 99.99 % y mediana de 98.53 %. Doce de los 16 superan el 98 % de ANI, lo que indica correspondencias con especies descritas.




FIGURA 7.5: Evaluación de novedad taxonómica frente a la referencia GTDB más cercana. ANI frente a fracción alineada (AF) de cada genoma respecto de su referencia GTDB más cercana. Las líneas discontinuas marcan los criterios de confirmación de especie (ANI igual o superior al 95 % y AF igual o superior al 65 %). Los 16 genomas del cuadrante sombreado tienen especie confirmada. Dos genomas adicionales (**bin-1-51**, *Pantoea* sp., y **bin-9-71**, *Aristophania* sp.) fueron clasificados únicamente por topología del árbol, sin cálculo de ANI, y no aparecen representados.

Los 5 genomas restantes se distribuyen en dos situaciones distintas (Figura 7.5). Dos de ellos, **bin-1-51** (*Pantoea* sp.) y **bin-9-71** (*Aristophania* sp.), fueron ubicados por GTDB-Tk mediante la topología del árbol de colocación sin que se calculara ANI, de modo que su clasificación se detiene en el rango de género por ausencia de una referencia suficientemente próxima. Por ese motivo, esas secuencias se descartan para la fase 3.

Los otros 3 sí produjeron valores de ANI, pero por debajo del umbral de especie, y constituyen el hallazgo taxonómico más relevante de esta fase. Los dos genomas de *Corynebacterium* sp. (**bin-1-68** y **bin-2-69**) alcanzan un ANI de 90.55 y 90.50 % frente a su referencia más cercana, con fracciones alineadas de apenas

44,3 y 44.0 %. El genoma de *Sporosarcina* sp. (bin-3-64) queda en 91.25 % de ANI y 60.4 % de AF. Los tres valores de ANI se encuentran por debajo del umbral de similitud utilizado para la circunscripción de especies en GTDB, lo que indica que ninguno de estos genomas puede asignarse a la misma especie que su referencia más cercana.

En el caso de los *Corynebacterium* la fracción alineada, inferior al 45 %, indica que menos de la mitad del genoma encuentra correspondencia en la referencia. Estos genomas son, por tanto, candidatos a especies no descritas en la versión R220 del GTDB.

Hacemos énfasis en este resultado porque ambos *Corynebacterium* proceden de muestras distintas y presentan completitud del 100 %, de modo que la divergencia observada no es atribuible a una reconstrucción defectuosa.

7.2.2.4. Desreplicación y definición de linajes

La desreplicación con dRep agrupó los 21 genomas en 19 linajes, definidos como clústeres de especie al 95 % de ANI. Solo dos pares colapsaron.




FIGURA 7.6: Matriz de similitud genómica entre los 21 genomas seleccionados. Similitud MASH (100— distancia MASH) entre todas las parejas de genomas, ordenadas por filo y género. Solo dos parejas presentan similitud máxima: los dos *Telluria timonae* (muestras 50 y 52) y los dos *Corynebacterium* sp. (muestras 68 y 69). Nota metodológica: dRep ejecuta fastANI únicamente dentro de cada clúster primario definido por MASH, de modo que no existe una matriz de ANI completa para los 21 genomas; la matriz de todos contra todos disponible es la de MASH.

Las dos parejas sometidas a fastANI dentro de su clúster primario superan el umbral de especie con amplitud: *Corynebacterium* sp. (bin-1-68 ↔ bin-2-69) alcanza 99.96 % de ANI con 97.1 % de cobertura del alineamiento, y *Telluria timonae* (bin-3-52 ↔ bin-6-50), 99.78 % de ANI con 85.2 % de cobertura. Ambas colapsan en un único linaje.

El resto de los genomas resulta mutuamente distante (Figura 7.6), incluido el par de *Cytobacillus* (bin-5-50 y bin-2-57), que pese a compartir género se mantiene como dos linajes separados con una similitud MASH del 80 %. Este es el motivo de que 21 genomas den lugar a 19 linajes y no a un número menor: la redundancia entre muestras es baja, y la mayor parte de lo recuperado corresponde a organismos distintos y no a reconstrucciones repetidas del mismo genoma.

7.2.2.5. Prevalencia espacial de los linajes




FIGURA 7.7: Prevalencia espacial de los linajes. **(a)** Matriz de presencia de cada linaje (filas, ordenadas por prevalencia descendente) en cada muestra (columnas); el color indica el filo. **(b)** Prevalencia de cada linaje, definida como el número de muestras distintas en que aparece, coloreada por filo. **(c)** Número de genomas de alta calidad recuperados por muestra, coloreado por filo. Limitación: la prevalencia se calcula sobre el número de muestras y no sobre zonas físicas de la estela, porque no se dispone de un mapeo muestra → zona en formato analizable.

La prevalencia espacial resultó baja en todo el conjunto. Diecisiete de los 19 linajes aparecen en una sola muestra, y solo dos alcanzan una prevalencia de dos: L1 (*Telluria timonae*, muestras 50 y 52) y L2 (*Corynebacterium* sp., muestras 68 y 69). Ningún linaje se recuperó en tres o más puntos. Además, de las 22 librerías que produjeron bins, solo 15 aportaron al menos un genoma de alta calidad tras la Fase 1 (Figura 7.7(c)).

Este resultado limita el poder discriminante de la métrica. Con un rango efectivo de apenas dos valores, la prevalencia no permite ordenar los linajes ni separar con seguridad a los colonizadores estables de las detecciones puntuales.

Dos hipótesis resultan compatibles con los datos. La primera es que la comunidad viable de la estela sea genuinamente heterogénea entre muestras, sin un núcleo de organismos compartido. La segunda es que la recuperación de genomas de alta calidad sea limitada, de modo que un linaje presente en varias muestras solo pueda reconstruirse con suficiente calidad en una de ellas.

Los datos disponibles no permiten discriminar entre ambas. La segunda tampoco puede descartarse, dado que el flujo retuvo apenas el 21.65 % de los bins iniciales.

Por esta razón, la prevalencia espacial se reporta aquí como caracterización de la distribución de cada linaje sobre el monumento, pero no se emplea como criterio para decidir qué especies ingresan al análisis pangenómico.

Por ese motivo, el criterio de selección de bins para el pangenoma (fase 3) cambia como se explica en la siguiente sección.

7.2.2.6. Implicancia para el OE2

El OE2 se cumple: los 21 genomas quedan clasificados con resolución de especie en 16 casos y de género en los 5 restantes, y agrupados en 19 linajes operativos que constituyen la unidad de análisis de las fases siguientes.

Dos resultados condicionan el diseño posterior. El primero es la baja redundancia entre muestras: con 19 linajes sobre 21 genomas, y 17 de ellos representados por un único genoma, no es posible construir un pangenoma empleando exclusivamente material de la estela. El análisis pangenómico de la Fase 3 debe apoyarse necesariamente en conjuntos de genomas de referencia públicos. El segundo es la detección de tres candidatos a especies no descritas, entre ellos los dos *Corynebacterium* de completitud íntegra, que por carecer de referencia comparable quedan fuera del análisis pangenómico pero constituyen un hallazgo reportable por sí mismo.

TABLA 7.5: Linajes definidos en la Fase 2, ordenados por prevalencia espacial descendente.

Linaje	Taxonomía (GTDB)	Prev.	Muestras	Representante	Especie conf.
L1	<i>Telluria timonae</i>	2	50, 52	bin-6-50	Sí
L2	<i>Corynebacterium</i> sp.	2	68, 69	bin-2-69	No
L3	<i>Bacillus_AB infantis</i>	1	61	bin-6-61	Sí
L4	<i>Sporosarcina</i> sp.	1	64	bin-3-64	No
L5	<i>Pantoea</i> sp.	1	51	bin-1-51	—
L6	<i>Brevibacterium</i> sp021023135	1	57	bin-1-57	Sí
L7	<i>Paenibacillus</i> sp001955535	1	59	bin-1-59	Sí
L8	<i>Acinetobacter schindleri</i>	1	52	bin-4-52	Sí
L9	<i>Priestia flexa</i>	1	60	bin-5-60	Sí
L10	<i>Aristophania</i> sp.	1	71	bin-9-71	—
L11	<i>Staphylococcus warneri_A</i>	1	53	bin-1-53	Sí
L12	<i>Peribacillus frigoritolerans</i>	1	54	bin-1-54	Sí
L13	<i>Rosellomorea marisflavi</i>	1	63	bin-2-63	Sí
L14	<i>Bacillus licheniformis</i>	1	64	bin-1-64	Sí
L15	<i>Metabacillus halosaccharovorans</i>	1	53	bin-2-53	Sí
L16	<i>Bacillus altitudinis</i>	1	63	bin-5-63	Sí
L17	<i>Cytobacillus oceanisediminis</i>	1	57	bin-2-57	Sí
L18	<i>Cytobacillus firmus_B</i>	1	50	bin-5-50	Sí
L19	<i>Mesobacillus</i> sp014856545	1	58	bin-2-58	Sí

Nota. Prev.: prevalencia espacial, número de muestras distintas que aportan al menos un genoma al linaje. Especie conf.: confirmación de especie por ANI igual o superior al 95 % y AF igual o superior al 65 %; el guion indica los linajes clasificados por topología del árbol, sin cálculo de ANI. Los sufijos _A y _B y los epítetos alfanuméricos del tipo **sp**<dígitos> corresponden a la nomenclatura propia del GTDB.

7.2.3 Sensibilidad de los resultados a los umbrales elegidos

Los resultados anteriores corresponden a una sola configuración. Esta sección responde a una pregunta distinta: cuánto habrían cambiado esos resultados con otros

umbrales. La respuesta permite saber si el conjunto de 21 genomas es un resultado estable o el producto de una elección afortunada.

7.2.3.1. Umbrales de calidad genómica

Los escenarios E1 y E2 recalcularon la selección sobre los 66 bins procariotas variando de forma simultánea los dos umbrales de CheckM2. La Tabla 7.6 muestra el resultado.

TABLA 7.6: Número de genomas retenidos sobre los 66 bins procariotas al variar los umbrales de completitud y contaminación. La celda en negrita corresponde al caso base.

Completitud	Cont. < 1 %	Cont. < 3 %	Cont. < 5 %	Cont. < 10 %
> 50 %	17	22	24	25
> 60 %	17	22	24	25
> 70 %	16	19	21	22
> 80 %	12	15	17	18
> 90 %	12	14	16	17
> 95 %	10	12	14	15

El conjunto seleccionado resulta poco sensible al umbral de completitud. Bajarlo de 70 a 50 % solo añade tres genomas. Subirlo de 70 a 90 % solo retira cinco. La explicación está en la distribución de la completitud dentro del conjunto retenido, descrita en la Sección 7.2.1: la mediana alcanza el 99.86 % y trece genomas superan el 99 %. La mayoría de los genomas seleccionados está lejos del umbral, de modo que moverlo no los afecta.

El umbral de contaminación pesa más. Entre 1 y 5 % el conjunto pasa de 16 a 21 genomas, y cinco genomas dependen por completo de dónde se ponga ese límite. La contaminación es también el criterio que rechazó más bins en el caso base, con

20 exclusiones por ese solo motivo. En conjunto, la contaminación es el parámetro que gobierna el tamaño final del conjunto, y no la completitud.

Aumentar la contaminación hasta el 10 % habría añadido un solo genoma frente al caso base. Esto indica que el límite del 5 % no está descartando material útil que un criterio algo más permisivo habría recuperado. Entre 5 y 10 % de contaminación casi no hay bins.

7.2.3.2. Criterio de discriminación por dominio

El caso base decide el dominio de cada bin por mayoría simple sobre la longitud clasificada. El escenario E3 reemplazó ese criterio por un umbral explícito sobre la fracción procariota. La Tabla 7.7 compara ambas opciones.

TABLA 7.7: Número de bins retenidos, sobre los 97 de partida, según el criterio de discriminación por dominio.

Criterio	Bins retenidos
Mayoría simple (caso base)	66
Fracción procariota > 25 %	56
Fracción procariota > 40 %	54
Fracción procariota > 50 %	50
Fracción procariota > 60 %	44
Fracción procariota > 75 %	34
Fracción procariota > 90 %	30

Este es el punto del flujo más sensible al criterio elegido. La mayoría simple retiene 66 bins, mientras que exigir más de la mitad de la longitud clasificada como procariota retendría 50. La diferencia de 16 bins se explica porque la mayoría simple compara la fracción procariota contra las fracciones eucariota, organelar y desconocida por separado. Un bin con 40 % de longitud procariota, 30 % eucariota y 30 %

desconocida tiene mayoría procariota, aunque menos de la mitad de su longitud lo sea.

Hay 22 bins cuya fracción procariota queda entre el 25 y el 75 %. La afirmación de la Sección 7.2.1 sobre la concentración de los bins en los extremos de la escala describe bien la tendencia general, pero este grupo intermedio existe y conviene dimensionarlo.

El efecto sobre el resultado final es menor de lo que sugieren estas cifras. El filtro de calidad de CheckM2 actúa después y elimina de todos modos los bins con mezcla de dominios, porque esa mezcla aparece como contaminación. El criterio de dominio afecta sobre todo al costo de cómputo de la etapa siguiente, ya que determina cuántos bins se someten a CheckM2.

7.2.3.3. Umbral de ANI para la definición de linaje

El escenario E4 varió el umbral de ANI con el que dRep agrupa genomas en linajes. El resultado es que el número de linajes no cambia: se mantiene en 19 para umbrales de 95, 98, 99 y 99.5 % de ANI.

La razón está en los valores observados. Solo dos parejas de genomas fueron comparadas con fastANI dentro de su clúster primario, y ambas presentan identidades muy altas: 99.95 % entre los dos *Corynebacterium* y 99.78 % entre los dos *Telluria timonae*. Ambas parejas siguen colapsando incluso con un umbral del 99.5 %. El resto de los genomas está tan separado que ningún umbral razonable los uniría.

Por lo tanto, la definición de linaje es insensible al umbral dentro de este conjunto. Este resultado refuerza la conclusión de la Sección 7.2.2 sobre la baja redundancia del material recuperado.

7.2.3.4. Continuidad del ensamblaje

El caso base no filtra por número de contigs. El escenario E5 añadió ese filtro para medir su efecto. Aplicar un límite de 300 contigs sobre los 21 genomas seleccionados dejaría 17. Saldrían **bin-5-50** (1041 contigs), **bin-6-50** (591), **bin-3-64** (459) y **bin-9-71** (346).

Este filtro no se aplicó en la Fase 1 por una razón concreta. Los cuatro genomas afectados incluyen a **bin-6-50**, representante del linaje más prevalente, y a **bin-9-71**, único representante de su género. Excluirlos habría reducido la descripción taxonómica de la comunidad, que es el objetivo del OE2, a cambio de una mejora que solo importa en el análisis pangenómico posterior. La decisión fue conservarlos en las Fases 1 y 2 y trasladar el control de continuidad a la etapa donde la fragmentación sí genera un error, tal como se discute en la Sección 7.2.1 a propósito de **bin-5-50**.

7.2.4 Iteraciones de diseño derivadas de los resultados

El diseño del flujo no se mantuvo fijo durante la ejecución. Dos resultados obligaron a modificarlo. Esta sección documenta ambos casos siguiendo el ciclo de prueba, evaluación y rediseño.

Conviene precisar en qué consiste cada cambio. El diseño descrito en el Capítulo IV es el punto de partida, y las pruebas de este capítulo son precisamente el mecanismo previsto para ponerlo a prueba. En los dos casos siguientes, los cambios se hicieron a partir de resultados obtenidos durante el análisis. Uno se debió a un requerimiento de memoria mayor al disponible y el otro a una métrica que no permitió diferenciar adecuadamente los resultados. Para mantener la trazabilidad, se presentan por separado el diseño original, la evidencia que motivó el cambio y el diseño corregido.

7.2.4.1. Primera iteración: alcance del árbol filogenómico

El diseño inicial contemplaba construir un árbol *de novo* que incluyera los genomas propios junto con el conjunto completo de genomas de referencia del dominio bacteriano de GTDB. La prueba mostró que ese cálculo no cabe en los 98 GB de memoria asignados a la cuenta.

La evaluación de ese fallo distingue dos problemas. El primero es de recursos y no admite solución dentro de la cuota disponible. El segundo es de alcance: el objetivo del OE2 no requiere un árbol del dominio completo, sino verificar la coherencia de las asignaciones taxonómicas.

El rediseño consistió en dos cambios. Para la Fase 2 se calculó un árbol de distancias sobre el alineamiento concatenado de los 120 marcadores, restringido a los nuestros genomas. Ese árbol es el que aparece en la Figura 7.4 y cumple la función de verificación interna.

7.2.4.2. Segunda iteración: criterio de selección de linajes para el pan-genoma

El diseño original preveía seleccionar los linajes del análisis pangenómico por prevalencia espacial. La lógica era que un linaje presente en varios puntos del monumento resulta más relevante para el biodeterioro que una detección aislada.

La prueba invalidó ese criterio. Como muestra la Sección 7.2.2, diecisiete de los 19 linajes aparecen en una sola muestra y solo dos alcanzan una prevalencia de dos. Con esa distribución no es posible construir un ranking ni separar bacterias colonizadoras estables de detecciones puntuales.

La evaluación de este resultado identificó además una restricción más básica. Con 19 linajes sobre 21 genomas, y 17 de ellos representados por un único genoma,

el material propio no alcanza para construir ningún pangenoma. El análisis pangenómico depende necesariamente de genomas de referencia públicos, de modo que el criterio de selección debe incorporar la disponibilidad de esas referencias.

El rediseño reemplazó la prevalencia espacial por la disponibilidad genómica pública. Un linaje ingresa al análisis pangenómico si existe para su especie un número suficiente de genomas públicos de calidad adecuada. El umbral adoptado es de 15 genomas.

Es importante mencionar que la inclusión de genomas filogenéticamente redundantes infla de forma artificial el tamaño del core y subestima el genoma accesorio, lo que puede llevar a describir como cerrado un pangenoma que en realidad es abierto [58]. Quince genomas redundantes no equivalen a quince genomas informativos. Por lo tanto, este parámetro está abierto a iteración.

La prevalencia espacial se conserva como resultado descriptivo del OE2 y se reporta en la Tabla 7.5, pero deja de cumplir función de criterio de selección.

7.3 Verificación del cumplimiento de las especificaciones técnicas

Esta sección dictamina si el desempeño del *pipeline* alcanza los valores comprometidos. Las especificaciones se derivan de los objetivos específicos OE1 y OE2 y son las únicas que admiten una verificación cuantitativa directa. La Tabla 7.8 cruza cada especificación con su método de verificación y con el resultado obtenido.

TABLA 7.8: Matriz de verificación del cumplimiento de las especificaciones técnicas.

Especificación	Método de verificación	Objetivo	Resultado obtenido	Cumple
Calidad del conjunto final de genomas	CheckM2 sobre cada genoma	Compleitud $> 70\%$ y contaminación $< 5\%$	21 de 21 genomas; mediana de completitud 99.86 % y de contaminación 0.44 %	Sí
Resolución taxonómica de la asignación	GTDB-Tk sobre datos R220, con confirmación por ANI	Asignación al menos a nivel de género	21 de 21 a género; 16 de 21 con especie confirmada ($ANI \geq 95\%$, $AF \geq 65\%$)	Sí
Trazabilidad entre genoma y muestra de origen	Registro de correspondencia generado en la normalización de nombres	21 de 21 genomas	21 de 21 genomas vinculados a su librería de origen	Sí
Definición de unidades de análisis no redundantes	Desreplicación con dRep al 95 % de ANI	Conjunto sin genomas duplicados	19 linajes sobre 21 genomas; dos parejas colapsadas	Sí
Reproducibilidad de la ejecución	Registro de versiones y control de versiones del código	Versiones de herramientas y bases registradas	Registro de versiones por fase; scripts y resultados versionados en repositorio	Sí

7.4 Verificación del cumplimiento de restricciones

Las restricciones son límites que el diseño no podía cruzar, a diferencia de las especificaciones, que son metas de desempeño. La Tabla 7.9 verifica cada una.

TABLA 7.9: Matriz de verificación del cumplimiento de las restricciones del proyecto.

Restricción	Origen	Forma en que el diseño la respeta	Cumple
Cuota de cómputo de 32 núcleos, 98 GB de memoria y 24 h por trabajo	Política de asignación del clúster Khipu	Ambas fases se ejecutaron como trabajos únicos y finalizaron dentro del límite de tiempo asignado. El árbol de referencia completo se reemplazó por un árbol focalizado tras exceder la memoria disponible	Sí
Los nodos de cómputo no tienen acceso a internet	Arquitectura del clúster	Las bases de datos de CheckM2 y GTDB R220 se descargaron en el nodo de login antes de la ejecución. Ninguna etapa del flujo requiere conexión durante el cálculo	Sí
No se dispone de las lecturas crudas de secuenciación	Condición de entrega del material por el centro de secuenciación	El flujo se diseñó para operar sobre bins ya ensamblados. No se recalculan coberturas ni se rehace el ensamblaje ni el <i>binning</i>	Sí
El conjunto de muestras es cerrado y no ampliable	Condición de acceso al monumento	El diseño trabaja con las 22 librerías disponibles. Las limitaciones de prevalencia se reportan como tales y no se compensan con muestreo adicional	Sí
Uso exclusivo de software de licencia libre y bases de datos públicas	Restricción presupuestal del proyecto	Todas las herramientas y bases empleadas son de acceso abierto	Sí

REFERENCIAS BIBLIOGRÁFICAS

- [1] A. Cordy-Collins, “Richard I. Burger, *Chavín and the Origins of Andean Civilization*. 248 pages, 245 illustrations. London: Thames & Hudson, 1992. ISBN 0-500-05069-4, hardback,” *Antiquity*, vol. 67, no. 257, pp. 947–948, Dec 1993, book review.
- [2] R. Hernández Asensio, “Las piedras suplican auxilio. arqueólogos, huaqueros y autoridades locales en Chavín de Huántar (1870–1945),” *Histórica*, vol. 36, no. 2, pp. 113–138, 2012.
- [3] Museo Nacional de Arqueología, Antropología e Historia del Perú, *Los Tesoros del Museo: Colección Lítica*. Lima, Perú: Ministerio de Cultura del Perú, 2015.
- [4] T. C. Dakal and S. S. Cameotra, “Microbially induced deterioration of architectural heritages: routes and mechanisms involved,” *Environmental Sciences Europe*, vol. 24, p. 36, 2012.
- [5] F. Villa, P. S. Stewart, I. Klapper, J. M. Jacob, and F. Cappitelli, “Subaerial biofilms on outdoor stone monuments: changing the perspective toward an ecological framework,” *BioScience*, vol. 66, no. 4, pp. 285–294, 2016.
- [6] D. G. Alonso-Reyes, F. S. Galván, N. N. Alvarado, M. C. D’Arpino, L. J. Martinez, H. J. Esquivel, C. A. Gallardo, M. J. Silva Manco, and V. H. Albarracín, “Echoes of 1816: microbial footprints in heritage artifacts from Argentina’s museum of independence,” *Frontiers in Microbiology*, vol. 16, p. 1611832, 2025.

- [7] P. J. A. Skipper, L. K. Skipper, and R. A. Dixon, “A metagenomic analysis of the bacterial microbiome of limestone, and the role of associated biofilms in the biodeterioration of heritage stone surfaces,” *Scientific Reports*, vol. 12, p. 4877, 2022.
- [8] T. Branyšová, K. Demnerová, M. Ďurovič, and H. Stiborová, “Microbial biodeterioration of cultural heritage and identification of the active agents over the last two decades,” *Journal of Cultural Heritage*, vol. 55, pp. 245–260, 2022.
- [9] M. A. Pita-Galeana, M. Ruhle, L. López-Vázquez, G. de Anda-Jáuregui, and E. Hernández-Lemus, “Computational metagenomics: state of the art,” *International Journal of Molecular Sciences*, vol. 26, no. 18, p. 9206, 2025.
- [10] P. Tsukayama Cisneros, S. Zurita Macalupú, R. Cristóbal Delgado, A. Ampuero León, Y. Piucón Campos, F. Caballero Salazar, P. Carrasco Zúñiga, and K. Lugo Bardales, “Informe técnico del análisis microbiológico de la Estela Raimondi,” Universidad Peruana Cayetano Heredia y Museo Nacional de Arqueología, Antropología e Historia del Perú (MNAAHP), Lima, Perú, Informe técnico interno Orden de Servicio N.º 0006172-2025, 2025.
- [11] F. Jroundi, K. Elert, E. Ruiz-Agudo, M. T. González-Muñoz, and C. Rodríguez-Navarro, “Bacterial diversity evolution in Maya plaster and stone following a bio-conservation treatment,” *Frontiers in Microbiology*, vol. 11, p. 599144, 2020.
- [12] K. Sterflinger and G. Piñar, “Microbial deterioration of cultural heritage and works of art — tilting at windmills?” *Applied Microbiology and Biotechnology*, vol. 97, no. 22, pp. 9637–9646, 2013.
- [13] F. Cappitelli, C. Cattò, and F. Villa, “The control of cultural heritage microbial deterioration,” *Microorganisms*, vol. 8, no. 10, p. 1542, 2020.

- [14] A. Chklovski, D. H. Parks, B. J. Woodcroft, and G. W. Tyson, “CheckM2: a rapid, scalable and accurate tool for assessing microbial genome quality using machine learning,” *Nature Methods*, vol. 20, no. 8, pp. 1203–1212, 2023.
- [15] P.-A. Chaumeil, A. J. Mussig, P. Hugenholtz, and D. H. Parks, “GTDB-Tk: a toolkit to classify genomes with the Genome Taxonomy Database,” *Bioinformatics*, vol. 36, no. 6, pp. 1925–1927, 2020.
- [16] H. Suchy, P. Zalar, and M. F. Macedo, “Microbial diversity of biodeteriorated limestone cultural heritage assets identified using molecular approaches—A literature review,” *Applied Sciences*, vol. 14, p. 7429, 2024.
- [17] Q. Li, B. Zhang, X. Yang, and Q. Ge, “Deterioration-associated microbiome of stone monuments: structure, variation, and assembly,” *Applied and Environmental Microbiology*, vol. 84, no. 7, pp. e02680–17, 2018.
- [18] B. Gutarowska, S. Celikkol-Aydin, V. Bonifay, A. Otlewska, E. Aydin, A. L. Oldham, J. I. Brauer, K. E. Duncan, J. Adamiak, J. A. Sunner, and I. B. Beech, “Metabolomic and high-throughput sequencing analysis—modern approach for the assessment of biodeterioration of materials from historic buildings,” *Frontiers in Microbiology*, vol. 6, p. 979, 2015.
- [19] E. Zanardini, E. May, K. J. Purdy, and J. C. Murrell, “Nutrient cycling potential within microbial communities on culturally important stoneworks,” *Environmental Microbiology Reports*, vol. 11, no. 2, pp. 147–154, 2019.
- [20] A. A. Gorbushina, “Life on the rocks,” *Environmental Microbiology*, vol. 9, no. 10, pp. 2418–2425, 2007.
- [21] G. Chimienti, R. Piredda, G. Pepe, I. D. van der Werf, L. Sabbatini, C. Crecchio, P. Ricciuti, A. M. D’Erchia, C. Manzari, G. Pesole *et al.*, “Profile of microbial communities on carbonate stones of the medieval church of San Leonardo di

- Siponto (Italy) by Illumina-based deep sequencing,” *Applied Microbiology and Biotechnology*, vol. 100, no. 19, pp. 8537–8548, 2016.
- [22] X. Ding, W. Lan, J. Wu, Y. Hong, Y. Li, Q. Ge, C. Urzì, Y. Katayama, and J.-D. Gu, “Microbiome and nitrate removal processes by microorganisms on the ancient Preah Vihear temple of cambodia revealed by metagenomics and N-15 isotope analyses,” *Applied Microbiology and Biotechnology*, vol. 104, no. 22, pp. 9823–9837, 2020.
- [23] X. Ding, W. Lan, and J.-D. Gu, “A review on sampling techniques and analytical methods for microbiota of cultural properties and historical architecture,” *Applied Sciences*, vol. 10, no. 22, p. 8099, 2020.
- [24] E. Gallego-Cartagena, H. Morillas, and M. Maguregui, “Biodeterioration of built heritage in the context of climate change and atmospheric pollution: Toward transdisciplinary conservation strategies,” *Science of The Total Environment*, vol. 1013, p. 181313, 2026.
- [25] S. Yadav and D. Purchase, “Biodeterioration of cultural heritage monuments: A review of their deterioration mechanisms and conservation,” *International Biodeterioration & Biodegradation*, vol. 201, p. 106066, 2025.
- [26] H.-C. Flemming and J. Wingender, “The biofilm matrix,” *Nature Reviews Microbiology*, vol. 8, no. 9, pp. 623–633, 2010.
- [27] M. Y. Galperin, N. Yutin, Y. I. Wolf, R. Vera Alvarez, and E. V. Koonin, “Conservation and evolution of the sporulation gene set in diverse members of the Firmicutes,” *Journal of Bacteriology*, vol. 204, no. 6, pp. e00 079–22, 2022.
- [28] D. Li, C.-M. Liu, R. Luo, K. Sadakane, and T.-W. Lam, “MEGAHIT: An ultra-fast single-node solution for large and complex metagenomics assembly via succinct de Bruijn graph,” *Bioinformatics*, vol. 31, no. 10, pp. 1674–1676, 2015.

- [29] S. Nurk, D. Meleshko, A. Korobeynikov, and P. A. Pevzner, “metaSPAdes: a new versatile metagenomic assembler,” *Genome Research*, vol. 27, no. 5, pp. 824–834, 2017.
- [30] R. M. Bowers, N. C. Kyrpides, R. Stepanauskas, M. Harmon-Smith, D. Doud, T. B. K. Reddy, F. Schulz, J. Jarett, A. R. Rivers, E. A. Elie-Fadrosh *et al.*, “Minimum information about a single amplified genome (MISAG) and a metagenome-assembled genome (MIMAG) of bacteria and archaea,” *Nature Biotechnology*, vol. 35, no. 8, pp. 725–731, 2017.
- [31] D. D. Kang, F. Li, E. Kirton, A. Thomas, R. S. Egan, H. An, and Z. Wang, “MetaBAT 2: an adaptive binning algorithm for robust and efficient genome reconstruction from metagenome assemblies,” *PeerJ*, vol. 7, p. e7359, 2019.
- [32] C. M. K. Sieber, A. J. Probst, A. Sharrar, B. C. Thomas, M. Hess, S. G. Tringe, and J. F. Banfield, “Recovery of genomes from metagenomes via a dereplication, aggregation and scoring strategy,” *Nature Microbiology*, vol. 3, no. 7, pp. 836–843, 2018.
- [33] A. M. Eren, Ö. C. Esen, C. Quince, J. H. Vineis, H. G. Morrison, M. L. Sogin, and T. O. Delmont, “Anvi’o: an advanced analysis and visualization platform for ’omics data,” *PeerJ*, vol. 3, p. e1319, 2015.
- [34] M. Shaffer, M. A. Borton, B. B. McGivern, A. A. Zayed, S. L. La Rosa, L. M. Solden, P. Liu, A. B. Narrowe, J. Rodríguez-Ramos, B. Bolduc *et al.*, “DRAM for distilling microbial metabolism to automate the curation of microbiome function,” *Nucleic Acids Research*, vol. 48, no. 16, pp. 8883–8900, 2020.
- [35] G. Tonkin-Hill, N. MacAlasdair, C. Ruis, A. Weimann, G. Horesh, J. A. Lees, N. J. Croucher, R. Carter, D. M. Aanensen, S. D. Bentley *et al.*, “Producing polished prokaryotic pangenomes with the Panaroo pipeline,” *Genome Biology*, vol. 21, no. 1, p. 180, 2020.

- [36] D. H. Parks, M. Imelfort, C. T. Skennerton, P. Hugenholtz, and G. W. Tyson, “CheckM: assessing the quality of microbial genomes recovered from isolates, single cells, and metagenomes,” *Genome Research*, vol. 25, no. 7, pp. 1043–1055, 2015.
- [37] C. Jain, L. M. Rodriguez-R, A. M. Phillippy, K. T. Konstantinidis, and S. Aluru, “High throughput ANI analysis of 90k prokaryotic genomes reveals clear species boundaries,” *Nature Communications*, vol. 9, p. 5114, 2018.
- [38] D. H. Parks, M. Chuvochina, C. Rinke, A. J. Mussig, P.-A. Chaumeil, and P. Hugenholtz, “GTDB: an ongoing census of bacterial and archaeal diversity through a phylogenetically consistent, rank normalized and complete genome-based taxonomy,” *Nucleic Acids Research*, vol. 50, no. D1, pp. D785–D794, 2022.
- [39] M. R. Olm, C. T. Brown, B. Brooks, and J. F. Banfield, “drep: a tool for fast and accurate genomic comparisons that enables improved genome recovery from metagenomes through de-replication,” *The ISME Journal*, vol. 11, no. 12, pp. 2864–2868, 2017.
- [40] B. Q. Minh, H. A. Schmidt, O. Chernomor, D. Schrempf, M. D. Woodhams, A. von Haeseler, and R. Lanfear, “Iq-tree 2: New models and efficient methods for phylogenetic inference in the genomic era,” *Molecular Biology and Evolution*, vol. 37, no. 5, pp. 1530–1534, 2020.
- [41] S. Kalyaanamoorthy, B. Q. Minh, T. K. F. Wong, A. von Haeseler, and L. S. Jermin, “ModelFinder: fast model selection for accurate phylogenetic estimates,” *Nature Methods*, vol. 14, no. 6, pp. 587–589, 2017.
- [42] D. T. Hoang, O. Chernomor, A. von Haeseler, B. Q. Minh, and L. S. Vinh, “UFBoot2: improving the ultrafast bootstrap approximation,” *Molecular Biology and Evolution*, vol. 35, no. 2, pp. 518–522, 2018.

- [43] H. Tettelin, V. Massignani, M. J. Cieslewicz, C. Donati, D. Medini, N. L. Ward, S. V. Angiuoli, J. Crabtree, A. L. Jones, A. S. Durkin *et al.*, “Genome analysis of multiple pathogenic isolates of *Streptococcus agalactiae*: implications for the microbial “pan-genome”,” *Proceedings of the National Academy of Sciences*, vol. 102, no. 39, pp. 13 950–13 955, 2005.
- [44] A. J. Page, C. A. Cummins, M. Hunt, V. K. Wong, S. Reuter, M. T. G. Holden, M. Fookes, D. Falush, J. A. Keane, and J. Parkhill, “Roary: rapid large-scale prokaryote pan genome analysis,” *Bioinformatics*, vol. 31, no. 22, pp. 3691–3693, 2015.
- [45] S. M. Soucy, J. Huang, and J. P. Gogarten, “Horizontal gene transfer: building the web of life,” *Nature Reviews Microbiology*, vol. 13, no. 8, pp. 490–503, 2015.
- [46] G. Gautreau, A. Bazin, M. Gachet, R. Planel, L. Burlot, M. Dubois, A. Perrin, C. Médigue, A. Calteau, S. Cruveiller *et al.*, “PPanGGOLiN: Depicting microbial diversity via a partitioned pangenome graph,” *PLOS Computational Biology*, vol. 16, no. 3, p. e1007732, 2020.
- [47] D. Hyatt, G.-L. Chen, P. F. Locascio, M. L. Land, F. W. Larimer, and L. J. Hauser, “Prodigal: prokaryotic gene recognition and translation initiation site identification,” *BMC Bioinformatics*, vol. 11, p. 119, 2010.
- [48] T. Seemann, “Prokka: rapid prokaryotic genome annotation,” *Bioinformatics*, vol. 30, no. 14, pp. 2068–2069, 2014.
- [49] O. Schwengers, L. Jelonek, M. A. Dieckmann, S. Beyvers, J. Blom, and A. Goessmann, “Bakta: rapid and standardized annotation of bacterial genomes via alignment-free sequence identification,” *Microbial Genomics*, vol. 7, no. 11, p. 000685, 2021.

- [50] M. Kanehisa, M. Furumichi, Y. Sato, M. Kawashima, and M. Ishiguro-Watanabe, “KEGG for taxonomy-based analysis of pathways and genomes,” *Nucleic Acids Research*, vol. 51, no. D1, pp. D587–D592, 2023.
- [51] B. L. Cantarel, P. M. Coutinho, C. Rancurel, T. Bernard, V. Lombard, and B. Henrissat, “The carbohydrate-active enzymes database (CAZy): an expert resource for glycogenomics,” *Nucleic Acids Research*, vol. 37, no. Supplement 1, pp. D233–D238, 2009.
- [52] H. Zhang, T. Yohe, L. Huang, S. Entwistle, P. Wu, Z. Yang, P. K. Busk, Y. Xu, and Y. Yin, “dbCAN2: a meta server for automated carbohydrate-active enzyme annotation,” *Nucleic Acids Research*, vol. 46, no. W1, pp. W95–W101, 2018.
- [53] B. P. Alcock, A. R. Raphenya, T. T. Y. Lau, K. K. Tsang, M. Bouchard, A. Edalatmand, W. Huynh, A.-L. V. Nguyen, A. A. Cheng, S. Liu, S. Y. Min, A. Miroshnichenko, H.-K. Tran, R. E. Werfalli, J. A. Nasir, M. Oloni, D. J. Speicher, A. Florescu, B. Singh, M. Faltyn, A. Hernandez-Koutoucheva, A. N. Sharma, E. Bordeleau, A. C. Pawlowski, H. L. Zubyk, D. Dooley, E. Griffiths, F. Maguire, G. L. Winsor, R. G. Beiko, F. S. L. Brinkman, W. W. L. Hsiao, G. V. Domselaar, and A. G. McArthur, “CARD 2020: antibiotic resistance surveillance with the Comprehensive Antibiotic Resistance Database,” *Nucleic Acids Research*, vol. 48, no. D1, pp. D517–D525, 2020.
- [54] M. Karlicki, S. Antonowicz, and A. Karnkowska, “Tiara: deep learning-based classification system for eukaryotic sequences,” *Bioinformatics*, vol. 38, no. 2, pp. 344–350, 2022.
- [55] L. J. U. Pronk and M. H. Medema, “Whokaryote: distinguishing eukaryotic and prokaryotic contigs in metagenomes based on gene structure,” *Microbial Genomics*, vol. 8, no. 5, p. mgen000823, 2022.

- [56] P. T. West, A. J. Probst, I. V. Grigoriev, B. C. Thomas, and J. F. Banfield, “Genome-reconstruction for eukaryotes from complex natural microbial communities,” *Genome Research*, vol. 28, no. 4, pp. 569–580, 2018.
- [57] A. Basile, F. P. Riggio, M. Tescari, A. Chebbi, A. Sodo, F. Bartoli, F. Imperi, G. Caneva, and P. Visca, “Metagenome-resolved functional traits of *Rubrobacter* species implicated in rosy discoloration of ancient frescoes in two Georgian cathedrals,” *Science of the Total Environment*, vol. 958, p. 178135, 2025.
- [58] A. Guerra, “The pangenome: a statistical model, not a fixed biological property,” *Bioinformatics Advances*, vol. 6, no. 1, p. vbag069, 2026.

ANEXOS

ANEXO ABET ING 1 - Resolución de problemas

Para filtrar por dominio los MAGs obtenidos se evaluaron las siguientes herramientas:

Tiara: Es una herramienta de clasificación de secuencias metagenómicas basada en *deep learning* que permite separar contigs en categorías como arqueas, bacterias, procariotas, eucariotas, orgánulos y secuencias desconocidas mediante un esquema de dos etapas [54]. Según su publicación original, mostró un rendimiento similar a EukRep para la clasificación de secuencias procariotas, pero superior para secuencias eucariotas, además de requerir menor tiempo de cómputo [54]. Su principal ventaja es que no solo discrimina entre eucariotas y procariotas, sino que también puede identificar ADN organelar, lo que la hace especialmente útil en metagenomas complejos. Sin embargo, al basarse principalmente en patrones de composición de secuencia, puede presentar ambigüedad en linajes evolutivamente inusuales o muy cercanos a eucariotas, por lo que sus resultados deben interpretarse como una clasificación preliminar y no como una asignación taxonómica definitiva.

Whokaryote: Es un clasificador diseñado para distinguir contigs eucariotas y procariotas a partir de características de estructura génica, como la densidad génica, la distancia intergénica y la longitud de los genes, utilizando un modelo de *random*

forest [55]. A diferencia de Tiara y EukRep, que dependen sobre todo de frecuencias de *k-mers*, Whokaryote se apoya en diferencias biológicas más interpretables entre ambos dominios. En su artículo, los autores reportan una exactitud cercana al 97 %, indicando además que su desempeño es comparable al de Tiara y EukRep, con la ventaja adicional de aportar una validación independiente basada en otro tipo de señal [55]. Su principal fortaleza es precisamente esa complementariedad metodológica, ya que puede ayudar a confirmar o cuestionar clasificaciones obtenidas por herramientas basadas en composición. Como desventaja, depende de rasgos derivados de genes predichos, por lo que su ejecución es menos directa y puede ser más sensible a la calidad del ensamblado y de la predicción génica subyacente.

EukRep: Es una de las herramientas pioneras para separar secuencias eucariotas de procariotas en ensamblados metagenómicos, utilizando frecuencias de *k-mers* y un clasificador lineal tipo SVM [56]. Su objetivo principal es servir como filtro inicial para recuperar secuencias eucariotas y permitir después el uso de *pipelines* de anotación y análisis específicos para eucariotas. En su publicación original, mostró una exactitud global cercana al 90 % con fragmentos de 3 kb y de aproximadamente 98 % con fragmentos de 20 kb, lo que evidencia un mejor rendimiento en contigs largos [56]. Su ventaja principal es que se trata de una herramienta ampliamente reconocida y adoptada en estudios de recuperación de genomas eucariotas a partir de metagenomas. No obstante, sus limitaciones incluyen un menor desempeño relativo frente a Tiara en la clasificación de eucariotas y la ausencia de una clasificación explícita de secuencias organelares, además de que su precisión puede disminuir en fragmentos más cortos o en ensamblados altamente fragmentados.

ANEXO ABET ING 5 - Trabajo en equipo

En este anexo se presenta la evidencia del trabajo colaborativo desarrollado durante la ejecución del proyecto. Se podrán incluir reuniones de coordinación, distribución de tareas, seguimiento de avances y productos elaborados en conjunto.




FIGURA 7.8: Diagrama de Gantt del trabajo en equipo durante el desarrollo del proyecto.

ANEXO ABET ING 6 — Experimentación




FIGURA 7.9: Flujograma del marco metodológico: cuatro fases consecutivas (OE1 a OE4) desde el origen de los datos metagenómicos hasta la caracterización del potencial metabólico y de riesgo.

ANEXO ABET ING 7 — Aprendizaje continuo

TABLA 7.10: Aprendizaje continuo: fuentes consultadas, contenido aprendido y su aplicación en el documento.

Ref.	Información o contenido aprendido	Aplicación (en el documento)
[4], [17], [21], [22]	Mecanismos de biodeterioro microbiano de la roca: acidólisis y quelación iónica por ácidos orgánicos de bajo peso molecular, y producción de ácidos nítrico y sulfúrico por bacterias de los ciclos del nitrógeno y del azufre que corroen los minerales. Fundamenta por qué ciertos genes metabólicos implican riesgo material.	Marco Teórico 2.1; Estado del arte; Marco Metodológico
[5], [9], [23], [26]	Marco ecológico de las biopelículas subaéreas en piedra, arquitectura de la matriz de EPS y rol dual biodeterioro/bioprotección, que motiva pasar de la identidad taxonómica al repertorio funcional.	Formulación del problema; Marco Teórico 2.2; Justificación
[9], [30]	Flujo de la metagenómica <i>shotgun</i> : ensamblaje <i>de novo</i> por grafos de De Bruijn y <i>binning</i> por composición de tetranucleótidos y cobertura diferencial para reconstruir MAGs.	Formulación del problema; Marco Teórico 2.3; Marco Metodológico
[14], [30], [36]	Definición de completitud y contaminación mediante genes marcadores de copia única; categorías de calidad MIMAG; estimación por aprendizaje automático (CheckM2) sin asignación taxonómica previa.	Marco Teórico 2.4; Marco Metodológico 4.1.3

Tabla 7.10 – continuación

Ref.	Información o contenido aprendido	Aplicación
[15], [37], [38], [39]	Clasificación genómica normalizada por divergencia evolutiva (GTDB-Tk/GTDB), delimitación de especie por ANI (umbral del 95 %) y sdereplicación para colapsar genomas redundantes y definir linajes.	Marco Teórico 2.5; Marco Metodológico 4.1.4
[35], [43]	Concepto de pangenoma y partición en genoma núcleo, cubierta y accesorio; la transferencia horizontal como motor de adaptación; corrección de la inflación del accesorio por fragmentación mediante grafos (Panaroo).	Marco Teórico 2.6; Marco Metodológico 4.1.5
[34], [47], [49]	Predicción de ORFs y anotación estandarizada sin alineamiento (Bakta); destilación del metabolismo y cálculo de completitud de módulos/rutas (DRAM) sobre ortólogos KEGG, base para inferir el potencial de biodeterioro.	Marco Teórico 2.7; Marco Metodológico 4.1.6
[54], [55], [56]	Clasificadores de contigs por dominio: aprendizaje profundo sobre composición (Tiara), estructura génica con <i>random forest</i> (Whokaryote) y <i>k-mers</i> con SVM (EukRep); criterios para seleccionar la herramienta de filtrado.	Marco Metodológico 4.1.3.1; Anexo 1
[1], [2], [3]	Contexto histórico-arqueológico de la Estela de Raimondi: filiación con la cultura Chavín, hallazgo, traslados sucesivos y custodia museística actual.	Introducción (Presentación del proyecto)

7.5 Anexo: Repositorio de GitHub

Link: [GitHub](#)

7.6 Anexo: Reporte completo de calidad y selección de bins (Fase 1)

TABLA 7.11: Reporte completo de evaluación y filtrado de bins genómicos (Fase 1).

Bin	Contigs	Long (bp)	Dom.	Comp. (%)	Contam. (%)	Motivo
bin-1-49	87	545.053	euk	–	–	dominio mayoritario: euk
bin-1-50	224	2.609.893	prok	62.29	2.66	completitud $62.29 \leq 70$
bin-1-51	51	4.727.435	prok	100.00	0.00	-
bin-1-52	26	415.732	prok	6.05	0.20	completitud $6.05 \leq 70$
bin-1-53	30	2.476.631	prok	99.84	0.12	-
bin-1-54	49	4.312.038	prok	92.25	0.01	-
bin-1-55	247	34.242.081	euk	–	–	dominio mayoritario: euk
bin-1-56	12	230.366	euk	–	–	dominio mayoritario: euk

Continúa en la siguiente página...

Tabla 7.11 – Continuación de la página anterior

Bin	Contigs	Long (bp)	Dom.	Comp. (%)	Contam. (%)	Motivo
bin-1-57	22	4.032.412	prok	99.99	3.23	-
bin-1-58	4725	12.125.594	unknown	0.00	17.71	completitud $0.00 \leq 70$; contamina- cion $17.71 \geq 5$
bin-1-59	98	5.907.869	prok	99.97	3.07	-
bin-1-60	302	8.273.570	prok	100.00	24.87	contaminacion $24.87 \geq 5$
bin-1-61	448	40.131.343	euk	–	–	dominio mayoritario: euk
bin-1-62	320	7.390.811	prok	99.72	72.67	contaminacion $72.67 \geq 5$
bin-1-63	162	65.185.746	prok	84.85	39.63	contaminacion $39.63 \geq 5$
bin-1-64	163	3.944.265	prok	99.84	0.59	-
bin-1-65	322	29.636.962	euk	–	–	dominio mayoritario: euk
bin-1-68	50	2.465.224	prok	100.00	1.79	-
bin-1-69	67	251.086	prok	6.60	0.14	completitud $6.60 \leq 70$

Continúa en la siguiente página...

Tabla 7.11 – Continuación de la página anterior

Bin	Contigs	Long (bp)	Dom.	Comp. (%)	Contam. (%)	Motivo
bin-1-70	3805	494.251.631	unknown	31.70	28.68	completitud $31.70 \leq 70$; contamina- cion $28.68 \geq 5$
bin-1-71	37	11.498.934	prok	67.71	15.05	completitud $67.71 \leq 70$; contamina- cion $15.05 \geq 5$
bin-1-72	16	7.408.652	unknown	5.87	0.19	completitud $5.87 \leq 70$
bin-10-71	506	2.845.557	prok	97.57	30.13	contaminacion $30.13 \geq 5$
bin-11-71	4161	101.946.556	unknown	65.68	17.72	completitud $65.68 \leq 70$; contamina- cion $17.72 \geq 5$
bin-12-71	383	1.015.904	unknown	43.42	3.52	completitud $43.42 \leq 70$
bin-2-49	134	27.557.437	euk	–	–	dominio mayoritario: euk

Continúa en la siguiente página...

Tabla 7.11 – Continuación de la página anterior

Bin	Contigs	Long (bp)	Dom.	Comp. (%)	Contam. (%)	Motivo
bin-2-50	464	53.406.620	euk	–	–	dominio mayoritario: euk
bin-2-52	270	5.347.688	prok	99.93	8.10	contaminacion $8.10 \geq 5$
bin-2-53	39	5.164.804	prok	99.99	0.57	-
bin-2-54	106	7.273.841	prok	100.00	15.52	contaminacion $15.52 \geq 5$
bin-2-56	816	49.647.189	euk	–	–	dominio mayoritario: euk
bin-2-57	28	5.172.263	prok	99.96	1.01	-
bin-2-58	17	4.771.531	prok	100.00	0.06	-
bin-2-59	424	23.212.147	prok	91.94	115.89	contaminacion $115.89 \geq 5$
bin-2-60	290	10.390.751	prok	100.00	100.33	contaminacion $100.33 \geq 5$
bin-2-61	9	614.253	euk	–	–	dominio mayoritario: euk

Continúa en la siguiente página...

Tabla 7.11 – Continuación de la página anterior

Bin	Contigs	Long (bp)	Dom.	Comp. (%)	Contam. (%)	Motivo
bin-2-62	5	227.679	euk	–	–	dominio mayoritario: euk
bin-2-63	150	4.282.638	prok	92.39	0.34	-
bin-2-64	924	226.083.286	unknown	0.02	16.03	completitud $0.02 \leq 70$; contamina- cion $16.03 \geq 5$
bin-2-65	141	17.056.380	euk	–	–	dominio mayoritario: euk
bin-2-68	70	246.182	prok	4.99	0.03	completitud $4.99 \leq 70$
bin-2-69	61	2.481.071	prok	99.99	0.18	-
bin-2-70	87	278.635	unknown	5.38	0.09	completitud $5.38 \leq 70$
bin-2-71	618	1.368.774	unknown	56.83	26.01	completitud $56.83 \leq 70$; contamina- cion $26.01 \geq 5$
bin-2-72	667	2.485.725	prok	79.16	54.30	contaminacion $54.30 \geq 5$

Continúa en la siguiente página...

Tabla 7.11 – Continuación de la página anterior

Bin	Contigs	Long (bp)	Dom.	Comp. (%)	Contam. (%)	Motivo
bin-3-50	30	2.607.902	unknown	13.03	0.08	completitud $13.03 \leq 70$
bin-3-52	204	5.184.467	prok	98.97	0.58	-
bin-3-53	301	29.244.092	euk	–	–	dominio mayoritario: euk
bin-3-56	160	26.628.065	euk	–	–	dominio mayoritario: euk
bin-3-57	818	25.745.728	euk	–	–	dominio mayoritario: euk
bin-3-58	265	29.647.785	euk	–	–	dominio mayoritario: euk
bin-3-60	959	2.321.293	unknown	39.27	0.00	completitud $39.27 \leq 70$
bin-3-61	50	10.715.439	euk	–	–	dominio mayoritario: euk
bin-3-62	117	449.659	euk	–	–	dominio mayoritario: euk

Continúa en la siguiente página...

Tabla 7.11 – Continuación de la página anterior

Bin	Contigs	Long (bp)	Dom.	Comp. (%)	Contam. (%)	Motivo
bin-3-63	4589	19.740.558	prok	99.91	102.18	contaminacion $102.18 \geq 5$
bin-3-64	459	2.352.198	prok	70.14	0.64	-
bin-3-65	5256	27.711.612	euk	–	–	dominio mayoritario: euk
bin-3-70	169	64.261.799	unknown	77.48	75.48	contaminacion $75.48 \geq 5$
bin-3-71	3657	12.324.162	prok	97.39	70.70	contaminacion $70.70 \geq 5$
bin-3-72	174	16.597.747	prok	98.53	98.35	contaminacion $98.35 \geq 5$
bin-4-50	97	1.654.013	prok	43.00	0.23	completitud $43.00 \leq 70$
bin-4-52	96	3.497.259	prok	99.86	0.25	-
bin-4-56	122	1.739.035	euk	–	–	dominio mayoritario: euk
bin-4-57	977	39.075.173	euk	–	–	dominio mayoritario: euk

Continúa en la siguiente página...

Tabla 7.11 – Continuación de la página anterior

Bin	Contigs	Long (bp)	Dom.	Comp. (%)	Contam. (%)	Motivo
bin-4-60	4482	25.724.799	euk	–	–	dominio mayoritario: euk
bin-4-61	1610	11.012.084	prok	100.00	58.51	contaminacion $58.51 \geq 5$
bin-4-62	270	79.759.046	prok	90.25	65.70	contaminacion $65.70 \geq 5$
bin-4-63	856	56.508.797	euk	–	–	dominio mayoritario: euk
bin-4-64	428	29.693.972	euk	–	–	dominio mayoritario: euk
bin-4-65	2506	20.150.702	prok	99.99	106.28	contaminacion $106.28 \geq 5$
bin-4-70	484	1.565.460	prok	64.00	2.55	completitud $64.00 \leq 70$
bin-4-71	216	488.562	unknown	32.24	2.32	completitud $32.24 \leq 70$
bin-4-72	72	248.801	prok	4.69	0.01	completitud $4.69 \leq 70$
bin-5-50	1041	3.472.002	prok	76.56	0.44	-

Continúa en la siguiente página...

Tabla 7.11 – Continuación de la página anterior

Bin	Contigs	Long (bp)	Dom.	Comp. (%)	Contam. (%)	Motivo
bin-5-52	1099	3.740.736	prok	95.51	12.95	contaminacion $12.95 \geq 5$
bin-5-56	146	552.204	euk	–	–	dominio mayoritario: euk
bin-5-57	12	224.138	euk	–	–	dominio mayoritario: euk
bin-5-60	97	2.849.856	prok	77.53	0.10	-
bin-5-61	273	5.811.268	prok	97.82	10.64	contaminacion $10.64 \geq 5$
bin-5-62	222	27.886.446	euk	–	–	dominio mayoritario: euk
bin-5-63	90	2.758.939	prok	72.46	0.05	-
bin-5-64	217	39.450.268	prok	100.00	67.99	contaminacion $67.99 \geq 5$
bin-5-65	24	222.213	euk	–	–	dominio mayoritario: euk
bin-5-70	28	2.628.283	unknown	48.48	2.40	completitud $48.48 \leq 70$

Continúa en la siguiente página...

Tabla 7.11 – Continuación de la página anterior

Bin	Contigs	Long (bp)	Dom.	Comp. (%)	Contam. (%)	Motivo
bin-5-71	118	438.388	prok	12.74	0.54	completitud $12.74 \leq 70$
bin-6-50	591	5.543.214	prok	100.00	0.65	-
bin-6-56	116	9.578.458	euk	–	–	dominio mayoritario: euk
bin-6-57	126	448.524	euk	–	–	dominio mayoritario: euk
bin-6-61	30	4.792.746	prok	100.00	0.74	-
bin-6-63	21	367.167	euk	–	–	dominio mayoritario: euk
bin-6-64	71	239.057	euk	–	–	dominio mayoritario: euk
bin-6-70	319	48.190.971	unknown	68.24	17.99	completitud $68.24 \leq 70$; contamina- cion $17.99 \geq 5$
bin-6-71	34	453.921	prok	11.79	0.16	completitud $11.79 \leq 70$

Continúa en la siguiente página...

Tabla 7.11 – Continuación de la página anterior

Bin	Contigs	Long (bp)	Dom.	Comp. (%)	Contam. (%)	Motivo
bin-7-64	1246	3.769.741	prok	60.17	0.22	completitud $60.17 \leq 70$
bin-7-71	95	258.968	unknown	7.21	0.05	completitud $7.21 \leq 70$
bin-8-71	908	2.450.575	unknown	81.92	35.87	contaminacion $35.87 \geq 5$
bin-9-71	346	1.832.072	prok	85.09	2.13	-