UNIVERSIDAD DE INGENIERÍA Y TECNOLOGÍA

CARRERA DE BIOINGENIERÍA



Diseño de un modelo predictivo de riesgo de deterioro de la Estela de Raimondi basado en genómica comparativa y potencial metabólico

PROYECTO FINAL DE CARRERA

AUTOR(ES)

Eduardo Esteban Tello Osorio

Ana Sofía Barrientos Uriarte

ASESOR(ES)

Pablo Tsukayama Cisneros

Monica Cecilia Santa María Fuster

Harry Gustavo Saavedra Espinoza

Lima - Perú

2026

TABLA DE CONTENIDO

Pág.

RESUMEN 1
ABSTRACT 2

CAPÍTULO I INTRODUCCIÓN **3**
Presentación del proyecto 3
Descripción de la situación problemática 3
Formulación del problema 4
Objetivos del proyecto 5
Objetivo general 5
Objetivos específicos 5
Justificación 6
Alcance y limitaciones 7

CAPÍTULO II ESTADO DEL ARTE **8**
2.1 Soluciones precedentes 8
2.1.1 Protocolos basados en cultivo microbiológico (método tradicional) 8
2.1.2 Tratamientos y limpieza con biocidas químicos 10
2.2 Análisis comparativo de tecnologías actuales 10
2.3 Insuficiencia tecnológica 12

CAPÍTULO III MARCO TEÓRICO **14**
3.1 Biodeterioro microbiano en sustratos graníticos 14

3.2 Biopelículas subaéreas en patrimonio pétreo 15
3.3 Metagenómica *shotgun* y ensamblaje de genomas metagenómicos (MAGs) 16
3.4 Evaluación de calidad genómica 17
3.5 Posicionamiento filogenómico y ANI 18
3.5.1 La jerarquía taxonómica 21
3.6 Análisis pangenómico comparativo 22
3.7 Anotación funcional y predicción del potencial metabólico 23
3.8 Limitaciones de la inferencia funcional basada en datos genómicos 25

CAPÍTULO IV MARCO REFERENCIAL 26

4.1 Estándares bioinformáticos 26
4.2 Restricciones realistas del proyecto 27

CAPÍTULO V MARCO METODOLÓGICO 30

5.1 Metodología 30
5.1.1 Diseño general y criterios de decisión metodológica 30
5.1.2 Origen de los datos y unidad de análisis 30
5.1.3 Fase 1. Control de calidad y selección de genomas (OE1) 32
5.1.3.1 Filtrado por dominio 32
5.1.3.2 Evaluación de la calidad genómica 34
5.1.4 Fase 2. Asignación taxonómica y definición de linajes (OE2) 35
5.1.4.1 Clasificación taxonómica genómica 35
5.1.4.2 Confirmación de especie por ANI 35
5.1.4.3 Desreplicación y definición de linajes 36
5.1.4.4 Confirmación filogenómica 37
5.1.4.5 Selección de linajes para el análisis comparativo . . . 38
5.1.5 Fase 3. Análisis pangenómico comparativo (OE3) 39
5.1.5.1 Recopilación de genomas de referencia 39
5.1.5.2 Anotación estructural y funcional consistente 39

5.1.5.3 Reconstrucción del pangenoma 40
5.1.5.4 Identificación de genes candidatos exclusivos de la Estela 42
5.1.6 Fase 4. Caracterización del potencial metabólico y del riesgo (OE4) . . . 42
5.1.6.1 Anotación funcional del potencial metabólico 42
5.1.6.2 Definición de marcadores de riesgo y supervivencia . 43
5.1.6.3 Integración del potencial funcional con la estructura del pangenoma 44
5.1.7 Reproducibilidad 45

CAPÍTULO VI DISEÑO TECNOLÓGICO 48

6.1 Cálculo de los parámetros y dimensionamiento de los componentes 48
6.1.1 Bases de diseño: el conjunto de datos de entrada 48
6.1.2 Parámetros operativos del diseño 50
6.1.3 Dimensionamiento del cómputo 51
6.1.4 Dimensionamiento del almacenamiento 53
6.2 Selección de materiales, componentes y equipos de la solución 54
6.2.1 Versiones de software y compatibilidad 54
6.2.2 Bases de datos como insumo de referencia 55
6.2.3 Entorno de ejecución y plataforma de cómputo 56
6.3 Integración e implementación de los componentes en la solución final . . . 57
6.3.1 Organización del sistema en programas 57
6.3.2 Normalización de la entrada y trazabilidad 57
6.3.3 Encadenamiento entre etapas 58
6.3.4 Implementación de la verificación de genes específicos 59
6.3.5 Implementación de los scripts de ejecución 60
6.3.6 Control de versiones 61
6.4 Representación gráfica de la solución y su verificación 61
6.4.1 Diagrama de flujo del sistema 62

6.4.2 Arquitectura de cómputo 66
6.4.3 Verificación de la correspondencia entre el diagrama y la implementación 67

CAPÍTULO VII PRUEBAS Y RESULTADOS 68

7.1 Plan de pruebas de la solución 68
7.1.1 Caso base 68
7.1.2 Variables medidas y escenarios de sensibilidad 69
7.2 Análisis de los resultados de las pruebas 69
7.2.1 Resultados de la Fase 1: control de calidad y selección de genomas (OE1) 69
7.2.2 Resultados de la Fase 2: asignación taxonómica y definición de linajes (OE2) 71
7.2.3 Resultados de la Fase 3: análisis pangenómico comparativo (OE3) 74
7.2.3.1 Selección de especies y de referencias 74
7.2.3.2 Pangenoma de cada especie 75
7.2.3.3 Posición de cada bin en su especie 76
7.2.3.4 Contenido accesorio, parentesco y hábitat 78
7.2.3.5 Genes específicos de la cepa 79
7.2.3.6 Implicancia para el OE3 80
7.2.4 Sensibilidad de los resultados a los umbrales elegidos 81
7.2.5 Iteraciones de diseño derivadas de los resultados 81
7.3 Verificación del cumplimiento de las especificaciones técnicas 82
7.4 Verificación del cumplimiento de restricciones 83
ANEXOS 97
Resolución de problemas 97
Trabajo en equipo 99
Experimentación 100
Aprendizaje continuo 101
7.5 Anexo: Repositorio de GitHub 103
7.6 Anexo: Programas y archivos del sistema 103

7.7 Anexo: Extractos de código 106
7.8 Anexo: Calidad y selección de bins (Fase 1) 109
7.9 Anexo: Figuras complementarias de la Fase 2 121
7.10 Anexo: Resultados complementarios de la Fase 3 124
7.11 Anexo: Análisis de sensibilidad 132
7.12 Anexo: Iteraciones de diseño 137

ÍNDICE DE TABLAS

Tabla 3.1 Categorías de calidad MIMAG para MAGs bacterianos y arqueales [30]. 18

Tabla 4.1 Matriz de restricciones realistas del proyecto y su impacto en las decisiones de diseño metodológico. 28

Tabla 5.1 Bins genómicos recuperados por muestra (previos al filtrado por dominio y calidad). 33

Tabla 5.2 Matriz de selección de software para la clasificación de contigs. 34

Tabla 5.3 Matriz de selección de software para la confirmación filogenómica. 37

Tabla 5.4 Matriz de selección de software para la anotación estructural y funcional. 40

Tabla 5.5 Matriz de selección de software para la reconstrucción del pangenoma. 41

Tabla 5.6 Marcadores genómicos *a priori* de biodeterioro, supervivencia y contexto, con la regla de presencia de cada función. 46

Tabla 6.1 Bases de diseño del conjunto de entrada 49

Tabla 6.2 Parámetros operativos implementados 50

Tabla 6.3 Dimensionamiento de cómputo por etapa 52

Tabla 6.4 Dimensionamiento del almacenamiento 53

Tabla 6.5 Versiones de software seleccionadas 54

Tabla 6.6 Insumos de referencia del sistema 55

Tabla 6.7 Implementación de los filtros de genes específicos 59

Tabla 7.1 Linajes de la Fase 2 y genomas públicos disponibles 73
Tabla 7.2 Tamaño y partición del pangenoma 75
Tabla 7.3 Posición de cada bin en su especie 77
Tabla 7.4 Embudo de genes específicos de la cepa 79
Tabla 7.5 Matriz de verificación de especificaciones técnicas 82
Tabla 7.6 Matriz de verificación de restricciones 83
Tabla 7.7 Aprendizaje continuo: fuentes consultadas, contenido aprendido y su aplicación en el documento. 101
Tabla 7.8 Programas que componen el sistema 103
Tabla 7.9 Archivos que encadenan las etapas 105
Tabla 7.10 Archivos que encadenan la Fase 3 105
Tabla 7.11 Reporte completo de evaluación y filtrado de bins genómicos (Fase 1). 111
Tabla 7.12 Árboles del genoma core 129
Tabla 7.13 Escenarios de sensibilidad 132
Tabla 7.14 Sensibilidad a los umbrales de calidad 134
Tabla 7.15 Sensibilidad del criterio de dominio 135
Tabla 7.16 Sensibilidad al umbral de desreplicación 136
Tabla 7.17 Sensibilidad al modo de limpieza de Panaroo 137
Tabla 7.18 Iteraciones de diseño 137
Tabla 7.19 Diferencias entre el diseño original y la ejecución de la Fase 3 . 139

ÍNDICE DE FIGURAS

Figura 5.1 Esquema de muestreo de la Estela de Raimondi. Se señalan los 20 puntos de hisopado distribuidos sobre las cinco regiones del monumento (base superior, cara frontal, laterales izquierda y derecha, y sección inferior). En cada punto se recolectaron dos hisopados independientes: el hisopo A, destinado a la extracción directa de ADN para secuenciación de amplicones, y el hisopo B, destinado al cultivo de la fracción viable, posteriormente secuenciado por metagenómica *shotgun*. Tomado del informe técnico de la UPCH [10]. 31

Figura 6.1 Diagrama de flujo del sistema 63

Figura 6.2 Diagrama de flujo de la Fase 3 65

Figura 6.3 Arquitectura de cómputo del sistema 66

Figura 7.1 Embudo de selección de genomas 70

Figura 7.2 Evaluación de novedad taxonómica 72

Figura 7.3 Diagrama de Gantt del trabajo en equipo durante el desarrollo del proyecto. 99

Figura 7.4 Flujograma del marco metodológico: cuatro fases consecutivas (OE1 a OE4) desde el origen de los datos metagenómicos hasta la caracterización del potencial metabólico y de riesgo. 100

Figura 7.5 Calidad y métricas de ensamblaje 110

Figura 7.6 Composición taxonómica 121

Figura 7.7 Árbol filogenómico de los 21 genomas 122

Figura 7.8 Matriz de similitud genómica 123
Figura 7.9 Prevalencia espacial de los linajes 124
Figura 7.10 Curvas de acumulación del pangenoma 125
Figura 7.11 Diagnóstico de la apertura del pangenoma 127
Figura 7.12 Posición de cada bin en el pangenoma 128
Figura 7.13 Árboles del genoma core de las tres especies 130
Figura 7.14 ANI de cada bin y coherencia con el árbol 131

RESUMEN

El patrimonio pétreo está expuesto al biodeterioro microbiano, proceso mediante el cual las comunidades que colonizan la roca disuelven su matriz mineral y alteran su superficie. La Estela de Raimondi, litoescultura de granito de la cultura Chavín bajo custodia museística, presenta biopelículas y alteraciones cromáticas cuya evaluación previa se limitó a la identificación taxonómica, sin esclarecer la capacidad de deterioro de los organismos vivos que la habitan. El objetivo de este proyecto fue diseñar un flujo de análisis computacional para caracterizar el potencial de biodeterioro y las señales de adaptación genómica de los linajes bacterianos dominantes de la fracción viable del monumento, con el fin de sustentar la evaluación del riesgo y una conservación preventiva basada en evidencia genómica. Se partió de datos de secuenciación metagenómica masiva obtenidos de la fracción cultivable de la superficie, sobre los que se estructuró un flujo reproducible que integró el control de calidad genómica, la clasificación taxonómica basada en el genoma completo, la agrupación de genomas redundantes en linajes, la reconstrucción pangenómica comparativa frente a referencias globales y la anotación funcional del potencial metabólico.

Palabras clave:

Biodeterioro; Patrimonio pétreo; Metagenómica; Pangenoma; Potencial metabólico; Conservación preventiva; Estela de Raimondi

ABSTRACT

Stone heritage is exposed to microbial biodeterioration, a process by which the communities colonizing the rock dissolve its mineral matrix and alter its surface. The Raimondi Stela, a granite lithosculpture of the Chavín culture held in a national museum, exhibits biofilms and chromatic alterations whose prior assessment was limited to taxonomic identification, without clarifying the deterioration capacity of the living organisms inhabiting it. The objective of this project was to design a computational analysis workflow to characterize the biodeterioration potential and the genomic adaptation signals of the dominant bacterial lineages of the monument's viable fraction, in order to support risk assessment and genomics-based preventive conservation. High-throughput metagenomic sequencing data obtained from the cultivable surface fraction were used as the starting point, upon which a reproducible workflow was structured, integrating genomic quality control, whole-genome-based taxonomic classification, the grouping of redundant genomes into lineages, comparative pangenomic reconstruction against global references, and functional annotation of metabolic potential.

Keywords:

Biodeterioration; Stone heritage; Metagenomics; Pangenome; Metabolic potential; Preventive conservation; Raimondi Stela

CAPÍTULO I

INTRODUCCIÓN

Presentación del proyecto

La Estela de Raimondi es una de las piezas más importantes de la cultura Chavín (Horizonte Temprano, 1200 a.C. - 400 a.C.) y un pilar de la arqueología andina. Elaborada en granito pulido, esta litoescultura de casi dos metros de altura representa a una divinidad antropomorfa, el "Dios de los Báculos", caracterizada por una compleja iconografía que integra rasgos de felinos, aves de rapiña y serpientes [1]. Tras su hallazgo a mediados del siglo XIX, inicialmente por el agricultor Timoteo Espinoza en 1840 y su posterior reconocimiento valórico por Antonio Raimondi en 1860 en el Templo Nuevo de Chavín de Huántar, la Estela ha sido objeto de múltiples traslados y, por consiguiente, daños, desde su uso doméstico en Áncash hasta su actual custodia en el Museo Nacional de Arqueología, Antropología e Historia del Perú (MNAAHP) [2].

El presente proyecto de tesis surge de la necesidad de aplicar herramientas de genómica avanzada y bioinformática para entender la ecología microbiana que habita este monumento, integrando el análisis del pangenoma de linajes bacterianos para identificar poblaciones propias de la región, así como para predecir riesgos de deterioro en elementos arqueológicos.

Descripción de la situación problemática

A pesar de encontrarse en un ambiente controlado de museo, la Estela de

Raimondi no es inmune al paso del tiempo ni a la interacción con agentes biológicos. Históricamente, la pieza ha sufrido daños físicos, incluyendo fracturas por el terremoto de 1940 [3]. Sin embargo, informes técnicos recientes han identificado la presencia de biopelículas y alteraciones cromáticas en la superficie del granito.

Las piedras arqueológicas, como la caliza, el granito o la toba volcánica, son altamente susceptibles al daño causado por comunidades microbianas, incluyendo bacterias, cianobacterias, algas y hongos. Los microorganismos penetran los poros y fisuras de la piedra mediante hifas fúngicas o forman biopelículas [4]. Estas comunidades pueden inducir biocorrosión mediante la secreción de ácidos orgánicos que disuelven la matriz mineral o generar pigmentos que alteran irreparablemente la estética del monumento [4, 5]. Sin embargo, se ha demostrado que las biopelículas subaéreas tienen un rol dual, pues mientras algunas causan deterioro, otras pueden actuar como una capa bioprotectora que regula la humedad térmica, consolida la superficie y protege a la piedra de los contaminantes atmosféricos [5, 6].

El problema reside en que las estrategias tradicionales de conservación suelen ser reactivas y basadas en identificación taxonómica básica, ignorando el potencial metabólico real, las poblaciones favorables y las capacidades adaptativas de las bacterias que dominan la biopelícula.

Formulación del problema

Si bien estudios previos sobre la Estela de Raimondi permitieron caracterizar la diversidad taxonómica de su microbioma mediante secuenciación de amplicones (16S rRNA e ITS2) a partir de ADN ambiental, esta aproximación presenta limitaciones importantes para evaluar su papel en el biodeterioro del monumento. Por un lado, el ADN ambiental no permite distinguir entre microorganismos metabólicamente activos, latentes o muertos, ni diferenciar a los verdaderos colonizadores

del sustrato de aquellos microorganismos depositados pasivamente desde el ambiente [7, 8]. Por otro lado, la secuenciación de amplicones ofrece información sobre la identidad taxonómica de la comunidad microbiana, pero no permite determinar su potencial metabólico ni las capacidades adaptativas de las poblaciones presentes [9].

Frente a ello, la presente tesis se concentra en la fracción viable del microbioma, es decir, en aquellos microorganismos capaces de crecer en cultivo y, por tanto, confirmados como vivos. A partir de esta fracción se realizó secuenciación metagenómica *shotgun* [10]. Mediante el ensamblaje de genomas metagenómicos (MAGs) y el análisis comparativo de sus genes accesorios frente a referencias globales, se busca caracterizar el potencial metabólico y las señales de adaptación evolutiva de los linajes bacterianos dominantes en el sustrato lítico. Esta aproximación permite identificar biomarcadores genómicos asociados a la producción de ácidos y a la formación de biopelículas, aportando parámetros técnicos para la evaluación del riesgo de biodeterioro y el diseño de protocolos de conservación preventiva basados en evidencia genómica.

Objetivos del proyecto

Objetivo general

Diseñar un modelo predictivo para determinar el potencial metabólico y la evolución genómica de los linajes bacterianos dominantes en la Estela de Raimondi mediante análisis de pangenoma y potencial metabólico.

Objetivos específicos

1. Seleccionar los MAGs con mayor integridad ($> 70\,\%$) y baja contaminación ($< 5\,\%$).

2. Determinar la posición filogenómica de los MAGs seleccionados mediante el cálculo de ANI (Identidad Nucleotídica Promedio) y filogenia frente a bases de datos internacionales como NCBI y GTDB.

3. Definir el genoma core y el genoma accesorio de los linajes dominantes de la fracción viable de la Estela frente a genomas de referencia globales, identificando genes exclusivos, es decir, específicos de la Estela.

4. Mapear las rutas metabólicas de supervivencia, como la esporulación, y de deterioro, como la formación de biopelículas y la producción de ácidos, analizando si los genes responsables se encuentran en el genoma accesorio, es decir, si fueron adquiridos por adaptación al monumento.

Justificación

El presente trabajo surge de la necesidad de transitar de una caracterización taxonómica convencional hacia un análisis de resolución genómica. En el contexto de la conservación del patrimonio en Latinoamérica, los estudios microbiológicos suelen detenerse en la descripción de géneros, dejando sin respuesta la interrogante sobre qué mecanismos biológicos específicos están siendo ejecutados activamente en la superficie del monumento [5, 6]. El uso de bioinformática avanzada para la reconstrucción de MAGs y el análisis pangenómico permitirá identificar si los determinantes de biodeterioro, como la síntesis de ácidos orgánicos o la formación de biopelículas, son rasgos intrínsecos de los linajes o adaptaciones adquiridas para la supervivencia en el monumento [7, 11]. Este estudio no solo posiciona el análisis del patrimonio cultural peruano a la vanguardia tecnológica regional, sino que provee una base científica para predecir riesgos y optimizar estrategias de conservación preventiva menos invasivas.

Alcance y limitaciones

El alcance de esta tesis es de naturaleza estrictamente computacional y descriptiva, basándose en el análisis de datos metagenómicos previamente secuenciados de la Estela de Raimondi por la Universidad Peruana Cayetano Heredia (Laboratorio de Genómica Microbiana). El estudio se centrará exclusivamente en los linajes bacterianos dominantes que presenten métricas de calidad genómica adecuadas para un análisis pangenómico robusto.

Entre las limitaciones, se debe precisar que la caracterización describe la fracción del microbioma recuperable mediante cultivo, que corresponde a un subconjunto de la comunidad viable y no necesariamente a la totalidad de las poblaciones dominantes *in situ* [8, 12]. A cambio, garantiza que los genomas analizados provienen de organismos vivos, condición necesaria para atribuirles un rol activo en el biodeterioro. Asimismo, al no contar con datos de metatranscriptómica (RNA-seq), la caracterización funcional representa el potencial metabólico y no la actividad biológica real en el momento de la toma de muestra [13]. Además, la integridad y el grado de contaminación de los MAGs están intrínsecamente ligados a la profundidad de la secuenciación original y a la complejidad de la biopelícula colonizadora [5, 14]. Por otro lado, la potencia del análisis pangenómico está sujeta a la disponibilidad y representatividad de genomas de referencia de alta calidad en bases de datos globales como NCBI o GTDB [15]. Finalmente, factores abióticos externos, como las fluctuaciones de humedad y temperatura en el museo, solo se utilizarán como marco contextual para interpretar las estrategias de supervivencia microbiana.

CAPÍTULO II

ESTADO DEL ARTE

A lo largo del tiempo, la evaluación del biodeterioro en monumentos arqueológicos e históricos ha pasado por distintas etapas tecnológicas, donde cada método presentó limitaciones operativas y alcances técnicos que influyeron en la evolución del área. En este contexto, el propósito de este capítulo es revisar de manera crítica las soluciones analíticas y de intervención desarrolladas tanto en el ámbito académico como industrial, estableciendo un marco comparativo basado en parámetros de rendimiento, cobertura y viabilidad técnica. Esto permitirá comprender las fortalezas y limitaciones de los enfoques previos, así como justificar el desarrollo y la adopción de aproximaciones diagnósticas contemporáneas.

2.1 Soluciones precedentes

2.1.1 Protocolos basados en cultivo microbiológico (método tradicional)

Durante décadas, el estudio de los ecosistemas microbianos en el patrimonio pétreo dependió casi exclusivamente de técnicas dependientes de cultivo. Las muestras extraídas del sustrato se sembraban en medios de laboratorio generales, como Agar Nutritivo, MEA o PDA, frecuentemente suplementados con antibióticos o cicloheximida para la selección de grupos específicos [8]. Este enfoque permitió aislar e identificar morfológicamente a numerosos taxa bacterianos y fúngicos asociados al biodeterioro.

No obstante, esta metodología introduce sesgos selectivos, siendo su principal limitación la estructural: se estima que aproximadamente el 99 % de los microorganismos ambientales son ”viables pero no cultivables”(VBNC) en condiciones de laboratorio estándar, dado que los medios artificiales no replican las condiciones oligotróficas, de estrés hídrico y radiación UV características de las superficies pétreas [8, 12, 16]. En contraste con las tecnologías moleculares modernas, los métodos de cultivo solo logran detectar entre el 1 % y el 5 % de la comunidad microbiana total [17]. Un estudio ilustrativo realizado en el campo de concentración de Auschwitz demostró que el cultivo detectó apenas 8 géneros bacterianos, mientras que la secuenciación NGS reveló 99 géneros en el mismo material [18]. Adicionalmente, los medios de cultivo imponen concentraciones artificialmente elevadas de nutrientes, lo que favorece a microorganismos heterótrofos de rápido crecimiento que pueden no ser los colonizadores dominantes ni los principales agentes de deterioro in situ [8, 19].

Ahora bien, esta misma selectividad adquiere valor metodológico cuando el objetivo no es inventariar la comunidad total, sino identificar a los organismos con capacidad real de deterioro. A diferencia del ADN ambiental, que persiste en el sustrato tras la muerte celular y no distingue entre células activas y muertas [8], el crecimiento en cultivo constituye una prueba directa de viabilidad: todo microorganismo aislado está, por definición, vivo. Por ello, la secuenciación metagenómica aplicada sobre la fracción cultivada permite acoplar la certeza de viabilidad con la resolución genómica, estrategia adoptada en la presente tesis [10]. La contrapartida, que se mantiene explícita, es que dicha fracción representa únicamente el subconjunto cultivable de la comunidad viable, por lo que sus conclusiones no se extienden a los linajes que no crecen en los medios empleados.

2.1.2 Tratamientos y limpieza con biocidas químicos

Para el control del biodeterioro, la práctica conservativa tradicional recurrió históricamente a sustancias antimicrobianas de síntesis química: alcoholes, fenoles, aldehídos, compuestos de amonio cuaternario (como el cloruro de benzalconio), sales de estaño, derivados de isotiazolinonas y tratamientos de fumigación con óxido de etileno [12, 13]. Estas estrategias presentan ventajas a corto plazo en términos de reducción de biomasa visible, pero exhiben graves inconvenientes a mediano y largo plazo.

En primer lugar, la eficacia del biocida es frecuentemente transitoria y requiere reaplicaciones periódicas [13]. En segundo lugar, generan toxicidad tanto para los operadores humanos como para el ecosistema circundante [13]. Desde el punto de vista material, los biocidas oxidantes pueden inducir manchas por herrumbre y eflorescencias sobre la piedra, mientras que las soluciones de limpieza ácida o alcalina comprometen la integridad mineralógica del sustrato [13]. Finalmente, y de mayor relevancia para la gestión del biodeterioro a largo plazo, los biocidas eliminan el microbioma natural sin remover la biomasa celular residual, la cual actúa como sustrato nutritivo que acelera la recolonización. Bajo la presión selectiva del biocida, las comunidades que recolonizan son frecuentemente resistentes al tratamiento y presentan perfiles metabólicos más agresivos, involucrando tanto a cepas bacterianas resistentes como a una mayor presencia de hongos altamente melanizados [13, 20]. Este efecto fue documentado de forma notable tras los tratamientos masivos realizados en las cuevas de Lascaux y en la tumba de San Pablo en Éfeso [12].

2.2 Análisis comparativo de tecnologías actuales

La introducción de las tecnologías de secuenciación de próxima generación (NGS) como Illumina MiSeq, NovaSeq, PacBio y Oxford Nanopore, redefinió los

estándares del análisis del microbioma del patrimonio pétro. En la práctica contemporánea, coexisten diversos enfoques que compiten en términos de rendimiento de datos, costos operativos y viabilidad de estandarización.

La secuenciación de amplicones de genes marcadores evolutivamente conservados, como las regiones hipervariables V3-V6 del gen 16S rRNA (para bacterias y arqueas) y las regiones ITS1/ITS2 (para hongos), permite la identificación filogenética de alta resolución sin necesidad de cultivo previo [16, 21].

La metagenómica de escopeta (shotgun metagenomics) secuencia la totalidad del material genético presente en la muestra, superando el sesgo de la amplificación específica por PCR y revelando no solo qué organismos están presentes, sino que permite determinar potencialmente qué rutas metabólicas y genes funcionales contiene la comunidad [16, 22]. Estudios previos demostraron que la secuenciación de amplicones permite detectar una diversidad microbiana significativamente superior a la obtenida mediante métodos clásicos y, en combinación con herramientas bioinformáticas predictivas, inferir el potencial funcional del microbioma en monumentos pétreos [17, 21].

Cabe precisar que la metagenómica *shotgun* puede aplicarse tanto sobre ADN extraído directamente del ambiente como sobre material previamente enriquecido por cultivo; en el segundo caso, la comunidad se acota a su fracción viable a cambio de un ADN de mayor calidad y trazabilidad, un compromiso relevante en muestras de baja biomasa como las superficies pétreas [10, 23].

En términos comparativos con los métodos tradicionales, la NGS supera significativamente al cultivo en cobertura taxonómica, sensibilidad y representatividad de la comunidad real [12, 16, 18]. No obstante, su coste por muestra es considerablemente más elevado, requiere equipamiento especializado, genera grandes volúmenes de datos que demandan análisis bioinformáticos complejos, y presenta limitaciones

propias: artefactos genéticos generados durante la amplificación por PCR (secuencias quiméricas), resolución taxonómica que frecuentemente no alcanza el nivel de especie, y dificultades de extracción de ADN en estructuras resistentes como las endosporas de Bacillus spp. [7, 8, 17].

En la frontera tecnológica se ubican la metatranscriptómica y la metabolómica ambiental, diseñadas para resolver el perfil funcional dinámico del microbioma in situ [13, 18]. La metatranscriptómica ofrece la medición directa de los transcritos de ARN activos al momento del muestreo, discriminando con precisión entre células muertas, en estado viable pero no cultivable (VBNC) o metabólicamente activas [8]. Sin embargo, la secuenciación de ARN ambiental en el patrimonio pétreo se encuentra aún en una etapa inicial y carece de estandarización operativa; esto se debe en gran medida a la inestabilidad de la molécula y a que los costos de este análisis molecular siguen siendo demasiado altos en relación con los recursos habituales disponibles para los laboratorios de restauración [12, 16]. Por su parte, la metabolómica acoplada a espectrometría de masas (UPLC/HRMS) permite identificar los productos reales del catabolismo (como los ácidos orgánicos implicados en la disolución mineral), pero se enfrenta a la limitación de utilizar bases de datos de referencia ambiental incompletas que generan un volumen considerable de falsos positivos, situando los resultados en un nivel de identificación que requiere precaución y validación adicional [18].

2.3 Insuficiencia tecnológica

A pesar de los importantes avances moleculares, las soluciones actuales presentan vacíos estructurales al ser incapaces de confirmar si el potencial genético detectado se traduce en una actividad de deterioro real in situ, ya que el ADN perdura tras la muerte celular y disocia el inventario microbiano del daño activo [8, 13, 22]. Además, existe una carencia crítica de metodologías estandarizadas y

cuantitativas que permitan relacionar el perfil metabólico con el riesgo material [13], lo que impide diferenciar empíricamente si una biopelícula ejerce un rol de degradación o de bioprotección sobre la piedra [13]. En este contexto, se ha subrayado la necesidad de transitar desde diagnósticos descriptivos y centrados en el material hacia marcos predictivos basados en la función microbiana [24]; sin embargo, estas propuestas permanecen mayoritariamente en un plano conceptual, con énfasis en sustratos calcáreos y sin una implementación operativa que permita particionar el repertorio génico de los linajes colonizadores ni distinguir los rasgos de deterioro intrínsecos de aquellos adquiridos por adaptación al nicho. Por consiguiente, establecer una causalidad directa entre microorganismos específicos y el daño observado sigue siendo un reto profundo debido a las barreras económicas, logísticas y metodológicas para integrar datos multiómicos y petrofísicos [8, 18], lo que evidencia la necesidad urgente de desarrollar plataformas diagnósticas integrales que vinculen la taxonomía con la actividad metabólica activa y el impacto real sobre el sustrato [13].

CAPÍTULO III

MARCO TEÓRICO

3.1 Biodeterioro microbiano en sustratos graníticos

El granito es una roca ígnea intrusiva de textura fanerítica compuesta principalmente por cuarzo (SiO_2), feldespatos potásicos ($KAlSi_3O_8$), plagioclasas ($NaAlSi_3O_8$–$CaAl_2Si_2O_8$) y micas (biotita, moscovita) [3]. Esta composición lo hace susceptible a la biocorrosión química mediada por el microbioma colonizador, que actúa a través de dos mecanismos principales: la acidólisis y la quelatación iónica [4, 25]. En el primer mecanismo, bacterias heterótrofas y hongos secretan ácidos orgánicos de bajo peso molecular, incluyendo ácido oxálico, cítrico, glucónico, láctico y 2-cetoglucónico, que reducen el pH local del microambiente de la biopelícula y disuelven activamente los feldespatos y silicatos de la matriz mineral [18, 25]. En el segundo, estos mismos ácidos actúan como agentes quelantes que secuestran cationes estructurales esenciales (Fe^{2+}, Al^{3+}, Mg^{2+}, Ca^{2+}) de la red cristalina, debilitando la cohesión mineral [25]. Géneros bacterianos como *Bacillus*, *Arthrobacter* y *Streptomyces* han sido identificados como productores de ácido 2-cetoglucónico, un quelante altamente eficiente de la sílice presente en monumentos graníticos [18].

Adicionalmente, bacterias quimiolitoautotróficas del ciclo del nitrógeno (*Nitrosomonas*, *Nitrospira*) y del azufre (*Thiobacillus*, *Sulfurimonas*) producen ácido nítrico y sulfúrico como subproductos metabólicos, que corroen directamente los minerales carbonatados y silicatados de la roca [4, 16, 23]. A nivel físico, las hifas fúngicas ejercen

presión mecánica de turgencia que les permite penetrar microporos y fisuras en proceso casmolítico y criptoendolítico, ampliando progresivamente el sistema de poros del granito y facilitando la entrada de agua [20, 25].

3.2 Biopelículas subaéreas en patrimonio pétreo

Las biopelículas subaéreas (SABs, *Subaerial Biofilms*) constituyen la forma dominante de vida microbiana en superficies líticas expuestas a la atmósfera [5]. Su formación sigue un proceso secuencial regulado molecularmente: (1) adhesión reversible mediada por fuerzas de Van der Waals y electrostáticas; (2) adhesión irreversible mediante proteínas de adhesión de superficie, pili tipo IV y fimbrias; (3) maduración con producción de sustancias poliméricas extracelulares (EPS); y (4) dispersión de células al entorno [26]. La matriz de EPS, que puede representar más del 90 % del volumen de la biopelícula madura, es producida por operones específicos como *epsA-O* en *Bacillus subtilis*, los clusters *pel* y *psl* en *Pseudomonas aeruginosa*, y el operón *csgA* responsable de la síntesis de fibras de curli en enterobacterias [26]. Esta matriz actúa como una esponja biológica que retiene agua, captura nutrientes orgánicos del aire y protege a las células de la desecación y los biocidas [13, 26].

En el contexto del patrimonio pétreo, Villa et al. [5] proponen un marco ecológico fundamental para este proyecto: las biopelículas subaéreas tienen un rol dual. Por un lado, pueden inducir biodeterioro activo mediante la producción de ácidos, pigmentos y presión mecánica; por el otro, pueden actuar como capa de bioprotección que amortigua las fluctuaciones térmicas e hídricas, consolida la superficie y limita la disolución química al entrar en contacto con agua de lluvia o condensación [5, 13]. Esta dualidad funcional implica que la sola identificación taxonómica de microorganismos es insuficiente para determinar el riesgo real de deterioro; es necesaria la caracterización del repertorio funcional, específicamente de los genes

accesorios, para discernir qué mecanismos se encuentran genómicamente codificados en cada linaje [7, 13].

Las estrategias de supervivencia en el nicho oligotrófico del granito incluyen la esporulación (operón *spo0A*/*spoIIA* /*spoIIE* en Firmicutes, altamente prevalentes en ambientes líticos), la melanización en hongos meristemáticos negros (*Ochroconis*, *Coniosporium*) como escudo contra estrés oxidativo y radiación UV, y la síntesis de carotenoides en arqueas y bacterias halotolerantes como *Rubrobacter* spp. [6–8, 12, 19, 27]. Estos rasgos de supervivencia constituyen los biomarcadores genómicos de mayor relevancia para el modelo predictivo de riesgo.

3.3 Metagenómica *shotgun* y ensamblaje de genomas metagenómicos (MAGs)

La metagenómica *shotgun* permite el acceso directo al material genómico total de una comunidad microbiana sin necesidad de cultivo previo, superando el sesgo de cultivabilidad que limita los estudios clásicos al 1–5 % de la diversidad real [7, 9, 17]. En este enfoque, el ADN extraído de la muestra ambiental se fragmenta y secuencia masivamente, generando millones de lecturas cortas (*reads*) que representan fragmentos aleatorios de todos los genomas presentes en la comunidad [8, 9].

El proceso de reconstrucción de MAGs sigue tres etapas principales: ensamblaje, binning y refinamiento. En la etapa de ensamblaje, los *reads* se ensamblan *de novo* en contigs mediante ensambladores basados en grafos de De Bruijn, como MEGAHIT [28] o SPAdes [29], que fragmentan las lecturas en *k-mers* y reconstruyen las secuencias por solapamiento. En la etapa de *binning*, los contigs se agrupan en MAGs candidatos mediante dos señales complementarias: la composición nucleotídica (frecuencia de tetra-nucleótidos, un vector de 256 dimensiones) y el perfil de cobertura diferencial (razón de *reads* alineados sobre longitud del contig a lo largo de

múltiples muestras) [9, 30]. La premisa biológica es que contigs del mismo organismo tendrán firmas de composición y coberturas similares. MetaBAT 2 [31] modela esta relación con una distribución de probabilidad Gaussiana, mientras que DAS Tool [32] integra las predicciones de múltiples *binners* para maximizar el número de MAGs de alta calidad por muestra. El refinamiento manual mediante Anvi'o [30, 33] permite inspeccionar visualmente la coherencia de cada *bin* y eliminar contaminantes.

Esta aproximación supera directamente la limitación del 16S rRNA *amplicon* identificada en la formulación del problema de la tesis: mientras la secuenciación de amplicones provee información taxonómica a nivel de género o especie, los MAGs reconstruyen el genoma completo potencial de cada linaje, habilitando el análisis pangenómico y la predicción del potencial metabólico [9, 34, 35].

3.4 Evaluación de calidad genómica

La calidad de un MAG se define por dos métricas fundamentales: completitud y contaminación [30]. La completitud refleja qué fracción del genoma real ha sido capturada en el MAG; la contaminación indica la proporción de contigs provenientes de organismos distintos al organismo *target*.

Ambas métricas se estiman contando los genes marcadores de copia única (SCGs, *Single-Copy Genes*): genes que evolucionaron para existir exactamente en copia única en >97 % de todos los procariotas. Un SCG ausente sugiere incompletitud; un SCG presente en múltiples copias sugiere contaminación por contigs de otro organismo [30, 36].

$$\text{Completitud} = \frac{\text{SCGs detectados}}{\text{SCGs esperados para el linaje}} \times 100\,\% \tag{III.1}$$

$$\text{Contaminación} = \frac{\text{SCGs redundantes}}{\text{SCGs esperados}} \times 100\,\% \tag{III.2}$$

CheckM2 [14] moderniza este cálculo mediante modelos de *machine learning* (*gradient boosting* y redes neuronales) entrenados sobre cientos de miles de genomas sintéticos simulados a partir de referencias de alta calidad. A diferencia de su predecesor, no requiere asignación taxonómica previa y es más preciso en linajes divergentes como Patescibacteria o el superphylum CPR [14].

El estándar internacional MIMAG [30] establece tres categorías, resumidas en la tabla 3.1: (a) alta calidad (HQ): completitud ≥90 %, contaminación <5 %, ARNr 16S completo; (b) calidad media (MQ): 50–90 % completitud, <10 % contaminación; (c) baja calidad: <50 %. El criterio del OE1 (>70 %, <5 %) se posiciona como un umbral intermedio conservador, apropiado para análisis pangenómicos que requieren representación mínima del *core genome* [14, 30].

Tabla 3.1: Categorías de calidad MIMAG para MAGs bacterianos y arqueales [30].

Categoría	**Completitud (%)**	**Contaminación (%)**	**Criterios adicionales**
Alta calidad (HQ)	≥ 90	< 5	ARNr + ≥ 18 ARNt
Media calidad (MQ)	≥ 50	< 10	—
Baja calidad (LQ)	< 50	Cualquiera	Solo referencial

3.5 Posicionamiento filogenómico y ANI

La identidad nucleotídica promedio (ANI, *Average Nucleotide Identity*) es la métrica estándar actual para la delimitación de especies procarióticas a nivel genómico, sustituyendo empíricamente a la hibridación ADN-ADN (DDH) con mayor reproducibilidad y escala computacional [37]. El ANI se calcula como el promedio ponderado de identidad de secuencia de todos los fragmentos ortólogos entre dos genomas:

$$\mathrm{ANI}(A,B) \;=\; \frac{\sum_{i} \mathrm{identity}(f_i^A, f_i^B) \times |f_i|}{\sum_{i} |f_i|} \tag{III.3}$$

donde f_i^A y f_i^B son fragmentos ortólogos de 3 kb. Un ANI $\geq$95 % (con fracción de alineamiento, AF $\geq$65 %) equivale a un DDH $\geq$70 %, el umbral convencional de especie [15, 37]. FastANI [37] implementa este cálculo mediante *locality-sensitive hashing* sobre *k-mers* (*sketching* de MinHash), permitiendo comparaciones a escala masiva.

El clasificador GTDB-Tk [15] ubica los MAGs en un árbol filogenómico de referencia usando 120 genes marcadores bacterianos (*bac120*) o 122 arqueales (*arc122*), colocando cada genoma en la taxonomía del *Genome Taxonomy Database* (GTDB) [38]. GTDB corrige las inconsistencias del NCBI normalizando los rangos taxonómicos por divergencia evolutiva relativa (RED, por sus siglas en inglés), siendo especialmente relevante para MAGs ambientales que con frecuencia representan linajes sin cultivos de referencia [15, 38].

Un problema adicional al de la sola delimitación taxonómica surge cuando se aplica el ANI a colecciones completas de MAGs recuperados por metagenómica *shotgun*: dado que el ensamblaje y el *binning* se realizan de forma independiente por muestra, un mismo linaje presente en varios puntos de muestreo puede recuperarse varias veces como genomas ligeramente distintos entre sí, debido a diferencias en la profundidad de secuenciación o en el proceso de ensamblaje de cada muestra. A este proceso de identificar y colapsar genomas redundantes se le conoce como *desreplicación*, y la herramienta estándar para realizarlo es dRep [39], que agrupa los genomas de una colección en clústeres según su ANI y selecciona, dentro de cada clúster, un único genoma representativo.

Internamente, dRep realiza esta comparación en dos pasos. Primero ejecuta una comparación rápida entre todos los genomas mediante *MinHash* (Mash), que agrupa genomas claramente similares en clústeres preliminares de forma poco costosa computacionalmente. Luego, dentro de cada clúster preliminar, calcula el ANI de forma precisa mediante ANIm o FastANI para confirmar la agrupación final. El genoma representativo de cada clúster se escoge según un *score* de calidad que pondera completitud, contaminación y contigüidad (N50), con criterios análogos a los de calidad descritos en la sección 2.4.

El umbral de ANI usado en el segundo paso define qué tan estricta es la agrupación: un umbral cercano al 95 % agrupa genomas de la misma especie, de forma consistente con el umbral de DDH descrito previamente, mientras que un umbral cercano al 99 % agrupa solo genomas de la misma cepa. Este último valor representa además el límite práctico de detección del método, ya que dos copias idénticas de un mismo genoma comparadas entre sí suelen rendir valores de ANI de aproximadamente 99.99 %, por lo que exigir una identidad mayor ya no aporta resolución real [37, 39]. De este modo, la desreplicación cumple dos funciones: elimina la redundancia técnica generada por el ensamblaje independiente de cada muestra, y define operativamente la unidad de análisis, el linaje, sobre la cual se construye posteriormente el pangenoma comparativo descrito en la siguiente sección.

IQ-TREE [40] es un programa de inferencia filogenética que reconstruye árboles mediante el criterio de máxima verosimilitud. Su algoritmo de búsqueda combina perturbaciones de tipo *nearest neighbor interchange* estocástico con una estrategia de hill-climbing eficiente, lo que le permite explorar un espacio amplio de topologías sin caer prematuramente en óptimos locales, un problema frecuente en métodos de búsqueda heurística más simples. Antes de la búsqueda del árbol, IQ-TREE incorpora ModelFinder [41], un procedimiento que evalúa de forma automática el ajuste estadístico de distintos modelos de sustitución de aminoácidos o nucleótidos sobre

el alineamiento de entrada y selecciona el más adecuado según criterios de información (AIC, BIC), evitando que el usuario deba fijar el modelo de forma arbitraria. El soporte estadístico de cada rama del árbol resultante se estima mediante el ultrafast bootstrap (UFBoot) [42], una aproximación computacionalmente eficiente al remuestreo bootstrap tradicional que aproxima de forma no sesgada los valores de soporte con un costo varios órdenes de magnitud menor, permitiendo ejecutar miles de réplicas en una fracción del tiempo que requeriría el bootstrap clásico de Felsenstein. Por estas características, IQ-TREE es ampliamente utilizado en filogenómica bacteriana para construir árboles focalizados a partir de alineamientos concatenados de genes marcadores, como los conjuntos bac120 y ar122 empleados por el GTDB [15], en escenarios donde se requiere no solo inferir la topología del árbol, sino cuantificar la confianza estadística de cada agrupamiento, como la monofilia de un linaje frente a sus genomas de referencia.

3.5.1 La jerarquía taxonómica

La clasificación taxonómica organiza a los organismos en diferentes niveles jerárquicos según sus características y relaciones evolutivas. El **filo** agrupa organismos que comparten características estructurales y evolutivas generales, mientras que la **clase** reúne grupos más específicos dentro de un mismo filo. El **orden** subdivide las clases de acuerdo con características adicionales compartidas entre los organismos, y la **familia** agrupa géneros que presentan una relación evolutiva cercana. El **género** reúne especies estrechamente relacionadas y constituye la primera parte del nombre científico de un organismo. Finalmente, la **especie** representa el nivel taxonómico más específico y permite identificar grupos de organismos con características genéticas y biológicas altamente similares. En conjunto, estos niveles siguen una jerarquía de mayor a menor amplitud: **filo** → **clase** → **orden** → **familia** → **género** → **especie**.

3.6 Análisis pangenómico comparativo

El pangenoma de una especie o linaje bacteriano representa el conjunto total de genes presentes en todos los miembros del grupo [43]. Introducido formalmente por Tettelin et al. [43] con una división inicial entre genes núcleo y accesorios, la genómica computacional moderna lo estructura algorítmicamente en tres compartimentos principales [35, 44]: (a) el ***core genome*** (G_c): genes presentes en $\geq$95 % de los genomas; codifican funciones esenciales conservadas (metabolismo central, replicación, traducción); (b) el ***shell genome***: genes en el 15–95 % de los genomas; representan adaptaciones frecuentes en el nicho; y (c) el ***cloud genome*** (o *dispensable*): genes presentes en <15 %; incluyen genes singulares (*singletons*) posiblemente adquiridos por HGT para nichos específicos.

Los genes accesorios son el producto directo de la transferencia horizontal de genes (HGT, *Horizontal Gene Transfer*): el mecanismo por el cual las bacterias adquieren genes de organismos filogenéticamente distantes mediante conjugación, transformación o transducción [45]. Este proceso permite la rápida adquisición de rasgos fenotípicos, incluyendo la capacidad de producir ácidos orgánicos o *biopelículas*, sin necesidad de mutaciones secuenciales, lo que lo convierte en el principal motor de adaptación ecológica en procariotas [45]. En este microambiente, la propia matriz de la *biopelícula* actúa como un reservorio de ADN extracelular que facilita y potencia estos eventos de transferencia génica [26]. Herramientas recientes como PPanGGOLiN [46] han introducido modelos estadísticos basados en grafos para particionar el pangenoma en sus componentes de manera probabilística. Sin embargo, en colecciones de MAGs, la fragmentación intrínseca de los ensamblajes sigue provocando una sobreestimación de genes accesorios. Para superar esta limitación, Panaroo [35] emplea una representación gráfica del pangenoma que corrige activamente los errores de anotación y ensamblaje mediante la propagación del contexto

genómico vecino, lo que reduce de manera drástica la inflación artificial del genoma accesorio debida a la fragmentación.

3.7 Anotación funcional y predicción del potencial metabólico

La anotación funcional de MAGs sigue un proceso jerárquico descrito en la metagenómica computacional [9], el cual inicia con la predicción de ORFs (*Open Reading Frames*) mediante algoritmos como Prodigal [47] (frecuentemente integrado en *pipelines* como Prokka [48]).

Bakta [49] constituye una evolución de este enfoque de anotación estructural y funcional. A diferencia de *pipelines* anteriores como Prokka, que dependen de alineamientos de secuencias contra bases de datos de referencia limitadas, Bakta incorpora un módulo de identificación de secuencias sin alineamiento (*alignment-free sequence identification*, AFSI), el cual calcula *hashes* MD5 a partir de secuencias proteicas completas para acelerar la asignación de homología. Al emplear una base de datos taxonómicamente independiente, esta característica resulta especialmente relevante para MAGs ambientales, donde la especie o el género del organismo colonizador con frecuencia pertenece a linajes raros o carece de representación cercana en las bases de datos curadas. Para las secuencias no identificadas por AFSI, Bakta integra fuentes complementarias como RefSeq y PSC (*Protein Sequence Clusters* derivados de UniRef90), así como modelos de covarianza de Rfam para ARN no codificante.

A continuación, se realiza una búsqueda de homología contra bases de datos de referencia y la posterior asignación a categorías funcionales, para culminar finalmente con la reconstrucción de rutas metabólicas [34].

Las principales bases de datos funcionales utilizadas en este tipo de análisis son:

- **KEGG Orthology (KO)** [50]: organiza genes en módulos metabólicos y rutas de señalización; la completitud de una ruta se calcula como la fracción de KOs esenciales detectados en el genoma.
- **COG** (*Clusters of Orthologous Groups*) [27]: categorías funcionales de alto nivel (metabolismo, transporte, regulación de transcripción).
- **dbCAN/CAZy** [51, 52]: enzimas activas sobre carbohidratos, relevantes para la degradación de EPS y polisacáridos de la biopelícula.
- **CARD** (*Comprehensive Antibiotic Resistance Database*) [53]: genes de resistencia antimicrobiana, útil para evaluar persistencia bajo tratamientos biocidas.

DRAM (*Distilled and Refined Annotation of Metabolism*) [34] integra estas bases de datos en un sistema de anotación que produce tablas de completitud por módulo metabólico y resúmenes de los principales ciclos biogeoquímicos (nitrógeno, azufre y carbono), así como del inventario de enzimas activas sobre carbohidratos (CAZymes) [34]. Esta herramienta es especialmente apropiada para el presente estudio dado que el mapeo de estas rutas metabólicas permite inferir el potencial de biodeterioro de la comunidad: los ciclos inorgánicos (N y S) están directamente vinculados a la disolución de minerales por acidólisis y biocorrosión [4, 19], mientras que la síntesis de polisacáridos se relaciona con la producción de EPS para la biopelícula. De este modo, la destilación metabólica se alinea perfectamente con la identificación de factores de riesgo exigida en los objetivos del OE4.

La completitud de una vía metabólica se expresa formalmente en la metodología de DRAM [34] como:

$$\text{Completitud}_{\text{vía}} = \frac{\text{módulos KO detectados}}{\text{módulos KO totales en la vía}} \times 100\,\% \tag{III.4}$$

Los biomarcadores genómicos de mayor relevancia para el modelo predictivo de riesgo ecológico incluyen: genes del ciclo TCA (*acnA*, *sdhA*, *fumA*) asociados a la producción de ácidos orgánicos biocorrosivos [13, 19]; la gluconato deshidrogenasa (*gcd*) responsable de la síntesis del ácido 2-cetoglucónico, un potente quelante de silicatos [18]; genes de biosíntesis de EPS (como el operón *pel*) cruciales para la arquitectura de la *biopelícula* [26]; y los operones de esporulación (con reguladores maestros como *spo0A*) como marcadores de persistencia y resistencia extrema [27].

3.8 Limitaciones de la inferencia funcional basada en datos genómicos

La caracterización del potencial metabólico mediante análisis genómico de MAGs representa una aproximación de alto poder inferencial, pero con una limitación intrínseca en ausencia de datos de metatranscriptómica. Dado que los MAGs analizados en esta tesis se recuperaron a partir de la fracción cultivable (hisopo B), los organismos representados demostraron ser metabólicamente viables al proliferar bajo las condiciones de cultivo empleadas; sin embargo, el propio cultivo constituye un filtro selectivo cuyas condiciones (medio, temperatura, tiempo de incubación) no reproducen el ambiente real del monumento (radiación UV, desecación, escasez de nutrientes). Por ello, la detección de un gen no garantiza que su función se exprese de la misma forma *in situ*, y los resultados de este proyecto describen el potencial metabólico codificado en los linajes colonizadores, no la actividad biológica real sobre la piedra, tal como se declara en el alcance de la tesis.

CAPÍTULO IV

MARCO REFERENCIAL

El presente marco referencial contextualiza el entorno operativo para el análisis genómico de la Estela de Raimondi, estableciendo las directrices, limitaciones y consideraciones éticas que fundamentan las decisiones metodológicas del proyecto. Para transitar de un simple inventario taxonómico a la caracterización del potencial metabólico mediante genomas metagenómicos (MAGs), el diseño del estudio asume compromisos técnicos (trade-offs) justificados a través de tres componentes críticos: los estándares de ingeniería bioinformática, las restricciones del entorno real y el análisis ético de la conservación patrimonial.

4.1 Estándares bioinformáticos

El flujo de trabajo para el ensamblaje, control de calidad y análisis comparativo de linajes bacterianos se rige por métricas consensuadas internacionalmente en genómica ambiental, las cuales garantizan la viabilidad técnica de las conclusiones:

- **Estándares MIMAG para la calidad de genomas:** De acuerdo a lo mencionado en el marco teórico, este umbral (>70 % completitud, <5 % contaminación) representa un *trade-off* de diseño, pues flexibiliza el rigor de completitud para maximizar la recuperación de genomas ambientales fragmentados, pero adopta la máxima restricción de contaminación ($< 5\,\%$) para asegurar que el análisis del genoma accesorio no se vea sesgado por la inclusión de ADN foráneo [30].

- **Estandarización taxonómica y genómica:** Para evitar ambigüedades en la clasificación de los MAGs, el diseño requiere el uso de bases de datos curadas y de alta resolución, como la base de datos GTDB (*Genome Taxonomy Database*) a través de herramientas como GTDB-Tk, la cual provee una asignación taxonómica objetiva basada en la divergencia evolutiva relativa y la Identidad Nucleotídica Promedio (ANI) [15]. Asimismo, el mapeo de rutas de esporulación y biodeterioro se enmarca en la capacidad de herramientas de destilación metabólica como DRAM, diseñadas para decodificar las contribuciones microbianas a los ciclos geoquímicos a partir de datos genómicos [34].

- **Requerimientos para el pangenoma:** La comparación genómica a nivel poblacional debe mitigar los errores inherentes a la anotación automatizada, como la fragmentación de ensamblajes que infla artificialmente el tamaño del genoma accesorio [35]. Por ello, se asume el requerimiento de utilizar algoritmos basados en grafos (como la topología de red de Panaroo) que permiten corregir errores de traducción y colapsar familias de genes diversos, asegurando que los genes exclusivos de la Estela correspondan a verdaderas adaptaciones evolutivas (xenólogos o parálogos) y no a artefactos del ensamblaje [35].

4.2 Restricciones realistas del proyecto

Las decisiones de diseño del estudio no solo responden a la teoría bioinformática, sino que están fuertemente moldeadas por las limitaciones del objeto de estudio y su entorno:

- **Restricciones físicas y normativas:** La Estela de Raimondi es una pieza única, inscrita en el Registro Nacional Informatizado del Perú (Pieza L-8741) y de incalculable valor para la nación [3]. Normativamente, cualquier muestreo debe ser estrictamente no destructivo e *in situ*, prohibiendo la alteración física

del soporte [8]. Esto obliga a utilizar técnicas de hisopado superficial en seco que generan cantidades de ADN extremadamente limitadas (baja biomasa) [10]. Esta restricción justifica directamente la decisión de priorizar en los objetivos únicamente a los linajes bacterianos dominantes, pues la secuenciación profunda del microbioma "raro" resulta computacionalmente inviable y estadísticamente ruidosa frente a la baja cantidad de material genético extraíble.

- **Restricciones económicas:** Las tecnologías de secuenciación de próxima generación (NGS) y la evaluación bioinformática profunda presentan altos costos financieros y computacionales. Esta barrera económica justifica el compromiso de emplear metodologías metagenómicas basadas en ADN en lugar de aproximaciones dinámicas más costosas como la metatranscriptómica (ARN) [8].

Las restricciones materiales, operativas y éticas del proyecto se resumen en la tabla 4.1. Cada restricción se asocia a la decisión metodológica concreta que originó.

Tabla 4.1: Matriz de restricciones realistas del proyecto y su impacto en las decisiones de diseño metodológico.

Categoría	**Restricción**	**Consecuencia metodológica**
Ético-patrimonial	Prohibición de muestreo destructivo (raspado, corte, extracción de fragmentos).	Adopción de hisopado seco estéril sobre área $<10\,\mathrm{cm}^2$; no es viable la metaproteómica directa.
Computacional	Capacidad del clúster institucional (memoria RAM, núcleos disponibles).	Selección de MEGAHIT sobre metaSPAdes por menor huella de memoria; binning con MetaBAT 2 en lugar de ensamble de herramientas.
Histórica	Ausencia de muestras previas conservadas de la Estela.	No es posible comparar el estado actual con líneas de base históricas; la inferencia de cambios temporales se limita a hipótesis ecológicas.

El conjunto de restricciones de la tabla 4.1 no constituye una limitación accesoria del trabajo, sino el marco que define qué preguntas pueden responderse con

rigor y cuáles permanecen fuera del alcance metodológico de esta tesis. En particular, la caracterización del potencial metabólico (OE4) es alcanzable bajo estas restricciones; la verificación de su actividad real *in situ*, en cambio, exigiría intervenciones (metatranscriptómica directa o metaproteómica) que el marco ético-patrimonial vigente no permite y que se proponen como continuidad de la investigación en el capítulo final.

CAPÍTULO V

MARCO METODOLÓGICO

5.1 Metodología

5.1.1 Diseño general y criterios de decisión metodológica

El estudio es de naturaleza estrictamente computacional y descriptiva. Parte de datos metagenómicos shotgun previamente secuenciados y ensamblados en el marco del informe técnico microbiológico de la Estela de Raimondi, realizado por UPCH [10], sobre los cuales se construye un flujo bioinformático que va desde el control de calidad de los genomas hasta la inferencia del potencial metabólico de los linajes dominantes. El flujo se organiza en cuatro fases consecutivas, cada una asociada a un objetivo específico (OE1 a OE4), y se ejecuta en el orden presentado a continuación.

5.1.2 Origen de los datos y unidad de análisis

El microbioma de la Estela de Raimondi fue muestreado mediante hisopado en seco sobre la superficie del monumento. En cada punto de muestreo se recolectaron dos hisopados independientes: el hisopo A, destinado a la extracción directa de ADN ambiental para secuenciación de amplicones (16S rRNA e ITS2), y el hisopo B, destinado al cultivo microbiológico de la fracción viable [10]. La secuenciación metagenómica shotgun analizada en esta tesis se realizó sobre el material proveniente del cultivo (hisopo B).

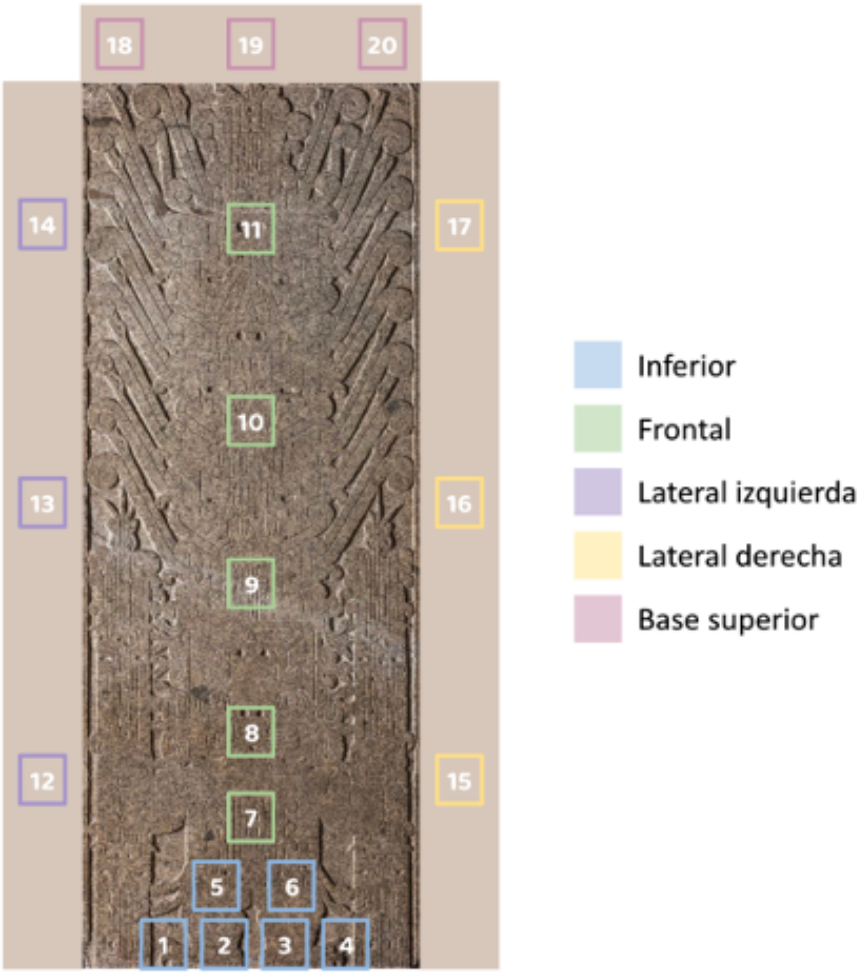


FIGURA 5.1: Esquema de muestreo de la Estela de Raimondi. Se señalan los 20 puntos de hisopado distribuidos sobre las cinco regiones del monumento (base superior, cara frontal, laterales izquierda y derecha, y sección inferior). En cada punto se recolectaron dos hisopados independientes: el hisopo A, destinado a la extracción directa de ADN para secuenciación de amplicones, y el hisopo B, destinado al cultivo de la fracción viable, posteriormente secuenciado por metagenómica *shotgun*. Tomado del informe técnico de la UPCH [10].

Si bien la metagenómica suele aplicarse de forma independiente de cultivo, en el estudio del patrimonio pétreo se han documentado también aproximaciones dependientes de cultivo acopladas a la identificación molecular por secuenciación [16].

En consecuencia, los genomas reconstruidos representan la fracción microbiana recuperable mediante cultivo y no necesariamente las poblaciones dominantes *in situ*. Esta condición se trata de forma explícita como limitación en la Fase 3.

Las lecturas crudas (archivos FASTQ) no estuvieron disponibles para este trabajo. Por ello, todo el flujo se ejecuta sobre los genomas ensamblados (bins) y no sobre lecturas. En consecuencia, la importancia de cada linaje no se mide por abundancia, sino por prevalencia espacial: el número de puntos de muestreo distintos en los que se recuperó ese linaje. Esta métrica no depende de las lecturas crudas y es más robusta frente al sesgo del cultivo.

5.1.3 Fase 1. Control de calidad y selección de genomas (OE1)

5.1.3.1. Filtrado por dominio

Los bins se filtraron primero por dominio para descartar contigs de origen eucariota u organelar antes de cualquier métrica basada en genes procariotas. Se utilizó Tiara [54], un clasificador de secuencias metagenómicas basado en aprendizaje profundo que opera sobre la composición de los contigs en un esquema de dos etapas. La elección de Tiara frente a Whokaryote [55] y EukRep [56] se sustentó en la matriz de selección ponderada (Tabla 5.2), en la que Tiara obtuvo la mayor puntuación total gracias a su facilidad de instalación, su menor costo computacional y su capacidad adicional de identificar ADN organelar; la descripción detallada de cada herramienta evaluada se presenta en el Anexo 1.

Tabla 5.1: Bins genómicos recuperados por muestra (previos al filtrado por dominio y calidad).

Muestra	N.º bins	Long. total (Mb)	Rango bin (Mb)	N50 prom. (kb)	%GC prom.
49	2	28.1	0.55–27.6	173	36.2
50	6	67.3	0.61–53.4	47	59.5
51	1	4.7	4.73	189	52.6
52	5	18.2	0.42–5.3	37	61.6
53	3	36.9	2.48–29.2	264	40.5
54	2	11.6	4.31–7.3	167	38.7
55	1	34.2	34.24	404	51.1
56	6	88.4	0.23–49.6	95	45.6
57	6	74.7	0.22–39.1	164	46.9
58	3	46.5	4.77–29.6	418	48.5
59	2	29.1	5.91–23.2	283	40.9
60	5	49.6	2.32–25.7	52	43.5
61	6	73.1	0.61–40.1	207	47.7
62	5	45.7	0.23–27.9	128	39.4
63	6	88.8	0.37–56.5	40	45.7
64	7	75.5	0.24–29.7	33	43.4
65	5	94.8	0.22–29.6	89	47.0
66	0	—	—	—	—
67	0	—	—	—	—
68	2	2.7	0.25–2.5	43	49.2
69	2	2.7	0.25–2.5	40	49.1
70	6	109.2	0.28–94.3	3	44.0
71	12	126.9	0.26–101.9	6	47.2
72	4	9.7	0.25–6.6	4	38.9
Total	**97**				

Nota. Se dispuso de 24 librerías de secuenciación Illumina, identificadas con los códigos 49 a 72. El procesamiento previo, documentado por el centro de secuenciación, comprendió el ensamblaje por muestra mediante MEGAHIT, la segmentación del ensamblaje en bins genómicos mediante MetaBAT2, la evaluación de métricas de ensamblaje con QUAST y la anotación preliminar de cada bin con Bakta, junto con una asignación taxonómica preliminar basada en Kraken2. Un bin corresponde, en este punto del flujo, a un subconjunto de contigs del ensamblaje agrupados según su perfil de cobertura y composición de tetranucleótidos, bajo el supuesto de que los contigs pertenecientes a un mismo organismo comparten estas señales. Por tanto, cada bin constituye una reconstrucción parcial o completa de un genoma individual, cuya pureza taxonómica y calidad genómica se evalúan posteriormente. De las 24 librerías, 22 produjeron bins, con un total de 97 bins; las muestras 66 y 67 no recuperaron bins y fueron excluidas del análisis genómico. Las cifras mostradas corresponden a bins crudos entregados por el centro de secuenciación y preceden al filtrado por dominio y al control de calidad genómica descritos en la Fase 1; por ello, no implican que la totalidad de los bins listados sean genomas procariotas completos o libres de contaminación.

Tabla 5.2: Matriz de selección de software para la clasificación de contigs.

		Tiara		Whokaryote		EukRep	
Criterio	**Peso (%)**	**Pts**	**Peso×Pts**	**Pts**	**Peso×Pts**	**Pts**	**Peso×Pts**
Facilidad de instalación	10	4	40	3	30	2	20
Acceso a dependencias	15	4	60	2	30	2	30
Costo computacional	10	3	30	2	20	3	30
Integración en pipeline	15	4	60	3	45	2	30
Calidad de resultado	30	4	120	3	90	2	60
Alcance funcional	10	4	40	2	20	2	20
Interpretabilidad	10	3	30	4	40	2	20
Total	**100**		**380**		**275**		**210**

Se aplicó una longitud mínima de contig de 3000 pares de bases, valor por debajo del cual los clasificadores basados en composición de secuencia pierden exactitud, y se descartaron los bins cuya fracción mayoritaria de longitud se clasificó como eucariota u organelar. Dado que Tiara discrimina entre procariotas y eucariotas pero no separa bacterias de arqueas, esta última distinción se resolvió en las fases posteriores mediante CheckM2 y GTDB-Tk.

5.1.3.2. Evaluación de la calidad genómica

La completitud y la contaminación de los bins procariotas se estimaron con CheckM2 [14], que predice ambas métricas mediante modelos de aprendizaje automático entrenados sobre genomas de referencia y no requiere asignación taxonómica previa, lo que mejora su desempeño en linajes divergentes [14]. Se conservaron únicamente los genomas con completitud superior al 70 % y contaminación inferior al 5 %.

El umbral no corresponde a ninguna categoría MIMAG estándar. Se adoptó un valor intermedio que flexibiliza la exigencia de completitud, con el fin de recuperar genomas ambientales fragmentados, pero mantiene la restricción más estricta de contaminación (inferior al 5 %) para evitar que la posterior reconstrucción del genoma accesorio se sesgue por la inclusión de ADN foráneo [30]. Este compromiso se documenta como criterio propio del proyecto y no como un estándar MIMAG de alta calidad.

5.1.4 Fase 2. Asignación taxonómica y definición de linajes (OE2)

5.1.4.1. Clasificación taxonómica genómica

Los genomas que superaron el control de calidad se clasificaron taxonómicamente con GTDB-Tk [15], empleando los conjuntos de marcadores bac120 para bacterias y arc122 para arqueas. GTDB-Tk ubica cada genoma en el árbol de referencia del GTDB, que normaliza los rangos taxonómicos según la divergencia evolutiva relativa [15, 38]. Este enfoque basado en el genoma completo reemplaza a la asignación preliminar por Kraken2, de naturaleza basada en lecturas, por una clasificación de mayor resolución y consistencia filogenética.

5.1.4.2. Confirmación de especie por ANI

La clasificación de GTDB-Tk asigna taxonomía comparando características genómicas globales, pero no compara directamente el genoma completo contra una cepa de referencia. Para confirmar la identidad a nivel de especie, se calculó la Identidad Nucleotídica Promedio (ANI) entre cada genoma ensamblado y el genoma de referencia oficial de su taxón asignado. Este genoma de referencia corresponde a la cepa tipo de la especie (el organismo depositado en bases de datos públicas cuando

esa especie fue descrita por primera vez, y que actualmente actúa como estándar de comparación).

El ANI mide qué tan parecidas son dos secuencias de ADN a lo largo del genoma completo. Dos genomas se consideran de la misma especie cuando el ANI es igual o superior al 95 % y al menos el 65 % del genoma puede alinearse [15, 37].

5.1.4.3. Desreplicación y definición de linajes

Dado que el ensamblaje y el binning se realizaron por muestra de forma independiente, un mismo organismo presente en varias muestras pudo recuperarse como bins redundantes. Para colapsar esta redundancia se aplicó dRep [39], que agrupa los genomas en clústeres según su Identidad Nucleotídica Promedio (ANI). Se utilizó un umbral primario del 95 % de ANI para delimitar clústeres a nivel de especie, congruente con el radio de circunscripción taxonómica estándar empleado por la base de datos GTDB [15]. De forma complementaria, el agrupamiento secundario se definió a un umbral estricto del 99 % de ANI para lograr una resolución de cepa. Este último umbral permite agrupar genomas casi idénticos [39], asegurando la desreplicación de poblaciones clonales sin colapsar cepas de la misma especie que pudieran albergar variaciones intraespecíficas relevantes. Cada clúster resultante se define operativamente como un linaje.

La desreplicación cumple dos funciones determinantes. Primero, provee varios genomas de la Estela por linaje, lo que habilita la construcción de un pangenoma interno con réplicas reales en la Fase 4. Segundo, permite definir una métrica de prevalencia objetiva, calculada como el número de muestras, sobre el total de 24, que aportan al menos un genoma a cada clúster. Esta métrica no depende de las lecturas crudas y por ello constituye el criterio primario de importancia de un linaje.

5.1.4.4. Confirmación filogenómica

La ubicación de cada linaje se visualizó mediante un árbol filogenómico focalizado que incluyó los genomas de la Estela y los genomas de referencia, inferido de novo por GTDB-Tk [15] a partir de los mismos marcadores bac120 empleados en la clasificación taxonómica. Esta elección, frente a la alternativa de inferir el árbol externamente con IQ-TREE [57], se sustentó en la matriz de selección ponderada (Tabla 5.3), en la que GTDB-Tk obtuvo la mayor puntuación gracias a su integración directa en el flujo ya ejecutado y a su menor costo computacional, criterio priorizado dada la restricción de cómputo propia de un proyecto de pregrado. Como contrapartida, el árbol de novo de GTDB-Tk no provee selección de modelo de sustitución ni soporte de rama mediante bootstrap, por lo que la topología resultante se interpreta como una verificación visual de la monofilia de cada linaje frente a las referencias, y no como una confirmación con soporte estadístico cuantificado.

Tabla 5.3: Matriz de selección de software para la confirmación filogenómica.

		GTDB-Tk (árbol de novo)		**IQ-TREE**	
Criterio	**Peso (%)**	**Pts**	**Peso×Pts**	**Pts**	**Peso×Pts**
Facilidad de instalación	20	4	80	3	60
Acceso a dependencias	20	4	80	3	60
Costo computacional	15	4	60	2	30
Integración en pipeline	20	4	80	3	60
Calidad de resultado	10	2	20	4	40
Alcance funcional	5	2	10	4	20
Interpretabilidad	10	2	20	4	40
Total	**100**		**350**		**310**

5.1.4.5. Selección de linajes para el análisis comparativo

A partir de los linajes definidos, entendidos como los clústeres de especie obtenidos al 95 % de ANI, se priorizaron los de mayor prevalencia. Por restricciones de cómputo, el análisis comparativo se concentró en los tres linajes de mayor prevalencia. Para esta selección, no se utilizó la abundancia de secuencias, ya que los cultivos previos en laboratorio sesgan estos números. En su lugar, se utilizó el criterio de **prevalencia espacial** [39]. Esto consistió en seleccionar a las especies que lograron ser ensambladas en la mayor cantidad de puntos físicos distintos de la Estela Raimondi. La detección repetida de un mismo genoma a través de múltiples muestras independientes demuestra que se trata de microorganismos residentes y estables, y no de simple polvo o contaminación ambiental

Esta elección de la especie como unidad primaria de análisis resulta indispensable para el correcto funcionamiento de Panaroo, dado que el algoritmo requiere comparar un conjunto de genomas estrechamente emparentados para diferenciar con precisión los genes esenciales y conservados (genoma core) de aquellos genes ganados o perdidos como producto de la adaptación evolutiva al nicho específico (genoma accesorio). Cuando la comparación se realiza entre genomas filogenéticamente distantes, esta distinción pierde fiabilidad, pues la divergencia de secuencia entre especies no relacionadas introduce una subestimación artificial del genoma core, atribuible a limitaciones del método de detección de ortólogos y no a una reducción real del repertorio génico compartido [35].

5.1.5 Fase 3. Análisis pangenómico comparativo (OE3)

5.1.5.1. Recopilación de genomas de referencia

Para cada uno de los tres linajes seleccionados se recopilaron genomas de referencia desde NCBI RefSeq y GTDB. Se incluyeron genomas de la especie asignada por GTDB-Tk y, cuando el número de referencias a nivel de especie fue insuficiente, se amplió al género correspondiente. Se priorizaron los ensamblajes designados como completos o representativos en RefSeq, que ya han pasado por el proceso de curación de NCBI. Cuando un linaje no contó con referencias de especie en RefSeq, se recurrió a los genomas tipo de GTDB como alternativa.

El conjunto de referencias se desreplicó con dRep a un umbral del 99 % de ANI, con el fin de evitar que genomas casi clonales, frecuentes en taxones muy secuenciados, inflaran artificialmente el genoma núcleo. El número de genomas de referencia no se fijó de forma arbitraria, sino que se determinó mediante la curva de acumulación del pangenoma: se añadieron genomas secuencialmente hasta observar la estabilización del genoma núcleo [43]. Cuando un taxón presentó menos de aproximadamente diez genomas de referencia de calidad suficiente en bases de datos públicas, el conjunto se amplió siguiendo el mismo criterio. En el caso de los linajes arqueales, para los que la disponibilidad de referencias de calidad fue menor, el linaje se incluyó en el análisis comparativo solo si reunió genomas suficientes para estabilizar la curva; en caso contrario, se describió de forma individual sin pangenoma comparativo.

5.1.5.2. Anotación estructural y funcional consistente

La totalidad de los genomas, tanto los MAGs de la Estela como las referencias, se anotó con la misma herramienta y versión para garantizar la homogeneidad

requerida por el análisis pangenómico [35]. Se empleó Bakta [49], que realiza la predicción de marcos abiertos de lectura y la anotación mediante identificación de secuencias sin alineamiento, y que ya se había aplicado a los bins originales. Esta elección, frente a la alternativa de Prokka [48] (heredero directo de Prodigal [47]), se sustentó en la matriz de selección ponderada (Tabla 5.4), en la que Bakta obtuvo la mayor puntuación gracias a su continuidad con la anotación ya aplicada a los bins originales, su mayor resolución en linajes ambientales divergentes y su alcance funcional más amplio; Prokka resultó más liviano de instalar, pero con menor calidad de resultado en MAGs poco representados en bases de datos curadas. La anotación consistente evita que diferencias en la predicción génica se confundan con diferencias biológicas.

Tabla 5.4: Matriz de selección de software para la anotación estructural y funcional.

		Bakta		**Prokka**	
Criterio	**Peso (%)**	**Pts**	**Peso×Pts**	**Pts**	**Peso×Pts**
Facilidad de instalación	10	3	30	4	40
Acceso a dependencias	10	3	30	4	40
Costo computacional	5	3	15	4	20
Integración en pipeline	25	4	100	2	50
Calidad de resultado	25	4	100	2	50
Alcance funcional	15	4	60	3	45
Interpretabilidad	10	4	40	3	30
Total	**100**		**375**		**275**

5.1.5.3. Reconstrucción del pangenoma

El pangenoma de cada linaje se reconstruyó con Panaroo [35] en su modo estricto (clean-mode strict). Esta elección, frente a la alternativa de PPanGGOLiN

[46], se sustentó en la matriz de selección ponderada (Tabla 5.5), en la que Panaroo obtuvo la mayor puntuación gracias a su representación gráfica del pangenoma, que corrige errores de anotación y de ensamblaje mediante la propagación del contexto genómico vecino y reduce de forma marcada la inflación artificial del genoma accesorio asociada a la fragmentación de los MAGs; PPanGGOLiN, pese a ofrecer un modelo probabilístico de partición con módulos adicionales (regiones de plasticidad genómica), no corrige esta inflación con la misma eficacia en colecciones de MAGs fragmentados.

Tabla 5.5: Matriz de selección de software para la reconstrucción del pangenoma.

		Panaroo		**PPanGGOLiN**	
Criterio	**Peso (%)**	**Pts**	**Peso×Pts**	**Pts**	**Peso×Pts**
Facilidad de instalación	10	3	30	3	30
Acceso a dependencias	10	3	30	3	30
Costo computacional	5	3	15	4	20
Integración en pipeline	15	3	45	3	45
Calidad de resultado	35	4	140	2	70
Alcance funcional	15	3	45	4	60
Interpretabilidad	10	4	40	3	30
Total	**100**		**345**		**285**

El pangenoma se particionó en tres compartimentos siguiendo la convención de la genómica comparativa [35, 43, 44]: genoma nuclear (genes presentes en al menos el 95 % de los genomas), genoma de cubierta o shell (genes en el 15 a 95 %) y genoma accesorio o cloud (genes en menos del 15 %).

5.1.5.4. Identificación de genes candidatos exclusivos de la Estela

Los genes candidatos a ser exclusivos de la Estela se definieron como aquellos presentes en uno o más MAGs del monumento y ausentes en todos los genomas de referencia. Para reducir la probabilidad de errores, se exigió que el gen estuviera completo y no truncado en el borde de un contig. Los candidatos se contrastaron mediante búsqueda de homología frente a las bases de datos nr (non-redundant) y nt (nucleotide) para descartar contaminación. Estos genes se interpretan en el marco de la transferencia horizontal de genes como principal motor de adaptación ecológica en procariotas [45]. Dado que la incompletitud de los MAGs implica que la ausencia observada de un gen no equivale a su ausencia real [30], los resultados se reportan como candidatos a exclusivos y como adquisición probable, sin afirmar certeza.

5.1.6 Fase 4. Caracterización del potencial metabólico y del riesgo (OE4)

5.1.6.1. Anotación funcional del potencial metabólico

El potencial metabólico de los linajes seleccionados se caracterizó con la herramienta DRAM [34], la cual integra la asignación de ortólogos KEGG (KO) y produce resúmenes de los ciclos biogeoquímicos del nitrógeno, el azufre y el carbono, así como el inventario de enzimas activas sobre carbohidratos (CAZymes) basado en las bases dbCAN y CAZy. Para la evaluación de los módulos de KEGG, DRAM modela las vías como redes dirigidas y calcula la completitud como el porcentaje de cobertura de la ruta que presenta la mayor proporción de genes (nodos) detectados [34]. Sobre esta base, en el presente estudio se estableció un umbral operativo estricto: un módulo metabólico se consideró funcionalmente ”presente”solo cuando su porcentaje de completitud alcanzó o superó el 66 %. Para las funciones que dependen de varios genes, la presencia se definió mediante una regla explícita para cada función, descrita en la Tabla 5.6.

5.1.6.2. Definición de marcadores de riesgo y supervivencia

La interpretación funcional se ancló en una tabla de marcadores genómicos definida *a priori*, es decir, fijada antes de observar los resultados, con el fin de evitar el sesgo de confirmación. Cada marcador corresponde a una función y no a un gen aislado, de modo que una función que requiere varios genes se cuenta una sola vez. La tabla organiza las funciones en tres categorías. La primera reúne los marcadores de riesgo de biodeterioro: la producción de ácido glucónico y de ácido 2-cetoglucónico, que acidifican el sustrato y actúan como quelantes de silicatos [18]; la biosíntesis de sustancias poliméricas extracelulares (EPS) y la adhesión mediante curli, que sostienen la biopelícula [26]; y la nitrificación y la oxidación del azufre como fuentes de ácidos inorgánicos [4, 19]. La segunda reúne los marcadores de supervivencia o persistencia: la esporulación [27], la síntesis de carotenoides, la respuesta al estrés oxidativo, la síntesis de los solutos compatibles ectoína y trehalosa, que protegen frente a la desecación [58, 59], y la reparación del ADN dañado por radiación ultravioleta [60]. La tercera reúne funciones de contexto que se reportan pero no se interpretan como marcadores de riesgo: el ciclo de los ácidos tricarboxílicos, presente en prácticamente todas las bacterias aerobias [19], las enzimas activas sobre carbohidratos (CAZymes) [51, 52] y la ureólisis, cuya precipitación de carbonato puede tanto proteger como alterar la superficie pétrea [61, 62].

La Tabla 5.6 detalla, para cada función, los genes representativos, sus identificadores KEGG Orthology (KO) y la regla con la que se considera presente. Las reglas exigen los genes necesarios para que la función sea operativa. Por ejemplo, la glucosa deshidrogenasa *gcd* solo se cuenta como productora de ácido glucónico si el genoma porta además los genes de síntesis de su cofactor, la pirroloquinolina quinona (*pqqA–E*). Del mismo modo, la nitrificación y la oxidación del azufre se evalúan con los módulos KEGG completos (M00528 y M00595) y no con genes aislados. Los genes cuya función no distingue el proceso de interés se excluyeron: la nitrato

reductasa *narG* comparte identificador KO con la nitrito oxidorreductasa *nxrA*, y la sulfito reductasa disimilatoria *dsrAB* participa tanto en la reducción como en la oxidación del azufre. Los identificadores KO y los módulos se verificaron directamente contra la base de datos KEGG [50]. Las CAZymes no poseen un identificador KO único; su detección se realiza mediante la base de datos dbCAN, integrada en DRAM. La detección efectiva de cada función en los genomas se obtiene de DRAM durante la fase de anotación funcional.

5.1.6.3. Integración del potencial funcional con la estructura del pangenoma

En el paso final, cada marcador de la tabla *a priori* se mapeó sobre la partición del pangenoma para determinar si reside en el genoma nuclear o en el accesorio. Para evaluar de forma cuantitativa si los marcadores de riesgo se concentran en el genoma accesorio, se aplicó una prueba exacta de Fisher sobre una tabla de contingencia de dos por dos que cruza la condición de gen de riesgo o no de riesgo con su pertenencia al genoma accesorio o nuclear, reportando tanto el valor de probabilidad como la razón de momios (odds ratio) como medida del tamaño del efecto. Cuando se evaluaron varias categorías funcionales de forma simultánea, los valores de probabilidad se ajustaron por comparaciones múltiples mediante el procedimiento de Benjamini y Hochberg. Esta prueba se interpreta con cautela por dos razones: las familias génicas no constituyen observaciones estadísticamente independientes, debido a la no independencia filogenética, y el número reducido de marcadores de riesgo limita la potencia estadística. Por ello, el resultado se presenta como evidencia de apoyo y no como prueba concluyente. De forma complementaria, se caracterizó la apertura del pangenoma estimando el parámetro de la ley de Heaps [46].

La lógica interpretativa es la siguiente. Si los genes de biodeterioro se enriquecen de forma significativa en el genoma accesorio, en particular si son compartidos

por varios MAGs del mismo linaje, ello aporta soporte cuantitativo a la hipótesis de que dichas funciones fueron adquiridas como adaptación al nicho del monumento. Si, por el contrario, residen en el genoma nuclear, se interpretan como rasgos intrínsecos y conservados del linaje. En coherencia con el alcance del estudio, estas conclusiones describen el potencial metabólico codificado y no la actividad biológica real en el momento del muestreo.

5.1.7 Reproducibilidad

Se registró la versión exacta de cada herramienta bioinformática y la versión de cada base de datos empleada, y cada identificador KO se verificó contra la versión vigente de KEGG. El conjunto de software comprende, en orden de ejecución, Tiara [54], CheckM2 [14], GTDB-Tk [15], FastANI [37], dRep [39], Bakta [49], Panaroo [35] y DRAM [34]. Las pruebas estadísticas se ejecutaron en un entorno de R con las bibliotecas correspondientes.

Los análisis computacionalmente intensivos se ejecutaron en el clúster de cómputo de alto rendimiento Khipu de la Universidad de Ingeniería y Tecnología (UTEC), modalidad Tesis. Este tipo de acceso permite el uso de las particiones `debug`, `debug-gpu`, `standard`, `gpu` y `big-mem`, con una asignación máxima por usuario de 32 núcleos de CPU, 98 GB de memoria RAM y 40 *GPU shards*, además de un tiempo máximo de ejecución de 24 horas por trabajo computacional. La disponibilidad de esta infraestructura permitió ejecutar de manera controlada y reproducible las etapas de filtrado, evaluación de calidad, clasificación taxonómica, comparación genómica, anotación funcional y análisis pangenómico.

Para asegurar la trazabilidad del flujo de trabajo, se conservaron los comandos utilizados, los parámetros de ejecución, los archivos de entrada y salida, y los registros generados por cada herramienta. Asimismo, los resultados intermedios relevantes

Tabla 5.6: Marcadores genómicos *a priori* de biodeterioro, supervivencia y contexto, con la regla de presencia de cada función.

Categoría	**Función / mecanismo**	**Genes**	**KO**	**Regla de presencia**	**Fuente**
Riesgo	Ácido glucónico (acidólisis y quelación)	gcd; pqqA–E	K00117; K06135–K06139	gcd y al menos 3 de 5 genes pqq	[18]
Riesgo	Ácido 2-cetoglucónico (quelación de silicatos)	gcd; pqqA–E; gluconato 2-deshidrogenasa	K00117; K06135–K06139; K06150, K06151, K06152	regla anterior y al menos 2 de 3 subunidades	[18]
Riesgo	EPS de biopelícula (Gram positivas)	epsA–O; tasA, tapA	K19419–K19431; K06336, K19433	al menos 66 % del operón eps, o tasA y tapA	[26]
Riesgo	EPS de biopelícula (Gram negativas)	pgaA, pgaB, pgaC, pgaD	K11935, K11931, K11936, K11937	al menos 3 de 4	[26]
Riesgo	Adhesión (curli)	csgA, csgB	K04334, K04335	ambos	[26]
Riesgo	Nitrificación (ácido nítrico)	amoA, amoB, amoC, hao	K28504, K10945, K10946, K10535	módulo M00528 al 66 % (3 de 4)	[19, 34]
Riesgo	Oxidación de azufre (ácido sulfúrico)	soxA, soxX, soxY, soxZ, soxB, soxC, soxD	K17222–K17227, K22622	módulo M00595 al 66 % (5 de 7)	[19]
Supervivencia	Esporulación (latencia y resistencia)	spo0A, spoIIAA, spoIIE	K07699, K06378, K06382	al menos 2 de 3	[27]
Supervivencia	Carotenoides (protección UV)	crtB, crtI	K02291 o K17841; K10027 o K15745	módulo M00097: crtB y crtI	[63]
Supervivencia	Estrés oxidativo	katA, sodA, dps	K03781, K04564, K04047	al menos 2 de 3	[6, 63]
Supervivencia	Desecación: ectoína	ectA, ectB, ectC	K06718, K00836, K06720	al menos 2 de 3	[58, 59]
Supervivencia	Desecación: trehalosa	otsA, otsB; treY, treZ; treS	K00697, K01087; K06044, K01236; K05343	otsA y otsB, o treY y treZ, o treS	[58]
Supervivencia	Reparación del daño UV	fotoliasas (phr)	K01669, K06876	al menos 1	[59, 60]
Contexto	Ácidos orgánicos del ciclo TCA	gltA, acnA, icd, sdhA, fumA	K01647, K01681, K00031, K00239, K01676	módulo M00009 (descriptivo)	[18, 19]
Contexto	CAZymes (polisacáridos)	familias GH, GT	sin KO único (dbCAN)	conteo por familia (descriptivo)	[51, 52]
Contexto	Ureólisis (precipitación de carbonato)	ureA, ureB, ureC	K01430, K01429, K01428	los tres (descriptivo)	[61, 62]

fueron organizados por etapa del análisis. Esta estructura permite auditar cada paso del procesamiento, repetir los análisis bajo las mismas condiciones computacionales y vincular los resultados finales con los archivos originales.

CAPÍTULO VI

DISEÑO TECNOLÓGICO

Este capítulo documenta cómo se construyó el flujo bioinformático con el que se ejecutaron las Fases 1, 2 y 3. El Capítulo V ya justificó cada herramienta y cada umbral. Por lo que aquí se determinan los recursos que el flujo necesita, las versiones y los entornos que lo hacen ejecutable, su implementación en código y la arquitectura que resulta. Las Fases 1 y 2 procesan solo los genomas propios contra bases de datos locales. La Fase 3, en cambio, compara cada genoma de la Estela con los genomas públicos de su especie. Es por eso que cada sección trata a la Fase 3 por separado cuando su diseño es distinto.

6.1 Cálculo de los parámetros y dimensionamiento de los componentes

Esta sección fija primero el volumen de datos de entrada y los parámetros operativos. A partir de ellos dimensiona el cómputo y el almacenamiento de cada etapa.

6.1.1 Bases de diseño: el conjunto de datos de entrada

El sistema opera sobre genomas ya ensamblados y agrupados en bins. No procesa lecturas crudas. La Tabla 6.1 resume las cifras de entrada de cada parte del flujo.

Tabla 6.1: Características del conjunto de entrada, medidas sobre los archivos FASTA de origen. Las medianas de la Fase 3 se dan en el orden *B. altitudinis*, *P. frigoritolerans* y *A. schindleri*.

Característica	**Valor**
Fases 1 y 2	
Bins de entrada (22 librerías)	97
Volumen total de secuencia	1.12 Gpb
Contigs totales	151 180
Tamaño por bin: mediana (mínimo–máximo)	4.28 (0.22–101.9) Mpb
Contigs en el bin más fragmentado	41 610
Fase 3	
Linajes de la Fase 2 con nombre de especie	12 de 19
Genomas públicos solicitados / válidos	660 / 656
Especies que pasan al análisis pangenómico	3
Genomas anotados (115 referencias y 3 bins)	118
Tamaño del genoma de referencia (mediana)	3.74 / 5.52 / 3.32 Mpb
Contigs por genoma de referencia (mediana)	15 / 39.5 / 46
Proteínas sometidas a la búsqueda remota (versión 2)	112

Dos cifras condicionan el diseño de las Fases 1 y 2. La primera es el bin más grande, `bin-11-71`, de 101.9 Mpb. Un bin de ese tamaño no es un genoma bacteriano sino una mezcla. Por lo que la primera etapa debe procesar archivos un orden de magnitud mayores que el caso típico. La segunda es el volumen total de 1.12 Gpb, que es modesto para la metagenómica. Es por eso que el cuello de botella no está en los datos propios, sino en las bases de datos de referencia.

En la Fase 3 solo entran 3 bins. El resto son genomas públicos. De los 656 válidos, 115 entran al pangenoma. Pero se conservan todos los de las tres especies seleccionadas (208, 69 y 29), porque se usan para verificar los genes propios de cada

bin y para calcular su ANI. El mayor costo de esta fase está en anotar los 118 genomas y en consultar las bases de datos del NCBI.

6.1.2 Parámetros operativos del diseño

La Tabla 6.2 reúne los parámetros de cada etapa en la forma en que quedan codificados. Cada uno es una variable de configuración al inicio del script de ejecución y no un valor escrito dentro de la llamada a la herramienta. Por lo que cambiar un umbral exige editar una sola línea. El valor efectivo queda además registrado en el archivo de versiones de cada ejecución. El análisis de sensibilidad del Capítulo VII se apoya en esa propiedad.

Tabla 6.2: Parámetros operativos y variable o argumento con que se implementan. Los de las Fases 1 y 2 se justifican en el Capítulo V. Los que se agregaron en la ejecución de la Fase 3 se justifican en el Capítulo VII. F1 a F6 son los filtros de genes específicos (Tabla 6.7).

Etapa	**Parámetro**	**Variable o argumento**	**Valor**
Fases 1 y 2			
Dominio	Longitud mínima de contig	`MIN_CONTIG_LEN`	3000
Dominio	Criterio de decisión	regla del resumen de Tiara	mayoría simple
Calidad	Completitud mínima / contaminación máxima (%)	`MIN_COMPLETENESS`, `MAX_CONTAMINATION`	70 / 5
Linajes	Umbral primario (MASH) / secundario (ANI) de dRep	`DREP_PA`, `DREP_SA`	0.90 / 0.95
Especie	ANI / fracción alineada mínimos (%)	`ANI_ESPECIE`, `AF_ESPECIE`	95 / 65
Fase 3			
Censo	Completitud / contaminación de la referencia (%)	`DEF_MIN_COMPLETITUD`, `DEF_MAX_CONTAMINACION`	95 / 5
Censo	Contigs máximos de la referencia	`DEF_MAX_CONTIGS`	300
Censo y selección	Genomas mínimos por especie	`DEF_UMBRAL`	15
Descarga	Diferencia de longitud tolerada	`DEF_TOLERANCIA`	0.01
Desreplicación	Umbral primario / secundario de dRep	`DREP_PA`, `DREP_SA`	0.90 / 0.99

Tabla 6.2 (continuación)

Etapa	**Parámetro**	**Variable o argumento**	**Valor**
Selección	Referencias máximas por especie; especies	`DEF_TOPE`, `DEF_TOP`	50; 3
Pangenoma	Modo de limpieza de Panaroo	`CLEAN_MODE`	moderate
Partición	Umbral de core / de cloud	`DEF_CORE`, `DEF_CLOUD`	0.95 / 0.15
Árbol	Réplicas de UFBoot; semilla	`UFBOOT`, `SEED`	1000; 12345
F1	Largo mínimo de la proteína (aa); distancia mínima al borde (pb)	`DEF_MIN_AA`, `DEF_MIN_BORDE`	100; 100
F3	Identidad y cobertura mínimas (%)	`DEF_F3_ID`, `DEF_F3_COV`	95 / 80
F4 y F5	Identidad y cobertura mínimas (%)	`DEF_F4_ID`, `DEF_F5_ID` y `_COV`	80 / 80
F5b	ANI de misma especie (%)	`DEF_ANI`	95
Advertencia	Identidad y cobertura (%)	`DEF_CASI_ID`, `DEF_CASI_COV`	99 / 90
F5 remoto	Proteínas por envío; espera máxima por búsqueda (h)	`LOTE`, `ESPERA_MAX_H`	10; 24

6.1.3 Dimensionamiento del cómputo

La cuenta del clúster Khipu admite como máximo 32 núcleos, 98 GB de memoria y 24 horas por trabajo. Ese límite es la restricción dura del diseño. En la Fase 3 apareció un segundo límite: SLURM admite solo cinco trabajos enviados y tres en ejecución a la vez. Por lo que rechazaba un arreglo con una tarea por cada uno de los 118 genomas. La Tabla 6.3 indica el recurso crítico de cada etapa, lo que se pidió, lo que se midió y la decisión que hizo caber el consumo en la cuota.

Tabla 6.3: Recurso crítico, recursos pedidos y consumo medido de cada etapa. Los valores por especie se dan en el orden *B. altitudinis*, *P. frigoritolerans* y *A. schindleri*.

Etapa	**Recurso crítico**	**Pedido y medido**	**Decisión de dimensionamiento**
Tiara	Procesador	32 núcleos, 90 GB, 24 h (trabajo de la Fase 1)	Un bin por vez con los 32 núcleos. Así el bin de 101.9 Mpb no coincide en memoria con otros bins grandes
CheckM2	Memoria y disco	mismo trabajo	Una sola llamada sobre todos los bins procariotas. La base de DIAMOND se carga una vez y no una por genoma
GTDB-Tk	Memoria	32 núcleos, 90 GB, 12 h (trabajo de la Fase 2); unos 55 GB en la colocación	`--pplacer_cpus 1`. La memoria de la colocación filogenética crece con el número de hilos y no con el de genomas. Con más hilos supera la cuota
GTDB-Tk	Tiempo y disco	mismo trabajo	`--skip_ani_screen`: omite el prefiltrado por MASH y su base de datos. La especie se confirma igual con el ANI interno
dRep	Tiempo	mismo trabajo	`--genomeInfo`: reutiliza la calidad de CheckM2 y no la recalcula
Censo y descarga	Red	nodo de login	Primero se piden los metadatos y después las secuencias, con reintentos ante cortes
dRep al 99 %	Tiempo y número de trabajos	16 núcleos, 32 GB, hasta 6 h por especie	Siete especies enviadas en dos tramos
Bakta	Memoria y número de trabajos	3 lotes de 10 núcleos y 32 GB; ∼4.5 h y 30.5–31.0 GB por lote	Cada lote anota en serie un tercio de los genomas. Un piloto de 4 genomas (2 h 01 min, 30.0 GB) fijó la memoria
Panaroo	Memoria	32 núcleos, 90 GB; 38 / 50 / 12 min y 8.5 / 14 / 5 GB	Una especie a la vez
IQ-TREE	Tiempo	32 núcleos, 90 GB, 24 h; 2 h 08 / 2 h 50 / 25 min	Una especie a la vez
BLAST local (F3, F4)	Procesador	16 núcleos, 32 GB; menos de 1 min por especie	Una tarea por especie
BLAST remoto (F5, F6)	Cola externa del NCBI	nodo de login; ∼7 / 6 / 4 h en la versión 1	Sesión persistente (`tmux`). El programa espera hasta 24 h por búsqueda y puede reanudarse

Los trabajos piden 90 GB y no los 98 GB de la cuota. El motivo por el cual se deja ese margen es que SLURM rechaza el trabajo si la solicitud excede la cuota. Además, algunas herramientas reservan memoria fuera del proceso principal.

6.1.4 Dimensionamiento del almacenamiento

El volumen de datos propios es pequeño frente al de las bases de referencia, como muestra la Tabla 6.4.

Tabla 6.4: Requerimiento de almacenamiento por componente.

Componente	**Tipo**	**Tamaño**
Bins de entrada	Datos propios	1.12 Gpb
Base de datos de CheckM2 (DIAMOND)	Insumo de referencia	∼3 GB
Base de datos de GTDB R220	Insumo de referencia	∼110 GB
Resultados completos de la Fase 2	Salida	406 MB
Alineamiento concatenado bac120	Salida intermedia	230 MB
Base de datos de Bakta v6.0 (*full*)	Insumo de referencia	∼84 GB
Datos y salidas de la Fase 3	Datos y salidas	∼19 GB

La base de GTDB determina por sí sola el requerimiento de disco. Su descompresión es larga, debe hacerse en el nodo de login y excede la tolerancia de una sesión interactiva. Por lo que el script de preparación verifica el espacio libre antes de empezar y se ejecuta en segundo plano. La base de Bakta es la segunda más grande y también se descarga una sola vez en el login. Los genomas públicos se conservan hasta el final de la Fase 3, porque la búsqueda de genes propios y el ANI de cada bin usan todos los genomas válidos de la especie.

6.2 Selección de materiales, componentes y equipos de la solución

En este diseño los materiales son las versiones del software, las bases de datos de referencia y el entorno de ejecución. La elección de cada herramienta se justificó en el Capítulo V. Aquí se selecciona su versión, su insumo y su entorno.

6.2.1 Versiones de software y compatibilidad

La Tabla 6.5 indica la versión de cada herramienta y el criterio con que se fijó.

Tabla 6.5: Versiones de software empleadas y criterio de selección de cada una.

Componente	**Versión**	**Criterio de selección de la versión**
GTDB-Tk	2.6.1	Compatible con los datos R220. Una combinación incorrecta de programa y datos clasifica mal sin emitir error
Python	3.11	Fijada en todos los entornos. Sin ella se instala Python 3.14 y GTDB-Tk no arranca
Tiara, CheckM2	1.0.3; 1.1.0	Sin restricción, porque no dependen de una versión de datos externa. Se reportan las instaladas
dRep, fastANI, Mash	3.7.1; 1.34; 2.3	Entorno propio con Python 3.11, reutilizado en la Fase 3
NCBI Datasets CLI	18.38.0	Descarga cada genoma por su accesión exacta
Bakta	1.12.1	La base de datos v6.0 exige Bakta 1.11 o superior. Los 118 genomas se anotan con el mismo programa
Panaroo	1.8.0	Fijada junto con su conversor de formato, de la misma versión del código fuente. Incluye CD-HIT 4.8.1 y MAFFT 7.526
IQ-TREE, snp-sites	3.1.3; 2.5.1	snp-sites solo se instaló como respaldo, que no hizo falta
BLAST+, TaxonKit	2.17.0; 0.20.0	Búsquedas locales (F3, F4) y recuperación de las remotas. TaxonKit asigna el linaje con la taxonomía del NCBI del 04-10-2026
R	4.5.0	Estadística y figuras en el equipo local: vegan 2.7.2, ape 5.8.1, phangorn 2.12.1, ggtree 3.16.3 y gggenes 0.7.0

Dos decisiones de compatibilidad fueron determinantes. En primer lugar, la versión de Python. Sin fijarla, el error no aparece al instalar sino en la primera ejecución, cuando ya se descargaron 110 GB y se encoló un trabajo. Fijarla convierte ese fallo tardío en una condición que se verifica al crear el entorno. En segundo lugar, el formato de anotación. Bakta entrega GFF3 y Panaroo espera el formato de Prokka. Panaroo acepta GFF3, pero con los archivos de Bakta pierde o malinterpreta genes. Por lo que cada archivo se convirtió con `convert_bakta_to_prokka_gff.py`, que los autores de Panaroo distribuyen en su repositorio. La conversión descarta las secuencias codificantes que no se pueden traducir. Fueron 5, todas en *A. schindleri*.

6.2.2 Bases de datos como insumo de referencia

Las bases de datos son material externo que el sistema consume y del que depende la validez del resultado. La Tabla 6.6 las especifica.

Tabla 6.6: Bases de datos empleadas como insumo de referencia.

Insumo	**Versión**	**Etapa que lo consume**
Base de datos de CheckM2	la que distribuye la herramienta	Calidad genómica
Base de datos de GTDB	R220	Clasificación taxonómica y ANI
Metadatos de GTDB (`bac120_metadata`)	R220	Censo y clasificación de referencias
Base de datos de Bakta (*full*)	v6.0 (24-02-2025)	Anotación
Taxonomía del NCBI (*taxdump*)	descargada el 04-10-2026	F5
NCBI nr y core_nt (remotas)	fecha de la consulta	F5 y F6
NCBI IPG y Datasets API v2 (remotas)	fecha de la consulta	F5b
UniProtKB, vía EBI (remota)	fecha de la consulta	Comparación de F5
Diccionarios propios de hábitat y países	versionados en el repositorio	Clasificación de referencias

La versión del insumo forma parte del resultado. Un genoma clasificado contra R220 puede recibir otro nombre en una versión posterior, porque la taxonomía del

GTDB se reorganiza. Es por eso que la versión se registra en cada ejecución. La base de Bakta v6.0 incluye versiones fijas de otras bases, como RefSeq 228, UniProtKB/ Swiss-Prot 2025_01 y Pfam 37.2. Pero nr y core_nt se consultan en línea y cambian a diario. Un gen sin copias en su especie hoy puede tenerlas mañana. Por lo que la fecha de cada búsqueda se reporta con su resultado. Los diccionarios propios clasifican los genomas por hábitat de aislamiento (expresiones regulares) y por continente (258 países). Se versionan con el código, junto con la lista de genomas excluidos a mano, porque un cambio en ellos cambia la clasificación.

6.2.3 Entorno de ejecución y plataforma de cómputo

El sistema usa un entorno conda por herramienta. El motivo por el cual se separan es un conflicto real: Tiara, CheckM2 y GTDB-Tk requieren versiones incompatibles de las mismas bibliotecas. El canal `defaults` no es accesible desde el clúster y produce un fallo de red al crear el entorno. Por lo que el diseño declara solo los canales `conda-forge` y `bioconda` en cada creación (Anexo 7.7). Cada script de preparación exporta al final un archivo de bloqueo por entorno, con todos los paquetes y sus versiones exactas, en la carpeta `envs/` del repositorio. La Fase 3 agregó cinco entornos (`ncbi-datasets`, `bakta`, `panaroo`, `iqtree` y `blast`) con las mismas reglas y reutilizó el de dRep. Su script de preparación comprueba al final que cada entorno responde con su versión, que la base de Bakta es la v6 y que los metadatos de GTDB tienen las columnas que necesita el censo.

El sistema se ejecuta en la partición `standard` del clúster Khipu, bajo el gestor de colas SLURM. Sus nodos tienen en su mayoría 32 núcleos y 224 GB. No se usan las particiones de GPU, porque ninguna herramienta las aprovecha, ni la de memoria ampliada, a la que la cuenta no tiene acceso. Solo el nodo de login tiene internet. Es por eso que el sistema se reparte en dos clases de programas. Los de preparación descargan bases y crean entornos en el login. Los scripts de ejecución se

envían a la cola y no necesitan conexión. La Fase 3 rompe en parte esta separación. La búsqueda de los genes propios de cada bin consulta nr y core_nt en los servidores del NCBI, porque esas bases son demasiado grandes para instalarse en el clúster. Por lo que esa etapa corre en el login, dentro de una sesión de `tmux` que sigue activa aunque se cierre la conexión SSH.

6.3 Integración e implementación de los componentes en la solución final

Esta sección documenta cómo se encadenan las etapas y qué mecanismos impiden que el encadenamiento se rompa.

6.3.1 Organización del sistema en programas

Las Fases 1 y 2 se implementan en seis programas y la Fase 3 en quince. Se agrupan en cuatro clases según dónde se ejecutan. En primer lugar, los de preparación, que crean entornos y descargan bases en el login. En segundo lugar, los scripts de ejecución, que se envían a la cola. En tercer lugar, los de ejecución con red, que corren en el login porque consultan el NCBI. Por último, los de procesamiento, que contienen la lógica de decisión del flujo. Los de procesamiento están escritos en Python con solo la biblioteca estándar. Por lo que corren con el intérprete de cualquier entorno, sin dependencias adicionales. El Anexo 7.6 lista cada programa con su función y cada archivo que conecta una etapa con la siguiente.

6.3.2 Normalización de la entrada y trazabilidad

La prevalencia espacial de la Fase 2 exige saber de qué muestra viene cada genoma. Los archivos de origen se llaman `bin-<N>-<muestra>`, de modo que ya codifican la muestra. El programa de preparación los copia a una carpeta limpia,

descarta los ensamblajes por muestra que no son bins y construye una tabla con la muestra, el número de bin, los contigs y la longitud de cada genoma. Al final verifica que se procesaron 97 genomas. Esa comprobación protege contra el error más probable de la etapa, que es leer una carpeta equivocada.

En la Fase 3 cada genoma público se identifica por su accesión del NCBI, con guion bajo en lugar del punto. Se descarga la versión exacta del ensamblaje que indica GTDB. Si ya no existe, no se sustituye, porque las métricas de calidad con que se eligió corresponden a esa versión. Por último, se compara la longitud descargada con la de GTDB y se acepta hasta 1 % de diferencia. Este control verifica la integridad de la descarga y no la calidad del genoma.

6.3.3 Encadenamiento entre etapas

Las etapas se comunican por archivos en disco. Cada etapa escribe un archivo y la siguiente lo lee (Anexo 7.6). Cuatro puntos de esa cadena resuelven problemas de integración.

En primer lugar, la Fase 2 recibe una carpeta con exactamente los genomas que superaron la Fase 1, y no una lista de nombres. Por lo que el criterio de selección se aplica una sola vez y no puede divergir entre fases.

En segundo lugar, dRep evalúa por omisión la calidad de cada genoma con su propio procedimiento. Eso duplicaría el cálculo y podría descartar genomas que la Fase 1 aceptó. El diseño convierte el reporte de CheckM2 al formato que dRep espera y desactiva sus filtros propios (Anexo 7.7).

En tercer lugar, la partición del pangenoma. Panaroo clasifica cada familia como core, shell o cloud según cuántos genomas la contienen, incluido el bin. Pero el bin está incompleto. Una familia presente en 48 de 50 referencias tiene una frecuencia

de 96 % y es core. Si falta en el bin, su frecuencia baja a 48 de 51 (94.1 %) y pasa a shell solo por la incompletitud del bin. Del mismo modo, una familia presente solo en el bin quedaría como cloud, aunque podría ser un gen propio de la cepa. Es por eso que el sistema conserva las familias de Panaroo, pero recalcula su frecuencia solo con las referencias y ubica después los genes del bin en esas categorías (Anexo 7.7).

Por último, el pangenoma usa solo las referencias seleccionadas. Pero la búsqueda de los genes propios del bin y el cálculo de su ANI usan la lista completa de genomas válidos de la especie. Esa lista incluye los que quitaron la desreplicación y el tope de 50.

6.3.4 Implementación de la verificación de genes específicos

Un gen candidato es un gen del bin sin equivalente en ninguna referencia del pangenoma. Antes de considerarlo propio de la cepa, el sistema lo somete a la cadena de filtros de la Tabla 6.7. Sus umbrales están en la Tabla 6.2.

TABLA 6.7: Filtros de genes específicos de la cepa, en el orden en que se aplican.

Filtro	**Qué comprueba y qué descarta**	**Dónde se ejecuta**	**Herramienta**
F1	Estructura del gen. Descarta pseudogenes, proteínas cortas y genes cerca del borde del contig, que suelen estar partidos [64, 65]	Cola, sin red	Anotación de Bakta
F2	Anclaje del contig. No descarta: marca como huérfano el contig que no comparte ninguna familia con las referencias, como posible contaminación [66]	Cola, sin red	Partición de Panaroo
F4	Presencia en otros genomas de la especie. Descarta los genes que aparecen en algún genoma válido	Cola, sin red	`tblastn` [67]
F3	Presencia en otros bins de la misma muestra. Solo advierte, porque puede ser ADN intercambiado o un error de reconstrucción	Cola, sin red	`blastn`

Tabla 6.7 (continuación)

Filtro	Qué comprueba y qué descarta	Dónde se ejecuta	Herramienta
F6	Origen de los contigs huérfanos. Descarta el contig cuyo mejor parecido es de otro género o casi idéntico a otra especie del mismo género	Login, NCBI	`blastn` contra core_nt
F5	Presencia en nr. Descarta el gen que tiene un organismo de la misma especie	Login, NCBI	`blastp` contra nr; linaje con TaxonKit [68]
F5b	Especie de los genomas portadores, decidida por el ANI que el NCBI calcula contra las cepas tipo [69] y no por el nombre depositado	Login, NCBI	IPG y NCBI Datasets [70]

Los filtros se ordenan por costo. Los locales tardan segundos y descartan la mayoría de los candidatos. Por lo que solo los sobrevivientes llegan a los remotos, que pueden tardar horas. La etapa está dividida en dos programas. El primero se envía a la cola y deja escritas las consultas. El segundo las envía desde el login. La parte remota usa la interfaz web de BLAST del NCBI con `curl`, porque la opción `-remote` de BLAST+ quedaba esperando en el clúster sin devolver resultados. El programa guarda el identificador de cada consulta, revisa su estado cada 60 segundos (el mínimo que pide el NCBI) y recupera el resultado con `blast_formatter`. Las proteínas se envían en lotes de diez. Si el NCBI cancela un lote, sus proteínas se reenvían una por una. Las que vuelven a fallar se marcan como «sin resultado», para no confundirlas con las proteínas «sin parecidos».

6.3.5 Implementación de los scripts de ejecución

Cada script de ejecución declara primero los recursos que pide a SLURM y después la configuración del análisis (Anexo 7.7). Además, incorpora tres mecanismos de robustez. En primer lugar, se detiene ante el primer error y propaga el error a

través de las tuberías, pero no aborta ante variables no definidas. Esa última opción es incompatible con el sistema de módulos del clúster, que usa una variable sin definirla. En segundo lugar, antes de calcular nada comprueba que existan la carpeta de bins, la base de datos y el entorno conda. Así un error de configuración aparece en segundos y no después de horas de cola. En tercer lugar, escribe un archivo con la fecha, el trabajo, el nodo, los umbrales efectivos y la versión de cada herramienta. Ese archivo acompaña a los resultados como evidencia de reproducibilidad.

La Fase 3 agregó dos mecanismos. La anotación con Bakta se divide en tres tareas, y al reenviar una tarea interrumpida se omiten los genomas ya anotados. Además, el flujo se detiene en cada punto de control (C0 a C8) si un resultado no es el esperado. Por ejemplo, el C5 exige que cada anotación tenga un número de genes dentro de ± 20 % de la mediana de su especie. El C6 exige que cada referencia contenga al menos el 97 % del genoma core. El Capítulo VII reporta ambos controles.

6.3.6 Control de versiones

El código, las tablas de resultados y los archivos de bloqueo de los entornos se mantienen en un repositorio de control de versiones (Anexo 7.5). Los archivos grandes que no aportan a la reproducibilidad, como el alineamiento concatenado de 230 MB, se excluyen y se conservan solo en el almacenamiento local.

6.4 Representación gráfica de la solución y su verificación

Esta sección representa el sistema de dos maneras: el flujo de datos entre etapas y la arquitectura de cómputo donde corre cada pieza.

6.4.1 Diagrama de flujo del sistema

La Figura 6.1 representa las Fases 1 y 2 como una secuencia de operaciones conectadas por archivos. Las cifras indican cuántos genomas atraviesan cada punto del flujo. El flujo es secuencial y tiene una sola conexión entre fases: la desreplicación reutiliza la evaluación de calidad de la Fase 1.

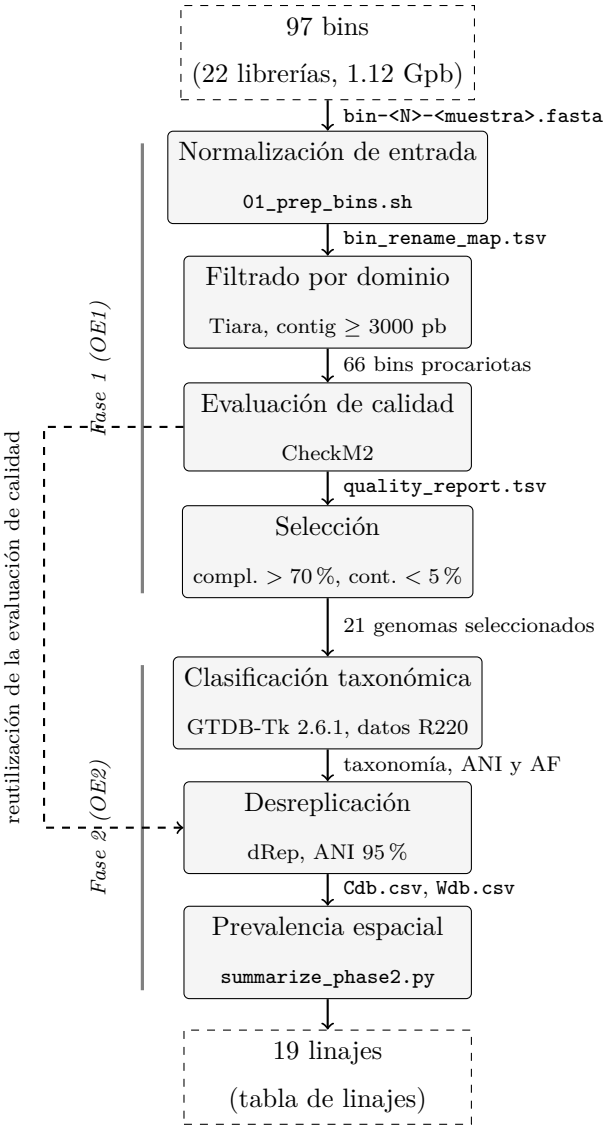


FIGURA 6.1: Diagrama de flujo de las Fases 1 y 2. Los recuadros de borde continuo son etapas de procesamiento; los de borde discontinuo, los datos de entrada (97 bins) y el resultado final (19 linajes). Las etiquetas sobre las flechas son los archivos que pasan de una etapa a la siguiente. La flecha discontinua lateral indica que la desreplicación de la Fase 2 reutiliza la evaluación de calidad de la Fase 1 (Sección 6.3.3).

La Figura 6.2 representa la Fase 3. Muestra cómo se reduce el conjunto en cada etapa: de 12 linajes con nombre de especie, 7 superan el censo y aportan 656 genomas válidos. Tras la desreplicación y la selección quedan 3 especies con 115

referencias, que se anotan junto con los 3 bins. Después del pangenoma el flujo se divide en dos ramas. El árbol del genoma core ubica a cada bin entre las cepas de su especie. Los filtros de genes específicos producen la lista que pasa a la Fase 4.

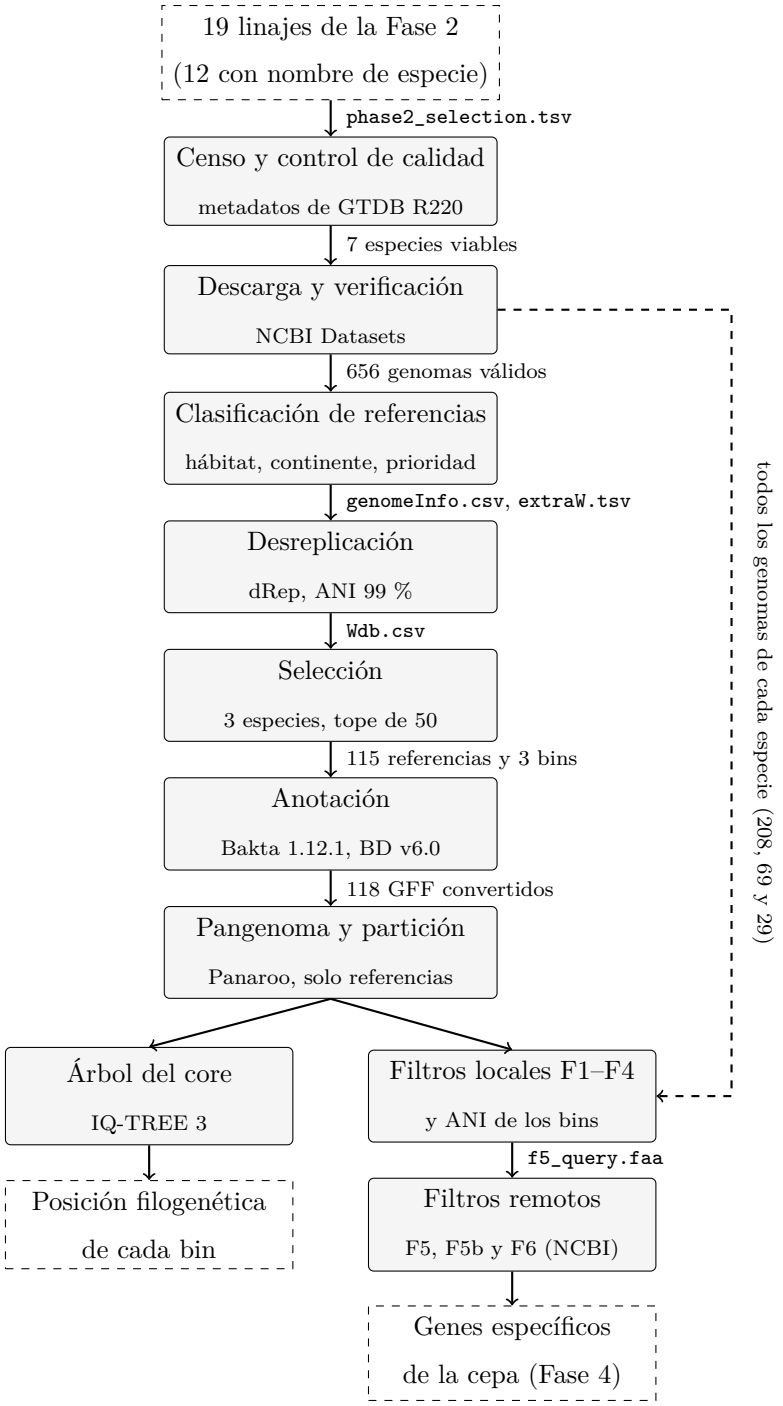


FIGURA 6.2: Diagrama de flujo de la Fase 3. Los recuadros de borde continuo son etapas de procesamiento; los de borde discontinuo, los datos de entrada (19 linajes) y los resultados (posición filogenética de cada bin y genes específicos de la cepa). Las etiquetas sobre las flechas son los archivos o las cifras que pasan de una etapa a la siguiente. La flecha discontinua lateral lleva todos los genomas válidos de cada especie directamente a la búsqueda local de genes y al cálculo de ANI de los bins, sin pasar por la desreplicación ni por la selección.

6.4.2 Arquitectura de cómputo

La Figura 6.3 representa dónde se ejecuta cada pieza. La división entre el nodo de login y los nodos de cómputo es una restricción de diseño, porque decide qué programas pueden descargar insumos y cuáles deben encontrarlos ya disponibles. La Fase 3 agrega dos elementos externos al clúster: los servicios del NCBI, que el login consulta durante el análisis, y el equipo local donde se generan la estadística y las figuras.

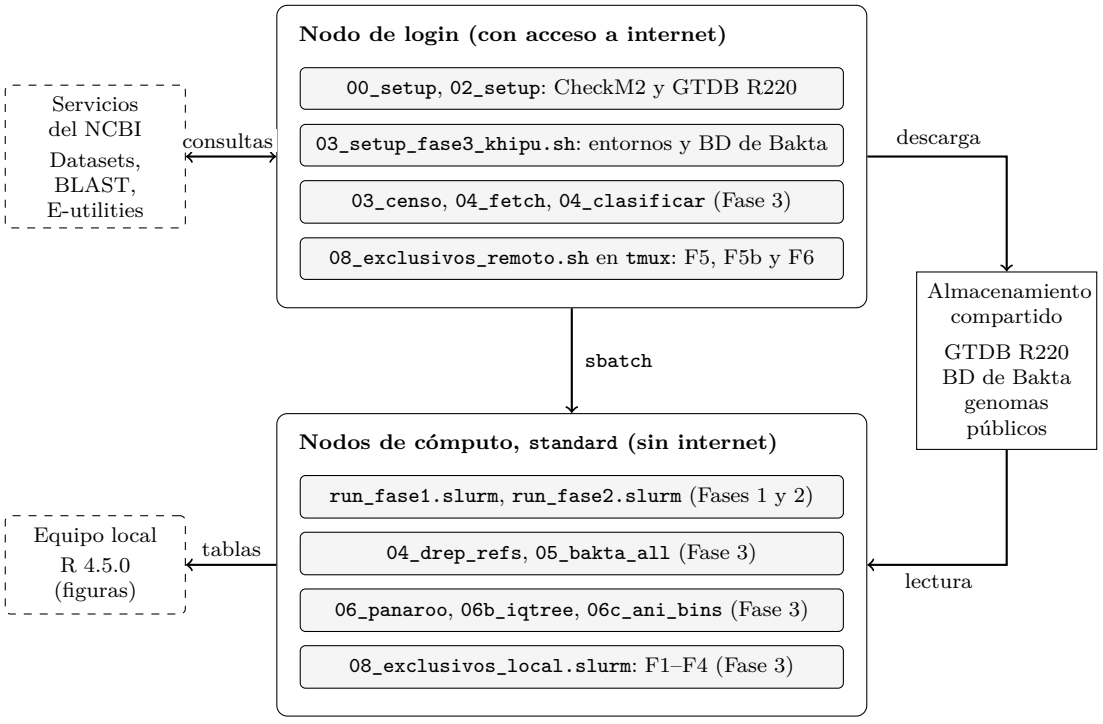


FIGURA 6.3: Arquitectura de cómputo del sistema sobre el clúster Khipu. Los programas de preparación y las etapas que necesitan red (censo, descarga y verificación remota de genes de la Fase 3) se ejecutan en el nodo de login, único con acceso a internet. Los scripts de ejecución se envían a la cola con `sbatch` y corren en nodos de cómputo sin conexión, que solo leen lo que el login dejó en el almacenamiento compartido. Las tablas de resultados se copian a un equipo local, donde se calculan la estadística y las figuras.

6.4.3 Verificación de la correspondencia entre el diagrama y la implementación

Cada bloque de la Figura 6.1 corresponde a una invocación dentro de uno de los dos scripts de ejecución de las Fases 1 y 2. Cada bloque de la Figura 6.2 corresponde a uno de los programas del Anexo 7.6. Cada archivo rotulado sobre las flechas es un archivo que el sistema escribe en disco y que se conserva en el repositorio. Las cifras de genomas provienen de la ejecución real y coinciden con las del Capítulo VII. Los extractos de código con las decisiones de diseño están en el Anexo 7.7, y los programas completos, en el repositorio.

CAPÍTULO VII

PRUEBAS Y RESULTADOS

Este capítulo presenta el desempeño del flujo diseñado en el Capítulo VI. Primero define cómo se probó. Después expone los resultados de las Fases 1, 2 y 3 y los ajustes de diseño que obligaron a hacer. Por último verifica las especificaciones y las restricciones del proyecto.

7.1 Plan de pruebas de la solución

Los resultados del flujo dependen de umbrales que el equipo eligió. Es por eso que la prueba no consiste en ejecutarlo una sola vez. Consiste en ejecutarlo con una configuración de referencia y medir después cuánto cambia el resultado si se mueven sus umbrales.

7.1.1 Caso base

El caso base son los parámetros de la Tabla 6.2 con las versiones de la Tabla 6.5. Se ejecutó en Khipu en los trabajos SLURM 49286 (Fase 1), 49316 (Fase 2), 54664 (Bakta), 54744 (Panaroo), 54753 (IQ-TREE, modelo elegido por BIC), 54889 (filtros F1–F4) y 54890 (ANI de los bins con fastANI). Los filtros remotos F5, F5b y F6 corrieron en el nodo de login. Es importante mencionar que GTDB-Tk 2.6.1 calcula el ANI de confirmación de especie con skani [71]. fastANI solo interviene en dRep y en el ANI de los bins de la Fase 3. Para los genes específicos, el caso base es la segunda versión del análisis. Esa versión incluye como candidatos los genes del

bin que Panaroo eliminó y decide la especie de cada genoma por su ANI (F5b). La primera versión se documenta como iteración.

7.1.2 Variables medidas y escenarios de sensibilidad

En cada etapa se registró la variable que permite juzgar si funcionó: genomas retenidos, especie confirmada, linajes, genomas no redundantes, partición del pangenoma, soporte del árbol, ANI y candidatos que sobreviven a cada filtro. La sensibilidad se evaluó con 13 escenarios (E1 a E13), que se detallan con su resultado en el Anexo 7.11. La mayoría se recalculó sobre las tablas de salida del caso base, porque cada herramienta ya entrega el valor sobre el que actúa cada filtro. Solo E8, E10 y E11 exigieron una nueva ejecución.

7.2 Análisis de los resultados de las pruebas

7.2.1 Resultados de la Fase 1: control de calidad y selección de genomas (OE1)

La Fase 1 aplicó dos filtros en orden sobre los 97 bins: primero el dominio con Tiara y después la calidad con CheckM2. El orden no es intercambiable, porque CheckM2 mide completitud y contaminación con marcadores procariotas. La Figura 7.1 resume el resultado.

Tiara descartó 31 de los 97 bins, en su mayoría eucariotas u organelares. Era esperable, porque una piedra a la intemperie acumula material fúngico, algal y vegetal. CheckM2 rechazó después 45 de los 66 bins restantes: 18 solo por completitud, 20 solo por contaminación y 7 por ambas. Quedaron 21 genomas, el 21.65 % del total. Los bins contaminados son el problema más grave. Contienen contigs de organismos distintos que MetaBAT2 agrupó por error (hasta 24.87 % en `bin-1-60`)

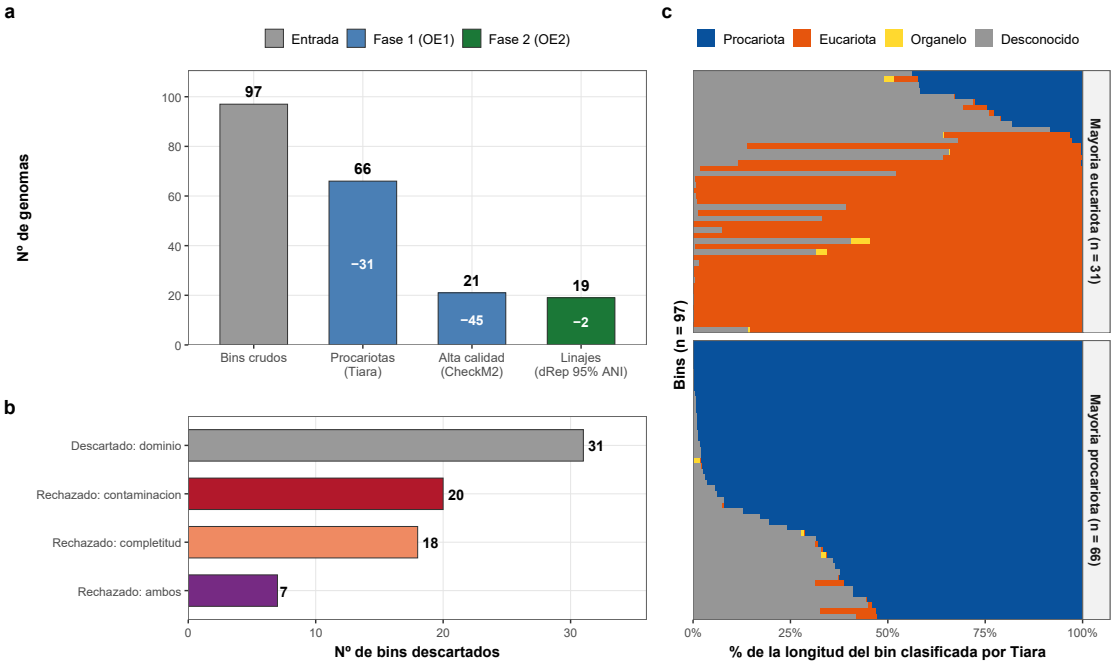


FIGURA 7.1: Embudo de selección de genomas desde los bins crudos hasta los linajes. **(a)** Genomas que sobreviven a cada etapa: 97 bins crudos de 22 librerías, 66 con dominio mayoritariamente procariota según Tiara, 21 que superan los umbrales de CheckM2 (completitud superior al 70 %, contaminación inferior al 5 %) y 19 linajes tras la desreplicación con dRep al 95 % de ANI. Las cifras en blanco son las pérdidas de cada paso. **(b)** Motivos de descarte de los 76 bins eliminados. **(c)** Composición por dominio de cada bin según Tiara, como porcentaje de su longitud. Los bins se separan por su dominio mayoritario y se ordenan por la fracción procariota.

y podrían sesgar el genoma accesorio. Es por eso que la contaminación se mantuvo estricta (5 %) y la completitud se fijó en 70 %.

Los 21 genomas quedan lejos de los umbrales. La mediana de completitud es 99.86 % y la de contaminación, 0.44 %. Pero su continuidad es heterogénea: tienen de 17 a 1041 contigs (mediana 90), y cuatro superan los 300 (`bin-5-50`, `bin-6-50`, `bin-3-64` y `bin-9-71`). El caso de `bin-5-50` muestra que calidad y fragmentación son cosas distintas. Tiene 76.56 % de completitud, pero sus 3.47 Mb están en más de mil contigs de 3.3 kb en promedio. CheckM2 lo califica bien porque sus genes marcadores caben completos en contigs cortos. Pero un gen partido entre dos contigs

puede pasar por un falso gen exclusivo en la Fase 3, que por eso incluye controles para esos casos. El Anexo 7.8 reúne las métricas de los 97 bins con su motivo de descarte y la figura de calidad.

El OE1 se cumple. Se obtuvieron 21 genomas procariotas con la completitud y la pureza que exigen la asignación taxonómica y la comparación genómica. El costo fue descartar el 78.35 % del material de partida. Por lo que la diversidad real de la fracción viable es mayor que la que representan estos 21 genomas.

7.2.2 Resultados de la Fase 2: asignación taxonómica y definición de linajes (OE2)

GTDB-Tk clasificó los 21 genomas en tres filos bacterianos y en ninguno arqueal. Así se resolvió la ambigüedad que Tiara dejaba entre bacterias y arqueas. Predomina Bacillota, con 13 genomas (62 %), seguido de Pseudomonadota con 5 (24 %) y Actinomycetota con 3 (14 %). Los 21 genomas se reparten en 11 órdenes y 17 géneros, y solo cuatro géneros aportan más de un genoma. La mayoría de los géneros de Bacillota forma endosporas, una estrategia que favorece la supervivencia sobre una piedra expuesta a desecación, radiación ultravioleta y cambios de temperatura [11]. El árbol filogenómico de los 21 genomas es congruente con esta asignación, pero solo verifica la coherencia interna del conjunto. Las figuras de composición, árbol, similitud y prevalencia están en el Anexo 7.9.

Dieciséis genomas cumplen los criterios de especie (ANI $\geq$ 95 % y AF $\geq$ 65 %), con ANI entre 95.61 y 99.99 % (mediana 98.53 %), como muestra la Figura 7.2. Dos genomas, `bin-1-51` (*Pantoea* sp.) y `bin-9-71` (*Aristophania* sp.), se ubicaron solo por la topología del árbol de GTDB-Tk, sin ANI, por lo que su clasificación se detiene en género. Los tres restantes son el hallazgo taxonómico de esta fase. Los dos *Corynebacterium* sp. (`bin-1-68` y `bin-2-69`) tienen 90.55 y 90.50 % de ANI con

su referencia más cercana y solo 44.3 y 44.0 % de fracción alineada. *Sporosarcina* sp. (`bin-3-64`) tiene 91.25 % de ANI y 60.4 % de AF. Los tres quedan bajo el umbral de especie del GTDB, por lo que son candidatos a especies no descritas en la versión R220. En los *Corynebacterium* la divergencia no se debe a una mala reconstrucción, porque vienen de muestras distintas y tienen 100 % de completitud.

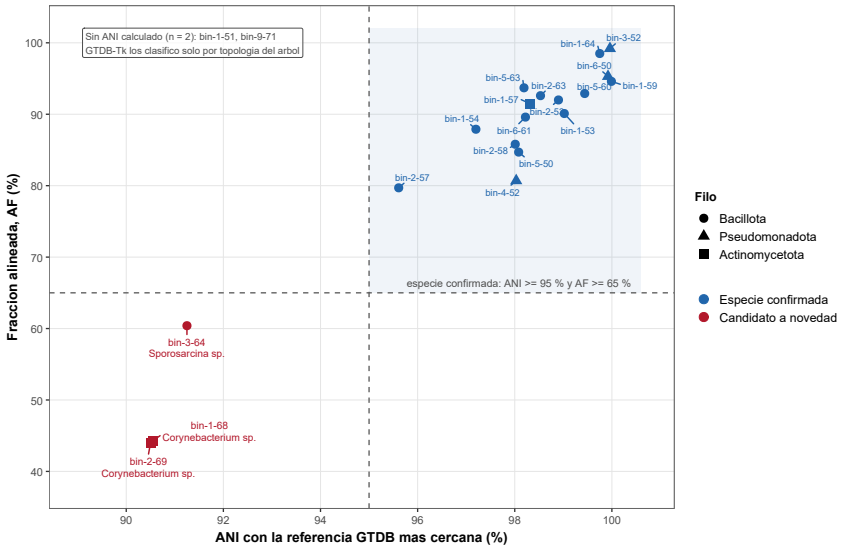


FIGURA 7.2: ANI frente a fracción alineada (AF) de cada genoma respecto de su referencia GTDB más cercana. Las líneas discontinuas marcan los criterios de especie (ANI $\geq$ 95 %, AF $\geq$ 65 %). Los 16 genomas del cuadrante sombreado tienen especie confirmada. `bin-1-51` y `bin-9-71` se clasificaron sin ANI y no aparecen.

dRep agrupó los 21 genomas en 19 linajes (Tabla 7.1, columnas de la izquierda). Solo colapsaron dos pares: los *Corynebacterium* (99.96 % de ANI, 97.1 % de cobertura) y los *Telluria timonae* (99.78 %, 85.2 %). El resto es mutuamente distante. Por lo que la redundancia entre muestras es baja y casi todo lo recuperado son organismos distintos. La prevalencia espacial también resultó baja. Diecisiete linajes aparecen en una sola muestra y ninguno en tres o más. Con apenas dos valores posibles, la prevalencia no permite ordenar los linajes. Los datos no permiten distinguir entre una comunidad viable heterogénea entre muestras y una recuperación limitada de genomas, que solo reconstruye bien un linaje en una de las muestras donde está.

Es por eso que la prevalencia se reporta como descripción y no se usa para elegir las especies del pangenoma (Sección 7.2.5).

Tabla 7.1: Linajes definidos en la Fase 2, ordenados por prevalencia espacial, y genomas públicos de su especie en cada paso de la selección de la Fase 3.

				Genomas públicos			
Linaje	**Taxonomía (GTDB)**	**Muestras**	**Conf.**	**Post-QC**	**Válidos**	**No red.**	**Fase 3**
L1	*Telluria timonae*	50, 52	Sí	3	—	—	No viable
L2	*Corynebacterium* sp.	68, 69	No	—	—	—	Sin especie
L3	*Bacillus_AB infantis*	61	Sí	9	—	—	No viable
L4	*Sporosarcina* sp.	64	No	—	—	—	Sin especie
L5	*Pantoea* sp.	51	—	—	—	—	Sin especie
L6	*Brevibacterium* sp021023135	57	Sí	—	—	—	Nombre provisional
L7	*Paenibacillus* sp001955535	59	Sí	—	—	—	Nombre provisional
L8	*Acinetobacter schindleri*	52	Sí	29	29	23	**Seleccionada**
L9	*Priestia flexa*	60	Sí	29	29	4	No viable
L10	*Aristophania* sp.	71	—	—	—	—	Sin especie
L11	*Staphylococcus warneri_A*	53	Sí	24	24	4	No viable
L12	*Peribacillus frigoritolerans*	54	Sí	72	69	42	**Seleccionada**
L13	*Rossellomorea marisflavi*	63	Sí	4	—	—	No viable
L14	*Bacillus licheniformis*	64	Sí	279	279	1	No viable
L15	*Metabacillus halosaccharovorans*	53	Sí	4	—	—	No viable
L16	*Bacillus altitudinis*	63	Sí	209	208	137	**Seleccionada**
L17	*Cytobacillus oceanisediminis*	57	Sí	1	—	—	No viable
L18	*Cytobacillus firmus_B*	50	Sí	18	18	12	No viable
L19	*Mesobacillus* sp014856545	58	Sí	—	—	—	Nombre provisional

Nota. Muestras: la prevalencia espacial es su número. Conf.: especie confirmada por ANI $\geq 95\,\%$ y AF $\geq 65\,\%$; el guion indica clasificación por topología, sin ANI. Post-QC: genomas aislados (sin MAGs) que pasan el control de calidad. Válidos: descargados y verificados, sin las exclusiones manuales. No red.: tras la desreplicación al 99 % de ANI. Los sufijos `_A`, `_B` y los epítetos `sp`⟨dígitos⟩ son nomenclatura propia del GTDB.

El OE2 se cumple. Los 21 genomas quedan clasificados a especie en 16 casos y a género en 5, y agrupados en 19 linajes. Dos resultados condicionan la Fase 3. En primer lugar, 17 linajes tienen un solo genoma, por lo que ningún pangenoma puede construirse solo con material de la Estela y hacen falta genomas públicos. En segundo lugar, los tres candidatos a especies no descritas quedan fuera del pangenoma por falta de referencias, pero son un hallazgo reportable por sí mismo.

7.2.3 Resultados de la Fase 3: análisis pangenómico comparativo (OE3)

La Fase 3 compara cada bin con los genomas públicos de su especie. Responde tres preguntas: cómo es el repertorio de genes de la especie, a qué cepa conocida se parece la cepa de la Estela y qué genes de esa cepa no tiene ninguna otra cepa conocida. Las cifras por especie se dan siempre en el orden *B. altitudinis* (L16), *P. frigoritolerans* (L12) y *A. schindleri* (L8).

7.2.3.1. Selección de especies y de referencias

Solo 12 de los 19 linajes tienen nombre de especie en GTDB. Quedaron fuera los cuatro clasificados hasta género (L2, L4, L5 y L10) y los tres con un nombre provisional del tipo `sp`⟨número⟩ (L6, L7 y L19), que no tienen un nombre estable en el NCBI. A los genomas públicos de cada especie se les exigió completitud de al menos 95 %, contaminación de hasta 5 %, no más de 300 contigs y ser aislados, no MAGs. A las referencias se les exige más que a los bins porque los bins son el objeto de estudio y las referencias se pueden elegir. El censo cuenta los genomas del clúster de especie de GTDB y no los del NCBI, porque ambos nombran distinto algunas especies (por ejemplo, *Telluria timonae* es *Massilia timonae* en el NCBI). Las columnas de la derecha de la Tabla 7.1 muestran cada paso.

Siete especies superaron los 15 genomas en el censo. *Telluria timonae* (L1) quedó fuera aunque es el linaje más prevalente, porque solo tiene ocho genomas en GTDB y cinco son MAGs. Se descargaron 660 genomas y se excluyeron cuatro que el NCBI rotula con un género de otro filo, lo que sugiere un ensamblaje quimérico. La desreplicación al 99 % cambió el orden. *B. licheniformis* (L14) pasó de 279 genomas a un solo grupo, con 99.58 % de ANI medio entre ellos: es en la práctica un clon muy secuenciado. Solo tres especies conservaron al menos 15 genomas no redundantes. Como el máximo previsto era de tres especies, no hubo que descartar ninguna. Solo

B. altitudinis superó el tope de 50. Ahí entraron primero sus cepas tipo y su único aislado de sustrato pétreo o árido, y el resto por rotación entre 10 hábitats y 8 continentes. En las otras dos especies entraron todos los no redundantes. En total entraron 115 referencias y 3 bins. Es importante mencionar que ninguna referencia procede de patrimonio pétreo y que el 28 % de los 656 genomas no declara su fuente de aislamiento.

7.2.3.2. Pangenoma de cada especie

Los 118 genomas se anotaron con Bakta sin ninguna alerta del control C5. Cada familia de genes se clasificó, solo con las referencias, como core (al menos en el 95 %), shell (del 15 al 95 %) o cloud (menos del 15 %). El accesorio es shell más cloud. El umbral del 95 % es el *soft core* de Roary [44]. La Tabla 7.2 resume el resultado.

Tabla 7.2: Tamaño y partición del pangenoma de cada especie, calculados solo con las referencias. Singletons: familias de una sola referencia. α: exponente de la ley de Heaps, con su rango al quitar un genoma cada vez.

Especie	Ref.	Core	Shell	Cloud	Pangenoma	Singletons	α
B. altitudinis	50	3303	847	2909	7059	1546 (22 %)	0.66 (0.64–0.68)
P. frigoritolerans	42	3961	2142	10022	16125	6103 (38 %)	0.57 (0.55–0.58)
A. schindleri	23	2389	1114	4096	7599	2782 (37 %)	0.55 (0.52–0.57)

En las tres especies el pangenoma sigue creciendo con la última referencia (Anexo 7.10). El exponente α de la ley de Heaps está entre 0.55 y 0.66. Un valor menor que 1 indica un pangenoma abierto, en el que cada genoma nuevo sigue aportando familias [72]. Se estimó con 500 permutaciones, con el procedimiento de micropan [73]. Es un resumen de la muestra de genomas disponible y no una propiedad fija de la especie [74]. *P. frigoritolerans* tiene el pangenoma más grande, con 16 125 familias. El orden se mantiene con submuestras de 23 genomas: unas 12 900 familias, frente a unas 6 000 en *B. altitudinis* y 7 599 en *A. schindleri*.

Un pangenoma puede parecer abierto por un error técnico. En un ensamblaje fragmentado, un gen partido entre dos contigs se cuenta como dos familias e infla el accesorio [35, 65]. Se descartó esa explicación con tres pruebas (Anexo 7.10). En primer lugar, las referencias con más contigs no tienen más familias únicas. En segundo lugar, α casi no cambia al usar solo genomas completos en *B. altitudinis* (0.64) y *A. schindleri* (0.55). En *P. frigoritolerans* sube a 0.74, con solo siete genomas completos. En tercer lugar, las proteínas hipotéticas son menos de la mitad del cloud (29 a 45 %). Por lo que la apertura no se debe a genes partidos. En *P. frigoritolerans* los genomas fragmentados la aumentan, pero no la explican.

La partición se calculó sin el bin (Sección 6.3.3). Si se cuenta el bin como un genoma más, el core pierde solo 15, 32 y 5 familias (0.2 a 0.8 %), porque el bin es uno entre 24 y 51 genomas. Pero con pocos genomas el efecto es grande [75]: en el piloto de cuatro genomas, el core cayó de 3 410 a 2 539 familias. Además, las familias exclusivas del bin (14, 34 y 70) habrían pasado al cloud y se habrían perdido como candidatas.

7.2.3.3. Posición de cada bin en su especie

La Tabla 7.3 reúne lo que se sabe de cada bin frente a su especie: sus genes, su lugar en el pangenoma, su pariente más cercano en el árbol del genoma core y su ANI contra todos los genomas válidos. Los árboles son de máxima verosimilitud, inferidos con IQ-TREE 3 [40] sobre el alineamiento del core con el bin incluido. Los árboles, sus estadísticas y las figuras complementarias están en el Anexo 7.10.

El bin de *P. frigoritolerans* tiene el 78 % de los genes de una cepa típica, aunque su completitud es de 92.3 %. El motivo por el cual ocurre es que CheckM2 mide la completitud con genes marcadores conservados, que se reconstruyen bien. Las regiones variables o móviles del accesorio suelen perderse en un MAG. Por lo

Tabla 7.3: Genes, posición en el pangenoma, pariente más cercano en el árbol del core y ANI de cada bin. Candidatos: genes de familias ausentes en todas las referencias. Eliminados: genes del bin que Panaroo eliminó en su limpieza. Distancia en sustituciones por sitio. ρ: correlación de Spearman entre el ANI y la distancia en el árbol.

	B. altitudinis	***P. frigoritolerans***	***A. schindleri***
Bin; completitud (CheckM2)	bin-5-63; 72.5 %	bin-1-54; 92.3 %	bin-4-52; 99.9 %
CDS del bin / mediana de la especie	2738 / 3789 (72 %)	4164 / 5337 (78 %)	3265 / 3123 (105 %)
Genes core / shell / cloud	2465 / 213 / 15	3406 / 520 / 200	2383 / 345 / 367
Candidatos / eliminados	14 / 32	34 / 7	70 / 101
Core de las referencias en el bin	75.2 %	85.7 %	99.0 %
Pariente más cercano	GCF_000828455.1	GCA_024160055.1	GCF_025514435.1
Origen del pariente	cereal fermentado, Países Bajos	suelo, Corea del Sur	clínico, EE. UU.
Distancia al pariente; UFBoot	0.016; 100	0.0017; 100	0.013; 100
Genomas comparados; con ANI $\geq 99\,\%$	208; 2	69; 8	29; 0
ANI máximo	99.06 %	99.98 %	98.39 %
ρ entre ANI y distancia	-0.33	-0.90	-0.50

que un gen presente en el bin indica que la cepa lo tiene, pero un gen ausente no prueba que le falte. Los tres bins contienen del core de las referencias un porcentaje parecido a su completitud, dentro de 10 puntos (control C6). Además, tienen menos candidatos que la referencia típica de su especie tiene familias únicas (18, 120 y 104). Por lo que las cepas de la Estela no tienen más genes propios que cualquier otra cepa.

Cada bin se agrupa con su pariente más cercano en el 100 % de las réplicas de UFBoot, por lo que su posición es confiable. El bin de *P. frigoritolerans* es prácticamente idéntico a un genoma ya secuenciado (99.98 % de ANI con GCA_900000145.1). Pertenece a un clon de ocho genomas aislado en cuatro continentes y seis ambientes distintos, desde suelo agrícola hasta nieve antártica, por lo que es un linaje cosmopolita. El de *B. altitudinis* también pertenece a un clon conocido (99.06 %), cuyos dos genomas quedaron fuera del pangenoma por la desreplicación o por el tope. El de *A. schindleri* no alcanza el 99 % con ningún genoma y cae dentro de un grupo de cepas clínicas, coherente con que 11 de sus 23 referencias lo son. Ningún bin se agrupa con las referencias de sustrato pétreo o árido. Pero el

hábitat del pariente refleja qué cepas se han secuenciado y no la ecología de la cepa en la Estela.

El árbol y el ANI miden el parentesco de dos maneras independientes, y concuerdan: el ANI baja cuando aumenta la distancia en el árbol (Tabla 7.3). En *B. altitudinis* la concordancia es débil porque todas las referencias quedan casi a la misma distancia del bin (98.0 a 98.4 % de ANI). En esa especie, además, 18 de los 48 nodos tienen UFBoot menor que 95, porque sus cepas son casi idénticas y la recombinación no se corrigió. Por lo que ese árbol ubica al bin, pero no ordena a las demás cepas.

7.2.3.4. Contenido accesorio, parentesco y hábitat

Esta prueba pregunta si dos cepas comparten genes accesorios porque están emparentadas o porque viven en el mismo hábitat. Si fuera por el hábitat, podría indicar adaptación a un ambiente como el sustrato pétreo. Para medirlo se calculó la distancia de Jaccard [76] entre el contenido accesorio de cada par de referencias, sin contar los singletons. Es decir, la fracción de familias accesorias que no comparten. La prueba de Mantel [77] mide si esa distancia sigue a la distancia en el árbol. La PERMANOVA [78] mide qué fracción de ella explica el hábitat, usando solo los hábitats con al menos tres referencias. Ambas usaron 9 999 permutaciones con una semilla fija.

En las tres especies las cepas emparentadas comparten más genes accesorios. La prueba de Mantel dio $r = 0.25$, 0.73 y 0.54, todas con $p < 0.001$. El hábitat, en cambio, no agrega una señal detectable. La PERMANOVA dio $R^2 = 0.17$ ($p = 0.36$, con 38 genomas en 7 hábitats), 0.04 ($p = 0.33$, con 28 en 2) y 0.15 ($p = 0.057$, con 17 en 3). Es el patrón descrito en el grupo *Bacillus pumilus*, al que pertenece *B. altitudinis* [79]. La prueba tiene poca potencia, porque hay pocos genomas por

hábitat y las categorías son gruesas. Que no se detecte un efecto no significa que no exista. Pero sí permite afirmar que el pangenoma, por sí solo, no aporta evidencia de adaptación al sustrato pétreo.

7.2.3.5. Genes específicos de la cepa

Un gen específico de la cepa es un gen del bin sin copia (al menos 80 % de identidad en el 80 % de su longitud) en ningún genoma de su especie depositado en el NCBI a la fecha de la búsqueda, el 10 de octubre de 2026. La definición es estrecha a propósito. No implica que el gen sea nuevo para la ciencia ni una adaptación a la piedra, porque puede estar idéntico en otra especie del mismo género. Los candidatos son los genes del bin cuya familia no aparece en ninguna referencia, más los que Panaroo eliminó. Cada candidato pasa por los filtros de la Tabla 6.7. La Tabla 7.4 muestra cuántos sobreviven a cada paso.

Tabla 7.4: Candidatos que sobreviven a cada filtro (versión 2). Entre paréntesis, los que proceden de genes eliminados por Panaroo.

Paso	***B. altitudinis***	***P. frigoritolerans***	***A. schindleri***
Candidatos	46 (32)	41 (7)	171 (101)
Descartados por F1 (cortos / borde / pseudogén)	12 / 9 / 0	12 / 0 / 0	26 / 4 / 4
Pasan F1	25	29	137
Presentes en otro genoma de la especie (F4)	11	28	40
Pasan F4 y van a F5	14	1	97
Contigs huérfanos enviados a F6	6	0	4
Advertencias por otros bins de la muestra (F3)	0	0	0
Descartados por F6 (contigs huérfanos)	12	0	1
Descartados por F5 (misma especie en nr)	0	1	45
Descartados por F5b (misma especie por ANI)	2	0	7
Genes específicos de la cepa	**0**	**0**	**44**
Con advertencia por identidad casi total	0	0	23

F4 es el filtro que más descarta. En *P. frigoritolerans*, 28 de los 29 candidatos están en otros genomas de la especie. En la primera versión, 24 de los 26 que F4 descartó estaban en un solo genoma, casi idéntico al bin, que la desreplicación había

sacado del pangenoma. En *A. schindleri* muchos estaban en las propias referencias con 80 a 97 % de identidad. Eran integrasas, transposasas y proteínas de fago que Panaroo separó en familias distintas. Por lo que sin buscar en todos los genomas de la especie la lista habría quedado inflada. En *B. altitudinis*, F6 descarta los 12 candidatos de contigs huérfanos. Ocho están en contigs idénticos a *B. subtilis* (99.86 a 100 %), es decir, ADN de otra bacteria de la muestra asignado al bin por error.

Solo *A. schindleri* conserva genes específicos: 44, en 13 contigs. Su mejor parecido en nr es otra especie de *Acinetobacter* en 39 casos, y 23 tienen al menos 99 % de identidad con ella, lo que sugiere una transferencia reciente. Los 44 genes forman 17 islas. En 15 de ellas el contenido de GC es menor que el del bin, 10 tienen cerca una integrasa, una transposasa o un gen de fago, y el 39 % de sus genes son proteínas hipotéticas (frente al 8 % del resto del bin). Esos tres rasgos indican transferencia horizontal [80]. Por lo que estos genes son, en su mayoría, ADN móvil adquirido de otras especies del género y no genes originados en la cepa. El detalle de las islas está en el Anexo 7.10. Bakta asignó un número KEGG a solo uno de los 44 genes, por lo que su relación con el biodeterioro se evaluará en la Fase 4 con DRAM.

7.2.3.6. Implicancia para el OE3

El OE3 se cumple para las tres especies con genomas públicos suficientes. Los resultados permiten afirmar lo siguiente:

- Los pangenomas de las tres especies son abiertos, con un core de 2 389 a 3 961 familias. La apertura no se explica por la fragmentación de los ensamblajes.
- Cada cepa de la Estela se ubica con soporte máximo junto a una cepa conocida de otro continente y de otro ambiente. La de *P. frigoritolerans* pertenece a un clon cosmopolita, la de *B. altitudinis* a un clon conocido y la de *A. schindleri* es distinta de todas las secuenciadas.

- El contenido accesorio sigue al parentesco y no al hábitat.
- Solo la cepa de *A. schindleri* tiene genes específicos (44), y casi todos parecen adquiridos de otras especies de *Acinetobacter*.

Estas afirmaciones tienen tres límites. En primer lugar, los bins son MAGs, por lo que la ausencia de un gen no es concluyente, sobre todo en `bin-5-63` (72.5 %). En segundo lugar, las referencias se limitan a GTDB R220, y los genomas posteriores solo se revisan a través de nr. Por último, la especificidad de un gen es relativa a lo secuenciado a la fecha de la consulta. A la Fase 4 pasan la ubicación de cada gen del bin en el pangenoma y la lista de genes específicos.

7.2.4 Sensibilidad de los resultados a los umbrales elegidos

Ninguno de los 13 escenarios cambia las conclusiones de las tres fases (Anexo 7.11). En la Fase 1, el umbral de contaminación es el que más define el tamaño del conjunto: entre 1 y 10 % se retienen de 16 a 22 genomas. El criterio de dominio es el paso más sensible, pero CheckM2 elimina después la mezcla de dominios. El número de linajes se mantiene en 19 con cualquier umbral de ANI entre 95 y 99.5 %. En la Fase 3 se seleccionan las mismas tres especies con 99 o 99.5 % de desreplicación y con 200 a 1 000 contigs. El core es idéntico entre los modos de Panaroo y crece menos de 3 % con un umbral del 90 %. Por último, usar UniProtKB en lugar de nr o el nombre de la especie en lugar del ANI habría dejado pasar 7 y 5 genes falsos como específicos. Es por eso que el caso base usa nr y el ANI.

7.2.5 Iteraciones de diseño derivadas de los resultados

El diseño cambió seis veces durante la ejecución porque algunos resultados obligaron a modificarlo. El Capítulo V conserva el diseño original, y el Anexo 7.12

detalla cada ciclo de prueba, evaluación y rediseño. En primer lugar, el árbol con todas las referencias de GTDB no cupo en la memoria y se reemplazó por un árbol interno en la Fase 2 y uno de máxima verosimilitud por especie en la Fase 3. En segundo lugar, la prevalencia espacial no permitió ordenar los linajes y se reemplazó por la disponibilidad de genomas públicos. En tercer lugar, el modo `strict` de Panaroo eliminaba justo los genes de un solo genoma que se buscaban, y se usó `moderate` con la partición calculada solo con las referencias. En cuarto lugar, la primera versión de los genes específicos perdía los genes que Panaroo eliminó y confiaba en el nombre de la especie. Por eso se ampliaron los candidatos y se agregaron F5b y la regla nueva de F6. En quinto lugar, la opción remota de BLAST+ no funcionaba en el clúster y se reemplazó por la interfaz web del NCBI. Por último, Bakta anotó con COG muy pocos genes, por lo que la comparación funcional pasa a la Fase 4.

7.3 Verificación del cumplimiento de las especificaciones técnicas

Las especificaciones se derivan de los objetivos OE1, OE2 y OE3 y admiten una verificación cuantitativa directa. La Tabla 7.5 cruza cada una con su método de verificación y su resultado.

Tabla 7.5: Matriz de verificación del cumplimiento de las especificaciones técnicas.

Especificación	**Método**	**Objetivo**	**Resultado**	**Cumple**
Fases 1 y 2 (OE1 y OE2)				
Calidad de los genomas	CheckM2	Compl. $> 70\,\%$, cont. $< 5\,\%$	21 de 21; medianas 99.86 y 0.44 %	Sí
Resolución taxonómica	GTDB-Tk (R220) y ANI	Al menos género	21 a género; 16 a especie	Sí
Trazabilidad genoma–muestra	Tabla de correspondencia	21 de 21	21 de 21	Sí
Unidades no redundantes	dRep al 95 % de ANI	Sin duplicados	19 linajes; 2 parejas colapsadas	Sí
Reproducibilidad	Registro y control de versiones	Versiones registradas	Registro por fase; repositorio	Sí

Tabla 7.5 (continuación)

Especificación	Método	Objetivo	Resultado	Cumple
Fase 3 (OE3)				
Especies con pangenoma	Censo y desreplicación	≥ 15 no redundantes	3 especies (137, 42 y 23)	Sí
Anotación homogénea	Bakta único; control C5	Sin alertas	118 de 118; 0 alertas	Sí
Partición estable	Sensibilidad (E7, E8)	Core estable	+0.8 a 3.0 %; idéntico entre modos	Sí
Calidad del bin	Core recuperado (C6)	±10 puntos de la completitud	3 de 3 (75.2, 85.7 y 99.0 %)	Sí
Ubicación filogenética	Máxima verosimilitud	UFBoot ≥ 95	UFBoot 100 en los 3 bins	Sí
Genes específicos	Filtros F1 a F6	Lista verificada	44 en *A. schindleri*; 0 en las otras	Sí
Selección reproducible	Reglas deterministas	Mismo resultado al repetir	Semillas fijas en IQ-TREE y R	Sí

7.4 Verificación del cumplimiento de restricciones

Las restricciones son límites que el diseño no podía cruzar (Tabla 4.1). La Tabla 7.6 verifica cada una.

Tabla 7.6: Matriz de verificación del cumplimiento de las restricciones del proyecto.

Restricción	Forma en que el diseño la respeta	Cumple
Cuota de 32 núcleos, 98 GB y 24 h por trabajo, y cinco trabajos enviados	Todos los trabajos terminaron dentro del límite (Tabla 6.3). El árbol con todas las referencias de GTDB se reemplazó por árboles más pequeños	Sí
Nodos de cómputo sin internet	Las bases y los genomas se descargan en el login. Solo el censo, la descarga y la búsqueda remota corren ahí	Sí
Sin lecturas crudas	El flujo opera sobre bins ya ensamblados	Sí
Muestras cerradas y no ampliables	Se trabaja con las 22 librerías. La baja prevalencia se reporta como limitación	Sí
Software y bases de acceso libre	Todas las herramientas y bases son abiertas, incluido el NCBI	Sí
Dependencia del NCBI	La búsqueda remota se reanuda tras un corte y distingue «sin resultado» de «sin parecidos». Se reporta la fecha de consulta	Sí

Tabla 7.6 (continuación)

Restricción	**Forma en que el diseño la respeta**	**Cumple**
Bases públicas con muestreo desigual	Desreplicación al 99 %, rotación de hábitats y verificación contra todos los genomas de la especie. El sesgo restante se declara	Sí

REFERENCIAS BIBLIOGRÁFICAS

[1] A. Cordy-Collins, "Richard l. burger, *Chavín and the Origins of Andean Civilization*. 248 pages, 245 illustrations. london: Thames & hudson, 1992. ISBN 0-500-05069-4, hardback," *Antiquity*, vol. 67, no. 257, pp. 947–948, dec 1993, book review.

[2] R. Hernández Asensio, "Las piedras suplican auxilio. arqueólogos, huaqueros y autoridades locales en chavín de huántar (1870–1945)," *Histórica*, vol. 36, no. 2, pp. 113–138, 2012.

[3] Museo Nacional de Arqueología, Antropología e Historia del Perú, *Los Tesoros del Museo: Colección Lítica*. Lima, Perú: Ministerio de Cultura del Perú, 2015.

[4] T. C. Dakal and S. S. Cameotra, "Microbially induced deterioration of architectural heritages: routes and mechanisms involved," *Environmental Sciences Europe*, vol. 24, p. 36, 2012.

[5] F. Villa, P. S. Stewart, I. Klapper, J. M. Jacob, and F. Cappitelli, "Subaerial biofilms on outdoor stone monuments: changing the perspective toward an ecological framework," *BioScience*, vol. 66, no. 4, pp. 285–294, 2016.

[6] D. G. Alonso-Reyes, F. S. Galván, N. N. Alvarado, M. C. D'Arpino, L. J. Martinez, H. J. Esquivel, C. A. Gallardo, M. J. Silva Manco, and V. H. Albarracín, "Echoes of 1816: microbial footprints in heritage artifacts from Argentina's museum of independence," *Frontiers in Microbiology*, vol. 16, p. 1611832, 2025.

[7] P. J. A. Skipper, L. K. Skipper, and R. A. Dixon, "A metagenomic analysis of the bacterial microbiome of limestone, and the role of associated biofilms in the biodeterioration of heritage stone surfaces," *Scientific Reports*, vol. 12, p. 4877, 2022.

[8] T. Branyšová, K. Demnerová, M. Ďurovič, and H. Stiborová, "Microbial biodeterioration of cultural heritage and identification of the active agents over the last two decades," *Journal of Cultural Heritage*, vol. 55, pp. 245–260, 2022.

[9] M. A. Pita-Galeana, M. Ruhle, L. López-Vázquez, G. de Anda-Jáuregui, and E. Hernández-Lemus, "Computational metagenomics: state of the art," *International Journal of Molecular Sciences*, vol. 26, no. 18, p. 9206, 2025.

[10] P. Tsukayama Cisneros, S. Zurita Macalupú, R. Cristóbal Delgado, A. Ampuero León, Y. Piucón Campos, F. Caballero Salazar, P. Carrasco Zúñiga, and K. Lugo Bardales, "Informe técnico del análisis microbiológico de la Estela Raimondi," Universidad Peruana Cayetano Heredia y Museo Nacional de Arqueología, Antropología e Historia del Perú (MNAAHP), Lima, Perú, Informe técnico interno Orden de Servicio N.º 0006172-2025, 2025.

[11] F. Jroundi, K. Elert, E. Ruiz-Agudo, M. T. González-Muñoz, and C. Rodriguez-Navarro, "Bacterial diversity evolution in Maya plaster and stone following a bio-conservation treatment," *Frontiers in Microbiology*, vol. 11, p. 599144, 2020.

[12] K. Sterflinger and G. Piñar, "Microbial deterioration of cultural heritage and works of art — tilting at windmills?" *Applied Microbiology and Biotechnology*, vol. 97, no. 22, pp. 9637–9646, 2013.

[13] F. Cappitelli, C. Cattò, and F. Villa, "The control of cultural heritage microbial deterioration," *Microorganisms*, vol. 8, no. 10, p. 1542, 2020.

[14] A. Chklovski, D. H. Parks, B. J. Woodcroft, and G. W. Tyson, "CheckM2: a rapid, scalable and accurate tool for assessing microbial genome quality using machine learning," *Nature Methods*, vol. 20, no. 8, pp. 1203–1212, 2023.

[15] P.-A. Chaumeil, A. J. Mussig, P. Hugenholtz, and D. H. Parks, "GTDB-Tk: a toolkit to classify genomes with the Genome Taxonomy Database," *Bioinformatics*, vol. 36, no. 6, pp. 1925–1927, 2020.

[16] H. Suchy, P. Zalar, and M. F. Macedo, "Microbial diversity of biodeteriorated limestone cultural heritage assets identified using molecular approaches—A literature review," *Applied Sciences*, vol. 14, p. 7429, 2024.

[17] Q. Li, B. Zhang, X. Yang, and Q. Ge, "Deterioration-associated microbiome of stone monuments: structure, variation, and assembly," *Applied and Environmental Microbiology*, vol. 84, no. 7, pp. e02 680–17, 2018.

[18] B. Gutarowska, S. Celikkol-Aydin, V. Bonifay, A. Otlewska, E. Aydin, A. L. Oldham, J. I. Brauer, K. E. Duncan, J. Adamiak, J. A. Sunner, and I. B. Beech, "Metabolomic and high-throughput sequencing analysis—modern approach for the assessment of biodeterioration of materials from historic buildings," *Frontiers in Microbiology*, vol. 6, p. 979, 2015.

[19] E. Zanardini, E. May, K. J. Purdy, and J. C. Murrell, "Nutrient cycling potential within microbial communities on culturally important stoneworks," *Environmental Microbiology Reports*, vol. 11, no. 2, pp. 147–154, 2019.

[20] A. A. Gorbushina, "Life on the rocks," *Environmental Microbiology*, vol. 9, no. 10, pp. 2418–2425, 2007.

[21] G. Chimienti, R. Piredda, G. Pepe, I. D. van der Werf, L. Sabbatini, C. Crecchio, P. Ricciuti, A. M. D'Erchia, C. Manzari, G. Pesole *et al.*, "Profile of microbial communities on carbonate stones of the medieval church of San Leonardo di

Siponto (Italy) by Illumina-based deep sequencing," *Applied Microbiology and Biotechnology*, vol. 100, no. 19, pp. 8537–8548, 2016.

[22] X. Ding, W. Lan, J. Wu, Y. Hong, Y. Li, Q. Ge, C. Urzì, Y. Katayama, and J.-D. Gu, "Microbiome and nitrate removal processes by microorganisms on the ancient Preah Vihear temple of cambodia revealed by metagenomics and N-15 isotope analyses," *Applied Microbiology and Biotechnology*, vol. 104, no. 22, pp. 9823–9837, 2020.

[23] X. Ding, W. Lan, and J.-D. Gu, "A review on sampling techniques and analytical methods for microbiota of cultural properties and historical architecture," *Applied Sciences*, vol. 10, no. 22, p. 8099, 2020.

[24] E. Gallego-Cartagena, H. Morillas, and M. Maguregui, "Biodeterioration of built heritage in the context of climate change and atmospheric pollution: Toward transdisciplinary conservation strategies," *Science of The Total Environment*, vol. 1013, p. 181313, 2026.

[25] S. Yadav and D. Purchase, "Biodeterioration of cultural heritage monuments: A review of their deterioration mechanisms and conservation," *International Biodeterioration & Biodegradation*, vol. 201, p. 106066, 2025.

[26] H.-C. Flemming and J. Wingender, "The biofilm matrix," *Nature Reviews Microbiology*, vol. 8, no. 9, pp. 623–633, 2010.

[27] M. Y. Galperin, N. Yutin, Y. I. Wolf, R. Vera Alvarez, and E. V. Koonin, "Conservation and evolution of the sporulation gene set in diverse members of the Firmicutes," *Journal of Bacteriology*, vol. 204, no. 6, pp. e00 079–22, 2022.

[28] D. Li, C.-M. Liu, R. Luo, K. Sadakane, and T.-W. Lam, "MEGAHIT: An ultra-fast single-node solution for large and complex metagenomics assembly via succinct de Bruijn graph," *Bioinformatics*, vol. 31, no. 10, pp. 1674–1676, 2015.

[29] S. Nurk, D. Meleshko, A. Korobeynikov, and P. A. Pevzner, "metaSPAdes: a new versatile metagenomic assembler," *Genome Research*, vol. 27, no. 5, pp. 824–834, 2017.

[30] R. M. Bowers, N. C. Kyrpides, R. Stepanauskas, M. Harmon-Smith, D. Doud, T. B. K. Reddy, F. Schulz, J. Jarett, A. R. Rivers, E. A. Eloe-Fadrosh *et al.*, "Minimum information about a single amplified genome (MISAG) and a metagenome-assembled genome (MIMAG) of bacteria and archaea," *Nature Biotechnology*, vol. 35, no. 8, pp. 725–731, 2017.

[31] D. D. Kang, F. Li, E. Kirton, A. Thomas, R. S. Egan, H. An, and Z. Wang, "MetaBAT 2: an adaptive binning algorithm for robust and efficient genome reconstruction from metagenome assemblies," *PeerJ*, vol. 7, p. e7359, 2019.

[32] C. M. K. Sieber, A. J. Probst, A. Sharrar, B. C. Thomas, M. Hess, S. G. Tringe, and J. F. Banfield, "Recovery of genomes from metagenomes via a dereplication, aggregation and scoring strategy," *Nature Microbiology*, vol. 3, no. 7, pp. 836–843, 2018.

[33] A. M. Eren, Ö. C. Esen, C. Quince, J. H. Vineis, H. G. Morrison, M. L. Sogin, and T. O. Delmont, "Anvi'o: an advanced analysis and visualization platform for 'omics data," *PeerJ*, vol. 3, p. e1319, 2015.

[34] M. Shaffer, M. A. Borton, B. B. McGivern, A. A. Zayed, S. L. La Rosa, L. M. Solden, P. Liu, A. B. Narrowe, J. Rodríguez-Ramos, B. Bolduc *et al.*, "DRAM for distilling microbial metabolism to automate the curation of microbiome function," *Nucleic Acids Research*, vol. 48, no. 16, pp. 8883–8900, 2020.

[35] G. Tonkin-Hill, N. MacAlasdair, C. Ruis, A. Weimann, G. Horesh, J. A. Lees, N. J. Croucher, R. Carter, D. M. Aanensen, S. D. Bentley *et al.*, "Producing polished prokaryotic pangenomes with the Panaroo pipeline," *Genome Biology*, vol. 21, no. 1, p. 180, 2020.

[36] D. H. Parks, M. Imelfort, C. T. Skennerton, P. Hugenholtz, and G. W. Tyson, "CheckM: assessing the quality of microbial genomes recovered from isolates, single cells, and metagenomes," *Genome Research*, vol. 25, no. 7, pp. 1043–1055, 2015.

[37] C. Jain, L. M. Rodriguez-R, A. M. Phillippy, K. T. Konstantinidis, and S. Aluru, "High throughput ANI analysis of 90k prokaryotic genomes reveals clear species boundaries," *Nature Communications*, vol. 9, p. 5114, 2018.

[38] D. H. Parks, M. Chuvochina, C. Rinke, A. J. Mussig, P.-A. Chaumeil, and P. Hugenholtz, "GTDB: an ongoing census of bacterial and archaeal diversity through a phylogenetically consistent, rank normalized and complete genome-based taxonomy," *Nucleic Acids Research*, vol. 50, no. D1, pp. D785–D794, 2022.

[39] M. R. Olm, C. T. Brown, B. Brooks, and J. F. Banfield, "drep: a tool for fast and accurate genomic comparisons that enables improved genome recovery from metagenomes through de-replication," *The ISME Journal*, vol. 11, no. 12, pp. 2864–2868, 2017.

[40] T. K. F. Wong, N. Ly-Trong, H. Ren, P. Demotte, H. Baños, A. J. Roger, E. Susko, C. Bielow, N. De Maio, N. Goldman, M. W. Hahn, M. dos Reis, L. S. Vinh, G. Huttley, R. Lanfear, and B. Q. Minh, "IQ-TREE 3: phylogenomic inference software using complex evolutionary models," *Molecular Biology and Evolution*, vol. 43, no. 5, p. msag117, 2026.

[41] S. Kalyaanamoorthy, B. Q. Minh, T. K. F. Wong, A. von Haeseler, and L. S. Jermiin, "ModelFinder: fast model selection for accurate phylogenetic estimates," *Nature Methods*, vol. 14, no. 6, pp. 587–589, 2017.

[42] D. T. Hoang, O. Chernomor, A. von Haeseler, B. Q. Minh, and L. S. Vinh, "UFBoot2: improving the ultrafast bootstrap approximation," *Molecular Biology and Evolution*, vol. 35, no. 2, pp. 518–522, 2018.

[43] H. Tettelin, V. Masignani, M. J. Cieslewicz, C. Donati, D. Medini, N. L. Ward, S. V. Angiuoli, J. Crabtree, A. L. Jones, A. S. Durkin *et al.*, "Genome analysis of multiple pathogenic isolates of *Streptococcus agalactiae*: implications for the microbial "pan-genome"," *Proceedings of the National Academy of Sciences*, vol. 102, no. 39, pp. 13 950–13 955, 2005.

[44] A. J. Page, C. A. Cummins, M. Hunt, V. K. Wong, S. Reuter, M. T. G. Holden, M. Fookes, D. Falush, J. A. Keane, and J. Parkhill, "Roary: rapid large-scale prokaryote pan genome analysis," *Bioinformatics*, vol. 31, no. 22, pp. 3691–3693, 2015.

[45] S. M. Soucy, J. Huang, and J. P. Gogarten, "Horizontal gene transfer: building the web of life," *Nature Reviews Genetics*, vol. 16, no. 8, pp. 472–482, 2015.

[46] G. Gautreau, A. Bazin, M. Gachet, R. Planel, L. Burlot, M. Dubois, A. Perrin, C. Médigue, A. Calteau, S. Cruveiller *et al.*, "PPanGGOLiN: Depicting microbial diversity via a partitioned pangenome graph," *PLOS Computational Biology*, vol. 16, no. 3, p. e1007732, 2020.

[47] D. Hyatt, G.-L. Chen, P. F. Locascio, M. L. Land, F. W. Larimer, and L. J. Hauser, "Prodigal: prokaryotic gene recognition and translation initiation site identification," *BMC Bioinformatics*, vol. 11, p. 119, 2010.

[48] T. Seemann, "Prokka: rapid prokaryotic genome annotation," *Bioinformatics*, vol. 30, no. 14, pp. 2068–2069, 2014.

[49] O. Schwengers, L. Jelonek, M. A. Dieckmann, S. Beyvers, J. Blom, and A. Goesmann, "Bakta: rapid and standardized annotation of bacterial genomes via

alignment-free sequence identification," *Microbial Genomics*, vol. 7, no. 11, p. 000685, 2021.

[50] M. Kanehisa, M. Furumichi, Y. Sato, M. Kawashima, and M. Ishiguro-Watanabe, "KEGG for taxonomy-based analysis of pathways and genomes," *Nucleic Acids Research*, vol. 51, no. D1, pp. D587–D592, 2023.

[51] B. L. Cantarel, P. M. Coutinho, C. Rancurel, T. Bernard, V. Lombard, and B. Henrissat, "The carbohydrate-active enzymes database (CAZy): an expert resource for glycogenomics," *Nucleic Acids Research*, vol. 37, no. Supplement 1, pp. D233–D238, 2009.

[52] H. Zhang, T. Yohe, L. Huang, S. Entwistle, P. Wu, Z. Yang, P. K. Busk, Y. Xu, and Y. Yin, "dbCAN2: a meta server for automated carbohydrate-active enzyme annotation," *Nucleic Acids Research*, vol. 46, no. W1, pp. W95–W101, 2018.

[53] B. P. Alcock, A. R. Raphenya, T. T. Y. Lau, K. K. Tsang, M. Bouchard, A. Edalatmand, W. Huynh, A.-L. V. Nguyen, A. A. Cheng, S. Liu, S. Y. Min, A. Miroshnichenko, H.-K. Tran, R. E. Werfalli, J. A. Nasir, M. Oloni, D. J. Speicher, A. Florescu, B. Singh, M. Faltyn, A. Hernandez-Koutoucheva, A. N. Sharma, E. Bordeleau, A. C. Pawlowski, H. L. Zubyk, D. Dooley, E. Griffiths, F. Maguire, G. L. Winsor, R. G. Beiko, F. S. L. Brinkman, W. W. L. Hsiao, G. V. Domselaar, and A. G. McArthur, "CARD 2020: antibiotic resistome surveillance with the Comprehensive Antibiotic Resistance Database," *Nucleic Acids Research*, vol. 48, no. D1, pp. D517–D525, 2020.

[54] M. Karlicki, S. Antonowicz, and A. Karnkowska, "Tiara: deep learning-based classification system for eukaryotic sequences," *Bioinformatics*, vol. 38, no. 2, pp. 344–350, 2022.

[55] L. J. U. Pronk and M. H. Medema, "Whokaryote: distinguishing eukaryotic and prokaryotic contigs in metagenomes based on gene structure," *Microbial Genomics*, vol. 8, no. 5, p. mgen000823, 2022.

[56] P. T. West, A. J. Probst, I. V. Grigoriev, B. C. Thomas, and J. F. Banfield, "Genome-reconstruction for eukaryotes from complex natural microbial communities," *Genome Research*, vol. 28, no. 4, pp. 569–580, 2018.

[57] B. Q. Minh, H. A. Schmidt, O. Chernomor, D. Schrempf, M. D. Woodhams, A. von Haeseler, and R. Lanfear, "Iq-tree 2: New models and efficient methods for phylogenetic inference in the genomic era," *Molecular Biology and Evolution*, vol. 37, no. 5, pp. 1530–1534, 2020.

[58] A. A. Elistratova, E. N. Dekhanova, D. R. Kamaldinova, E. I. Shagimardanova, M. R. Sharipova, M. F. Cohen, and I. V. Khilyas, "Extracellular molecular repertoire of xerotolerant actinobacteria colonizing serpentinite rocks," *International Journal of Molecular Sciences*, vol. 27, no. 10, p. 4233, 2026.

[59] D. G. Alonso-Reyes, F. S. Galván, L. R. Portero, N. N. Alvarado, M. E. Farías, M. P. Vazquez, and V. H. Albarracín, "Genomic insights into an andean multiresistant soil actinobacterium of biotechnological interest," *World Journal of Microbiology and Biotechnology*, vol. 37, no. 10, p. 166, 2021.

[60] N. Goosen and G. F. Moolenaar, "Repair of UV damage in bacteria," *DNA Repair*, vol. 7, no. 3, pp. 353–379, 2008.

[61] N. K. Dhami, M. S. Reddy, and A. Mukherjee, "Biomineralization of calcium carbonates and their engineered applications: a review," *Frontiers in Microbiology*, vol. 4, p. 314, 2013.

[62] Q. Li, B. Zhang, X. Yang, and Q. Ge, "Deterioration-associated microbiome of stone monuments: Structure, variation, and assembly," *Applied and Environmental Microbiology*, vol. 84, no. 7, pp. e02 680–17, 2018.

[63] A. Basile, F. P. Riggio, M. Tescari, A. Chebbi, A. Sodo, F. Bartoli, F. Imperi, G. Caneva, and P. Visca, "Metagenome-resolved functional traits of Rubrobacter species implicated in rosy discoloration of ancient frescoes in two Georgian cathedrals," *Science of the Total Environment*, vol. 958, p. 178135, 2025.

[64] M. Skovgaard, L. J. Jensen, S. Brunak, D. Ussery, and A. Krogh, "On the total number of genes and their length distribution in complete microbial genomes," *Trends in Genetics*, vol. 17, no. 8, pp. 425–428, 2001.

[65] J. F. Denton, J. Lugo-Martinez, A. E. Tucker, D. R. Schrider, W. C. Warren, and M. W. Hahn, "Extensive error in the number of genes inferred from draft genome assemblies," *PLoS Computational Biology*, vol. 10, no. 12, p. e1003998, 2014.

[66] A. Shaiber and A. M. Eren, "Composite metagenome-assembled genomes reduce the quality of public genome repositories," *mBio*, vol. 10, no. 3, pp. e00 725–19, 2019.

[67] C. Camacho, G. Coulouris, V. Avagyan, N. Ma, J. Papadopoulos, K. Bealer, and T. L. Madden, "BLAST+: architecture and applications," *BMC Bioinformatics*, vol. 10, p. 421, 2009.

[68] W. Shen and H. Ren, "TaxonKit: a practical and efficient NCBI taxonomy toolkit," *Journal of Genetics and Genomics*, vol. 48, no. 9, pp. 844–850, 2021.

[69] S. Ciufo, S. Kannan, S. Sharma, A. Badretdin, K. Clark, S. Turner, S. Brover, C. L. Schoch, A. Kimchi, and M. DiCuccio, "Using average nucleotide identity to improve taxonomic assignments in prokaryotic genomes at the NCBI," *International Journal of Systematic and Evolutionary Microbiology*, vol. 68, no. 7, pp. 2386–2392, 2018.

[70] N. A. O'Leary, E. Cox, J. B. Holmes, W. R. Anderson, R. Falk, V. Hem, M. T. N. Tsuchiya, G. D. Schuler, X. Zhang, J. Torcivia *et al.*, "Exploring and retrieving

sequence and metadata for species across the tree of life with NCBI Datasets," *Scientific Data*, vol. 11, p. 732, 2024.

[71] J. Shaw and Y. W. Yu, "Fast and robust metagenomic sequence comparison through sparse chaining with skani," *Nature Methods*, vol. 20, no. 11, pp. 1661–1665, 2023.

[72] H. Tettelin, D. Riley, C. Cattuto, and D. Medini, "Comparative genomics: the bacterial pan-genome," *Current Opinion in Microbiology*, vol. 11, no. 5, pp. 472–477, 2008.

[73] L. Snipen and K. H. Liland, "micropan: an R-package for microbial pan-genomics," *BMC Bioinformatics*, vol. 16, p. 79, 2015.

[74] A. Guerra, "The pangenome: a statistical model, not a fixed biological property," *Bioinformatics Advances*, vol. 6, no. 1, p. vbag069, 2026.

[75] T. Li and Y. Yin, "Critical assessment of pan-genomic analysis of metagenome-assembled genomes," *Briefings in Bioinformatics*, vol. 23, no. 6, p. bbac413, 2022.

[76] P. Jaccard, "The distribution of the flora in the alpine zone," *New Phytologist*, vol. 11, no. 2, pp. 37–50, 1912.

[77] N. Mantel, "The detection of disease clustering and a generalized regression approach," *Cancer Research*, vol. 27, no. 2, pp. 209–220, 1967.

[78] M. J. Anderson, "A new method for non-parametric multivariate analysis of variance," *Austral Ecology*, vol. 26, no. 1, pp. 32–46, 2001.

[79] X. Fu, L. Gong, Y. Liu, Q. Lai, G. Li, and Z. Shao, "*Bacillus pumilus* group comparative genomics: toward pangenome features, diversity, and marine environmental adaptation," *Frontiers in Microbiology*, vol. 12, p. 571212, 2021.

[80] M. Ravenhall, N. Škunca, F. Lassalle, and C. Dessimoz, "Inferring horizontal gene transfer," *PLoS Computational Biology*, vol. 11, no. 5, p. e1004095, 2015.

[81] J. L. Klassen and C. R. Currie, "Gene fragmentation in bacterial draft genomes: extent, consequences and mitigation," *BMC Genomics*, vol. 13, p. 14, 2012.

[82] D. H. Parks, M. Chuvochina, C. Rinke, A. J. Mussig, P.-A. Chaumeil, and P. Hugenholtz, "GTDB: an ongoing census of bacterial and archaeal diversity through a phylogenetically consistent, rank normalized and complete genome-based taxonomy," *Nucleic Acids Research*, vol. 50, no. D1, pp. D785–D794, 2022.

[83] N. Saitou and M. Nei, "The neighbor-joining method: a new method for reconstructing phylogenetic trees," *Molecular Biology and Evolution*, vol. 4, no. 4, pp. 406–425, 1987.

[84] J. Felsenstein, "Evolutionary trees from DNA sequences: a maximum likelihood approach," *Journal of Molecular Evolution*, vol. 17, no. 6, pp. 368–376, 1981.

ANEXOS

ANEXO ABET ING 1 - Resolución de problemas

Para filtrar por dominio los MAGs obtenidos se evaluaron las siguientes herramientas:

Tiara: Es una herramienta de clasificación de secuencias metagenómicas basada en *deep learning* que permite separar contigs en categorías como arqueas, bacterias, procariotas, eucariotas, orgánulos y secuencias desconocidas mediante un esquema de dos etapas [54]. Según su publicación original, mostró un rendimiento similar a EukRep para la clasificación de secuencias procariotas, pero superior para secuencias eucariotas, además de requerir menor tiempo de cómputo [54]. Su principal ventaja es que no solo discrimina entre eucariotas y procariotas, sino que también puede identificar ADN organelar, lo que la hace especialmente útil en metagenomas complejos. Sin embargo, al basarse principalmente en patrones de composición de secuencia, puede presentar ambigüedad en linajes evolutivamente inusuales o muy cercanos a eucariotas, por lo que sus resultados deben interpretarse como una clasificación preliminar y no como una asignación taxonómica definitiva.

Whokaryote: Es un clasificador diseñado para distinguir contigs eucariotas y procariotas a partir de características de estructura génica, como la densidad génica, la distancia intergénica y la longitud de los genes, utilizando un modelo de *random*

forest [55]. A diferencia de Tiara y EukRep, que dependen sobre todo de frecuencias de *k-mers*, Whokaryote se apoya en diferencias biológicas más interpretables entre ambos dominios. En su artículo, los autores reportan una exactitud cercana al 97 %, indicando además que su desempeño es comparable al de Tiara y EukRep, con la ventaja adicional de aportar una validación independiente basada en otro tipo de señal [55]. Su principal fortaleza es precisamente esa complementariedad metodológica, ya que puede ayudar a confirmar o cuestionar clasificaciones obtenidas por herramientas basadas en composición. Como desventaja, depende de rasgos derivados de genes predichos, por lo que su ejecución es menos directa y puede ser más sensible a la calidad del ensamblado y de la predicción génica subyacente.

EukRep: Es una de las herramientas pioneras para separar secuencias eucariotas de procariotas en ensamblados metagenómicos, utilizando frecuencias de *k-mers* y un clasificador lineal tipo SVM [56]. Su objetivo principal es servir como filtro inicial para recuperar secuencias eucariotas y permitir después el uso de *pipelines* de anotación y análisis específicos para eucariotas. En su publicación original, mostró una exactitud global cercana al 90 % con fragmentos de 3 kb y de aproximadamente 98 % con fragmentos de 20 kb, lo que evidencia un mejor rendimiento en contigs largos [56]. Su ventaja principal es que se trata de una herramienta ampliamente reconocida y adoptada en estudios de recuperación de genomas eucariotas a partir de metagenomas. No obstante, sus limitaciones incluyen un menor desempeño relativo frente a Tiara en la clasificación de eucariotas y la ausencia de una clasificación explícita de secuencias organelares, además de que su precisión puede disminuir en fragmentos más cortos o en ensamblados altamente fragmentados.

ANEXO ABET ING 5 - Trabajo en equipo

En este anexo se presenta la evidencia del trabajo colaborativo desarrollado durante la ejecución del proyecto. Se podrán incluir reuniones de coordinación, distribución de tareas, seguimiento de avances y productos elaborados en conjunto.

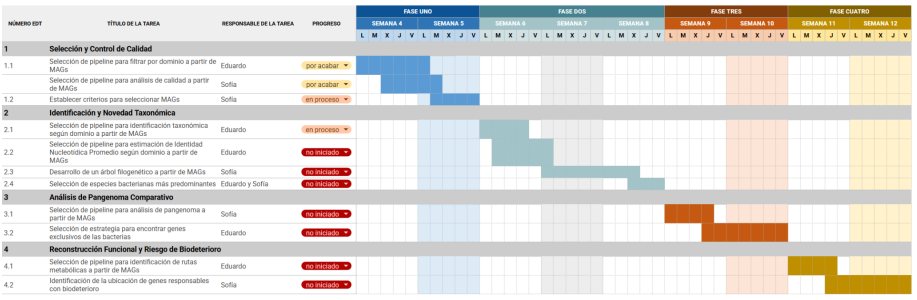


FIGURA 7.3: Diagrama de Gantt del trabajo en equipo durante el desarrollo del proyecto.

ANEXO ABET ING 6 — Experimentación

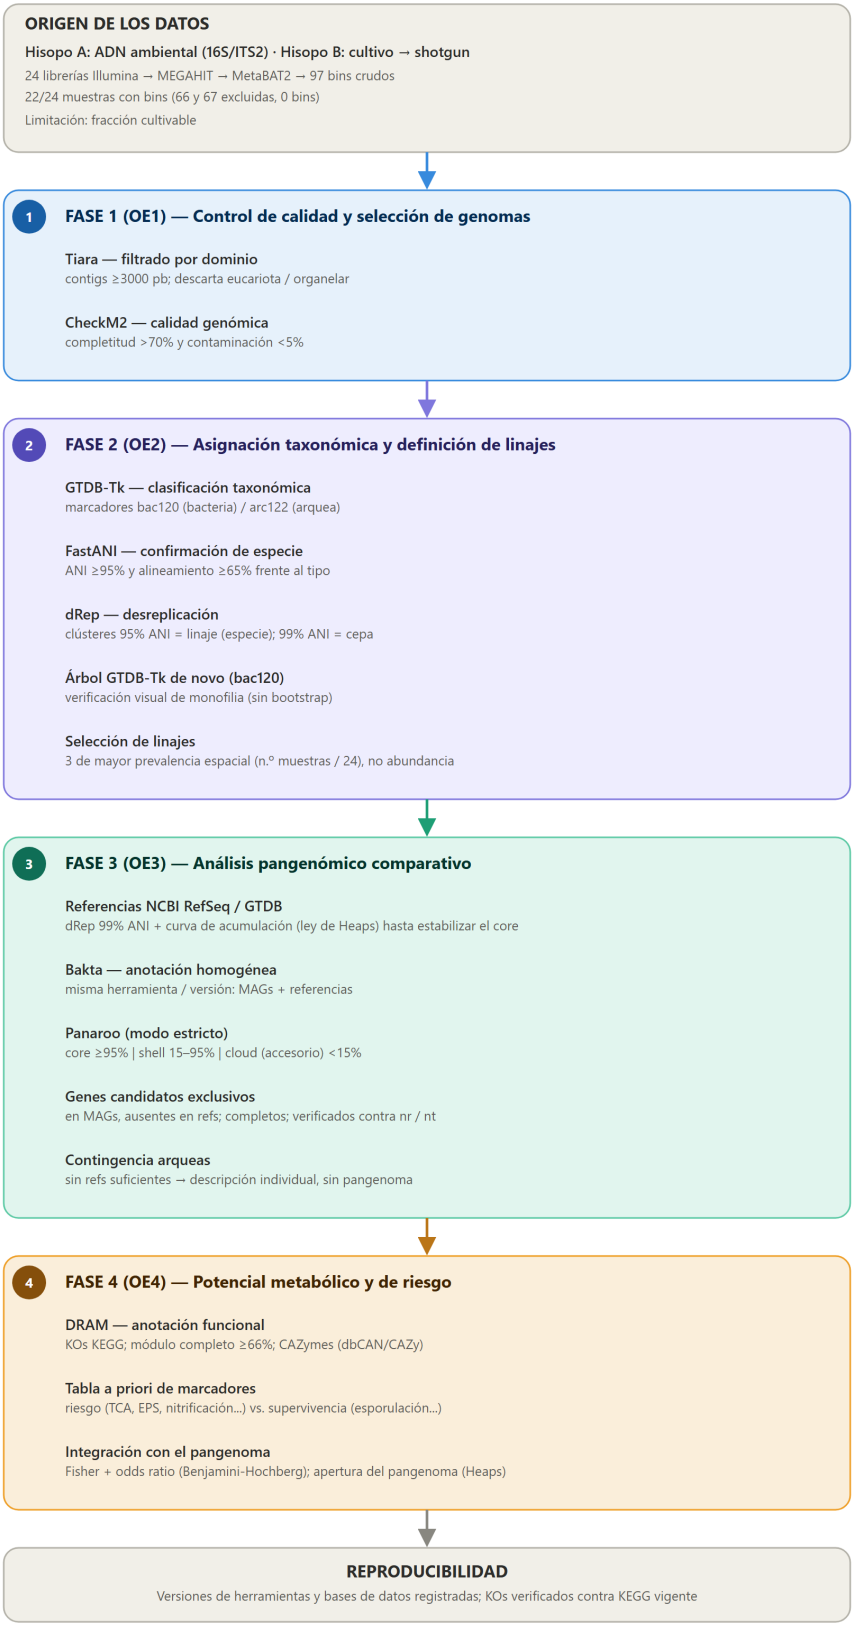


FIGURA 7.4: Flujograma del marco metodológico: cuatro fases consecutivas (OE1 a OE4) desde el origen de los datos metagenómicos hasta la caracterización del potencial metabólico y de riesgo.

ANEXO ABET ING 7 — Aprendizaje continuo

Tabla 7.7: Aprendizaje continuo: fuentes consultadas, contenido aprendido y su aplicación en el documento.

Ref.	**Información o contenido aprendido**	**Aplicación (en el documento)**
[4], [17], [21], [22]	Mecanismos de biodeterioro microbiano de la roca: acidólisis y quelación iónica por ácidos orgánicos de bajo peso molecular, y producción de ácidos nítrico y sulfúrico por bacterias de los ciclos del nitrógeno y del azufre que corroen los minerales. Fundamenta por qué ciertos genes metabólicos implican riesgo material.	Marco Teórico 2.1; Estado del arte; Marco Metodológico
[5], [9], [23], [26]	Marco ecológico de las biopelículas subaéreas en piedra, arquitectura de la matriz de EPS y rol dual biodeterioro/bioprotección, que motiva pasar de la identidad taxonómica al repertorio funcional.	Formulación del problema; Marco Teórico 2.2; Justificación
[9], [30]	Flujo de la metagenómica *shotgun*: ensamblaje *de novo* por grafos de De Bruijn y *binning* por composición de tetranucleótidos y cobertura diferencial para reconstruir MAGs.	Formulación del problema; Marco Teórico 2.3; Marco Metodológico
[14], [30], [36]	Definición de completitud y contaminación mediante genes marcadores de copia única; categorías de calidad MIMAG; estimación por aprendizaje automático (CheckM2) sin asignación taxonómica previa.	Marco Teórico 2.4; Marco Metodológico 4.1.3

Tabla 7.7 – continuación

Ref.	**Información o contenido aprendido**	**Aplicación**
[15], [37], [38], [39]	Clasificación genómica normalizada por divergencia evolutiva (GTDB-Tk/GTDB), delimitación de especie por ANI (umbral del 95 %) y sdereplicación para colapsar genomas redundantes y definir linajes.	Marco Teórico 2.5; Marco Metodológico 4.1.4
[35], [43]	Concepto de pangenoma y partición en genoma núcleo, cubierta y accesorio; la transferencia horizontal como motor de adaptación; corrección de la inflación del accesorio por fragmentación mediante grafos (Panaroo).	Marco Teórico 2.6; Marco Metodológico 4.1.5
[34], [47], [49]	Predicción de ORFs y anotación estandarizada sin alineamiento (Bakta); destilación del metabolismo y cálculo de completitud de módulos/rutas (DRAM) sobre ortólogos KEGG, base para inferir el potencial de biodeterioro.	Marco Teórico 2.7; Marco Metodológico 4.1.6
[54], [55], [56]	Clasificadores de contigs por dominio: aprendizaje profundo sobre composición (Tiara), estructura génica con *random forest* (Whokaryote) y *k-mers* con SVM (EukRep); criterios para seleccionar la herramienta de filtrado.	Marco Metodológico 4.1.3.1; Anexo 1
[1], [2], [3]	Contexto histórico-arqueológico de la Estela de Raimondi: filiación con la cultura Chavín, hallazgo, traslados sucesivos y custodia museística actual.	Introducción (Presentación del proyecto)

7.5 Anexo: Repositorio de GitHub

Link: GitHub

7.6 Anexo: Programas y archivos del sistema

Este anexo lista los programas que implementan el flujo (Tabla 7.8) y los archivos que conectan cada etapa con la siguiente en las Fases 1 y 2 (Tabla 7.9) y en la Fase 3 (Tabla 7.10).

TABLA 7.8: Programas del sistema, clase a la que pertenecen y función que cumplen. Los de la Fase 3 se listan en orden de ejecución.

Programa	**Clase**	**Función**
Fases 1 y 2		
`00_setup_khipu.sh`	Preparación (login)	Crea los entornos de Tiara y CheckM2 y descarga la base de datos de CheckM2
`01_prep_bins.sh`	Preparación (local)	Normaliza el conjunto de bins de entrada y genera la tabla de trazabilidad
`02_setup_fase2_khipu.sh`	Preparación (login)	Crea los entornos de GTDB-Tk y dRep con versiones fijadas y descomprime la base de GTDB R220
`run_fase1.slurm`	script de ejecución (cola)	Ejecuta el filtrado por dominio, la evaluación de calidad y la selección
`run_fase2.slurm`	script de ejecución (cola)	Ejecuta la clasificación taxonómica, la desreplicación y el cálculo de prevalencia
`summarize_phase1.py`, `summarize_phase2.py`	Procesamiento	Convierten las salidas de cada herramienta en las tablas de decisión del flujo y en los reportes legibles

Tabla 7.8 (continuación)

Programa	**Clase**	**Función**
Fase 3		
`03_setup_fase3_khipu.sh`	Preparación (login)	Crea los cinco entornos nuevos, descarga la base de Bakta, el conversor de formato de Panaroo, la taxonomía del NCBI y los metadatos de GTDB
`03_censo_genomas.py`	Ejecución con red (login)	Cuenta los genomas públicos de calidad de cada especie y decide su viabilidad
`04_fetch_refs.sh`	Ejecución con red (login)	Descarga del NCBI todos los genomas que pasan el control de calidad
`04_clasificar_refs.py`	Procesamiento	Verifica las descargas, asigna hábitat, continente y nivel de prioridad, y selecciona las especies y las referencias
`04_drep_refs.slurm`	Ejecución (cola)	Desreplica las referencias de cada especie al 99 % de ANI
`05_bakta_all.slurm`	Ejecución (cola)	Anota los 118 genomas en tres lotes
`06_panaroo.slurm`	Ejecución (cola)	Convierte las anotaciones y construye el pangenoma de cada especie
`06b_iqtree.slurm`	Ejecución (cola)	Infiere el árbol del genoma core de cada especie
`06c_ani_bins.slurm`	Ejecución (cola)	Calcula el ANI de cada bin contra todos los genomas de su especie
`07_particion.py`	Procesamiento	Clasifica las familias en core, shell y cloud y ubica al bin en esa partición
`08_exclusivos_local.slurm`, `08_exclusivos.py`	Ejecución (cola) y procesamiento	Aplica los filtros locales F1 a F4 a los genes candidatos del bin
`08_exclusivos_remoto.sh`	Ejecución con red (login)	Aplica los filtros remotos F5, F5b y F6 contra los servidores del NCBI
`bin/export_fase3.sh`, `figuras/R/f3_*.R`	Procesamiento	Reúne las tablas del clúster y genera la estadística y las figuras

Tabla 7.9: Archivos de datos que conectan las etapas del sistema.

Archivo	**Lo produce**	**Lo consume**
`bin_rename_map.tsv`	Preparación	La Fase 2, para asignar cada genoma a su muestra y calcular prevalencia
`tiara_bin_summary.tsv`	Tiara y su resumen	La copia selectiva de bins procariotas hacia la entrada de CheckM2
`quality_report.tsv`	CheckM2	La selección de la Fase 1 y, más adelante, dRep en la Fase 2
`phase1_selection.tsv`	Resumen de la Fase 1	El reporte de la Fase 1. Documenta el motivo de descarte de cada bin
`phase1_selected_genomes/`	Resumen de la Fase 1	La Fase 2 completa. Es su única entrada de secuencias
`genomeInfo.csv`	Resumen de la Fase 2	dRep, para evitar que recalcule la calidad de los genomas
`Cdb.csv`, `Wdb.csv`	dRep	El cálculo de linajes, representantes y prevalencia

Tabla 7.10: Archivos de datos que conectan las etapas de la Fase 3.

Archivo	**Lo crea**	**Lo usa**
`phase2_selection.tsv`	Fase 2	El censo, que toma de él la especie GTDB de cada linaje
`phase3_viabilidad.tsv`	Censo	La descarga, que solo pide genomas de especies viables
`genomas_ok_<especie>.txt`	Verificación de la descarga	dRep, el filtro F4 y el ANI de los bins: es la lista de todos los genomas válidos de la especie

Tabla 7.10 (continuación)

Archivo	Lo crea	Lo usa
`genomeInfo.csv`, `extraW.tsv`	Clasificación de referencias	dRep: calidad de cada genoma y peso extra de las cepas tipo y de los aislados de sustrato pétreo o árido
`Wdb.csv`	dRep	La selección, que elige las referencias entre los genomas no redundantes
`bakta_manifest.tsv`	Selección	Bakta: la lista de los 118 genomas que se anotan
GFF3 de Bakta → GFF de Prokka	Bakta y conversor	Panaroo
`gene_presence_absence.csv`	Panaroo	La partición, que recalcula las categorías solo con las referencias
`core_gene_alignment_filtered.aln`	Panaroo	IQ-TREE
`particion_familias.tsv`, `genes_bin.tsv`	Partición	La búsqueda de genes candidatos y, después, la Fase 4
`f5_query.faa`, `f6_query.fna`	Filtros locales	Los filtros remotos: proteínas y contigs que sobrevivieron a F1–F4
`exclusivos_verificados.tsv`	Filtros remotos	El análisis de genes específicos de la cepa y la Fase 4

7.7 Anexo: Extractos de código

Este anexo reúne los extractos de código que materializan las decisiones de diseño del Capítulo VI. Los programas completos están en el repositorio (Anexo 7.5).

LISTING VII.1: Creación del entorno de GTDB-Tk con versión de herramienta y de Python fijadas, y canales declarados de forma explícita (extracto de `02_setup_fase2_khipu.sh`).

```
# Versiones fijadas: GTDB-Tk al release de los datos y Python a
```

```
# una serie compatible. --override-channels evita 'defaults'.
$SOLVER create -y -n gtdbtk --override-channels \
    -c conda-forge -c bioconda \
    "gtdbtk=$GTDBTK_VERSION" "python=$PYTHON_VERSION"
```

LISTING VII.2: Extracción de la muestra de origen a partir del nombre de archivo y registro en la tabla de trazabilidad (extracto de `01_prep_bins.sh`).

```
# Parseo del nombre: bin-<N>-<muestra>.fasta
core="${bn%.fasta}"          # bin-1-49
sample="${core##*-}"         # 49
rest="${core%-*}"            # bin-1
binn="${rest##*-}"           # 1
nctg=$(grep -c '^>' "$DEST/$bn" || echo 0)
len=$(grep -v '^>' "$DEST/$bn" | tr -d '\n' | wc -c)
printf "%s\t%s\t%s\t%s\t%s\n" \
       "$bn" "$sample" "$binn" "$nctg" "$len" >> "$MAP"
```

LISTING VII.3: Reutilización de la evaluación de calidad de la Fase 1 y desactivación de los filtros propios de dRep (extracto de `run_fase2.slurm`).

```
# genomeInfo.csv a partir de CheckM2 (Fase 1): evita que dRep
# vuelva a estimar completitud y contaminacion.
python "$SCRIPTS_DIR/summarize_phase2.py" genomeinfo \
    --genomes-dir "$DREP_INPUT" --bin-ext "$BIN_EXT" \
    --checkm2 "$CHECKM2_REPORT" \
    --out "$RESULTS/genomeInfo.csv"

# -comp 0 -con 100: desactiva el filtro propio de dRep, ya
# aplicado en la Fase 1 (>70 % compl., <5 % contaminacion).
dRep dereplicate "$DREP_OUT" \
    -g "$DREP_INPUT"/*."$BIN_EXT" \
    -p "$THREADS" \
```

```
    -pa "$DREP_PA" -sa "$DREP_SA" \
    --S_algorithm fastANI \
    -comp 0 -con 100 \
    --genomeInfo "$RESULTS/genomeInfo.csv"
```

LISTING VII.4: Frecuencia de cada familia calculada solo con las referencias y ubicación del bin (extracto simplificado de `07_particion.py`).

```
refs = [g for g in genomas if manif[g]["tipo"] == "ref"]
bins = [g for g in genomas if manif[g]["tipo"] == "bin"]
for fam in familias:
    n_ref = sum(1 for g in refs if fam["celdas"][g])
    en_bin = [b for b in bins if fam["celdas"][b]]
    c95 = categoria(n_ref, len(refs), 0.95, 0.15, en_bin)


def categoria(n_ref, n_total, core, cloud, en_bin):
    if n_ref == 0:          # ninguna referencia la tiene
        return "exclusivo" if en_bin else "ninguno"
    f = n_ref / float(n_total)
    if f >= core:  return "core"
    if f >= cloud: return "shell"
    return "cloud"
```

LISTING VII.5: Envío de una búsqueda a la interfaz web de BLAST del NCBI (extracto simplificado de `08_exclusivos_remoto.sh`).

```
rid="$(curl␣-s␣--max-time␣300␣-X␣POST␣"$BLAST_URL"␣\
␣␣␣␣--data-urlencode␣"CMD=Put"␣\
␣␣␣␣--data-urlencode␣"PROGRAM=$prog"␣\
␣␣␣␣--data-urlencode␣"DATABASE=$db"␣\
␣␣␣␣--data-urlencode␣"EXPECT=$ev"␣\
␣␣␣␣--data-urlencode␣"HITLIST_SIZE=10"␣\
␣␣␣␣--data-urlencode␣"QUERY@$q"␣\
```

```
␣␣|␣sed␣-n␣'s/^␣*RID␣=␣*//p'␣|␣head␣-n1)"
# se guarda el RID para reanudar sin reenviar
echo "$rid" > "${out}.rid"
```

LISTING VII.6: Cabecera de solicitud de recursos a SLURM (extracto de `run_fase1.slurm`).

```
# Limites de la cuenta: 32 cores, 98 GB RAM, 24 h por trabajo.
#SBATCH --job-name=fase1_estela
#SBATCH --partition=standard
#SBATCH --nodes=1
#SBATCH --ntasks=1
#SBATCH --cpus-per-task=32
#SBATCH --mem=90G
#SBATCH --time=24:00:00
#SBATCH --output=fase1_%j.out
#SBATCH --error=fase1_%j.err
```

LISTING VII.7: Configuración de terminación ante error, compatible con el sistema de módulos del clúster (extracto de `run_fase1.slurm`).

```
# NO usar 'set -u' (nounset): Lmod referencia LD_PRELOAD sin
# definir y aborta la carga de modulos en Khipu.
set -eo pipefail
export LD_PRELOAD="${LD_PRELOAD:-}"
```

7.8 Anexo: Calidad y selección de bins (Fase 1)

La Figura 7.5 muestra la calidad de los 66 bins procariotas y las métricas de los 21 seleccionados. La Tabla 7.11 detalla los 97 bins con su motivo de descarte.

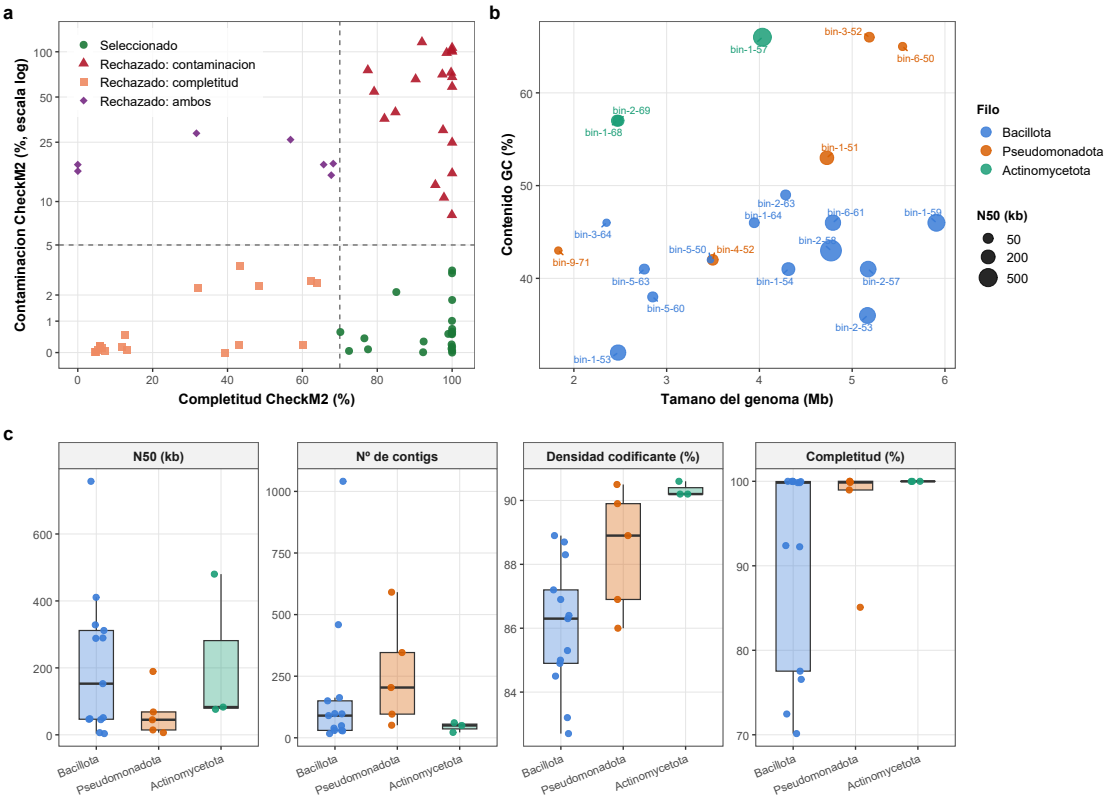


FIGURA 7.5: Calidad y métricas de ensamblaje de los genomas. **(a)** Completitud frente a contaminación (CheckM2) de los 66 bins procariotas. El eje de contaminación usa escala logarítmica ($\log(1+x)$) porque unos pocos bins superan el 60 % y comprimirían la región de interés. Las líneas discontinuas marcan los umbrales del estudio (completitud igual o superior al 70 %, contaminación inferior al 5 %) y la región sombreada, los 21 genomas seleccionados. **(b)** Tamaño del genoma frente a contenido GC de los 21 genomas seleccionados; el tamaño del punto es proporcional al N50 de los contigs y el color indica el filo. **(c)** Distribución de N50, número de contigs, densidad codificante y completitud por filo. Cada punto es un genoma; las cajas muestran mediana y cuartiles.

Tabla 7.11: Reporte completo de evaluación y filtrado de bins genómicos (Fase 1).

Bin	**Contigs**	**Long (bp)**	**Dom.**	**Comp. (%)**	**Contam. (%)**	**Motivo**
bin-1-49	87	545.053	euk	–	–	dominio mayoritario: euk
bin-1-50	224	2.609.893	prok	62.29	2.66	completitud $62.29 \leq 70$
bin-1-51	51	4.727.435	prok	100.00	0.00	-
bin-1-52	26	415.732	prok	6.05	0.20	completitud $6.05 \leq 70$
bin-1-53	30	2.476.631	prok	99.84	0.12	-
bin-1-54	49	4.312.038	prok	92.25	0.01	-
bin-1-55	247	34.242.081	euk	–	–	dominio mayoritario: euk
bin-1-56	12	230.366	euk	–	–	dominio mayoritario: euk
bin-1-57	22	4.032.412	prok	99.99	3.23	-
bin-1-58	4725	12.125.594	unknown	0.00	17.71	completitud $0.00 \leq 70$; contaminacion $17.71 \geq 5$

Continúa en la siguiente página...

Tabla 7.11 – Continuación de la página anterior

Bin	Contigs	Long (bp)	Dom.	Comp. (%)	Contam. (%)	Motivo
bin-1-59	98	5.907.869	prok	99.97	3.07	-
bin-1-60	302	8.273.570	prok	100.00	24.87	contaminacion 24.87 $\geq$ 5
bin-1-61	448	40.131.343	euk	–	–	dominio mayoritario: euk
bin-1-62	320	7.390.811	prok	99.72	72.67	contaminacion 72.67 $\geq$ 5
bin-1-63	162	65.185.746	prok	84.85	39.63	contaminacion 39.63 $\geq$ 5
bin-1-64	163	3.944.265	prok	99.84	0.59	-
bin-1-65	322	29.636.962	euk	–	–	dominio mayoritario: euk
bin-1-68	50	2.465.224	prok	100.00	1.79	-
bin-1-69	67	251.086	prok	6.60	0.14	completitud 6.60 $\leq$ 70
bin-1-70	3805	494.251.631	unknown	31.70	28.68	completitud 31.70 $\leq$ 70; contamina-cion 28.68 $\geq$ 5

Continúa en la siguiente página...

Tabla 7.11 – Continuación de la página anterior

Bin	Contigs	Long (bp)	Dom.	Comp. (%)	Contam. (%)	Motivo
bin-1-71	37	11.498.934	prok	67.71	15.05	completitud 67.71 $\leq$ 70; contamina-cion 15.05 $\geq$ 5
bin-1-72	16	7.408.652	unknown	5.87	0.19	completitud 5.87 $\leq$ 70
bin-10-71	506	2.845.557	prok	97.57	30.13	contaminacion 30.13 $\geq$ 5
bin-11-71	4161	101.946.556	unknown	65.68	17.72	completitud 65.68 $\leq$ 70; contamina-cion 17.72 $\geq$ 5
bin-12-71	383	1.015.904	unknown	43.42	3.52	completitud 43.42 $\leq$ 70
bin-2-49	134	27.557.437	euk	–	–	dominio mayoritario: euk
bin-2-50	464	53.406.620	euk	–	–	dominio mayoritario: euk
bin-2-52	270	5.347.688	prok	99.93	8.10	contaminacion 8.10 $\geq$ 5
bin-2-53	39	5.164.804	prok	99.99	0.57	-

Continúa en la siguiente página...

Tabla 7.11 – Continuación de la página anterior

Bin	Contigs	Long (bp)	Dom.	Comp. (%)	Contam. (%)	Motivo
bin-2-54	106	7.273.841	prok	100.00	15.52	contaminacion 15.52 $\geq$ 5
bin-2-56	816	49.647.189	euk	–	–	dominio mayoritario: euk
bin-2-57	28	5.172.263	prok	99.96	1.01	-
bin-2-58	17	4.771.531	prok	100.00	0.06	-
bin-2-59	424	23.212.147	prok	91.94	115.89	contaminacion 115.89 $\geq$ 5
bin-2-60	290	10.390.751	prok	100.00	100.33	contaminacion 100.33 $\geq$ 5
bin-2-61	9	614.253	euk	–	–	dominio mayoritario: euk
bin-2-62	5	227.679	euk	–	–	dominio mayoritario: euk
bin-2-63	150	4.282.638	prok	92.39	0.34	-
bin-2-64	924	226.083.286	unknown	0.02	16.03	completitud 0.02 $\leq$ 70; contamina-cion 16.03 $\geq$ 5

Continúa en la siguiente página...

Tabla 7.11 – Continuación de la página anterior

Bin	Contigs	Long (bp)	Dom.	Comp. (%)	Contam. (%)	Motivo
bin-2-65	141	17.056.380	euk	–	–	dominio mayoritario: euk
bin-2-68	70	246.182	prok	4.99	0.03	completitud $4.99 \leq 70$
bin-2-69	61	2.481.071	prok	99.99	0.18	-
bin-2-70	87	278.635	unknown	5.38	0.09	completitud $5.38 \leq 70$
bin-2-71	618	1.368.774	unknown	56.83	26.01	completitud $56.83 \leq 70$; contamina-cion $26.01 \geq 5$
bin-2-72	667	2.485.725	prok	79.16	54.30	contaminacion $54.30 \geq 5$
bin-3-50	30	2.607.902	unknown	13.03	0.08	completitud $13.03 \leq 70$
bin-3-52	204	5.184.467	prok	98.97	0.58	-
bin-3-53	301	29.244.092	euk	–	–	dominio mayoritario: euk

Continúa en la siguiente página...

Tabla 7.11 – Continuación de la página anterior

Bin	Contigs	Long (bp)	Dom.	Comp. (%)	Contam. (%)	Motivo
bin-3-56	160	26.628.065	euk	–	–	dominio mayoritario: euk
bin-3-57	818	25.745.728	euk	–	–	dominio mayoritario: euk
bin-3-58	265	29.647.785	euk	–	–	dominio mayoritario: euk
bin-3-60	959	2.321.293	unknown	39.27	0.00	completitud $39.27 \leq 70$
bin-3-61	50	10.715.439	euk	–	–	dominio mayoritario: euk
bin-3-62	117	449.659	euk	–	–	dominio mayoritario: euk
bin-3-63	4589	19.740.558	prok	99.91	102.18	contaminacion $102.18 \geq 5$
bin-3-64	459	2.352.198	prok	70.14	0.64	-
bin-3-65	5256	27.711.612	euk	–	–	dominio mayoritario: euk

Continúa en la siguiente página...

Tabla 7.11 – Continuación de la página anterior

Bin	Contigs	Long (bp)	Dom.	Comp. (%)	Contam. (%)	Motivo
bin-3-70	169	64.261.799	unknown	77.48	75.48	contaminacion $75.48 \geq 5$
bin-3-71	3657	12.324.162	prok	97.39	70.70	contaminacion $70.70 \geq 5$
bin-3-72	174	16.597.747	prok	98.53	98.35	contaminacion $98.35 \geq 5$
bin-4-50	97	1.654.013	prok	43.00	0.23	completitud $43.00 \leq 70$
bin-4-52	96	3.497.259	prok	99.86	0.25	-
bin-4-56	122	1.739.035	euk	–	–	dominio mayoritario: euk
bin-4-57	977	39.075.173	euk	–	–	dominio mayoritario: euk
bin-4-60	4482	25.724.799	euk	–	–	dominio mayoritario: euk
bin-4-61	1610	11.012.084	prok	100.00	58.51	contaminacion $58.51 \geq 5$
bin-4-62	270	79.759.046	prok	90.25	65.70	contaminacion $65.70 \geq 5$

Continúa en la siguiente página...

Tabla 7.11 – Continuación de la página anterior

Bin	Contigs	Long (bp)	Dom.	Comp. (%)	Contam. (%)	Motivo
bin-4-63	856	56.508.797	euk	–	–	dominio mayoritario: euk
bin-4-64	428	29.693.972	euk	–	–	dominio mayoritario: euk
bin-4-65	2506	20.150.702	prok	99.99	106.28	contaminacion $106.28 \geq 5$
bin-4-70	484	1.565.460	prok	64.00	2.55	completitud $64.00 \leq 70$
bin-4-71	216	488.562	unknown	32.24	2.32	completitud $32.24 \leq 70$
bin-4-72	72	248.801	prok	4.69	0.01	completitud $4.69 \leq 70$
bin-5-50	1041	3.472.002	prok	76.56	0.44	-
bin-5-52	1099	3.740.736	prok	95.51	12.95	contaminacion $12.95 \geq 5$
bin-5-56	146	552.204	euk	–	–	dominio mayoritario: euk

Continúa en la siguiente página...

Tabla 7.11 – Continuación de la página anterior

Bin	Contigs	Long (bp)	Dom.	Comp. (%)	Contam. (%)	Motivo
bin-5-57	12	224.138	euk	–	–	dominio mayoritario: euk
bin-5-60	97	2.849.856	prok	77.53	0.10	-
bin-5-61	273	5.811.268	prok	97.82	10.64	contaminacion $10.64 \geq 5$
bin-5-62	222	27.886.446	euk	–	–	dominio mayoritario: euk
bin-5-63	90	2.758.939	prok	72.46	0.05	-
bin-5-64	217	39.450.268	prok	100.00	67.99	contaminacion $67.99 \geq 5$
bin-5-65	24	222.213	euk	–	–	dominio mayoritario: euk
bin-5-70	28	2.628.283	unknown	48.48	2.40	completitud $48.48 \leq 70$
bin-5-71	118	438.388	prok	12.74	0.54	completitud $12.74 \leq 70$
bin-6-50	591	5.543.214	prok	100.00	0.65	-

Continúa en la siguiente página...

Tabla 7.11 – Continuación de la página anterior

Bin	Contigs	Long (bp)	Dom.	Comp. (%)	Contam. (%)	Motivo
bin-6-56	116	9.578.458	euk	–	–	dominio mayoritario: euk
bin-6-57	126	448.524	euk	–	–	dominio mayoritario: euk
bin-6-61	30	4.792.746	prok	100.00	0.74	-
bin-6-63	21	367.167	euk	–	–	dominio mayoritario: euk
bin-6-64	71	239.057	euk	–	–	dominio mayoritario: euk
bin-6-70	319	48.190.971	unknown	68.24	17.99	completitud $68.24 \leq 70$; contaminacion $17.99 \geq 5$
bin-6-71	34	453.921	prok	11.79	0.16	completitud $11.79 \leq 70$
bin-7-64	1246	3.769.741	prok	60.17	0.22	completitud $60.17 \leq 70$
bin-7-71	95	258.968	unknown	7.21	0.05	completitud $7.21 \leq 70$

Continúa en la siguiente página...

Tabla 7.11 – Continuación de la página anterior

Bin	Contigs	Long (bp)	Dom.	Comp. (%)	Contam. (%)	Motivo
bin-8-71	908	2.450.575	unknown	81.92	35.87	contaminacion $35.87 \geq 5$
bin-9-71	346	1.832.072	prok	85.09	2.13	-

7.9 Anexo: Figuras complementarias de la Fase 2

Este anexo reúne las figuras de la Fase 2 que respaldan la Sección 7.2.2. La Figura 7.6 muestra la composición taxonómica de los 21 genomas.

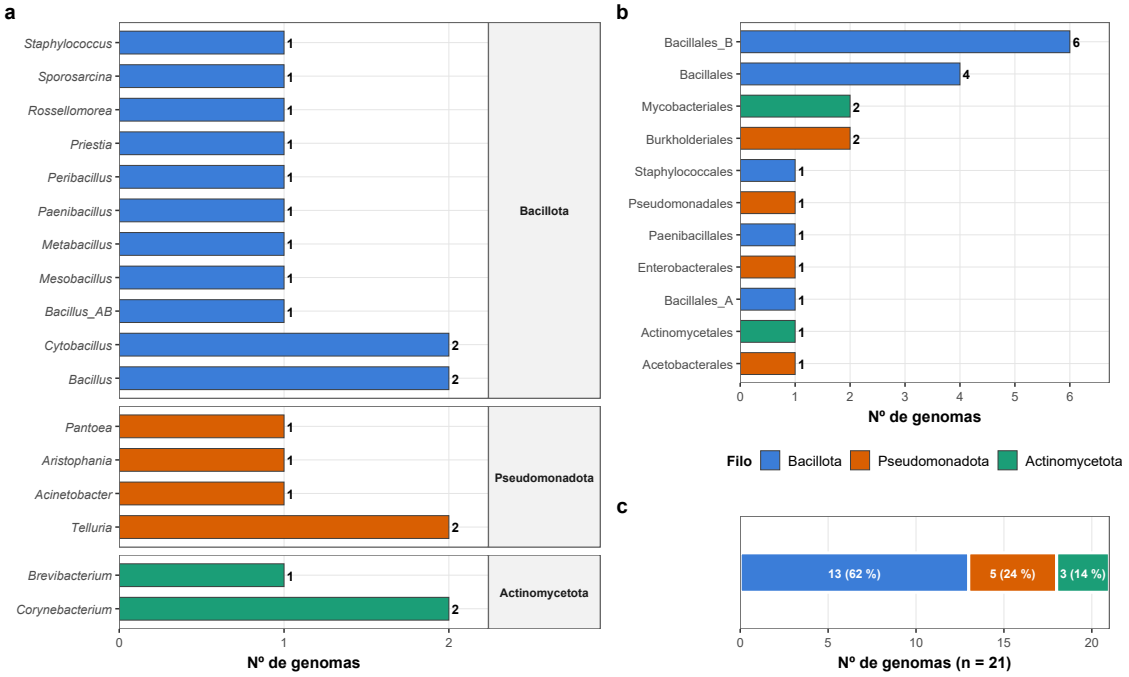


FIGURA 7.6: Composición taxonómica del conjunto de genomas seleccionados. **(a)** Número de genomas por género, agrupados por filo. **(b)** Número de genomas por orden. **(c)** Reparto de los 21 genomas entre los tres filos detectados.

El árbol de la Figura 7.7 recupera los tres filos como grupos separados y deja en ramas adyacentes a los genomas del mismo género, con *bootstrap* del 100 % en esos nodos. Es un árbol de distancias calculado solo sobre los genomas propios. Por lo que verifica la coherencia interna del conjunto, pero no es una prueba filogenética independiente.

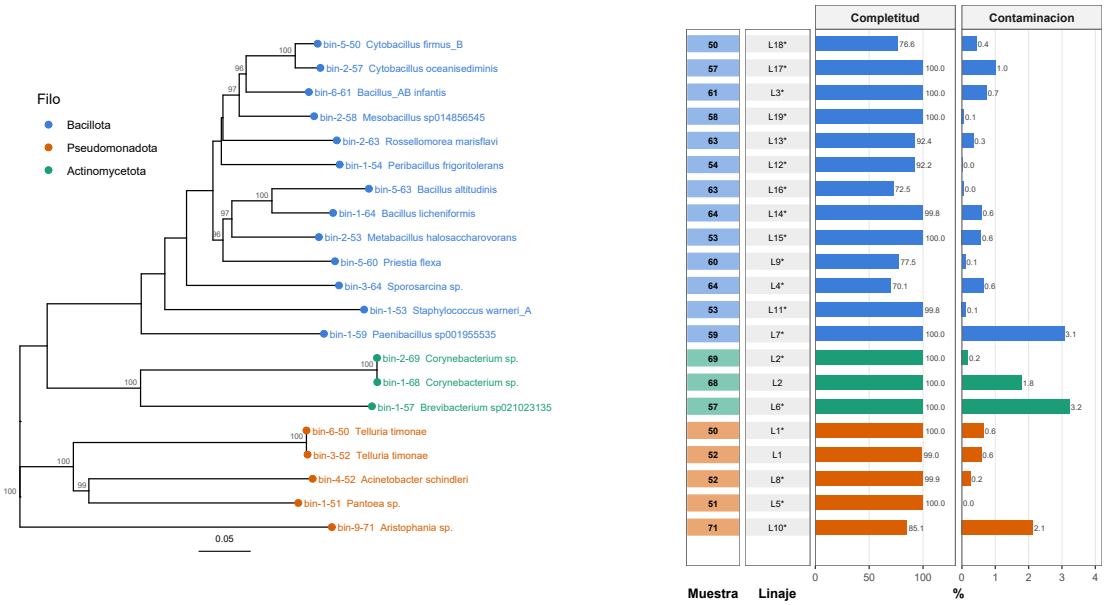


FIGURA 7.7: Árbol filogenómico de los 21 genomas seleccionados con sus metadatos. Árbol de Neighbor-Joining calculado sobre distancias-p a partir del alineamiento concatenado de los 120 marcadores bacterianos de copia única (bac120, 5035 posiciones) generado por GTDB-Tk (datos R220), enraizado en el filo Pseudomonadota. Los números sobre las ramas son valores de soporte de *bootstrap* (500 réplicas); solo se muestran los iguales o superiores al 70 %. Las columnas de la derecha indican, para cada genoma, la muestra de origen, el linaje asignado por dRep (el asterisco marca el genoma representante del linaje) y los valores de completitud y contaminación de CheckM2.

La matriz de la Figura 7.8 muestra que solo dos parejas son casi idénticas. El par de *Cytobacillus* (`bin-5-50` y `bin-2-57`) comparte género, pero se mantiene en dos linajes con una similitud MASH del 80 %.

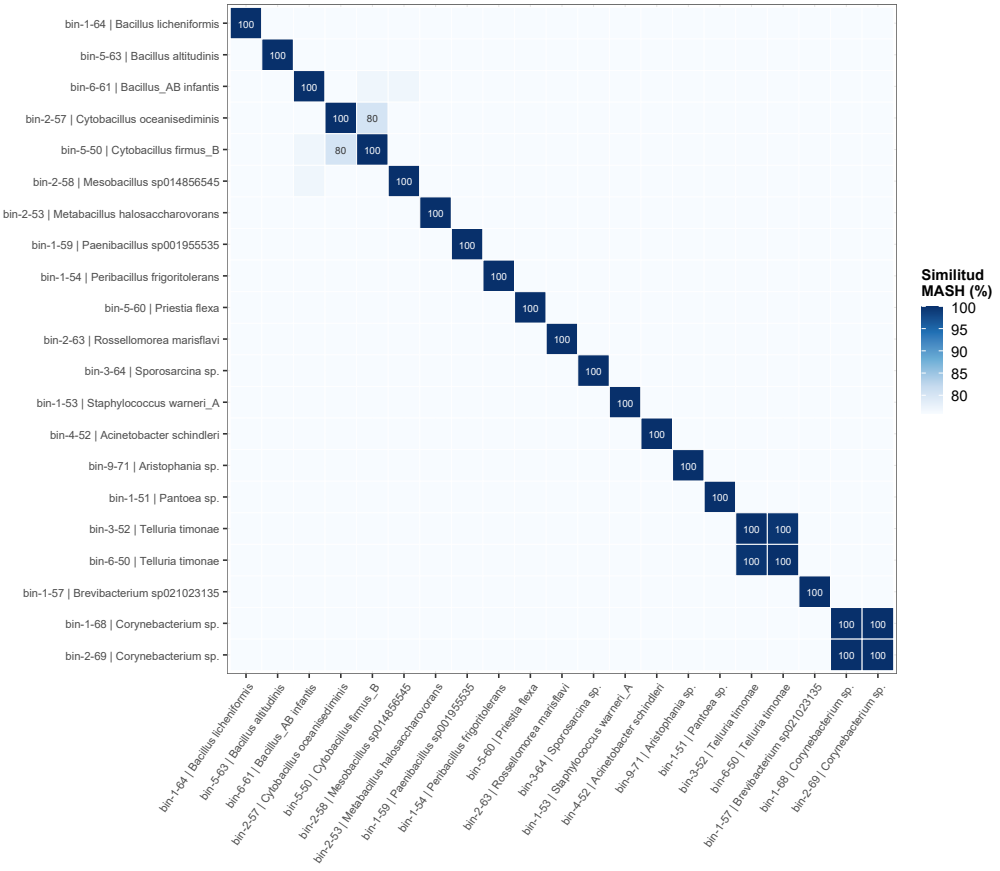


FIGURA 7.8: Matriz de similitud genómica entre los 21 genomas seleccionados. Similitud MASH (100− distancia MASH) entre todas las parejas de genomas, ordenadas por filo y género. Solo dos parejas presentan similitud máxima: los dos *Telluria timonae* (muestras 50 y 52) y los dos *Corynebacterium* sp. (muestras 68 y 69). Nota metodológica: dRep ejecuta fastANI únicamente dentro de cada clúster primario definido por MASH, de modo que no existe una matriz de ANI completa para los 21 genomas; la matriz de todos contra todos disponible es la de MASH.

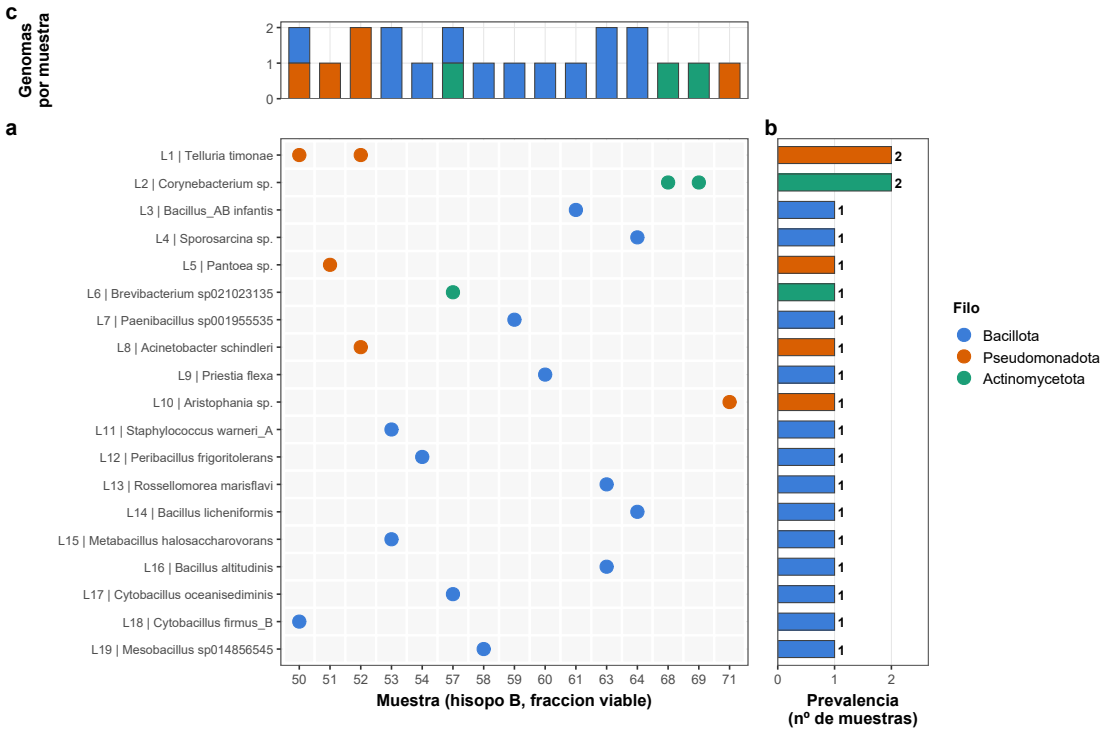


FIGURA 7.9: Prevalencia espacial de los linajes. **(a)** Matriz de presencia de cada linaje (filas, ordenadas por prevalencia descendente) en cada muestra (columnas); el color indica el filo. **(b)** Prevalencia de cada linaje, definida como el número de muestras distintas en que aparece, coloreada por filo. **(c)** Número de genomas de alta calidad recuperados por muestra, coloreado por filo. Limitación: la prevalencia se calcula sobre el número de muestras y no sobre zonas físicas de la estela, porque no se dispone de un mapeo muestra → zona en formato analizable.

7.10 Anexo: Resultados complementarios de la Fase 3

Este anexo reúne el detalle de la Sección 7.2.3.

Selección de referencias. GTDB llama *Telluria timonae* a la especie que el NCBI registra como *Massilia timonae*, por lo que buscar con el nombre de GTDB no devuelve ningún genoma. Los sufijos de GTDB como `_A`, `_B` o `_AB` marcan especies que el NCBI no separa, así que el conteo del NCBI para esos nombres sale inflado. Los cuatro genomas excluidos a mano son tres de *P. frigoritolerans*, rotulados en el NCBI como *Brevibacterium* sp. (dos) y *Vibrio vulnificus*, y uno de *B. altitudinis*, rotulado como *Micromonospora* sp.

El único aislado de sustrato pétreo o árido de *B. altitudinis* procede de un residuo minero de Portugal. Las referencias de *P. frigoritolerans* son sobre todo de suelo y plantas (28 de 42) y de Asia y Europa (30 de 42). Los cinco genomas clasificados como de sustrato pétreo o árido proceden de drenaje minero, sal de mina, arena del desierto, residuo minero y una ánfora romana.

Curvas de acumulación. La Figura 7.10 muestra que en las tres especies el pangenoma sigue creciendo con la última referencia.

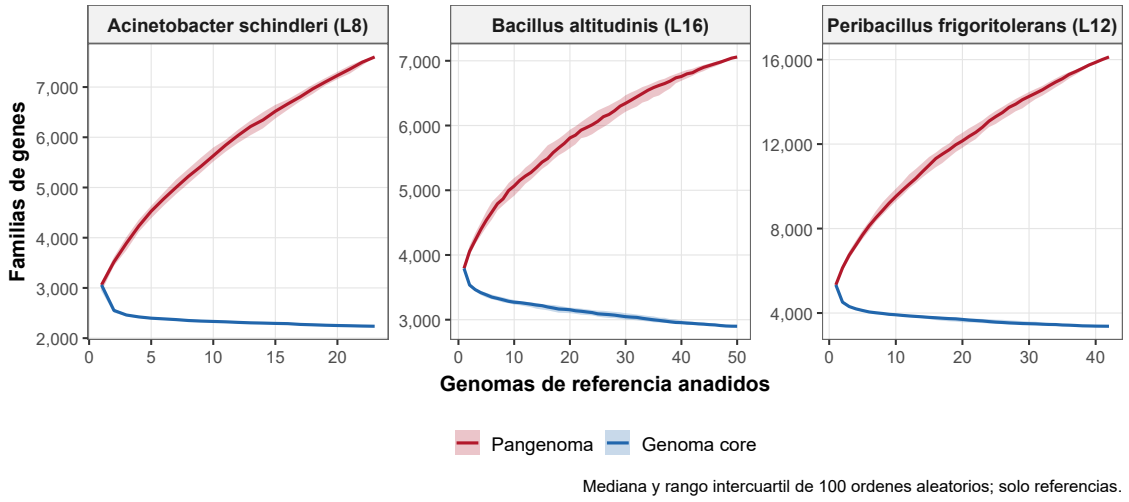


FIGURA 7.10: Curvas de acumulación del pangenoma (rojo) y del genoma core (azul) de cada especie, con todas sus referencias (50, 42 y 23) y sin el bin. Cada curva es la mediana de 100 órdenes aleatorios de los genomas y la banda, el rango intercuartil.

Apertura del pangenoma. La Figura 7.11 muestra las tres pruebas. En el panel a, la correlación de Spearman entre los contigs y las familias únicas de cada referencia es nula en *B. altitudinis* ($\rho = -0.05$) y en *P. frigoritolerans* ($\rho = -0.08$), y negativa en *A. schindleri* ($\rho = -0.52$, $p = 0.01$). Si la fragmentación inflara el pangenoma, ambas cifras crecerían juntas. En el panel b, α con solo genomas completos (*Complete Genome* o *Chromosome* en el NCBI) pasa de 0.66 a 0.64 en *B. altitudinis*, se mantiene en 0.55 en *A. schindleri* y sube de 0.57 a 0.74 en *P. frigoritolerans*. En esta última, parte de la apertura viene de los genomas fragmentados y de dos referencias con muchas más familias

únicas que las demás. En el panel c, las proteínas hipotéticas son del 29 al 45 % del cloud y del 13 al 17 % del core. Un gen partido suele quedar como proteína hipotética [81]. Por lo que un cloud formado sobre todo por fragmentos tendría una mayoría de ellas.

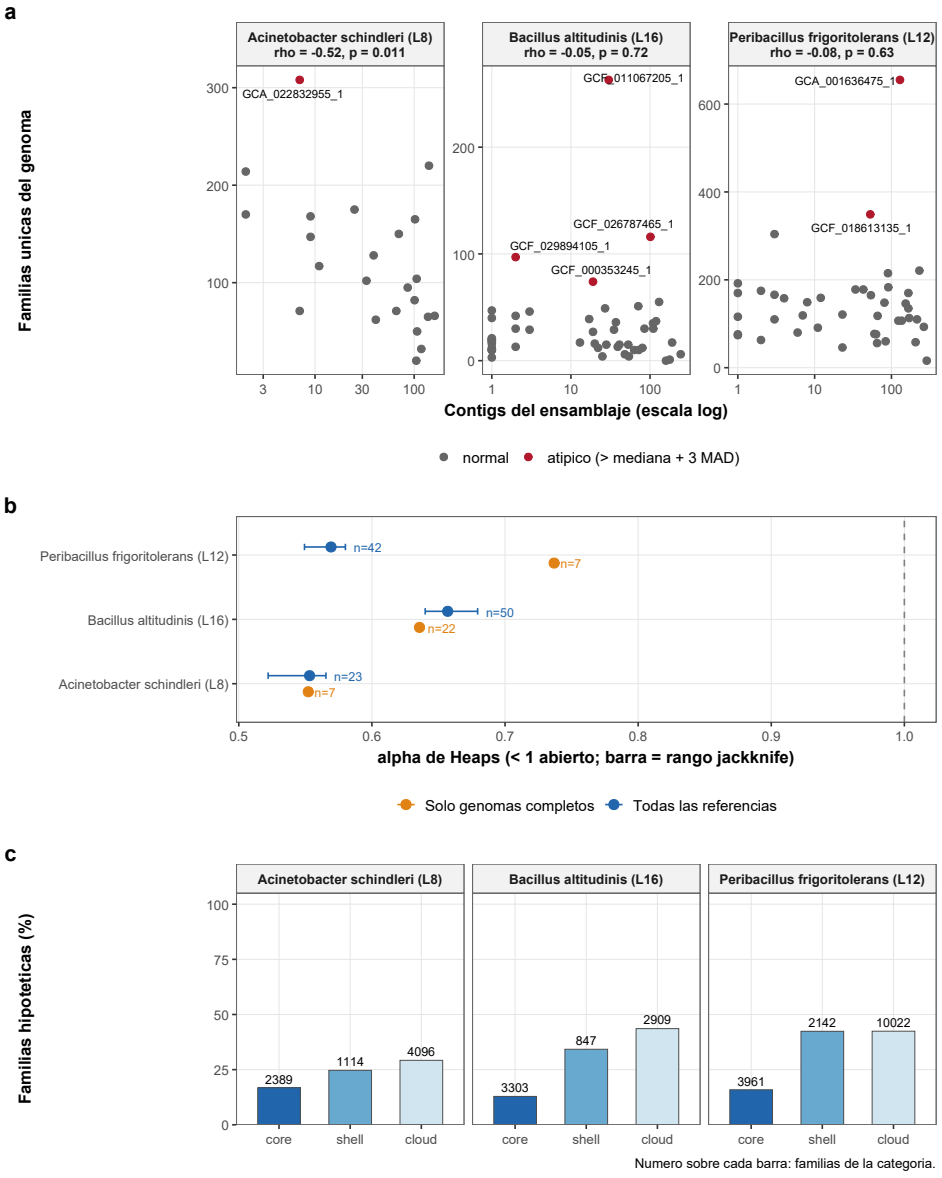


FIGURA 7.11: Diagnóstico de la apertura del pangenoma. **(a)** Familias únicas de cada referencia frente al número de contigs de su ensamblaje; en rojo, los genomas con más familias únicas que la mediana más tres desviaciones absolutas medianas. **(b)** Exponente α de Heaps con todas las referencias (azul; la barra es el rango al quitar un genoma cada vez) y solo con genomas cerrados (naranja). La línea discontinua marca $\alpha = 1$, el límite entre pangenoma abierto y cerrado. **(c)** Porcentaje de familias anotadas como proteína hipotética en cada categoría; el número sobre cada barra es el total de familias de la categoría.

Posición de cada bin. La Figura 7.12 muestra el reparto de los genes de cada

bin y el control C6. Ese control exige además que cada referencia contenga al menos el 97 % del core, y la mediana fue del 99.9 %. Solo GCF_018613135.1, de *P. frigoritolerans*, quedó en 94.6 %. Se mantuvo porque su calidad es alta (100 % de completitud y 0.5 % de contaminación), tiene un número normal de genes y su ANI promedio con las demás cepas es de 96.3 %. Es una cepa divergente y no un ensamblaje defectuoso.

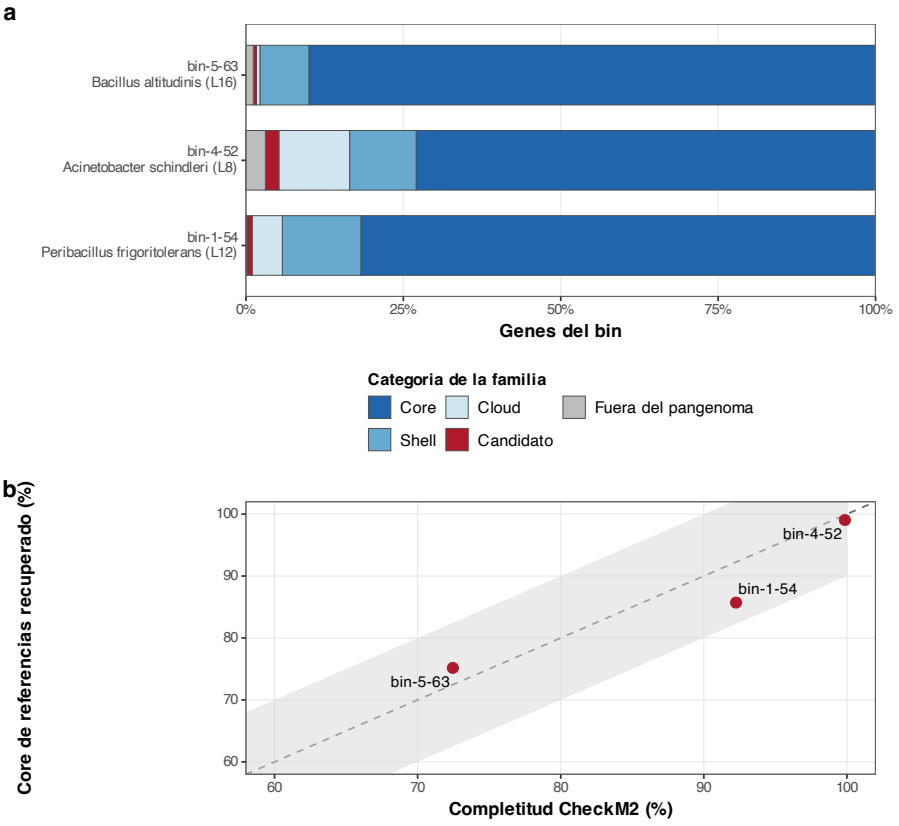


FIGURA 7.12: Posición de cada bin en el pangenoma de su especie. **(a)** Reparto de los genes del bin según la categoría de su familia en el pangenoma de las referencias; «fuera del pangenoma» son los genes que Panaroo eliminó. **(b)** Porcentaje del genoma core de las referencias presente en el bin frente a su completitud según CheckM2. La línea discontinua es la igualdad y la banda gris, un margen de ±10 puntos.

Árboles del genoma core. La Tabla 7.12 resume los tres árboles. Los genes core que faltan en el bin se tratan como datos faltantes, que el método tolera. En *B. altitudinis*

la rama del bin (0.0083) mide casi lo mismo que la de su pariente (0.0077), por lo que su incompletitud no la alarga.

TABLA 7.12: Estadísticas de los árboles del genoma core de cada especie. El pariente más cercano de cada bin está en la Tabla 7.3.

	B. altitudinis	***P. frigoritolerans***	***A. schindleri***
Genomas en el árbol	51	43	24
Sitios alineados	2.71 Mpb	3.24 Mpb	2.04 Mpb
Sitios constantes	92.4 %	87.2 %	90.6 %
Sitios informativos	4.9 %	6.2 %	6.1 %
Modelo elegido (BIC)	GTR+F+I+R5	GTR+F+R7	GTR+F+R4
Nodos con UFBoot < 95	18 de 48	2 de 40	0 de 21

Nota. El modelo de sustitución se eligió con el criterio de información bayesiano (BIC), que favorece el modelo que mejor se ajusta a los datos con el menor número de parámetros. GTR: cada tipo de cambio entre nucleótidos tiene su propia tasa. +F: frecuencias de nucleótidos tomadas del alineamiento. +I: proporción de sitios sin cambios. +Rk: los sitios variables se reparten en k categorías de velocidad. UFBoot: porcentaje de 1000 réplicas en que aparece cada agrupación. Un valor de 95 o más se considera confiable [42].

La Figura 7.13 muestra los tres árboles con el hábitat de cada referencia.

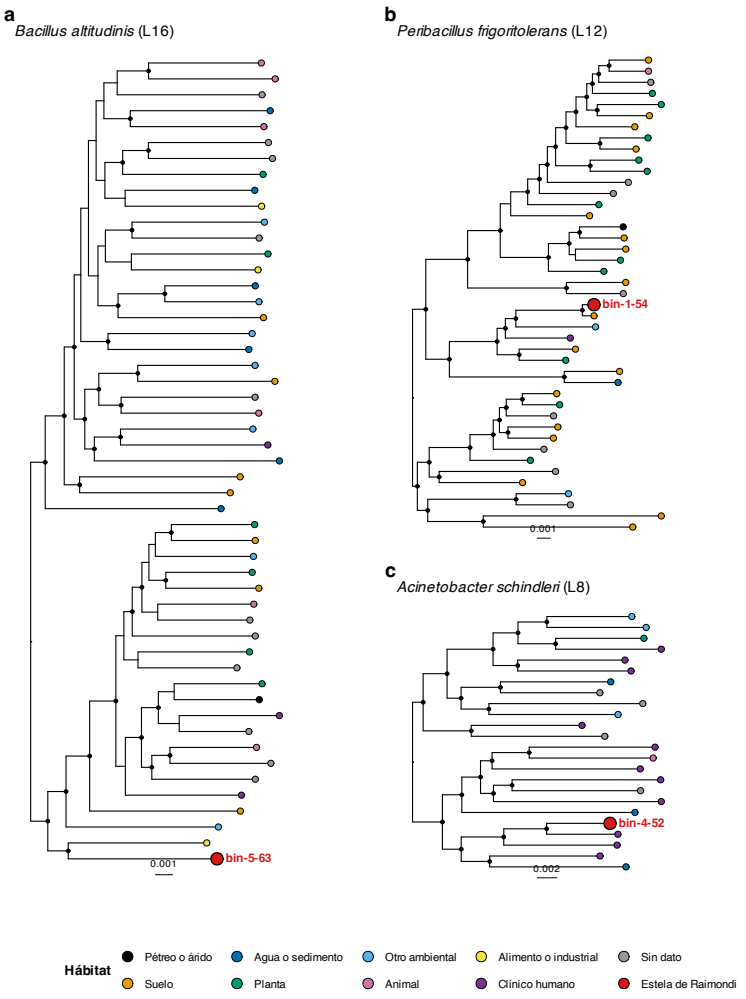


FIGURA 7.13: Árboles de máxima verosimilitud del genoma core de **(a)** *Bacillus altitudinis* (50 referencias y `bin-5-63`), **(b)** *Peribacillus frigoritolerans* (42 referencias y `bin-1-54`) y **(c)** *Acinetobacter schindleri* (23 referencias y `bin-4-52`), inferidos con IQ-TREE 3. El color de cada punta es el hábitat de aislamiento y el punto rojo grande, el bin de la Estela. Los puntos negros marcan los nodos con UFBoot ≥ 95. La raíz se ubicó en el punto medio solo para dibujar los árboles.

ANI de cada bin. La Figura 7.14 muestra el ANI de cada bin contra todos los genomas válidos de su especie y su relación con la distancia en el árbol. El clon de *P. frigoritolerans* se aisló de manzana y suelo agrícola en Alemania, semilla en Francia, suelo en Corea del Sur, nieve en la Antártida, una sala limpia y piel humana en Estados Unidos.

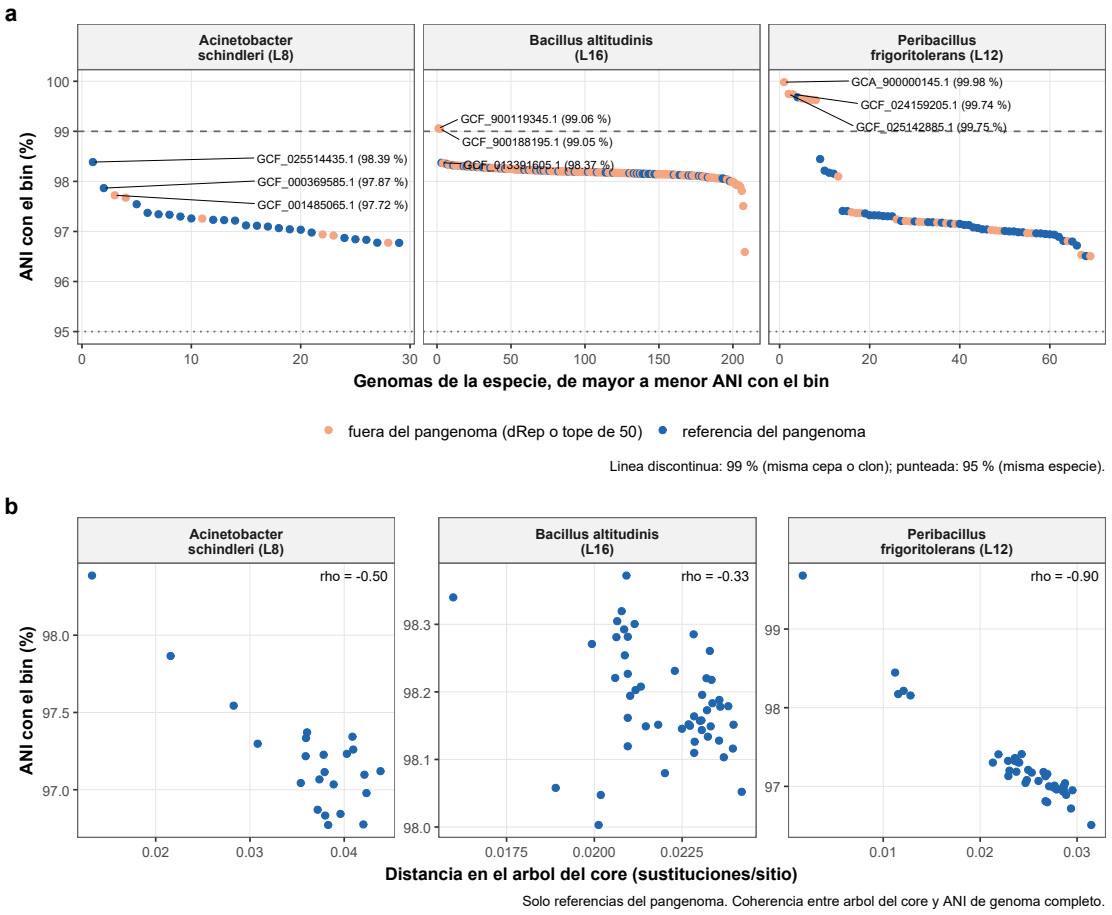


FIGURA 7.14: ANI de cada bin. **(a)** ANI del bin contra cada genoma válido de su especie, ordenados de mayor a menor. En azul, las referencias del pangenoma; en naranja, los genomas que quedaron fuera por la desreplicación o por el tope de 50. La línea discontinua marca el 99 % (misma cepa o clon) y la punteada, el 95 % (misma especie). **(b)** ANI del bin frente a la distancia en el árbol del core, para las referencias del pangenoma.

Genes específicos. En *B. altitudinis*, cuatro de los 12 candidatos que F6 descarta están en dos contigs que se parecen más a *Neobacillus*. Los otros ocho están en cuatro contigs de 1.6 a 3.4 kb que coinciden en toda su longitud con *B. subtilis*. Los dos candidatos que quedaban los encuentra F5b en una cepa de la especie depositada como *Bacillus* sp. En *A. schindleri*, 41 de los 44 genes están en contigs anclados a la especie. De los cinco genes cuyo mejor parecido no es otra especie de *Acinetobacter*, dos se parecen a proteínas de *A. schindleri* con solo 62 a 63 % de identidad, dos a un fago y uno a *Thauera*. En 11

de las 17 islas el GC es más de cinco puntos menor que el del bin. Una isla sin genes con advertencia destaca: tiene cinco genes en 5.4 kb y un 26 % de GC, frente al 42 % del bin. Codifica una O-antígeno ligasa, una glicosiltransferasa, una UDP-glucosa 6-deshidrogenasa y otras dos proteínas que fabrican los polisacáridos de la superficie celular. Sus genes más parecidos en otras especies de *Acinetobacter* tienen solo entre 62 y 85 % de identidad. Por lo que no es una copia reciente de un genoma secuenciado, sino una variante encontrada solo en esta cepa. El único gen con número KEGG es un transportador de ácidos grasos que no figura entre los marcadores de la Fase 4.

7.11 Anexo: Análisis de sensibilidad

La Tabla 7.13 resume los 13 escenarios de sensibilidad y su efecto. Después se detalla cada uno.

Tabla 7.13: Escenarios de sensibilidad y su efecto sobre el caso base. E1 a E5 corresponden a las Fases 1 y 2, y E6 a E13 a la Fase 3.

Esc.	**Variable y valores**	**Resultado**	**Efecto en las conclusiones**
E1	Completitud: 50 a 95 %	Con 50 % entran 3 genomas más y con 90 % salen 5	Ninguno: la mayoría está lejos del umbral
E2	Contaminación: 1 a 10 %	De 16 a 22 genomas. Con 10 % entra solo 1 más que con 5 %	Es el umbral que más define el tamaño del conjunto
E3	Dominio: mayoría simple o 25 a 90 % procariota	De 66 a 30 bins. Con más del 50 % quedarían 50	El paso más sensible. Pero CheckM2 elimina después la mezcla de dominios
E4	ANI de linaje: 95 a 99.5 %	19 linajes en todos los casos	Ninguno

Tabla 7.13 (continuación)

Esc.	Variable y valores	Resultado	Efecto en las conclusiones
E5	Hasta 300 contigs en los bins	De 21 a 17 genomas	No se aplicó: saldrían `bin-6-50` (L1) y `bin-9-71` (único de su género)
E6	Desreplicación: 99, 99.5 y 99.9 %	Mismas tres especies al 99 y al 99.5 %	Ninguno
E7	Core: 90 o 95 %	El core crece de 0.8 a 3.0 %	Ninguno
E8	Panaroo: moderate o sensitive	Core idéntico. Cloud +13 a 28 % y α de -0.04 a -0.09	Ninguno. α se reporta con su modo
E9	23 genomas por especie; solo completos	Se mantiene el orden de tamaño. α 0.64, 0.55 y 0.74	Ninguno
E10	F5 con UniProtKB en vez de nr	7 genes más pasarían como específicos	Se mantiene nr
E11	Especie por nombre en vez de ANI	5 genes más pasarían como específicos	Se mantiene el ANI
E12	Contigs de las referencias: 200, 300 y 1 000	Mismas especies viables	Ninguno
E13	Borde en F1: 0, 50 y 100 pb	Como máximo 4 o 13 candidatos más antes de F4 y F5	Ninguno

Umbrales de calidad (E1 y E2). La Tabla 7.14 recalcula la selección sobre los 66 bins procariotas. La completitud casi no cambia el resultado, porque la mediana de los seleccionados es 99.86 %. La contaminación pesa más: cinco genomas dependen de dónde se ponga el límite entre 1 y 5 %. Entre 5 y 10 % casi no hay bins. Por lo que el límite del 5 % no descarta material que un criterio algo más permisivo recuperaría.

Tabla 7.14: Número de genomas retenidos sobre los 66 bins procariotas al variar los umbrales de completitud y contaminación. La celda en negrita corresponde al caso base.

Completitud	**Cont.** $< 1\,\%$	**Cont.** $< 3\,\%$	**Cont.** $< 5\,\%$	**Cont.** $< 10\,\%$
$> 50\,\%$	17	22	24	25
$> 60\,\%$	17	22	24	25
$> 70\,\%$	16	19	**21**	22
$> 80\,\%$	12	15	17	18
$> 90\,\%$	12	14	16	17
$> 95\,\%$	10	12	14	15

Criterio de dominio (E3). La mayoría simple compara la fracción procariota con las fracciones eucariota, organelar y desconocida por separado. Por lo que un bin con 40 % procariota, 30 % eucariota y 30 % desconocido tiene mayoría procariota, aunque menos de la mitad de su longitud lo sea (Tabla 7.15). Hay 22 bins con fracción procariota entre el 25 y el 75 %. Pero el efecto final es menor, porque CheckM2 elimina después la mezcla de dominios como contaminación. El criterio afecta sobre todo al costo de cómputo de la etapa siguiente.

Tabla 7.15: Número de bins retenidos, sobre los 97 de partida, según el criterio de discriminación por dominio.

Criterio	**Bins retenidos**
Mayoría simple (caso base)	66
Fracción procariota $> 25\,\%$	56
Fracción procariota $> 40\,\%$	54
Fracción procariota $> 50\,\%$	50
Fracción procariota $> 60\,\%$	44
Fracción procariota $> 75\,\%$	34
Fracción procariota $> 90\,\%$	30

ANI de linaje y continuidad (E4 y E5). Las dos parejas que dRep comparó con fastANI tienen 99.96 y 99.78 % de ANI, por lo que siguen colapsando incluso al 99.5 %. El resto está demasiado separado para unirse con cualquier umbral razonable. El filtro de 300 contigs no se aplicó en la Fase 1, porque habría quitado al representante del linaje más prevalente y al único representante de su género. El control de continuidad se trasladó a la Fase 3, donde la fragmentación sí produce un error.

Desreplicación de las referencias (E6). La Tabla 7.16 usa la tabla de ANI que dRep ya había calculado. Al 99.9 % entrarían otras especies, pero ese umbral conserva como distintos genomas que difieren en una de cada mil bases. Se mantuvo el 99 %, el valor por defecto de dRep para separar cepas [39], fijado antes de ver los datos. En *B. licheniformis*, el par más distinto tiene 98.76 % de ANI y aun así todos forman un grupo al 99 %. El motivo por el cual ocurre es que dRep une grupos por enlace promedio. Es decir, usa el ANI promedio entre todos los pares y no el del par más distinto.

Tabla 7.16: Genomas no redundantes por especie según el umbral de ANI. Se resalta en negrita el caso base.

Especie	**99 %**	**99.5 %**	**99.9 %**
B. altitudinis	**137**	154	167
P. frigoritolerans	**42**	52	58
A. schindleri	**23**	24	25
C. firmus_B	**12**	17	17
P. flexa	**4**	15	24
S. warneri_A	**4**	8	17
B. licheniformis	**1**	7	125

Contigs de las referencias (E12). El límite de 300 contigs es más estricto que el de 1 000 que usan GTDB y los autores de PPanGGOLiN [46, 82]. Con 200 contigs, las tres especies tendrían 205, 65 y 29 genomas tras el control de calidad, y con 1 000, como mucho 212, 76 y 29. La especie no viable más cercana al umbral, *Bacillus_AB infantis*, llegaría como mucho a 10.

Modo de limpieza de Panaroo (E8). La Tabla 7.17 repite el pangenoma en modo `sensitive`, que conserva los genes de borde de contig presentes en un solo genoma. El core es idéntico y el shell cambia como máximo en tres familias. El cloud crece con esos genes de borde. Los valores de α de esta tabla usan las mismas permutaciones en ambos modos, por lo que el de *B. altitudinis* difiere en una centésima del de la Tabla 7.2. En modo `sensitive` los candidatos del bin (45, 38 y 171) son casi los mismos que recupera la versión 2 en modo `moderate` (46, 41 y 171).

Tabla 7.17: Pangenoma de cada especie con los modos de limpieza `moderate` (caso base) y `sensitive`.

Especie	Modo	Core	Shell	Cloud	α	Genes del bin eliminados	Candidatos del bin
B. altitudinis	moderate	3303	847	2909	0.65	32	14
	sensitive	3303	847	3293	0.61	1	45
P. frigoritolerans	moderate	3961	2142	10022	0.57	7	34
	sensitive	3961	2143	12295	0.49	3	38
A. schindleri	moderate	2389	1114	4096	0.55	101	70
	sensitive	2389	1117	5237	0.46	1	171

Base de datos y especie en la verificación (E10 y E11). Se evaluaron sobre la primera versión. Con UniProtKB pasarían siete genes que nr sí encontró en otra cepa de la especie (uno en *P. frigoritolerans* y seis en *A. schindleri*), porque UniProtKB omite genomas casi idénticos y le faltan muchos de los géneros más secuenciados. Con la especie según el nombre del NCBI pasarían cinco genes más, que estaban en cepas registradas solo con el género.

7.12 Anexo: Iteraciones de diseño

La Tabla 7.18 resume las iteraciones de diseño. Después se detalla cada una.

Tabla 7.18: Iteraciones de diseño: diseño original, evidencia que obligó a cambiarlo y diseño corregido.

Iteración	Diseño original	Evidencia	Rediseño
1. Árbol filogenómico	Árbol *de novo* con todas las referencias bacterianas de GTDB	No cabe en 98 GB de memoria	Árbol de distancias interno en la Fase 2 y árbol de máxima verosimilitud por especie en la Fase 3

Tabla 7.18 (continuación)

Iteración	Diseño original	Evidencia	Rediseño
2. Selección para el pangenoma	Prevalencia espacial	17 de 19 linajes en una sola muestra. El material propio no alcanza para ningún pangenoma	Disponibilidad pública: al menos 15 genomas no redundantes por especie
3. Pangenoma	Panaroo `strict`, con PPanGGOLiN como alternativa	`strict` elimina los genes de un solo genoma, que es lo que se busca. El bin incompleto reduce el core	Panaroo `moderate`, solo esa herramienta y partición solo con referencias
4. Genes específicos	Familias ausentes en las referencias, contrastadas con nr y nt	Panaroo eliminó 140 genes del bin. Cinco genes estaban en cepas depositadas solo con el género. Contigs de *B. subtilis* pasaban F6	Genes eliminados como candidatos, F5b por ANI, advertencia por identidad casi total y F6 contra otra especie del género
5. Búsqueda remota	Opción remota de BLAST+ contra nr y nt	La opción quedaba esperando sin resultado y el NCBI canceló búsquedas largas	Interfaz web del NCBI, core_nt y lotes que se dividen
6. Comparación funcional	Categorías COG del core y el accesorio	Bakta asignó COG a solo 4 a 31 % de los genes	Pasa a la Fase 4 con DRAM

Primera iteración: árbol filogenómico. El árbol *de novo* con todas las referencias bacterianas de GTDB no cupo en los 98 GB de la cuenta. El OE2 no necesita un árbol del dominio completo, sino verificar la coherencia de las asignaciones. Por lo que en la Fase 2 se calculó un árbol de distancias con los 120 marcadores, restringido a los genomas propios (Figura 7.7). En la Fase 3 la pregunta cambia: se ubica una cepa entre otras de su especie que difieren muy poco. Entre el 87 y el 92 % de los sitios del core son constantes. Un árbol de distancias como el de Neighbor-Joining [83] resume el alineamiento en una distancia por par y pierde la información de cada sitio. La máxima verosimilitud [84] usa cada sitio con un modelo de evolución y da un soporte por rama. Por eso se usó IQ-TREE 3 [40], con el modelo elegido por ModelFinder [41] según el BIC y 1000 réplicas de UFBoot [42]. El árbol de la Fase 2 queda como verificación interna y no como la prueba que preveía la Tabla 5.3.

Segunda iteración: criterio de selección para el pangenoma. El diseño preveía elegir los linajes por prevalencia espacial. Pero 17 de los 19 linajes aparecen en una sola muestra, y el material propio no alcanza para construir ningún pangenoma. Por lo que el criterio pasó a ser la disponibilidad de genomas públicos. La ejecución obligó a precisarlo en varios puntos (Tabla 7.19).

TABLA 7.19: Diferencias entre la Fase 3 descrita en el Capítulo V y la ejecutada.

Aspecto	**Capítulo V**	**Ejecutado**
Criterio de selección	Prevalencia espacial	Disponibilidad de genomas públicos
Umbral de genomas	Aproximadamente diez	15, contados después de la desreplicación
Linajes evaluados	Los seleccionados por prevalencia	Los 12 con nombre de especie en GTDB
Origen de las referencias	RefSeq y GTDB, con prioridad de RefSeq	Clúster de especie de GTDB R220, con ensamblajes de RefSeq y de GenBank
Control de calidad de las referencias	Sin especificar	Completitud $\geq 95\,\%$, contaminación $\leq 5\,\%$, ≤ 300 contigs, solo aislados
Referencias insuficientes	Ampliar al género	No se amplió: una especie sin referencias suficientes queda fuera
Número de referencias	Hasta estabilizar la curva de acumulación	Todas las no redundantes, con un tope de 50
Prioridad en la elección	Cepas latinoamericanas	Sin preferencia regional; prioridad a cepas tipo y a aislados de sustrato pétreo o árido
Exclusiones manuales	No previstas	Cuatro genomas con nombre de otro filo en el NCBI

El umbral de diez genomas no tenía respaldo bibliográfico y se elevó a 15, el mínimo con que los autores de PPanGGOLiN evaluaron la partición [46]. Se aplica después de la desreplicación, porque los genomas redundantes inflan el core y pueden hacer pasar por cerrado un pangenoma abierto [74]. No se amplió al género, porque un pangenoma solo separa bien el core del accesorio entre genomas muy emparentados. El número de referencias no se fijó con la curva de acumulación, porque en un pangenoma abierto la

curva no se estabiliza [72]. Se usaron todas las no redundantes con un tope de 50, que solo afectó a *B. altitudinis*. La preferencia por cepas latinoamericanas se eliminó por tres motivos. En primer lugar, el pangenoma debe representar la diversidad global de la especie. En segundo lugar, solo 19 de los 656 genomas válidos eran latinoamericanos. Por último, la búsqueda de genes específicos ya incluye todos los genomas descargados.

Tercera iteración: herramienta y modo de limpieza del pangenoma. El modo `strict` de Panaroo elimina de forma agresiva los genes de un solo genoma, porque cuando todos los genomas son de buena calidad suelen ser errores. Pero un gen propio de la cepa es, por definición, un gen de un solo genoma. Por lo que se adoptó el modo `moderate`. Se descartó PPanGGOLiN para no duplicar el análisis, y la ley de Heaps se estimó por separado [73]. Además, la frecuencia de cada familia se calcula solo con las referencias, porque en el piloto contar el bin hizo caer el core de 3 410 a 2 539 familias.

Cuarta iteración: verificación de genes específicos. La primera versión dejó 2, 0 y 30 genes específicos. Al revisarla aparecieron dos problemas. En primer lugar, en modo `moderate` Panaroo elimina el gen del extremo de un contig si aparece en menos de dos genomas, y repite la eliminación hacia el interior hasta llegar a un gen compartido [35]. Un MAG tiene muchos extremos de contig. En los tres bins se eliminaron 140 genes, 136 de ellos en tramos continuos desde un borde. Por eso F6 no había recibido ningún contig. En segundo lugar, cinco genes estaban en dos cepas depositadas como *Bacillus* sp. y *Acinetobacter* sp. Según el ANI que calcula el NCBI [69], pertenecen a *B. altitudinis* y a *A. schindleri*. Ambas son de rizosfera en China y se publicaron en agosto de 2025, después de GTDB R220. El rediseño incluyó como candidatos los genes eliminados, agregó F5b y agregó una advertencia para copias casi idénticas en otra especie (al menos 99 % de identidad en el 90 % del gen). Con la corrección por ANI la primera versión bajó a 0, 0 y 27. La segunda versión mostró un tercer problema: cuatro contigs huérfanos de *B. altitudinis* eran idénticos a *B. subtilis* y F6 solo descartaba los parecidos a otro género. Desde entonces F6 descarta también los contigs que coinciden con otra especie del mismo género con al menos 99 % de identidad y 90 % de cobertura. No cuentan los parecidos

registrados solo con el género. La regla se fijó antes de repetir el análisis y solo cambió *B. altitudinis*, de ocho genes específicos a ninguno.

Quinta iteración: búsqueda remota. La opción remota de BLAST+ quedaba esperando en el clúster sin devolver resultados. Se reemplazó por el envío directo a la interfaz web del NCBI, y para los contigs se consultó core_nt en lugar de nt. En la primera versión la cola del NCBI llegó a siete horas por especie, por lo que se probó UniProtKB como alternativa, sin éxito (E10). En la segunda versión el NCBI canceló una búsqueda por exceder su límite de tiempo de procesador. El programa pasó a enviar lotes más pequeños y a dividirlos si se cancelan, y la búsqueda terminó sin consultas fallidas.

Sexta iteración: comparación funcional. Bakta asignó una categoría COG (*Clusters of Orthologous Groups*) a solo entre el 4 y el 31 % de los genes, y la proporción con número KEGG fue parecida. Con tan pocos genes anotados la comparación del core y el accesorio no es confiable. Por lo que pasa a la Fase 4, que anota los genes con DRAM.