UNIVERSIDAD DE INGENIERÍA Y TECNOLOGÍA

CARRERA DE BIOINGENIERÍA



Diseño de un modelo predictivo de riesgo de deterioro de la Estela de Raimondi basado en genómica comparativa y potencial metabólico

PROYECTO FINAL DE CARRERA

AUTOR(ES)

Eduardo Esteban Tello Osorio

Ana Sofía Barrientos Uriarte

ASESOR(ES)

Pablo Tsukayama Cisneros

Monica Cecilia Santa María Fuster

Harry Gustavo Saavedra Espinoza

Lima - Perú

2026

TABLA DE CONTENIDO

Pág.

RESUMEN 1
ABSTRACT 2

CAPÍTULO I INTRODUCCIÓN **3**
Presentación del proyecto 3
Descripción de la situación problemática 3
Formulación del problema 4
Objetivos del proyecto 5
Objetivo general 5
Objetivos específicos 5
Justificación 6
Alcance y limitaciones 7

CAPÍTULO II ESTADO DEL ARTE **8**
2.1 Soluciones precedentes 8
2.1.1 Protocolos basados en cultivo microbiológico (método tradicional) 8
2.1.2 Tratamientos y limpieza con biocidas químicos 10
2.2 Análisis comparativo de tecnologías actuales 10
2.3 Insuficiencia tecnológica 12

CAPÍTULO III MARCO TEÓRICO **14**
3.1 Biodeterioro microbiano en sustratos graníticos 14

3.2 Biopelículas subaéreas en patrimonio pétreo 15
3.3 Metagenómica *shotgun* y ensamblaje de genomas metagenómicos (MAGs) 16
3.4 Evaluación de calidad genómica 17
3.5 Posicionamiento filogenómico y ANI 18
3.5.1 La jerarquía taxonómica 21
3.6 Análisis pangenómico comparativo 22
3.7 Anotación funcional y predicción del potencial metabólico 23
3.8 Limitaciones de la inferencia funcional basada en datos genómicos 25

CAPÍTULO IV MARCO REFERENCIAL 26

4.1 Estándares bioinformáticos 26
4.2 Restricciones realistas del proyecto 27

CAPÍTULO V MARCO METODOLÓGICO 30

5.1 Metodología 30
5.1.1 Diseño general y criterios de decisión metodológica 30
5.1.2 Origen de los datos y unidad de análisis 30
5.1.3 Fase 1. Control de calidad y selección de genomas (OE1) 32
5.1.3.1 Filtrado por dominio 32
5.1.3.2 Evaluación de la calidad genómica 34
5.1.4 Fase 2. Asignación taxonómica y definición de linajes (OE2) 35
5.1.4.1 Clasificación taxonómica genómica 35
5.1.4.2 Confirmación de especie por ANI 35
5.1.4.3 Desreplicación y definición de linajes 36
5.1.4.4 Confirmación filogenómica 37
5.1.4.5 Selección de linajes para el análisis comparativo . . . 38
5.1.5 Fase 3. Análisis pangenómico comparativo (OE3) 39
5.1.5.1 Recopilación de genomas de referencia 39
5.1.5.2 Anotación estructural y funcional consistente 39

5.1.5.3 Reconstrucción del pangenoma 40
5.1.5.4 Identificación de genes candidatos exclusivos de la Estela 42
5.1.6 Fase 4. Caracterización del potencial metabólico y del riesgo (OE4) . . . 42
5.1.6.1 Anotación funcional del potencial metabólico 42
5.1.6.2 Definición de marcadores de riesgo y supervivencia . 43
5.1.6.3 Integración del potencial funcional con la estructura del pangenoma 44
5.1.7 Reproducibilidad 45

CAPÍTULO VI DISEÑO TECNOLÓGICO 48

6.1 Cálculo de los parámetros y dimensionamiento de los componentes 48
6.1.1 Bases de diseño: el conjunto de datos de entrada 49
6.1.2 Parámetros operativos del diseño 50
6.1.3 Dimensionamiento del cómputo 53
6.1.4 Dimensionamiento del almacenamiento 57
6.2 Selección de materiales, componentes y equipos de la solución 58
6.2.1 Versiones de software y compatibilidad 58
6.2.2 Bases de datos como insumo de referencia 60
6.2.3 Entorno de ejecución 62
6.2.4 Plataforma de cómputo 63
6.3 Integración e implementación de los componentes en la solución final . . . 64
6.3.1 Organización del sistema en programas 64
6.3.2 Normalización de la entrada y trazabilidad 67
6.3.3 Encadenamiento entre etapas 68
6.3.4 Implementación de la verificación de genes específicos 73
6.3.5 Implementación de los scripts de ejecución 74
6.3.6 Control de versiones 77
6.4 Representación gráfica de la solución y su verificación 77

6.4.1 Diagrama de flujo del sistema 77
6.4.2 Arquitectura de cómputo 81
6.4.3 Verificación de la correspondencia entre el diagrama y la implementación 82

CAPÍTULO VII PRUEBAS Y RESULTADOS 84

7.1 Plan de pruebas de la solución 84
7.1.1 Caso base 84
7.1.2 Variables medidas 86
7.1.3 Escenarios de sensibilidad 87
7.2 Análisis de los resultados de las pruebas 88
7.2.1 Resultados de la Fase 1: control de calidad y selección de genomas (OE1) 89
7.2.1.1 Depuración secuencial del conjunto de bins 89
7.2.1.2 Calidad y estructura de los 21 genomas seleccionados 92
7.2.1.3 Implicancia para el OE1 94
7.2.2 Resultados de la Fase 2: asignación taxonómica y definición de linajes (OE2) 95
7.2.2.1 Composición taxonómica de la fracción viable 95
7.2.2.2 Confirmación filogenómica 97
7.2.2.3 Confirmación de especie y candidatos a novedad taxonómica 98
7.2.2.4 Desreplicación y definición de linajes 100
7.2.2.5 Prevalencia espacial de los linajes 102
7.2.2.6 Implicancia para el OE2 104
7.2.3 Resultados de la Fase 3: análisis pangenómico comparativo (OE3) 105
7.2.3.1 Selección de especies y de genomas de referencia . . 106
7.2.3.2 Anotación de los genomas 109
7.2.3.3 Pangenoma de cada especie 110
7.2.3.4 Posición de cada bin en el pangenoma de su especie 114
7.2.3.5 Ubicación filogenética de cada bin 116

7.2.3.6 ANI de cada bin y coherencia con el árbol 119
7.2.3.7 Contenido accesorio, parentesco y hábitat 121
7.2.3.8 Genes específicos de la cepa 122
7.2.3.9 Implicancia para el OE3 125
7.2.4 Sensibilidad de los resultados a los umbrales elegidos 126
7.2.4.1 Umbrales de calidad genómica 126
7.2.4.2 Criterio de discriminación por dominio 128
7.2.4.3 Umbral de ANI para la definición de linaje 129
7.2.4.4 Continuidad del ensamblaje 129
7.2.4.5 Umbral de desreplicación de las referencias 130
7.2.4.6 Umbral de contigs de las referencias 131
7.2.4.7 Umbral del genoma core 131
7.2.4.8 Modo de limpieza de Panaroo 132
7.2.4.9 Base de datos y definición de especie en la verificación 133
7.2.4.10 Distancia mínima al borde del contig 133
7.2.5 Iteraciones de diseño derivadas de los resultados 133
7.2.5.1 Primera iteración: alcance del árbol filogenómico . . 134
7.2.5.2 Segunda iteración: criterio de selección de linajes para el pangenoma 135
7.2.5.3 Tercera iteración: herramienta y modo de limpieza del pangenoma 138
7.2.5.4 Cuarta iteración: verificación de genes específicos . . 138
7.2.5.5 Quinta iteración: ejecución de la búsqueda remota . 140
7.2.5.6 Sexta iteración: comparación funcional del core y el accesorio 140
7.3 Verificación del cumplimiento de las especificaciones técnicas 140
7.4 Verificación del cumplimiento de restricciones 142
ANEXOS 157

Resolución de problemas 157
Trabajo en equipo 159
Experimentación 160
Aprendizaje continuo 161
7.5 Anexo: Repositorio de GitHub 163
7.6 Anexo: Reporte completo de calidad y selección de bins (Fase 1) 163

ÍNDICE DE TABLAS

Tabla 3.1 Categorías de calidad MIMAG para MAGs bacterianos y arqueales [30]. 18

Tabla 4.1 Matriz de restricciones realistas del proyecto y su impacto en las decisiones de diseño metodológico. 28

Tabla 5.1 Bins genómicos recuperados por muestra (previos al filtrado por dominio y calidad). 33

Tabla 5.2 Matriz de selección de software para la clasificación de contigs. 34

Tabla 5.3 Matriz de selección de software para la confirmación filogenómica. 37

Tabla 5.4 Matriz de selección de software para la anotación estructural y funcional. 40

Tabla 5.5 Matriz de selección de software para la reconstrucción del pangenoma. 41

Tabla 5.6 Marcadores genómicos *a priori* de biodeterioro, supervivencia y contexto, con la regla de presencia de cada función. 46

Tabla 6.1 Bases de diseño del conjunto de entrada 49

Tabla 6.2 Bases de diseño de la Fase 3 50

Tabla 6.3 Parámetros operativos implementados 51

Tabla 6.4 Parámetros operativos de la Fase 3 52

Tabla 6.5 Dimensionamiento de cómputo por etapa 54

Tabla 6.6 Dimensionamiento de cómputo de la Fase 3 55

Tabla 6.7 Consumo medido en la Fase 3 57

Tabla 6.8 Dimensionamiento del almacenamiento 57
Tabla 6.9 Versiones de software seleccionadas 59
Tabla 6.10 Insumos de referencia del sistema 61
Tabla 6.11 Programas que componen el sistema 65
Tabla 6.12 Programas de la Fase 3 66
Tabla 6.13 Archivos que encadenan las etapas 69
Tabla 6.14 Archivos que encadenan la Fase 3 70
Tabla 6.15 Implementación de los filtros de genes específicos 73

Tabla 7.1 Parámetros del caso base 85
Tabla 7.2 Parámetros del caso base de la Fase 3 86
Tabla 7.3 Variables medidas en cada etapa 87
Tabla 7.4 Escenarios de sensibilidad 88
Tabla 7.5 Métricas de los 21 MAGs seleccionados 94
Tabla 7.6 Linajes definidos en la Fase 2 105
Tabla 7.7 Viabilidad de las especies para el pangenoma 107
Tabla 7.8 Anotación de referencias y bins 109
Tabla 7.9 Tamaño y partición del pangenoma 110
Tabla 7.10 Genes del bin por categoría del pangenoma 114
Tabla 7.11 Árboles del genoma core 117
Tabla 7.12 ANI de cada bin contra su especie 119
Tabla 7.13 Contenido accesorio frente a parentesco y hábitat 122
Tabla 7.14 Embudo de genes específicos de la cepa 124
Tabla 7.15 Sensibilidad a los umbrales de calidad 127
Tabla 7.16 Sensibilidad del criterio de dominio 128
Tabla 7.17 Sensibilidad al umbral de desreplicación 130
Tabla 7.18 Sensibilidad al modo de limpieza de Panaroo 132
Tabla 7.19 Diferencias entre el diseño original y la ejecución de la Fase 3 . 136
Tabla 7.20 Matriz de verificación de especificaciones técnicas 141

Tabla 7.21 Matriz de verificación de restricciones 143
Tabla 7.22 Aprendizaje continuo: fuentes consultadas, contenido aprendido y su aplicación en el documento. 161
Tabla 7.23 Reporte completo de evaluación y filtrado de bins genómicos (Fase 1). 163

ÍNDICE DE FIGURAS

Figura 5.1 Esquema de muestreo de la Estela de Raimondi. Se señalan los 20 puntos de hisopado distribuidos sobre las cinco regiones del monumento (base superior, cara frontal, laterales izquierda y derecha, y sección inferior). En cada punto se recolectaron dos hisopados independientes: el hisopo A, destinado a la extracción directa de ADN para secuenciación de amplicones, y el hisopo B, destinado al cultivo de la fracción viable, posteriormente secuenciado por metagenómica *shotgun*. Tomado del informe técnico de la UPCH [10]. 31

Figura 6.1 Diagrama de flujo del sistema 78
Figura 6.2 Diagrama de flujo de la Fase 3 80
Figura 6.3 Arquitectura de cómputo del sistema 82

Figura 7.1 Embudo de selección de genomas 91
Figura 7.2 Calidad y métricas de ensamblaje 92
Figura 7.3 Composición taxonómica 96
Figura 7.4 Árbol filogenómico de los 21 genomas 97
Figura 7.5 Evaluación de novedad taxonómica 99
Figura 7.6 Matriz de similitud genómica 101
Figura 7.7 Prevalencia espacial de los linajes 102
Figura 7.8 Curvas de acumulación del pangenoma 111
Figura 7.9 Diagnóstico de la apertura del pangenoma 113
Figura 7.10 Posición de cada bin en el pangenoma 115

Figura 7.11 Árbol del genoma core de *P. frigoritolerans* 118
Figura 7.12 ANI de cada bin y coherencia con el árbol 120
Figura 7.13 Diagrama de Gantt del trabajo en equipo durante el desarrollo del proyecto. 159
Figura 7.14 Flujograma del marco metodológico: cuatro fases consecutivas (OE1 a OE4) desde el origen de los datos metagenómicos hasta la caracterización del potencial metabólico y de riesgo. 160

RESUMEN

El patrimonio pétreo está expuesto al biodeterioro microbiano, proceso mediante el cual las comunidades que colonizan la roca disuelven su matriz mineral y alteran su superficie. La Estela de Raimondi, litoescultura de granito de la cultura Chavín bajo custodia museística, presenta biopelículas y alteraciones cromáticas cuya evaluación previa se limitó a la identificación taxonómica, sin esclarecer la capacidad de deterioro de los organismos vivos que la habitan. El objetivo de este proyecto fue diseñar un flujo de análisis computacional para caracterizar el potencial de biodeterioro y las señales de adaptación genómica de los linajes bacterianos dominantes de la fracción viable del monumento, con el fin de sustentar la evaluación del riesgo y una conservación preventiva basada en evidencia genómica. Se partió de datos de secuenciación metagenómica masiva obtenidos de la fracción cultivable de la superficie, sobre los que se estructuró un flujo reproducible que integró el control de calidad genómica, la clasificación taxonómica basada en el genoma completo, la agrupación de genomas redundantes en linajes, la reconstrucción pangenómica comparativa frente a referencias globales y la anotación funcional del potencial metabólico.

Palabras clave:

Biodeterioro; Patrimonio pétreo; Metagenómica; Pangenoma; Potencial metabólico; Conservación preventiva; Estela de Raimondi

ABSTRACT

Stone heritage is exposed to microbial biodeterioration, a process by which the communities colonizing the rock dissolve its mineral matrix and alter its surface. The Raimondi Stela, a granite lithosculpture of the Chavín culture held in a national museum, exhibits biofilms and chromatic alterations whose prior assessment was limited to taxonomic identification, without clarifying the deterioration capacity of the living organisms inhabiting it. The objective of this project was to design a computational analysis workflow to characterize the biodeterioration potential and the genomic adaptation signals of the dominant bacterial lineages of the monument's viable fraction, in order to support risk assessment and genomics-based preventive conservation. High-throughput metagenomic sequencing data obtained from the cultivable surface fraction were used as the starting point, upon which a reproducible workflow was structured, integrating genomic quality control, whole-genome-based taxonomic classification, the grouping of redundant genomes into lineages, comparative pangenomic reconstruction against global references, and functional annotation of metabolic potential.

Keywords:

Biodeterioration; Stone heritage; Metagenomics; Pangenome; Metabolic potential; Preventive conservation; Raimondi Stela

CAPÍTULO I

INTRODUCCIÓN

Presentación del proyecto

La Estela de Raimondi es una de las piezas más importantes de la cultura Chavín (Horizonte Temprano, 1200 a.C. - 400 a.C.) y un pilar de la arqueología andina. Elaborada en granito pulido, esta litoescultura de casi dos metros de altura representa a una divinidad antropomorfa, el "Dios de los Báculos", caracterizada por una compleja iconografía que integra rasgos de felinos, aves de rapiña y serpientes [1]. Tras su hallazgo a mediados del siglo XIX, inicialmente por el agricultor Timoteo Espinoza en 1840 y su posterior reconocimiento valórico por Antonio Raimondi en 1860 en el Templo Nuevo de Chavín de Huántar, la Estela ha sido objeto de múltiples traslados y, por consiguiente, daños, desde su uso doméstico en Áncash hasta su actual custodia en el Museo Nacional de Arqueología, Antropología e Historia del Perú (MNAAHP) [2].

El presente proyecto de tesis surge de la necesidad de aplicar herramientas de genómica avanzada y bioinformática para entender la ecología microbiana que habita este monumento, integrando el análisis del pangenoma de linajes bacterianos para identificar poblaciones propias de la región, así como para predecir riesgos de deterioro en elementos arqueológicos.

Descripción de la situación problemática

A pesar de encontrarse en un ambiente controlado de museo, la Estela de

Raimondi no es inmune al paso del tiempo ni a la interacción con agentes biológicos. Históricamente, la pieza ha sufrido daños físicos, incluyendo fracturas por el terremoto de 1940 [3]. Sin embargo, informes técnicos recientes han identificado la presencia de biopelículas y alteraciones cromáticas en la superficie del granito.

Las piedras arqueológicas, como la caliza, el granito o la toba volcánica, son altamente susceptibles al daño causado por comunidades microbianas, incluyendo bacterias, cianobacterias, algas y hongos. Los microorganismos penetran los poros y fisuras de la piedra mediante hifas fúngicas o forman biopelículas [4]. Estas comunidades pueden inducir biocorrosión mediante la secreción de ácidos orgánicos que disuelven la matriz mineral o generar pigmentos que alteran irreparablemente la estética del monumento [4, 5]. Sin embargo, se ha demostrado que las biopelículas subaéreas tienen un rol dual, pues mientras algunas causan deterioro, otras pueden actuar como una capa bioprotectora que regula la humedad térmica, consolida la superficie y protege a la piedra de los contaminantes atmosféricos [5, 6].

El problema reside en que las estrategias tradicionales de conservación suelen ser reactivas y basadas en identificación taxonómica básica, ignorando el potencial metabólico real, las poblaciones favorables y las capacidades adaptativas de las bacterias que dominan la biopelícula.

Formulación del problema

Si bien estudios previos sobre la Estela de Raimondi permitieron caracterizar la diversidad taxonómica de su microbioma mediante secuenciación de amplicones (16S rRNA e ITS2) a partir de ADN ambiental, esta aproximación presenta limitaciones importantes para evaluar su papel en el biodeterioro del monumento. Por un lado, el ADN ambiental no permite distinguir entre microorganismos metabólicamente activos, latentes o muertos, ni diferenciar a los verdaderos colonizadores

del sustrato de aquellos microorganismos depositados pasivamente desde el ambiente [7, 8]. Por otro lado, la secuenciación de amplicones ofrece información sobre la identidad taxonómica de la comunidad microbiana, pero no permite determinar su potencial metabólico ni las capacidades adaptativas de las poblaciones presentes [9].

Frente a ello, la presente tesis se concentra en la fracción viable del microbioma, es decir, en aquellos microorganismos capaces de crecer en cultivo y, por tanto, confirmados como vivos. A partir de esta fracción se realizó secuenciación metagenómica *shotgun* [10]. Mediante el ensamblaje de genomas metagenómicos (MAGs) y el análisis comparativo de sus genes accesorios frente a referencias globales, se busca caracterizar el potencial metabólico y las señales de adaptación evolutiva de los linajes bacterianos dominantes en el sustrato lítico. Esta aproximación permite identificar biomarcadores genómicos asociados a la producción de ácidos y a la formación de biopelículas, aportando parámetros técnicos para la evaluación del riesgo de biodeterioro y el diseño de protocolos de conservación preventiva basados en evidencia genómica.

Objetivos del proyecto

Objetivo general

Diseñar un modelo predictivo para determinar el potencial metabólico y la evolución genómica de los linajes bacterianos dominantes en la Estela de Raimondi mediante análisis de pangenoma y potencial metabólico.

Objetivos específicos

1. Seleccionar los MAGs con mayor integridad ($> 70\,\%$) y baja contaminación ($< 5\,\%$).

2. Determinar la posición filogenómica de los MAGs seleccionados mediante el cálculo de ANI (Identidad Nucleotídica Promedio) y filogenia frente a bases de datos internacionales como NCBI y GTDB.

3. Definir el genoma core y el genoma accesorio de los linajes dominantes de la fracción viable de la Estela frente a genomas de referencia globales, identificando genes exclusivos, es decir, específicos de la Estela.

4. Mapear las rutas metabólicas de supervivencia, como la esporulación, y de deterioro, como la formación de biopelículas y la producción de ácidos, analizando si los genes responsables se encuentran en el genoma accesorio, es decir, si fueron adquiridos por adaptación al monumento.

Justificación

El presente trabajo surge de la necesidad de transitar de una caracterización taxonómica convencional hacia un análisis de resolución genómica. En el contexto de la conservación del patrimonio en Latinoamérica, los estudios microbiológicos suelen detenerse en la descripción de géneros, dejando sin respuesta la interrogante sobre qué mecanismos biológicos específicos están siendo ejecutados activamente en la superficie del monumento [5, 6]. El uso de bioinformática avanzada para la reconstrucción de MAGs y el análisis pangenómico permitirá identificar si los determinantes de biodeterioro, como la síntesis de ácidos orgánicos o la formación de biopelículas, son rasgos intrínsecos de los linajes o adaptaciones adquiridas para la supervivencia en el monumento [7, 11]. Este estudio no solo posiciona el análisis del patrimonio cultural peruano a la vanguardia tecnológica regional, sino que provee una base científica para predecir riesgos y optimizar estrategias de conservación preventiva menos invasivas.

Alcance y limitaciones

El alcance de esta tesis es de naturaleza estrictamente computacional y descriptiva, basándose en el análisis de datos metagenómicos previamente secuenciados de la Estela de Raimondi por la Universidad Peruana Cayetano Heredia (Laboratorio de Genómica Microbiana). El estudio se centrará exclusivamente en los linajes bacterianos dominantes que presenten métricas de calidad genómica adecuadas para un análisis pangenómico robusto.

Entre las limitaciones, se debe precisar que la caracterización describe la fracción del microbioma recuperable mediante cultivo, que corresponde a un subconjunto de la comunidad viable y no necesariamente a la totalidad de las poblaciones dominantes *in situ* [8, 12]. A cambio, garantiza que los genomas analizados provienen de organismos vivos, condición necesaria para atribuirles un rol activo en el biodeterioro. Asimismo, al no contar con datos de metatranscriptómica (RNA-seq), la caracterización funcional representa el potencial metabólico y no la actividad biológica real en el momento de la toma de muestra [13]. Además, la integridad y el grado de contaminación de los MAGs están intrínsecamente ligados a la profundidad de la secuenciación original y a la complejidad de la biopelícula colonizadora [5, 14]. Por otro lado, la potencia del análisis pangenómico está sujeta a la disponibilidad y representatividad de genomas de referencia de alta calidad en bases de datos globales como NCBI o GTDB [15]. Finalmente, factores abióticos externos, como las fluctuaciones de humedad y temperatura en el museo, solo se utilizarán como marco contextual para interpretar las estrategias de supervivencia microbiana.

CAPÍTULO II

ESTADO DEL ARTE

A lo largo del tiempo, la evaluación del biodeterioro en monumentos arqueológicos e históricos ha pasado por distintas etapas tecnológicas, donde cada método presentó limitaciones operativas y alcances técnicos que influyeron en la evolución del área. En este contexto, el propósito de este capítulo es revisar de manera crítica las soluciones analíticas y de intervención desarrolladas tanto en el ámbito académico como industrial, estableciendo un marco comparativo basado en parámetros de rendimiento, cobertura y viabilidad técnica. Esto permitirá comprender las fortalezas y limitaciones de los enfoques previos, así como justificar el desarrollo y la adopción de aproximaciones diagnósticas contemporáneas.

2.1 Soluciones precedentes

2.1.1 Protocolos basados en cultivo microbiológico (método tradicional)

Durante décadas, el estudio de los ecosistemas microbianos en el patrimonio pétreo dependió casi exclusivamente de técnicas dependientes de cultivo. Las muestras extraídas del sustrato se sembraban en medios de laboratorio generales, como Agar Nutritivo, MEA o PDA, frecuentemente suplementados con antibióticos o cicloheximida para la selección de grupos específicos [8]. Este enfoque permitió aislar e identificar morfológicamente a numerosos taxa bacterianos y fúngicos asociados al biodeterioro.

No obstante, esta metodología introduce sesgos selectivos, siendo su principal limitación la estructural: se estima que aproximadamente el 99 % de los microorganismos ambientales son ”viables pero no cultivables”(VBNC) en condiciones de laboratorio estándar, dado que los medios artificiales no replican las condiciones oligotróficas, de estrés hídrico y radiación UV características de las superficies pétreas [8, 12, 16]. En contraste con las tecnologías moleculares modernas, los métodos de cultivo solo logran detectar entre el 1 % y el 5 % de la comunidad microbiana total [17]. Un estudio ilustrativo realizado en el campo de concentración de Auschwitz demostró que el cultivo detectó apenas 8 géneros bacterianos, mientras que la secuenciación NGS reveló 99 géneros en el mismo material [18]. Adicionalmente, los medios de cultivo imponen concentraciones artificialmente elevadas de nutrientes, lo que favorece a microorganismos heterótrofos de rápido crecimiento que pueden no ser los colonizadores dominantes ni los principales agentes de deterioro in situ [8, 19].

Ahora bien, esta misma selectividad adquiere valor metodológico cuando el objetivo no es inventariar la comunidad total, sino identificar a los organismos con capacidad real de deterioro. A diferencia del ADN ambiental, que persiste en el sustrato tras la muerte celular y no distingue entre células activas y muertas [8], el crecimiento en cultivo constituye una prueba directa de viabilidad: todo microorganismo aislado está, por definición, vivo. Por ello, la secuenciación metagenómica aplicada sobre la fracción cultivada permite acoplar la certeza de viabilidad con la resolución genómica, estrategia adoptada en la presente tesis [10]. La contrapartida, que se mantiene explícita, es que dicha fracción representa únicamente el subconjunto cultivable de la comunidad viable, por lo que sus conclusiones no se extienden a los linajes que no crecen en los medios empleados.

2.1.2 Tratamientos y limpieza con biocidas químicos

Para el control del biodeterioro, la práctica conservativa tradicional recurrió históricamente a sustancias antimicrobianas de síntesis química: alcoholes, fenoles, aldehídos, compuestos de amonio cuaternario (como el cloruro de benzalconio), sales de estaño, derivados de isotiazolinonas y tratamientos de fumigación con óxido de etileno [12, 13]. Estas estrategias presentan ventajas a corto plazo en términos de reducción de biomasa visible, pero exhiben graves inconvenientes a mediano y largo plazo.

En primer lugar, la eficacia del biocida es frecuentemente transitoria y requiere reaplicaciones periódicas [13]. En segundo lugar, generan toxicidad tanto para los operadores humanos como para el ecosistema circundante [13]. Desde el punto de vista material, los biocidas oxidantes pueden inducir manchas por herrumbre y eflorescencias sobre la piedra, mientras que las soluciones de limpieza ácida o alcalina comprometen la integridad mineralógica del sustrato [13]. Finalmente, y de mayor relevancia para la gestión del biodeterioro a largo plazo, los biocidas eliminan el microbioma natural sin remover la biomasa celular residual, la cual actúa como sustrato nutritivo que acelera la recolonización. Bajo la presión selectiva del biocida, las comunidades que recolonizan son frecuentemente resistentes al tratamiento y presentan perfiles metabólicos más agresivos, involucrando tanto a cepas bacterianas resistentes como a una mayor presencia de hongos altamente melanizados [13, 20]. Este efecto fue documentado de forma notable tras los tratamientos masivos realizados en las cuevas de Lascaux y en la tumba de San Pablo en Éfeso [12].

2.2 Análisis comparativo de tecnologías actuales

La introducción de las tecnologías de secuenciación de próxima generación (NGS) como Illumina MiSeq, NovaSeq, PacBio y Oxford Nanopore, redefinió los

estándares del análisis del microbioma del patrimonio pétro. En la práctica contemporánea, coexisten diversos enfoques que compiten en términos de rendimiento de datos, costos operativos y viabilidad de estandarización.

La secuenciación de amplicones de genes marcadores evolutivamente conservados, como las regiones hipervariables V3-V6 del gen 16S rRNA (para bacterias y arqueas) y las regiones ITS1/ITS2 (para hongos), permite la identificación filogenética de alta resolución sin necesidad de cultivo previo [16, 21].

La metagenómica de escopeta (shotgun metagenomics) secuencia la totalidad del material genético presente en la muestra, superando el sesgo de la amplificación específica por PCR y revelando no solo qué organismos están presentes, sino que permite determinar potencialmente qué rutas metabólicas y genes funcionales contiene la comunidad [16, 22]. Estudios previos demostraron que la secuenciación de amplicones permite detectar una diversidad microbiana significativamente superior a la obtenida mediante métodos clásicos y, en combinación con herramientas bioinformáticas predictivas, inferir el potencial funcional del microbioma en monumentos pétreos [17, 21].

Cabe precisar que la metagenómica *shotgun* puede aplicarse tanto sobre ADN extraído directamente del ambiente como sobre material previamente enriquecido por cultivo; en el segundo caso, la comunidad se acota a su fracción viable a cambio de un ADN de mayor calidad y trazabilidad, un compromiso relevante en muestras de baja biomasa como las superficies pétreas [10, 23].

En términos comparativos con los métodos tradicionales, la NGS supera significativamente al cultivo en cobertura taxonómica, sensibilidad y representatividad de la comunidad real [12, 16, 18]. No obstante, su coste por muestra es considerablemente más elevado, requiere equipamiento especializado, genera grandes volúmenes de datos que demandan análisis bioinformáticos complejos, y presenta limitaciones

propias: artefactos genéticos generados durante la amplificación por PCR (secuencias quiméricas), resolución taxonómica que frecuentemente no alcanza el nivel de especie, y dificultades de extracción de ADN en estructuras resistentes como las endosporas de Bacillus spp. [7, 8, 17].

En la frontera tecnológica se ubican la metatranscriptómica y la metabolómica ambiental, diseñadas para resolver el perfil funcional dinámico del microbioma in situ [13, 18]. La metatranscriptómica ofrece la medición directa de los transcritos de ARN activos al momento del muestreo, discriminando con precisión entre células muertas, en estado viable pero no cultivable (VBNC) o metabólicamente activas [8]. Sin embargo, la secuenciación de ARN ambiental en el patrimonio pétreo se encuentra aún en una etapa inicial y carece de estandarización operativa; esto se debe en gran medida a la inestabilidad de la molécula y a que los costos de este análisis molecular siguen siendo demasiado altos en relación con los recursos habituales disponibles para los laboratorios de restauración [12, 16]. Por su parte, la metabolómica acoplada a espectrometría de masas (UPLC/HRMS) permite identificar los productos reales del catabolismo (como los ácidos orgánicos implicados en la disolución mineral), pero se enfrenta a la limitación de utilizar bases de datos de referencia ambiental incompletas que generan un volumen considerable de falsos positivos, situando los resultados en un nivel de identificación que requiere precaución y validación adicional [18].

2.3 Insuficiencia tecnológica

A pesar de los importantes avances moleculares, las soluciones actuales presentan vacíos estructurales al ser incapaces de confirmar si el potencial genético detectado se traduce en una actividad de deterioro real in situ, ya que el ADN perdura tras la muerte celular y disocia el inventario microbiano del daño activo [8, 13, 22]. Además, existe una carencia crítica de metodologías estandarizadas y

cuantitativas que permitan relacionar el perfil metabólico con el riesgo material [13], lo que impide diferenciar empíricamente si una biopelícula ejerce un rol de degradación o de bioprotección sobre la piedra [13]. En este contexto, se ha subrayado la necesidad de transitar desde diagnósticos descriptivos y centrados en el material hacia marcos predictivos basados en la función microbiana [24]; sin embargo, estas propuestas permanecen mayoritariamente en un plano conceptual, con énfasis en sustratos calcáreos y sin una implementación operativa que permita particionar el repertorio génico de los linajes colonizadores ni distinguir los rasgos de deterioro intrínsecos de aquellos adquiridos por adaptación al nicho. Por consiguiente, establecer una causalidad directa entre microorganismos específicos y el daño observado sigue siendo un reto profundo debido a las barreras económicas, logísticas y metodológicas para integrar datos multiómicos y petrofísicos [8, 18], lo que evidencia la necesidad urgente de desarrollar plataformas diagnósticas integrales que vinculen la taxonomía con la actividad metabólica activa y el impacto real sobre el sustrato [13].

CAPÍTULO III

MARCO TEÓRICO

3.1 Biodeterioro microbiano en sustratos graníticos

El granito es una roca ígnea intrusiva de textura fanerítica compuesta principalmente por cuarzo (SiO_2), feldespatos potásicos ($KAlSi_3O_8$), plagioclasas ($NaAlSi_3O_8$–$CaAl_2Si_2O_8$) y micas (biotita, moscovita) [3]. Esta composición lo hace susceptible a la biocorrosión química mediada por el microbioma colonizador, que actúa a través de dos mecanismos principales: la acidólisis y la quelatación iónica [4, 25]. En el primer mecanismo, bacterias heterótrofas y hongos secretan ácidos orgánicos de bajo peso molecular, incluyendo ácido oxálico, cítrico, glucónico, láctico y 2-cetoglucónico, que reducen el pH local del microambiente de la biopelícula y disuelven activamente los feldespatos y silicatos de la matriz mineral [18, 25]. En el segundo, estos mismos ácidos actúan como agentes quelantes que secuestran cationes estructurales esenciales (Fe^{2+}, Al^{3+}, Mg^{2+}, Ca^{2+}) de la red cristalina, debilitando la cohesión mineral [25]. Géneros bacterianos como *Bacillus*, *Arthrobacter* y *Streptomyces* han sido identificados como productores de ácido 2-cetoglucónico, un quelante altamente eficiente de la sílice presente en monumentos graníticos [18].

Adicionalmente, bacterias quimiolitoautotróficas del ciclo del nitrógeno (*Nitrosomonas*, *Nitrospira*) y del azufre (*Thiobacillus*, *Sulfurimonas*) producen ácido nítrico y sulfúrico como subproductos metabólicos, que corroen directamente los minerales carbonatados y silicatados de la roca [4, 16, 23]. A nivel físico, las hifas fúngicas ejercen

presión mecánica de turgencia que les permite penetrar microporos y fisuras en proceso casmolítico y criptoendolítico, ampliando progresivamente el sistema de poros del granito y facilitando la entrada de agua [20, 25].

3.2 Biopelículas subaéreas en patrimonio pétreo

Las biopelículas subaéreas (SABs, *Subaerial Biofilms*) constituyen la forma dominante de vida microbiana en superficies líticas expuestas a la atmósfera [5]. Su formación sigue un proceso secuencial regulado molecularmente: (1) adhesión reversible mediada por fuerzas de Van der Waals y electrostáticas; (2) adhesión irreversible mediante proteínas de adhesión de superficie, pili tipo IV y fimbrias; (3) maduración con producción de sustancias poliméricas extracelulares (EPS); y (4) dispersión de células al entorno [26]. La matriz de EPS, que puede representar más del 90 % del volumen de la biopelícula madura, es producida por operones específicos como *epsA-O* en *Bacillus subtilis*, los clusters *pel* y *psl* en *Pseudomonas aeruginosa*, y el operón *csgA* responsable de la síntesis de fibras de curli en enterobacterias [26]. Esta matriz actúa como una esponja biológica que retiene agua, captura nutrientes orgánicos del aire y protege a las células de la desecación y los biocidas [13, 26].

En el contexto del patrimonio pétreo, Villa et al. [5] proponen un marco ecológico fundamental para este proyecto: las biopelículas subaéreas tienen un rol dual. Por un lado, pueden inducir biodeterioro activo mediante la producción de ácidos, pigmentos y presión mecánica; por el otro, pueden actuar como capa de bioprotección que amortigua las fluctuaciones térmicas e hídricas, consolida la superficie y limita la disolución química al entrar en contacto con agua de lluvia o condensación [5, 13]. Esta dualidad funcional implica que la sola identificación taxonómica de microorganismos es insuficiente para determinar el riesgo real de deterioro; es necesaria la caracterización del repertorio funcional, específicamente de los genes

accesorios, para discernir qué mecanismos se encuentran genómicamente codificados en cada linaje [7, 13].

Las estrategias de supervivencia en el nicho oligotrófico del granito incluyen la esporulación (operón *spo0A*/*spoIIA* /*spoIIE* en Firmicutes, altamente prevalentes en ambientes líticos), la melanización en hongos meristemáticos negros (*Ochroconis*, *Coniosporium*) como escudo contra estrés oxidativo y radiación UV, y la síntesis de carotenoides en arqueas y bacterias halotolerantes como *Rubrobacter* spp. [6–8, 12, 19, 27]. Estos rasgos de supervivencia constituyen los biomarcadores genómicos de mayor relevancia para el modelo predictivo de riesgo.

3.3 Metagenómica *shotgun* y ensamblaje de genomas metagenómicos (MAGs)

La metagenómica *shotgun* permite el acceso directo al material genómico total de una comunidad microbiana sin necesidad de cultivo previo, superando el sesgo de cultivabilidad que limita los estudios clásicos al 1–5 % de la diversidad real [7, 9, 17]. En este enfoque, el ADN extraído de la muestra ambiental se fragmenta y secuencia masivamente, generando millones de lecturas cortas (*reads*) que representan fragmentos aleatorios de todos los genomas presentes en la comunidad [8, 9].

El proceso de reconstrucción de MAGs sigue tres etapas principales: ensamblaje, binning y refinamiento. En la etapa de ensamblaje, los *reads* se ensamblan *de novo* en contigs mediante ensambladores basados en grafos de De Bruijn, como MEGAHIT [28] o SPAdes [29], que fragmentan las lecturas en *k-mers* y reconstruyen las secuencias por solapamiento. En la etapa de *binning*, los contigs se agrupan en MAGs candidatos mediante dos señales complementarias: la composición nucleotídica (frecuencia de tetra-nucleótidos, un vector de 256 dimensiones) y el perfil de cobertura diferencial (razón de *reads* alineados sobre longitud del contig a lo largo de

múltiples muestras) [9, 30]. La premisa biológica es que contigs del mismo organismo tendrán firmas de composición y coberturas similares. MetaBAT 2 [31] modela esta relación con una distribución de probabilidad Gaussiana, mientras que DAS Tool [32] integra las predicciones de múltiples *binners* para maximizar el número de MAGs de alta calidad por muestra. El refinamiento manual mediante Anvi'o [30, 33] permite inspeccionar visualmente la coherencia de cada *bin* y eliminar contaminantes.

Esta aproximación supera directamente la limitación del 16S rRNA *amplicon* identificada en la formulación del problema de la tesis: mientras la secuenciación de amplicones provee información taxonómica a nivel de género o especie, los MAGs reconstruyen el genoma completo potencial de cada linaje, habilitando el análisis pangenómico y la predicción del potencial metabólico [9, 34, 35].

3.4 Evaluación de calidad genómica

La calidad de un MAG se define por dos métricas fundamentales: completitud y contaminación [30]. La completitud refleja qué fracción del genoma real ha sido capturada en el MAG; la contaminación indica la proporción de contigs provenientes de organismos distintos al organismo *target*.

Ambas métricas se estiman contando los genes marcadores de copia única (SCGs, *Single-Copy Genes*): genes que evolucionaron para existir exactamente en copia única en >97 % de todos los procariotas. Un SCG ausente sugiere incompletitud; un SCG presente en múltiples copias sugiere contaminación por contigs de otro organismo [30, 36].

$$\text{Completitud} = \frac{\text{SCGs detectados}}{\text{SCGs esperados para el linaje}} \times 100\,\% \tag{III.1}$$

$$\text{Contaminación} = \frac{\text{SCGs redundantes}}{\text{SCGs esperados}} \times 100\,\% \tag{III.2}$$

CheckM2 [14] moderniza este cálculo mediante modelos de *machine learning* (*gradient boosting* y redes neuronales) entrenados sobre cientos de miles de genomas sintéticos simulados a partir de referencias de alta calidad. A diferencia de su predecesor, no requiere asignación taxonómica previa y es más preciso en linajes divergentes como Patescibacteria o el superphylum CPR [14].

El estándar internacional MIMAG [30] establece tres categorías, resumidas en la tabla 3.1: (a) alta calidad (HQ): completitud ≥90 %, contaminación <5 %, ARNr 16S completo; (b) calidad media (MQ): 50–90 % completitud, <10 % contaminación; (c) baja calidad: <50 %. El criterio del OE1 (>70 %, <5 %) se posiciona como un umbral intermedio conservador, apropiado para análisis pangenómicos que requieren representación mínima del *core genome* [14, 30].

Tabla 3.1: Categorías de calidad MIMAG para MAGs bacterianos y arqueales [30].

Categoría	**Completitud (%)**	**Contaminación (%)**	**Criterios adicionales**
Alta calidad (HQ)	≥ 90	< 5	ARNr + ≥ 18 ARNt
Media calidad (MQ)	≥ 50	< 10	—
Baja calidad (LQ)	< 50	Cualquiera	Solo referencial

3.5 Posicionamiento filogenómico y ANI

La identidad nucleotídica promedio (ANI, *Average Nucleotide Identity*) es la métrica estándar actual para la delimitación de especies procarióticas a nivel genómico, sustituyendo empíricamente a la hibridación ADN-ADN (DDH) con mayor reproducibilidad y escala computacional [37]. El ANI se calcula como el promedio ponderado de identidad de secuencia de todos los fragmentos ortólogos entre dos genomas:

$$\mathrm{ANI}(A,B) \;=\; \frac{\sum_{i} \mathrm{identity}(f_i^A, f_i^B) \times |f_i|}{\sum_{i} |f_i|} \tag{III.3}$$

donde f_i^A y f_i^B son fragmentos ortólogos de 3 kb. Un ANI $\geq$95 % (con fracción de alineamiento, AF $\geq$65 %) equivale a un DDH $\geq$70 %, el umbral convencional de especie [15, 37]. FastANI [37] implementa este cálculo mediante *locality-sensitive hashing* sobre *k-mers* (*sketching* de MinHash), permitiendo comparaciones a escala masiva.

El clasificador GTDB-Tk [15] ubica los MAGs en un árbol filogenómico de referencia usando 120 genes marcadores bacterianos (*bac120*) o 122 arqueales (*arc122*), colocando cada genoma en la taxonomía del *Genome Taxonomy Database* (GTDB) [38]. GTDB corrige las inconsistencias del NCBI normalizando los rangos taxonómicos por divergencia evolutiva relativa (RED, por sus siglas en inglés), siendo especialmente relevante para MAGs ambientales que con frecuencia representan linajes sin cultivos de referencia [15, 38].

Un problema adicional al de la sola delimitación taxonómica surge cuando se aplica el ANI a colecciones completas de MAGs recuperados por metagenómica *shotgun*: dado que el ensamblaje y el *binning* se realizan de forma independiente por muestra, un mismo linaje presente en varios puntos de muestreo puede recuperarse varias veces como genomas ligeramente distintos entre sí, debido a diferencias en la profundidad de secuenciación o en el proceso de ensamblaje de cada muestra. A este proceso de identificar y colapsar genomas redundantes se le conoce como *desreplicación*, y la herramienta estándar para realizarlo es dRep [39], que agrupa los genomas de una colección en clústeres según su ANI y selecciona, dentro de cada clúster, un único genoma representativo.

Internamente, dRep realiza esta comparación en dos pasos. Primero ejecuta una comparación rápida entre todos los genomas mediante *MinHash* (Mash), que agrupa genomas claramente similares en clústeres preliminares de forma poco costosa computacionalmente. Luego, dentro de cada clúster preliminar, calcula el ANI de forma precisa mediante ANIm o FastANI para confirmar la agrupación final. El genoma representativo de cada clúster se escoge según un *score* de calidad que pondera completitud, contaminación y contigüidad (N50), con criterios análogos a los de calidad descritos en la sección 2.4.

El umbral de ANI usado en el segundo paso define qué tan estricta es la agrupación: un umbral cercano al 95 % agrupa genomas de la misma especie, de forma consistente con el umbral de DDH descrito previamente, mientras que un umbral cercano al 99 % agrupa solo genomas de la misma cepa. Este último valor representa además el límite práctico de detección del método, ya que dos copias idénticas de un mismo genoma comparadas entre sí suelen rendir valores de ANI de aproximadamente 99.99 %, por lo que exigir una identidad mayor ya no aporta resolución real [37, 39]. De este modo, la desreplicación cumple dos funciones: elimina la redundancia técnica generada por el ensamblaje independiente de cada muestra, y define operativamente la unidad de análisis, el linaje, sobre la cual se construye posteriormente el pangenoma comparativo descrito en la siguiente sección.

IQ-TREE [40] es un programa de inferencia filogenética que reconstruye árboles mediante el criterio de máxima verosimilitud. Su algoritmo de búsqueda combina perturbaciones de tipo *nearest neighbor interchange* estocástico con una estrategia de hill-climbing eficiente, lo que le permite explorar un espacio amplio de topologías sin caer prematuramente en óptimos locales, un problema frecuente en métodos de búsqueda heurística más simples. Antes de la búsqueda del árbol, IQ-TREE incorpora ModelFinder [41], un procedimiento que evalúa de forma automática el ajuste estadístico de distintos modelos de sustitución de aminoácidos o nucleótidos sobre

el alineamiento de entrada y selecciona el más adecuado según criterios de información (AIC, BIC), evitando que el usuario deba fijar el modelo de forma arbitraria. El soporte estadístico de cada rama del árbol resultante se estima mediante el ultrafast bootstrap (UFBoot) [42], una aproximación computacionalmente eficiente al remuestreo bootstrap tradicional que aproxima de forma no sesgada los valores de soporte con un costo varios órdenes de magnitud menor, permitiendo ejecutar miles de réplicas en una fracción del tiempo que requeriría el bootstrap clásico de Felsenstein. Por estas características, IQ-TREE es ampliamente utilizado en filogenómica bacteriana para construir árboles focalizados a partir de alineamientos concatenados de genes marcadores, como los conjuntos bac120 y ar122 empleados por el GTDB [15], en escenarios donde se requiere no solo inferir la topología del árbol, sino cuantificar la confianza estadística de cada agrupamiento, como la monofilia de un linaje frente a sus genomas de referencia.

3.5.1 La jerarquía taxonómica

La clasificación taxonómica organiza a los organismos en diferentes niveles jerárquicos según sus características y relaciones evolutivas. El **filo** agrupa organismos que comparten características estructurales y evolutivas generales, mientras que la **clase** reúne grupos más específicos dentro de un mismo filo. El **orden** subdivide las clases de acuerdo con características adicionales compartidas entre los organismos, y la **familia** agrupa géneros que presentan una relación evolutiva cercana. El **género** reúne especies estrechamente relacionadas y constituye la primera parte del nombre científico de un organismo. Finalmente, la **especie** representa el nivel taxonómico más específico y permite identificar grupos de organismos con características genéticas y biológicas altamente similares. En conjunto, estos niveles siguen una jerarquía de mayor a menor amplitud: **filo** → **clase** → **orden** → **familia** → **género** → **especie**.

3.6 Análisis pangenómico comparativo

El pangenoma de una especie o linaje bacteriano representa el conjunto total de genes presentes en todos los miembros del grupo [43]. Introducido formalmente por Tettelin et al. [43] con una división inicial entre genes núcleo y accesorios, la genómica computacional moderna lo estructura algorítmicamente en tres compartimentos principales [35, 44]: (a) el ***core genome*** (G_c): genes presentes en $\geq$95 % de los genomas; codifican funciones esenciales conservadas (metabolismo central, replicación, traducción); (b) el ***shell genome***: genes en el 15–95 % de los genomas; representan adaptaciones frecuentes en el nicho; y (c) el ***cloud genome*** (o *dispensable*): genes presentes en <15 %; incluyen genes singulares (*singletons*) posiblemente adquiridos por HGT para nichos específicos.

Los genes accesorios son el producto directo de la transferencia horizontal de genes (HGT, *Horizontal Gene Transfer*): el mecanismo por el cual las bacterias adquieren genes de organismos filogenéticamente distantes mediante conjugación, transformación o transducción [45]. Este proceso permite la rápida adquisición de rasgos fenotípicos, incluyendo la capacidad de producir ácidos orgánicos o *biopelículas*, sin necesidad de mutaciones secuenciales, lo que lo convierte en el principal motor de adaptación ecológica en procariotas [45]. En este microambiente, la propia matriz de la *biopelícula* actúa como un reservorio de ADN extracelular que facilita y potencia estos eventos de transferencia génica [26]. Herramientas recientes como PPanGGOLiN [46] han introducido modelos estadísticos basados en grafos para particionar el pangenoma en sus componentes de manera probabilística. Sin embargo, en colecciones de MAGs, la fragmentación intrínseca de los ensamblajes sigue provocando una sobreestimación de genes accesorios. Para superar esta limitación, Panaroo [35] emplea una representación gráfica del pangenoma que corrige activamente los errores de anotación y ensamblaje mediante la propagación del contexto

genómico vecino, lo que reduce de manera drástica la inflación artificial del genoma accesorio debida a la fragmentación.

3.7 Anotación funcional y predicción del potencial metabólico

La anotación funcional de MAGs sigue un proceso jerárquico descrito en la metagenómica computacional [9], el cual inicia con la predicción de ORFs (*Open Reading Frames*) mediante algoritmos como Prodigal [47] (frecuentemente integrado en *pipelines* como Prokka [48]).

Bakta [49] constituye una evolución de este enfoque de anotación estructural y funcional. A diferencia de *pipelines* anteriores como Prokka, que dependen de alineamientos de secuencias contra bases de datos de referencia limitadas, Bakta incorpora un módulo de identificación de secuencias sin alineamiento (*alignment-free sequence identification*, AFSI), el cual calcula *hashes* MD5 a partir de secuencias proteicas completas para acelerar la asignación de homología. Al emplear una base de datos taxonómicamente independiente, esta característica resulta especialmente relevante para MAGs ambientales, donde la especie o el género del organismo colonizador con frecuencia pertenece a linajes raros o carece de representación cercana en las bases de datos curadas. Para las secuencias no identificadas por AFSI, Bakta integra fuentes complementarias como RefSeq y PSC (*Protein Sequence Clusters* derivados de UniRef90), así como modelos de covarianza de Rfam para ARN no codificante.

A continuación, se realiza una búsqueda de homología contra bases de datos de referencia y la posterior asignación a categorías funcionales, para culminar finalmente con la reconstrucción de rutas metabólicas [34].

Las principales bases de datos funcionales utilizadas en este tipo de análisis son:

- **KEGG Orthology (KO)** [50]: organiza genes en módulos metabólicos y rutas de señalización; la completitud de una ruta se calcula como la fracción de KOs esenciales detectados en el genoma.
- **COG** (*Clusters of Orthologous Groups*) [27]: categorías funcionales de alto nivel (metabolismo, transporte, regulación de transcripción).
- **dbCAN/CAZy** [51, 52]: enzimas activas sobre carbohidratos, relevantes para la degradación de EPS y polisacáridos de la biopelícula.
- **CARD** (*Comprehensive Antibiotic Resistance Database*) [53]: genes de resistencia antimicrobiana, útil para evaluar persistencia bajo tratamientos biocidas.

DRAM (*Distilled and Refined Annotation of Metabolism*) [34] integra estas bases de datos en un sistema de anotación que produce tablas de completitud por módulo metabólico y resúmenes de los principales ciclos biogeoquímicos (nitrógeno, azufre y carbono), así como del inventario de enzimas activas sobre carbohidratos (CAZymes) [34]. Esta herramienta es especialmente apropiada para el presente estudio dado que el mapeo de estas rutas metabólicas permite inferir el potencial de biodeterioro de la comunidad: los ciclos inorgánicos (N y S) están directamente vinculados a la disolución de minerales por acidólisis y biocorrosión [4, 19], mientras que la síntesis de polisacáridos se relaciona con la producción de EPS para la biopelícula. De este modo, la destilación metabólica se alinea perfectamente con la identificación de factores de riesgo exigida en los objetivos del OE4.

La completitud de una vía metabólica se expresa formalmente en la metodología de DRAM [34] como:

$$\text{Completitud}_{\text{vía}} = \frac{\text{módulos KO detectados}}{\text{módulos KO totales en la vía}} \times 100\,\% \tag{III.4}$$

Los biomarcadores genómicos de mayor relevancia para el modelo predictivo de riesgo ecológico incluyen: genes del ciclo TCA (*acnA*, *sdhA*, *fumA*) asociados a la producción de ácidos orgánicos biocorrosivos [13, 19]; la gluconato deshidrogenasa (*gcd*) responsable de la síntesis del ácido 2-cetoglucónico, un potente quelante de silicatos [18]; genes de biosíntesis de EPS (como el operón *pel*) cruciales para la arquitectura de la *biopelícula* [26]; y los operones de esporulación (con reguladores maestros como *spo0A*) como marcadores de persistencia y resistencia extrema [27].

3.8 Limitaciones de la inferencia funcional basada en datos genómicos

La caracterización del potencial metabólico mediante análisis genómico de MAGs representa una aproximación de alto poder inferencial, pero con una limitación intrínseca en ausencia de datos de metatranscriptómica. Dado que los MAGs analizados en esta tesis se recuperaron a partir de la fracción cultivable (hisopo B), los organismos representados demostraron ser metabólicamente viables al proliferar bajo las condiciones de cultivo empleadas; sin embargo, el propio cultivo constituye un filtro selectivo cuyas condiciones (medio, temperatura, tiempo de incubación) no reproducen el ambiente real del monumento (radiación UV, desecación, escasez de nutrientes). Por ello, la detección de un gen no garantiza que su función se exprese de la misma forma *in situ*, y los resultados de este proyecto describen el potencial metabólico codificado en los linajes colonizadores, no la actividad biológica real sobre la piedra, tal como se declara en el alcance de la tesis.

CAPÍTULO IV

MARCO REFERENCIAL

El presente marco referencial contextualiza el entorno operativo para el análisis genómico de la Estela de Raimondi, estableciendo las directrices, limitaciones y consideraciones éticas que fundamentan las decisiones metodológicas del proyecto. Para transitar de un simple inventario taxonómico a la caracterización del potencial metabólico mediante genomas metagenómicos (MAGs), el diseño del estudio asume compromisos técnicos (trade-offs) justificados a través de tres componentes críticos: los estándares de ingeniería bioinformática, las restricciones del entorno real y el análisis ético de la conservación patrimonial.

4.1 Estándares bioinformáticos

El flujo de trabajo para el ensamblaje, control de calidad y análisis comparativo de linajes bacterianos se rige por métricas consensuadas internacionalmente en genómica ambiental, las cuales garantizan la viabilidad técnica de las conclusiones:

- **Estándares MIMAG para la calidad de genomas:** De acuerdo a lo mencionado en el marco teórico, este umbral (>70 % completitud, <5 % contaminación) representa un *trade-off* de diseño, pues flexibiliza el rigor de completitud para maximizar la recuperación de genomas ambientales fragmentados, pero adopta la máxima restricción de contaminación ($< 5\,\%$) para asegurar que el análisis del genoma accesorio no se vea sesgado por la inclusión de ADN foráneo [30].

- **Estandarización taxonómica y genómica:** Para evitar ambigüedades en la clasificación de los MAGs, el diseño requiere el uso de bases de datos curadas y de alta resolución, como la base de datos GTDB (*Genome Taxonomy Database*) a través de herramientas como GTDB-Tk, la cual provee una asignación taxonómica objetiva basada en la divergencia evolutiva relativa y la Identidad Nucleotídica Promedio (ANI) [15]. Asimismo, el mapeo de rutas de esporulación y biodeterioro se enmarca en la capacidad de herramientas de destilación metabólica como DRAM, diseñadas para decodificar las contribuciones microbianas a los ciclos geoquímicos a partir de datos genómicos [34].

- **Requerimientos para el pangenoma:** La comparación genómica a nivel poblacional debe mitigar los errores inherentes a la anotación automatizada, como la fragmentación de ensamblajes que infla artificialmente el tamaño del genoma accesorio [35]. Por ello, se asume el requerimiento de utilizar algoritmos basados en grafos (como la topología de red de Panaroo) que permiten corregir errores de traducción y colapsar familias de genes diversos, asegurando que los genes exclusivos de la Estela correspondan a verdaderas adaptaciones evolutivas (xenólogos o parálogos) y no a artefactos del ensamblaje [35].

4.2 Restricciones realistas del proyecto

Las decisiones de diseño del estudio no solo responden a la teoría bioinformática, sino que están fuertemente moldeadas por las limitaciones del objeto de estudio y su entorno:

- **Restricciones físicas y normativas:** La Estela de Raimondi es una pieza única, inscrita en el Registro Nacional Informatizado del Perú (Pieza L-8741) y de incalculable valor para la nación [3]. Normativamente, cualquier muestreo debe ser estrictamente no destructivo e *in situ*, prohibiendo la alteración física

del soporte [8]. Esto obliga a utilizar técnicas de hisopado superficial en seco que generan cantidades de ADN extremadamente limitadas (baja biomasa) [10]. Esta restricción justifica directamente la decisión de priorizar en los objetivos únicamente a los linajes bacterianos dominantes, pues la secuenciación profunda del microbioma "raro" resulta computacionalmente inviable y estadísticamente ruidosa frente a la baja cantidad de material genético extraíble.

- **Restricciones económicas:** Las tecnologías de secuenciación de próxima generación (NGS) y la evaluación bioinformática profunda presentan altos costos financieros y computacionales. Esta barrera económica justifica el compromiso de emplear metodologías metagenómicas basadas en ADN en lugar de aproximaciones dinámicas más costosas como la metatranscriptómica (ARN) [8].

Las restricciones materiales, operativas y éticas del proyecto se resumen en la tabla 4.1. Cada restricción se asocia a la decisión metodológica concreta que originó.

Tabla 4.1: Matriz de restricciones realistas del proyecto y su impacto en las decisiones de diseño metodológico.

Categoría	**Restricción**	**Consecuencia metodológica**
Ético-patrimonial	Prohibición de muestreo destructivo (raspado, corte, extracción de fragmentos).	Adopción de hisopado seco estéril sobre área $<10\,\mathrm{cm}^2$; no es viable la metaproteómica directa.
Computacional	Capacidad del clúster institucional (memoria RAM, núcleos disponibles).	Selección de MEGAHIT sobre metaSPAdes por menor huella de memoria; binning con MetaBAT 2 en lugar de ensamble de herramientas.
Histórica	Ausencia de muestras previas conservadas de la Estela.	No es posible comparar el estado actual con líneas de base históricas; la inferencia de cambios temporales se limita a hipótesis ecológicas.

El conjunto de restricciones de la tabla 4.1 no constituye una limitación accesoria del trabajo, sino el marco que define qué preguntas pueden responderse con

rigor y cuáles permanecen fuera del alcance metodológico de esta tesis. En particular, la caracterización del potencial metabólico (OE4) es alcanzable bajo estas restricciones; la verificación de su actividad real *in situ*, en cambio, exigiría intervenciones (metatranscriptómica directa o metaproteómica) que el marco ético-patrimonial vigente no permite y que se proponen como continuidad de la investigación en el capítulo final.

CAPÍTULO V

MARCO METODOLÓGICO

5.1 Metodología

5.1.1 Diseño general y criterios de decisión metodológica

El estudio es de naturaleza estrictamente computacional y descriptiva. Parte de datos metagenómicos shotgun previamente secuenciados y ensamblados en el marco del informe técnico microbiológico de la Estela de Raimondi, realizado por UPCH [10], sobre los cuales se construye un flujo bioinformático que va desde el control de calidad de los genomas hasta la inferencia del potencial metabólico de los linajes dominantes. El flujo se organiza en cuatro fases consecutivas, cada una asociada a un objetivo específico (OE1 a OE4), y se ejecuta en el orden presentado a continuación.

5.1.2 Origen de los datos y unidad de análisis

El microbioma de la Estela de Raimondi fue muestreado mediante hisopado en seco sobre la superficie del monumento. En cada punto de muestreo se recolectaron dos hisopados independientes: el hisopo A, destinado a la extracción directa de ADN ambiental para secuenciación de amplicones (16S rRNA e ITS2), y el hisopo B, destinado al cultivo microbiológico de la fracción viable [10]. La secuenciación metagenómica shotgun analizada en esta tesis se realizó sobre el material proveniente del cultivo (hisopo B).

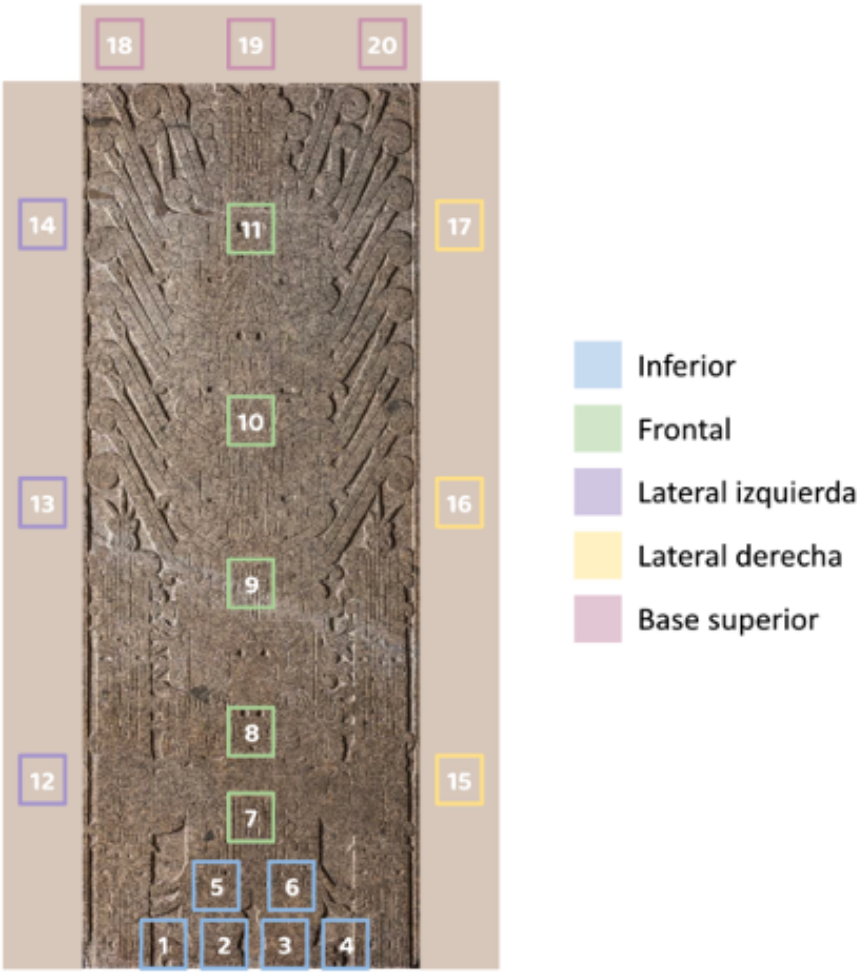


FIGURA 5.1: Esquema de muestreo de la Estela de Raimondi. Se señalan los 20 puntos de hisopado distribuidos sobre las cinco regiones del monumento (base superior, cara frontal, laterales izquierda y derecha, y sección inferior). En cada punto se recolectaron dos hisopados independientes: el hisopo A, destinado a la extracción directa de ADN para secuenciación de amplicones, y el hisopo B, destinado al cultivo de la fracción viable, posteriormente secuenciado por metagenómica *shotgun*. Tomado del informe técnico de la UPCH [10].

Si bien la metagenómica suele aplicarse de forma independiente de cultivo, en el estudio del patrimonio pétreo se han documentado también aproximaciones dependientes de cultivo acopladas a la identificación molecular por secuenciación [16].

En consecuencia, los genomas reconstruidos representan la fracción microbiana recuperable mediante cultivo y no necesariamente las poblaciones dominantes *in situ*. Esta condición se trata de forma explícita como limitación en la Fase 3.

Las lecturas crudas (archivos FASTQ) no estuvieron disponibles para este trabajo. Por ello, todo el flujo se ejecuta sobre los genomas ensamblados (bins) y no sobre lecturas. En consecuencia, la importancia de cada linaje no se mide por abundancia, sino por prevalencia espacial: el número de puntos de muestreo distintos en los que se recuperó ese linaje. Esta métrica no depende de las lecturas crudas y es más robusta frente al sesgo del cultivo.

5.1.3 Fase 1. Control de calidad y selección de genomas (OE1)

5.1.3.1. Filtrado por dominio

Los bins se filtraron primero por dominio para descartar contigs de origen eucariota u organelar antes de cualquier métrica basada en genes procariotas. Se utilizó Tiara [54], un clasificador de secuencias metagenómicas basado en aprendizaje profundo que opera sobre la composición de los contigs en un esquema de dos etapas. La elección de Tiara frente a Whokaryote [55] y EukRep [56] se sustentó en la matriz de selección ponderada (Tabla 5.2), en la que Tiara obtuvo la mayor puntuación total gracias a su facilidad de instalación, su menor costo computacional y su capacidad adicional de identificar ADN organelar; la descripción detallada de cada herramienta evaluada se presenta en el Anexo 1.

Tabla 5.1: Bins genómicos recuperados por muestra (previos al filtrado por dominio y calidad).

Muestra	N.º bins	Long. total (Mb)	Rango bin (Mb)	N50 prom. (kb)	%GC prom.
49	2	28.1	0.55–27.6	173	36.2
50	6	67.3	0.61–53.4	47	59.5
51	1	4.7	4.73	189	52.6
52	5	18.2	0.42–5.3	37	61.6
53	3	36.9	2.48–29.2	264	40.5
54	2	11.6	4.31–7.3	167	38.7
55	1	34.2	34.24	404	51.1
56	6	88.4	0.23–49.6	95	45.6
57	6	74.7	0.22–39.1	164	46.9
58	3	46.5	4.77–29.6	418	48.5
59	2	29.1	5.91–23.2	283	40.9
60	5	49.6	2.32–25.7	52	43.5
61	6	73.1	0.61–40.1	207	47.7
62	5	45.7	0.23–27.9	128	39.4
63	6	88.8	0.37–56.5	40	45.7
64	7	75.5	0.24–29.7	33	43.4
65	5	94.8	0.22–29.6	89	47.0
66	0	—	—	—	—
67	0	—	—	—	—
68	2	2.7	0.25–2.5	43	49.2
69	2	2.7	0.25–2.5	40	49.1
70	6	109.2	0.28–94.3	3	44.0
71	12	126.9	0.26–101.9	6	47.2
72	4	9.7	0.25–6.6	4	38.9
Total	**97**				

Nota. Se dispuso de 24 librerías de secuenciación Illumina, identificadas con los códigos 49 a 72. El procesamiento previo, documentado por el centro de secuenciación, comprendió el ensamblaje por muestra mediante MEGAHIT, la segmentación del ensamblaje en bins genómicos mediante MetaBAT2, la evaluación de métricas de ensamblaje con QUAST y la anotación preliminar de cada bin con Bakta, junto con una asignación taxonómica preliminar basada en Kraken2. Un bin corresponde, en este punto del flujo, a un subconjunto de contigs del ensamblaje agrupados según su perfil de cobertura y composición de tetranucleótidos, bajo el supuesto de que los contigs pertenecientes a un mismo organismo comparten estas señales. Por tanto, cada bin constituye una reconstrucción parcial o completa de un genoma individual, cuya pureza taxonómica y calidad genómica se evalúan posteriormente. De las 24 librerías, 22 produjeron bins, con un total de 97 bins; las muestras 66 y 67 no recuperaron bins y fueron excluidas del análisis genómico. Las cifras mostradas corresponden a bins crudos entregados por el centro de secuenciación y preceden al filtrado por dominio y al control de calidad genómica descritos en la Fase 1; por ello, no implican que la totalidad de los bins listados sean genomas procariotas completos o libres de contaminación.

Tabla 5.2: Matriz de selección de software para la clasificación de contigs.

		Tiara		Whokaryote		EukRep	
Criterio	**Peso (%)**	**Pts**	**Peso×Pts**	**Pts**	**Peso×Pts**	**Pts**	**Peso×Pts**
Facilidad de instalación	10	4	40	3	30	2	20
Acceso a dependencias	15	4	60	2	30	2	30
Costo computacional	10	3	30	2	20	3	30
Integración en pipeline	15	4	60	3	45	2	30
Calidad de resultado	30	4	120	3	90	2	60
Alcance funcional	10	4	40	2	20	2	20
Interpretabilidad	10	3	30	4	40	2	20
Total	**100**		**380**		**275**		**210**

Se aplicó una longitud mínima de contig de 3000 pares de bases, valor por debajo del cual los clasificadores basados en composición de secuencia pierden exactitud, y se descartaron los bins cuya fracción mayoritaria de longitud se clasificó como eucariota u organelar. Dado que Tiara discrimina entre procariotas y eucariotas pero no separa bacterias de arqueas, esta última distinción se resolvió en las fases posteriores mediante CheckM2 y GTDB-Tk.

5.1.3.2. Evaluación de la calidad genómica

La completitud y la contaminación de los bins procariotas se estimaron con CheckM2 [14], que predice ambas métricas mediante modelos de aprendizaje automático entrenados sobre genomas de referencia y no requiere asignación taxonómica previa, lo que mejora su desempeño en linajes divergentes [14]. Se conservaron únicamente los genomas con completitud superior al 70 % y contaminación inferior al 5 %.

El umbral no corresponde a ninguna categoría MIMAG estándar. Se adoptó un valor intermedio que flexibiliza la exigencia de completitud, con el fin de recuperar genomas ambientales fragmentados, pero mantiene la restricción más estricta de contaminación (inferior al 5 %) para evitar que la posterior reconstrucción del genoma accesorio se sesgue por la inclusión de ADN foráneo [30]. Este compromiso se documenta como criterio propio del proyecto y no como un estándar MIMAG de alta calidad.

5.1.4 Fase 2. Asignación taxonómica y definición de linajes (OE2)

5.1.4.1. Clasificación taxonómica genómica

Los genomas que superaron el control de calidad se clasificaron taxonómicamente con GTDB-Tk [15], empleando los conjuntos de marcadores bac120 para bacterias y arc122 para arqueas. GTDB-Tk ubica cada genoma en el árbol de referencia del GTDB, que normaliza los rangos taxonómicos según la divergencia evolutiva relativa [15, 38]. Este enfoque basado en el genoma completo reemplaza a la asignación preliminar por Kraken2, de naturaleza basada en lecturas, por una clasificación de mayor resolución y consistencia filogenética.

5.1.4.2. Confirmación de especie por ANI

La clasificación de GTDB-Tk asigna taxonomía comparando características genómicas globales, pero no compara directamente el genoma completo contra una cepa de referencia. Para confirmar la identidad a nivel de especie, se calculó la Identidad Nucleotídica Promedio (ANI) entre cada genoma ensamblado y el genoma de referencia oficial de su taxón asignado. Este genoma de referencia corresponde a la cepa tipo de la especie (el organismo depositado en bases de datos públicas cuando

esa especie fue descrita por primera vez, y que actualmente actúa como estándar de comparación).

El ANI mide qué tan parecidas son dos secuencias de ADN a lo largo del genoma completo. Dos genomas se consideran de la misma especie cuando el ANI es igual o superior al 95 % y al menos el 65 % del genoma puede alinearse [15, 37].

5.1.4.3. Desreplicación y definición de linajes

Dado que el ensamblaje y el binning se realizaron por muestra de forma independiente, un mismo organismo presente en varias muestras pudo recuperarse como bins redundantes. Para colapsar esta redundancia se aplicó dRep [39], que agrupa los genomas en clústeres según su Identidad Nucleotídica Promedio (ANI). Se utilizó un umbral primario del 95 % de ANI para delimitar clústeres a nivel de especie, congruente con el radio de circunscripción taxonómica estándar empleado por la base de datos GTDB [15]. De forma complementaria, el agrupamiento secundario se definió a un umbral estricto del 99 % de ANI para lograr una resolución de cepa. Este último umbral permite agrupar genomas casi idénticos [39], asegurando la desreplicación de poblaciones clonales sin colapsar cepas de la misma especie que pudieran albergar variaciones intraespecíficas relevantes. Cada clúster resultante se define operativamente como un linaje.

La desreplicación cumple dos funciones determinantes. Primero, provee varios genomas de la Estela por linaje, lo que habilita la construcción de un pangenoma interno con réplicas reales en la Fase 4. Segundo, permite definir una métrica de prevalencia objetiva, calculada como el número de muestras, sobre el total de 24, que aportan al menos un genoma a cada clúster. Esta métrica no depende de las lecturas crudas y por ello constituye el criterio primario de importancia de un linaje.

5.1.4.4. Confirmación filogenómica

La ubicación de cada linaje se visualizó mediante un árbol filogenómico focalizado que incluyó los genomas de la Estela y los genomas de referencia, inferido de novo por GTDB-Tk [15] a partir de los mismos marcadores bac120 empleados en la clasificación taxonómica. Esta elección, frente a la alternativa de inferir el árbol externamente con IQ-TREE [57], se sustentó en la matriz de selección ponderada (Tabla 5.3), en la que GTDB-Tk obtuvo la mayor puntuación gracias a su integración directa en el flujo ya ejecutado y a su menor costo computacional, criterio priorizado dada la restricción de cómputo propia de un proyecto de pregrado. Como contrapartida, el árbol de novo de GTDB-Tk no provee selección de modelo de sustitución ni soporte de rama mediante bootstrap, por lo que la topología resultante se interpreta como una verificación visual de la monofilia de cada linaje frente a las referencias, y no como una confirmación con soporte estadístico cuantificado.

Tabla 5.3: Matriz de selección de software para la confirmación filogenómica.

		GTDB-Tk (árbol de novo)		**IQ-TREE**	
Criterio	**Peso (%)**	**Pts**	**Peso×Pts**	**Pts**	**Peso×Pts**
Facilidad de instalación	20	4	80	3	60
Acceso a dependencias	20	4	80	3	60
Costo computacional	15	4	60	2	30
Integración en pipeline	20	4	80	3	60
Calidad de resultado	10	2	20	4	40
Alcance funcional	5	2	10	4	20
Interpretabilidad	10	2	20	4	40
Total	**100**		**350**		**310**

5.1.4.5. Selección de linajes para el análisis comparativo

A partir de los linajes definidos, entendidos como los clústeres de especie obtenidos al 95 % de ANI, se priorizaron los de mayor prevalencia. Por restricciones de cómputo, el análisis comparativo se concentró en los tres linajes de mayor prevalencia. Para esta selección, no se utilizó la abundancia de secuencias, ya que los cultivos previos en laboratorio sesgan estos números. En su lugar, se utilizó el criterio de **prevalencia espacial** [39]. Esto consistió en seleccionar a las especies que lograron ser ensambladas en la mayor cantidad de puntos físicos distintos de la Estela Raimondi. La detección repetida de un mismo genoma a través de múltiples muestras independientes demuestra que se trata de microorganismos residentes y estables, y no de simple polvo o contaminación ambiental

Esta elección de la especie como unidad primaria de análisis resulta indispensable para el correcto funcionamiento de Panaroo, dado que el algoritmo requiere comparar un conjunto de genomas estrechamente emparentados para diferenciar con precisión los genes esenciales y conservados (genoma core) de aquellos genes ganados o perdidos como producto de la adaptación evolutiva al nicho específico (genoma accesorio). Cuando la comparación se realiza entre genomas filogenéticamente distantes, esta distinción pierde fiabilidad, pues la divergencia de secuencia entre especies no relacionadas introduce una subestimación artificial del genoma core, atribuible a limitaciones del método de detección de ortólogos y no a una reducción real del repertorio génico compartido [35].

5.1.5 Fase 3. Análisis pangenómico comparativo (OE3)

5.1.5.1. Recopilación de genomas de referencia

Para cada uno de los tres linajes seleccionados se recopilaron genomas de referencia desde NCBI RefSeq y GTDB. Se incluyeron genomas de la especie asignada por GTDB-Tk y, cuando el número de referencias a nivel de especie fue insuficiente, se amplió al género correspondiente. Se priorizaron los ensamblajes designados como completos o representativos en RefSeq, que ya han pasado por el proceso de curación de NCBI. Cuando un linaje no contó con referencias de especie en RefSeq, se recurrió a los genomas tipo de GTDB como alternativa.

El conjunto de referencias se desreplicó con dRep a un umbral del 99 % de ANI, con el fin de evitar que genomas casi clonales, frecuentes en taxones muy secuenciados, inflaran artificialmente el genoma núcleo. El número de genomas de referencia no se fijó de forma arbitraria, sino que se determinó mediante la curva de acumulación del pangenoma: se añadieron genomas secuencialmente hasta observar la estabilización del genoma núcleo [43]. Cuando un taxón presentó menos de aproximadamente diez genomas de referencia de calidad suficiente en bases de datos públicas, el conjunto se amplió siguiendo el mismo criterio. En el caso de los linajes arqueales, para los que la disponibilidad de referencias de calidad fue menor, el linaje se incluyó en el análisis comparativo solo si reunió genomas suficientes para estabilizar la curva; en caso contrario, se describió de forma individual sin pangenoma comparativo.

5.1.5.2. Anotación estructural y funcional consistente

La totalidad de los genomas, tanto los MAGs de la Estela como las referencias, se anotó con la misma herramienta y versión para garantizar la homogeneidad

requerida por el análisis pangenómico [35]. Se empleó Bakta [49], que realiza la predicción de marcos abiertos de lectura y la anotación mediante identificación de secuencias sin alineamiento, y que ya se había aplicado a los bins originales. Esta elección, frente a la alternativa de Prokka [48] (heredero directo de Prodigal [47]), se sustentó en la matriz de selección ponderada (Tabla 5.4), en la que Bakta obtuvo la mayor puntuación gracias a su continuidad con la anotación ya aplicada a los bins originales, su mayor resolución en linajes ambientales divergentes y su alcance funcional más amplio; Prokka resultó más liviano de instalar, pero con menor calidad de resultado en MAGs poco representados en bases de datos curadas. La anotación consistente evita que diferencias en la predicción génica se confundan con diferencias biológicas.

Tabla 5.4: Matriz de selección de software para la anotación estructural y funcional.

		Bakta		**Prokka**	
Criterio	**Peso (%)**	**Pts**	**Peso×Pts**	**Pts**	**Peso×Pts**
Facilidad de instalación	10	3	30	4	40
Acceso a dependencias	10	3	30	4	40
Costo computacional	5	3	15	4	20
Integración en pipeline	25	4	100	2	50
Calidad de resultado	25	4	100	2	50
Alcance funcional	15	4	60	3	45
Interpretabilidad	10	4	40	3	30
Total	**100**		**375**		**275**

5.1.5.3. Reconstrucción del pangenoma

El pangenoma de cada linaje se reconstruyó con Panaroo [35] en su modo estricto (clean-mode strict). Esta elección, frente a la alternativa de PPanGGOLiN

[46], se sustentó en la matriz de selección ponderada (Tabla 5.5), en la que Panaroo obtuvo la mayor puntuación gracias a su representación gráfica del pangenoma, que corrige errores de anotación y de ensamblaje mediante la propagación del contexto genómico vecino y reduce de forma marcada la inflación artificial del genoma accesorio asociada a la fragmentación de los MAGs; PPanGGOLiN, pese a ofrecer un modelo probabilístico de partición con módulos adicionales (regiones de plasticidad genómica), no corrige esta inflación con la misma eficacia en colecciones de MAGs fragmentados.

Tabla 5.5: Matriz de selección de software para la reconstrucción del pangenoma.

		Panaroo		**PPanGGOLiN**	
Criterio	**Peso (%)**	**Pts**	**Peso×Pts**	**Pts**	**Peso×Pts**
Facilidad de instalación	10	3	30	3	30
Acceso a dependencias	10	3	30	3	30
Costo computacional	5	3	15	4	20
Integración en pipeline	15	3	45	3	45
Calidad de resultado	35	4	140	2	70
Alcance funcional	15	3	45	4	60
Interpretabilidad	10	4	40	3	30
Total	**100**		**345**		**285**

El pangenoma se particionó en tres compartimentos siguiendo la convención de la genómica comparativa [35, 43, 44]: genoma nuclear (genes presentes en al menos el 95 % de los genomas), genoma de cubierta o shell (genes en el 15 a 95 %) y genoma accesorio o cloud (genes en menos del 15 %).

5.1.5.4. Identificación de genes candidatos exclusivos de la Estela

Los genes candidatos a ser exclusivos de la Estela se definieron como aquellos presentes en uno o más MAGs del monumento y ausentes en todos los genomas de referencia. Para reducir la probabilidad de errores, se exigió que el gen estuviera completo y no truncado en el borde de un contig. Los candidatos se contrastaron mediante búsqueda de homología frente a las bases de datos nr (non-redundant) y nt (nucleotide) para descartar contaminación. Estos genes se interpretan en el marco de la transferencia horizontal de genes como principal motor de adaptación ecológica en procariotas [45]. Dado que la incompletitud de los MAGs implica que la ausencia observada de un gen no equivale a su ausencia real [30], los resultados se reportan como candidatos a exclusivos y como adquisición probable, sin afirmar certeza.

5.1.6 Fase 4. Caracterización del potencial metabólico y del riesgo (OE4)

5.1.6.1. Anotación funcional del potencial metabólico

El potencial metabólico de los linajes seleccionados se caracterizó con la herramienta DRAM [34], la cual integra la asignación de ortólogos KEGG (KO) y produce resúmenes de los ciclos biogeoquímicos del nitrógeno, el azufre y el carbono, así como el inventario de enzimas activas sobre carbohidratos (CAZymes) basado en las bases dbCAN y CAZy. Para la evaluación de los módulos de KEGG, DRAM modela las vías como redes dirigidas y calcula la completitud como el porcentaje de cobertura de la ruta que presenta la mayor proporción de genes (nodos) detectados [34]. Sobre esta base, en el presente estudio se estableció un umbral operativo estricto: un módulo metabólico se consideró funcionalmente ”presente”solo cuando su porcentaje de completitud alcanzó o superó el 66 %. Para las funciones que dependen de varios genes, la presencia se definió mediante una regla explícita para cada función, descrita en la Tabla 5.6.

5.1.6.2. Definición de marcadores de riesgo y supervivencia

La interpretación funcional se ancló en una tabla de marcadores genómicos definida *a priori*, es decir, fijada antes de observar los resultados, con el fin de evitar el sesgo de confirmación. Cada marcador corresponde a una función y no a un gen aislado, de modo que una función que requiere varios genes se cuenta una sola vez. La tabla organiza las funciones en tres categorías. La primera reúne los marcadores de riesgo de biodeterioro: la producción de ácido glucónico y de ácido 2-cetoglucónico, que acidifican el sustrato y actúan como quelantes de silicatos [18]; la biosíntesis de sustancias poliméricas extracelulares (EPS) y la adhesión mediante curli, que sostienen la biopelícula [26]; y la nitrificación y la oxidación del azufre como fuentes de ácidos inorgánicos [4, 19]. La segunda reúne los marcadores de supervivencia o persistencia: la esporulación [27], la síntesis de carotenoides, la respuesta al estrés oxidativo, la síntesis de los solutos compatibles ectoína y trehalosa, que protegen frente a la desecación [58, 59], y la reparación del ADN dañado por radiación ultravioleta [60]. La tercera reúne funciones de contexto que se reportan pero no se interpretan como marcadores de riesgo: el ciclo de los ácidos tricarboxílicos, presente en prácticamente todas las bacterias aerobias [19], las enzimas activas sobre carbohidratos (CAZymes) [51, 52] y la ureólisis, cuya precipitación de carbonato puede tanto proteger como alterar la superficie pétrea [61, 62].

La Tabla 5.6 detalla, para cada función, los genes representativos, sus identificadores KEGG Orthology (KO) y la regla con la que se considera presente. Las reglas exigen los genes necesarios para que la función sea operativa. Por ejemplo, la glucosa deshidrogenasa *gcd* solo se cuenta como productora de ácido glucónico si el genoma porta además los genes de síntesis de su cofactor, la pirroloquinolina quinona (*pqqA–E*). Del mismo modo, la nitrificación y la oxidación del azufre se evalúan con los módulos KEGG completos (M00528 y M00595) y no con genes aislados. Los genes cuya función no distingue el proceso de interés se excluyeron: la nitrato

reductasa *narG* comparte identificador KO con la nitrito oxidorreductasa *nxrA*, y la sulfito reductasa disimilatoria *dsrAB* participa tanto en la reducción como en la oxidación del azufre. Los identificadores KO y los módulos se verificaron directamente contra la base de datos KEGG [50]. Las CAZymes no poseen un identificador KO único; su detección se realiza mediante la base de datos dbCAN, integrada en DRAM. La detección efectiva de cada función en los genomas se obtiene de DRAM durante la fase de anotación funcional.

5.1.6.3. Integración del potencial funcional con la estructura del pangenoma

En el paso final, cada marcador de la tabla *a priori* se mapeó sobre la partición del pangenoma para determinar si reside en el genoma nuclear o en el accesorio. Para evaluar de forma cuantitativa si los marcadores de riesgo se concentran en el genoma accesorio, se aplicó una prueba exacta de Fisher sobre una tabla de contingencia de dos por dos que cruza la condición de gen de riesgo o no de riesgo con su pertenencia al genoma accesorio o nuclear, reportando tanto el valor de probabilidad como la razón de momios (odds ratio) como medida del tamaño del efecto. Cuando se evaluaron varias categorías funcionales de forma simultánea, los valores de probabilidad se ajustaron por comparaciones múltiples mediante el procedimiento de Benjamini y Hochberg. Esta prueba se interpreta con cautela por dos razones: las familias génicas no constituyen observaciones estadísticamente independientes, debido a la no independencia filogenética, y el número reducido de marcadores de riesgo limita la potencia estadística. Por ello, el resultado se presenta como evidencia de apoyo y no como prueba concluyente. De forma complementaria, se caracterizó la apertura del pangenoma estimando el parámetro de la ley de Heaps [46].

La lógica interpretativa es la siguiente. Si los genes de biodeterioro se enriquecen de forma significativa en el genoma accesorio, en particular si son compartidos

por varios MAGs del mismo linaje, ello aporta soporte cuantitativo a la hipótesis de que dichas funciones fueron adquiridas como adaptación al nicho del monumento. Si, por el contrario, residen en el genoma nuclear, se interpretan como rasgos intrínsecos y conservados del linaje. En coherencia con el alcance del estudio, estas conclusiones describen el potencial metabólico codificado y no la actividad biológica real en el momento del muestreo.

5.1.7 Reproducibilidad

Se registró la versión exacta de cada herramienta bioinformática y la versión de cada base de datos empleada, y cada identificador KO se verificó contra la versión vigente de KEGG. El conjunto de software comprende, en orden de ejecución, Tiara [54], CheckM2 [14], GTDB-Tk [15], FastANI [37], dRep [39], Bakta [49], Panaroo [35] y DRAM [34]. Las pruebas estadísticas se ejecutaron en un entorno de R con las bibliotecas correspondientes.

Los análisis computacionalmente intensivos se ejecutaron en el clúster de cómputo de alto rendimiento Khipu de la Universidad de Ingeniería y Tecnología (UTEC), modalidad Tesis. Este tipo de acceso permite el uso de las particiones `debug`, `debug-gpu`, `standard`, `gpu` y `big-mem`, con una asignación máxima por usuario de 32 núcleos de CPU, 98 GB de memoria RAM y 40 *GPU shards*, además de un tiempo máximo de ejecución de 24 horas por trabajo computacional. La disponibilidad de esta infraestructura permitió ejecutar de manera controlada y reproducible las etapas de filtrado, evaluación de calidad, clasificación taxonómica, comparación genómica, anotación funcional y análisis pangenómico.

Para asegurar la trazabilidad del flujo de trabajo, se conservaron los comandos utilizados, los parámetros de ejecución, los archivos de entrada y salida, y los registros generados por cada herramienta. Asimismo, los resultados intermedios relevantes

Tabla 5.6: Marcadores genómicos *a priori* de biodeterioro, supervivencia y contexto, con la regla de presencia de cada función.

Categoría	**Función / mecanismo**	**Genes**	**KO**	**Regla de presencia**	**Fuente**
Riesgo	Ácido glucónico (acidólisis y quelación)	gcd; pqqA–E	K00117; K06135–K06139	gcd y al menos 3 de 5 genes pqq	[18]
Riesgo	Ácido 2-cetoglucónico (quelación de silicatos)	gcd; pqqA–E; gluconato 2-deshidrogenasa	K00117; K06135–K06139; K06150, K06151, K06152	regla anterior y al menos 2 de 3 subunidades	[18]
Riesgo	EPS de biopelícula (Gram positivas)	epsA–O; tasA, tapA	K19419–K19431; K06336, K19433	al menos 66 % del operón eps, o tasA y tapA	[26]
Riesgo	EPS de biopelícula (Gram negativas)	pgaA, pgaB, pgaC, pgaD	K11935, K11931, K11936, K11937	al menos 3 de 4	[26]
Riesgo	Adhesión (curli)	csgA, csgB	K04334, K04335	ambos	[26]
Riesgo	Nitrificación (ácido nítrico)	amoA, amoB, amoC, hao	K28504, K10945, K10946, K10535	módulo M00528 al 66 % (3 de 4)	[19, 34]
Riesgo	Oxidación de azufre (ácido sulfúrico)	soxA, soxX, soxY, soxZ, soxB, soxC, soxD	K17222–K17227, K22622	módulo M00595 al 66 % (5 de 7)	[19]
Supervivencia	Esporulación (latencia y resistencia)	spo0A, spoIIAA, spoIIE	K07699, K06378, K06382	al menos 2 de 3	[27]
Supervivencia	Carotenoides (protección UV)	crtB, crtI	K02291 o K17841; K10027 o K15745	módulo M00097: crtB y crtI	[63]
Supervivencia	Estrés oxidativo	katA, sodA, dps	K03781, K04564, K04047	al menos 2 de 3	[6, 63]
Supervivencia	Desecación: ectoína	ectA, ectB, ectC	K06718, K00836, K06720	al menos 2 de 3	[58, 59]
Supervivencia	Desecación: trehalosa	otsA, otsB; treY, treZ; treS	K00697, K01087; K06044, K01236; K05343	otsA y otsB, o treY y treZ, o treS	[58]
Supervivencia	Reparación del daño UV	fotoliasas (phr)	K01669, K06876	al menos 1	[59, 60]
Contexto	Ácidos orgánicos del ciclo TCA	gltA, acnA, icd, sdhA, fumA	K01647, K01681, K00031, K00239, K01676	módulo M00009 (descriptivo)	[18, 19]
Contexto	CAZymes (polisacáridos)	familias GH, GT	sin KO único (dbCAN)	conteo por familia (descriptivo)	[51, 52]
Contexto	Ureólisis (precipitación de carbonato)	ureA, ureB, ureC	K01430, K01429, K01428	los tres (descriptivo)	[61, 62]

fueron organizados por etapa del análisis. Esta estructura permite auditar cada paso del procesamiento, repetir los análisis bajo las mismas condiciones computacionales y vincular los resultados finales con los archivos originales.

CAPÍTULO VI

DISEÑO TECNOLÓGICO

Este capítulo documenta la construcción del flujo bioinformático con el que se ejecutaron las Fases 1, 2 y 3. El Capítulo V estableció qué herramientas se emplean, por qué se eligieron frente a sus alternativas y qué valor toma cada umbral. Este capítulo parte de esas decisiones y no las repite. Frente a ello, el objetivo de este capítulo es determinar el tamaño de los recursos que el flujo necesita, seleccionar las versiones y los entornos que lo hacen ejecutable sobre la infraestructura disponible, implementarlo en código y describir la arquitectura que resulta de integrar todas sus piezas.

Las Fases 1 y 2 y la Fase 3 plantean problemas de diseño distintos, y por eso cada sección las trata por separado. Las dos primeras procesan solo los genomas propios y consultan bases de datos locales. La Fase 3 compara cada genoma de la Estela con los genomas públicos de su especie, de modo que el sistema pasa a descargar, anotar y comparar cientos de genomas ajenos y a consultar servicios remotos del NCBI. Ese cambio de escala y la dependencia de servicios externos son los que determinan las decisiones de diseño que se agregan en este capítulo.

6.1 Cálculo de los parámetros y dimensionamiento de los componentes

El dimensionamiento del flujo bioinformático no consiste en calcular el volumen de un equipo, sino en determinar cuántos recursos de cómputo, almacenamiento y tiempo consume cada etapa, y comprobar que esos consumos caben en la infraestructura disponible. Esta sección establece primero las bases de diseño, que son

el volumen de datos de entrada y los parámetros operativos heredados del marco metodológico, y a partir de ellas dimensiona cada etapa.

6.1.1 Bases de diseño: el conjunto de datos de entrada

El sistema opera sobre genomas ya ensamblados y agrupados. No procesa lecturas crudas. Esta condición fija las características de la entrada y, con ella, el orden de magnitud de todo el dimensionamiento posterior. La Tabla 6.1 resume las características del conjunto.

Tabla 6.1: Características del conjunto de bins de entrada, medidas sobre los archivos FASTA de origen.

Característica	**Valor**
Bins de entrada	97
Librerías de origen	22
Volumen total de secuencia	1.12 Gpb
Contigs totales	151 180
Tamaño mediano por bin	4.28 Mpb
Tamaño mínimo por bin	0.22 Mpb
Tamaño máximo por bin	101.9 Mpb
Contigs en el bin más fragmentado	41 610

Dos cifras de esta tabla condicionan el diseño. La primera es el tamaño máximo de 101.9 Mpb, que corresponde a `bin-11-71`. Un bin de ese tamaño no es un genoma bacteriano sino una mezcla, y su presencia en la entrada obliga a que la primera etapa del flujo sea capaz de procesar archivos un orden de magnitud mayores que el caso típico. La segunda es el volumen total de 1.12 Gpb, que es modesto para los estándares de la metagenómica. El cuello de botella del sistema no está, por

tanto, en el tamaño de los datos propios, sino en el tamaño de las bases de datos de referencia que el flujo debe consultar.

En la Fase 3 la entrada cambia de naturaleza. Los genomas propios que llegan a esta fase son pocos, y la mayor parte del volumen procede de genomas públicos de las mismas especies. La Tabla 6.2 resume las cifras que dimensionan esta fase, medidas en la ejecución.

Tabla 6.2: Características del conjunto de entrada de la Fase 3, medidas en la ejecución.

Característica	**Valor**
Linajes de la Fase 2 con nombre de especie	12 de 19
Genomas públicos solicitados al NCBI	660
Genomas públicos válidos tras la verificación	656
Especies que pasan al análisis pangenómico	3
Genomas anotados (115 referencias y 3 bins)	118
Tamaño mediano de las referencias	3.32 a 5.52 Mpb
Contigs por referencia (mediana)	15 a 46
Proteínas sometidas a la búsqueda remota (versión 2)	112

La cifra que dimensiona esta fase es la de 656 genomas públicos. Solo 115 de ellos entran al pangenoma, pero todos se descargan y se conservan, porque la verificación de los genes propios de cada bin y el cálculo de su ANI se hacen contra el conjunto completo de la especie y no solo contra las referencias elegidas. El cuello de botella vuelve a estar fuera de los datos propios: en la anotación de los 118 genomas y en la consulta de las bases de datos remotas del NCBI.

6.1.2 Parámetros operativos del diseño

Los parámetros que gobiernan cada etapa se establecieron en el Capítulo V junto con su fundamento. La Tabla 6.3 los reúne en la forma en que quedan codificados en el sistema, que es como variables de configuración al inicio de cada script de ejecución. El propósito de esta tabla no es justificarlos de nuevo, sino dejar constancia de la correspondencia exacta entre el valor definido en la metodología y el valor implementado.

Tabla 6.3: Parámetros operativos del diseño y variable con que se implementan. La justificación de cada valor se encuentra en el Capítulo V.

Fase	**Parámetro**	**Variable en el código**	**Valor**
1	Longitud mínima de contig	`MIN_CONTIG_LEN`	3000
1	Completitud mínima	`MIN_COMPLETENESS`	70
1	Contaminación máxima	`MAX_CONTAMINATION`	5
2	Umbral primario de dRep (MASH)	`DREP_PA`	0.90
2	Umbral secundario de dRep (ANI)	`DREP_SA`	0.95
2	ANI de confirmación de especie	`ANI_ESPECIE`	95
2	Fracción alineada mínima	`AF_ESPECIE`	65

Los parámetros se declaran como variables al principio del script y no aparecen escritos dentro de las llamadas a las herramientas. Esta decisión de implementación tiene una consecuencia práctica: cambiar un umbral exige editar una sola línea, y el valor efectivo queda registrado de forma automática en el archivo de versiones que el propio script ejecutado escribe. El análisis de sensibilidad del Capítulo VII se apoya en esa propiedad.

La Fase 3 sigue la misma regla. En los programas escritos en Python los parámetros se declaran como valores por omisión al inicio del archivo, con el prefijo `DEF_`, y pueden cambiarse desde la línea de comandos sin editar el código. La Tabla 6.4 los reúne.

Tabla 6.4: Parámetros operativos de la Fase 3 y variable o argumento con que se implementan. Los que no figuran en el Capítulo V se justifican en el Capítulo VII.

Etapa	**Parámetro**	**Variable o argumento**	**Valor**
Censo	Completitud mínima de la referencia	`DEF_MIN_COMPLETITUD`	95
Censo	Contaminación máxima de la referencia	`DEF_MAX_CONTAMINACION`	5
Censo	Contigs máximos de la referencia	`DEF_MAX_CONTIGS`	300
Censo y selección	Genomas mínimos por especie	`DEF_UMBRAL`	15
Descarga	Diferencia de longitud tolerada	`DEF_TOLERANCIA`	0.01
Desreplicación	Umbral primario / secundario de dRep	`DREP_PA`, `DREP_SA`	0.90 / 0.99
Selección	Referencias máximas por especie	`DEF_TOPE`	50
Selección	Especies que pasan al pangenoma	`DEF_TOP`	3
Pangenoma	Modo de limpieza de Panaroo	`CLEAN_MODE`	moderate
Partición	Umbral de core / de cloud	`DEF_CORE`, `DEF_CLOUD`	0.95 / 0.15
Árbol	Réplicas de UFBoot; semilla	`UFBOOT`, `SEED`	1000; 12345
F1	Largo mínimo de la proteína (aa)	`DEF_MIN_AA`	100
F1	Distancia mínima al borde del contig (pb)	`DEF_MIN_BORDE`	100
F4 y F5	Identidad y cobertura mínimas (%)	`DEF_F4_ID`, `DEF_F5_ID` y `_COV`	80 / 80
F3	Identidad y cobertura mínimas (%)	`DEF_F3_ID`, `DEF_F3_COV`	95 / 80
F5b	ANI de misma especie (%)	`DEF_ANI`	95
Advertencia	Identidad y cobertura (%)	`DEF_CASI_ID`, `DEF_CASI_COV`	99 / 90
F5 remoto	Proteínas por envío al NCBI	`LOTE`	10
F5 remoto	Espera máxima por búsqueda (h)	`ESPERA_MAX_H`	24

6.1.3 Dimensionamiento del cómputo

La cuenta de usuario en el clúster Khipu admite como máximo 32 núcleos, 98 GB de memoria y 24 horas de ejecución por trabajo. Ese límite es la restricción dura del dimensionamiento. La Tabla 6.5 indica, para cada etapa, cuál es el recurso crítico y qué decisión de diseño se tomó para que el consumo quepa dentro de la cuota.

Tabla 6.5: Recurso crítico de cada etapa y decisión de dimensionamiento adoptada.

Etapa	**Recurso crítico**	**Decisión de dimensionamiento**
Tiara	Procesador	Se ejecuta un bin por vez en un bucle, con los 32 núcleos asignados a cada llamada. El procesamiento secuencial evita que el bin de 101.9 Mpb coincida en memoria con otros bins grandes
CheckM2	Memoria y disco	Se ejecuta una sola llamada sobre el conjunto completo de bins procariotas, lo que carga la base de DIAMOND una vez en lugar de una por genoma
GTDB-Tk	Memoria	La etapa de colocación filogenética es la de mayor consumo de todo el flujo. Se fija `--pplacer_cpus 1`, con lo que el consumo de esa etapa se acota a unos 55 GB para el conjunto de marcadores bac120. Con más hilos el consumo crece por encima de la cuota
GTDB-Tk	Tiempo y disco	Se fija `--skip_ani_screen`, que omite el prefiltrado por MASH y elimina la necesidad de una base de datos adicional. La confirmación de especie se obtiene igualmente del cálculo interno de ANI
dRep	Tiempo	Se reutiliza la evaluación de calidad ya producida por CheckM2 en la Fase 1 mediante `--genomeInfo`, de modo que dRep no vuelve a estimar completitud ni contaminación

La asignación final de recursos se declara en la cabecera de cada script de ejecución. Ambas fases solicitan 32 núcleos y 90 GB de memoria, es decir, ocho gigabytes por debajo del límite máximo de la cuenta. Ese margen es deliberado: el planificador rechaza el trabajo si la solicitud excede la cuota, y algunas herramientas

reservan memoria adicional fuera del proceso principal. La Fase 1 solicita 24 horas y la Fase 2, doce.

La etapa de GTDB-Tk merece un comentario aparte porque es la que determina el dimensionamiento de todo el sistema. La colocación filogenética de los genomas sobre el árbol de referencia es un procedimiento cuyo consumo de memoria crece con el número de hilos, no con el número de genomas de consulta. Por ese motivo la única variable de ajuste disponible es el número de hilos de esa subetapa, y por ese motivo se fija en uno aunque el resto del flujo disponga de 32. Esta restricción es también la que impidió construir el árbol *de novo* con el conjunto completo de referencias del dominio bacteriano, como se documenta en el Capítulo VII.

En la Fase 3 la cuota se comporta de otra forma. El límite que más pesó no fue la memoria de un trabajo, sino el número de trabajos: la cuenta admite cinco trabajos enviados y tres en ejecución a la vez, y en un arreglo de trabajos de SLURM cada tarea cuenta como un trabajo. Un arreglo con una tarea por genoma, que es la forma natural de anotar 118 genomas, queda rechazado por el planificador. La Tabla 6.6 resume la decisión adoptada en cada etapa.

Tabla 6.6: Recurso crítico de cada etapa de la Fase 3 y decisión de dimensionamiento adoptada.

Etapa	**Recurso crítico**	**Decisión de dimensionamiento**
Censo y descarga	Red	Se ejecutan en el nodo de login, el único con acceso a internet. La descarga pide primero solo los metadatos de cada genoma y después las secuencias, con reintentos ante cortes de la conexión
dRep al 99 %	Tiempo y número de trabajos	Una tarea por especie (16 núcleos, 32 GB, hasta 6 h). Las siete especies se enviaron en dos tramos para no superar el límite de trabajos de la cuenta
Bakta	Memoria y número de trabajos	Tres lotes en paralelo de 10 núcleos y 32 GB. Cada lote anota en serie la tercera parte del conjunto, de modo que el arreglo tiene tres tareas y no 118

Tabla 6.6 (continuación)

Etapa	**Recurso crítico**	**Decisión de dimensionamiento**
Panaroo	Memoria	Una especie a la vez (32 núcleos, 90 GB). El consumo real quedó muy por debajo de lo pedido, con un máximo de 14 GB
IQ-TREE	Tiempo	Una especie a la vez (32 núcleos, 24 h). Se previó un respaldo por si un árbol no cabía en 24 h: reducir el alineamiento a sus sitios variables con `snp-sites` y corregir el sesgo de esa reducción en el modelo. No hizo falta
BLAST local (F3, F4)	Procesador	Una tarea por especie (16 núcleos, 32 GB). Tardó menos de un minuto por especie
BLAST remoto (F5, F6)	Cola externa del NCBI	Se ejecuta en el nodo de login dentro de una sesión persistente (`tmux`). El tiempo no lo controla el diseño sino la cola del NCBI, por lo que el programa espera hasta 24 h por búsqueda y puede reanudarse

La memoria de Bakta se fijó con una medición y no con una estimación. Antes de anotar los 118 genomas se ejecutó un piloto con tres referencias de *B. altitudinis* y su bin. El piloto anotó los cuatro genomas en 2 h 01 min con 10 núcleos, y su consumo máximo de memoria fue de 30.0 GB, exactamente el límite que se había pedido. Un consumo igual al límite indica que el trabajo estuvo a punto de ser terminado por falta de memoria, de modo que la solicitud por lote se subió a 32 GB. El tiempo del piloto sirvió como cota superior: a unos 30 min por genoma, cada lote de unos 40 genomas necesitaría cerca de 20 h, todavía por debajo del límite de 24 h por trabajo. Con tres lotes, por tanto, la anotación cabía en un solo envío incluso en el peor caso. La corrida real fue bastante más rápida, unos 7 min por genoma y 4.5 h en total, con un consumo máximo de 30.5 a 31.0 GB por lote, dentro de lo previsto. La Tabla 6.7 reúne los consumos medidos en las etapas pesadas.

Tabla 6.7: Tiempo de reloj y memoria máxima medidos en las etapas de mayor costo de la Fase 3. Los valores se dan por especie en el orden *B. altitudinis*, *P. frigoritolerans* y *A. schindleri*.

Etapa	**Recursos pedidos**	**Tiempo de reloj**	**Memoria máxima**
Piloto de Bakta (4 genomas)	10 núcleos, 30 GB	2 h 01 min	30.0 GB
Bakta (118 genomas)	3 lotes de 10 núcleos y 32 GB	∼4.5 h	30.5–31.0 GB por lote
Panaroo	32 núcleos, 90 GB	38 / 50 / 12 min	8.5 / 14 / 5 GB
IQ-TREE	32 núcleos, 90 GB	2 h 08 / 2 h 50 / 25 min	—
BLAST remoto, F5 (versión 1)	nodo de login	∼7 / 6 / 4 h	—

Salvo la memoria de Bakta, que el piloto permitió ajustar, las etapas locales caben con holgura en la cuota. El tiempo de la búsqueda remota es el mayor de toda la fase, y casi todo es espera en la cola del NCBI, no cálculo.

6.1.4 Dimensionamiento del almacenamiento

El volumen de datos propios es pequeño frente al de las bases de referencia. La Tabla 6.8 lo detalla.

Tabla 6.8: Requerimiento de almacenamiento por componente.

Componente	**Tipo**	**Tamaño**
Bins de entrada	Datos propios	1.12 Gpb
Base de datos de CheckM2 (DIAMOND)	Insumo de referencia	∼3 GB
Base de datos de GTDB R220	Insumo de referencia	∼110 GB
Resultados completos de la Fase 2	Salida	406 MB
Alineamiento concatenado bac120	Salida intermedia	230 MB
Base de datos de Bakta v6.0 (*full*)	Insumo de referencia	∼130 GB
Datos y salidas de la Fase 3	Datos y salidas	∼30 GB

Nota. Las dos filas de la Fase 3 corresponden al espacio libre que se reservó en el clúster antes de la ejecución, no a una medición posterior.

La base de GTDB determina por sí sola el requerimiento de disco del proyecto. Su descompresión desde el archivo comprimido es una operación de larga duración que debe ejecutarse en el nodo de login, único con acceso a internet, y que excede la tolerancia de una sesión interactiva. Por ese motivo el script de preparación de la Fase 2 verifica el espacio disponible antes de iniciar la descompresión y está diseñado para ejecutarse en un segundo plano.

En la Fase 3 la base de datos de Bakta ocupa el lugar que GTDB ocupaba en la Fase 2: es el componente más grande del sistema y se descarga una sola vez en el nodo de login. Los genomas públicos ocupan bastante menos, pero deben conservarse completos hasta el final de la fase. La razón es funcional: la búsqueda de los genes propios de cada bin y el cálculo de su ANI se hacen contra todos los genomas descargados de la especie, incluidos los que no entraron al pangenoma.

6.2 Selección de materiales, componentes y equipos de la solución

En un diseño de esta naturaleza los materiales son de tres clases: las versiones concretas del software, las bases de datos que actúan como insumo de referencia y el entorno de ejecución que hace reproducible el conjunto. La elección de cada herramienta ya se justificó en el Capítulo V. Lo que se selecciona aquí es la versión, el insumo y el entorno, decisiones que no son metodológicas sino de implementación, y que en este proyecto resultaron determinantes para que el flujo funcionara.

6.2.1 Versiones de software y compatibilidad

La Tabla 6.9 indica la versión empleada de cada herramienta y el criterio con que se fijó.

Tabla 6.9: Versiones de software empleadas y criterio de selección de cada una.

Componente	**Versión**	**Criterio de selección de la versión**
GTDB-Tk	2.6.1	Fijada de forma explícita por compatibilidad con el release R220 de la base de datos. La tabla de compatibilidad oficial de la herramienta vincula cada versión del programa con un release de datos determinado, y una combinación incorrecta produce clasificaciones erróneas sin emitir error
Python	3.11	Fijada de forma explícita en todos los entornos. Sin esta restricción el resolvedor instala Python 3.14, con el que GTDB-Tk no arranca porque la versión de su biblioteca de validación de datos no es compatible con esa versión
Tiara, CheckM2	1.0.3; 1.1.0	Sin restricción de versión al crear el entorno, porque ninguna de las dos depende de un release externo de datos. Las versiones que se reportan son las que quedaron instaladas
dRep, fastANI, Mash	3.7.1; 1.34; 2.3	Instaladas en un entorno propio con Python 3.11, para evitar la misma clase de incompatibilidad. El mismo entorno se reutilizó en la Fase 3
NCBI Datasets CLI	18.38.0	Descarga cada genoma por su accesión exacta, con la versión del ensamblaje que lista GTDB
Bakta	1.12.1	La base de datos v6.0 exige Bakta 1.11 o superior. Se fijó la versión para que los 118 genomas se anotaran con el mismo programa
Panaroo	1.8.0	Fijada junto con su conversor de formato, que se descarga del mismo número de versión del código fuente (ver texto). Incluye CD-HIT 4.8.1 y MAFFT 7.526
IQ-TREE, snp-sites	3.1.3; 2.5.1	snp-sites solo se instaló para el respaldo previsto, que no hizo falta
BLAST+, TaxonKit	2.17.0; 0.20.0	BLAST+ ejecuta las búsquedas locales (F3, F4) y, con `blast_formatter`, recupera los resultados de las remotas. TaxonKit asigna el linaje a cada resultado con la taxonomía del NCBI descargada el 04-10-2026
R	4.5.0	Estadística y figuras, en la estación local: vegan 2.7.2, ape 5.8.1, phangorn 2.12.1, ggtree 3.16.3 y gggenes 0.7.0

En la Fase 3 la decisión de compatibilidad más importante fue la del formato de anotación. Bakta entrega sus anotaciones en GFF3, y Panaroo espera el formato que produce Prokka. Aunque Panaroo acepta archivos GFF3, con los de

Bakta pierde o malinterpreta genes. La solución fue convertir cada archivo con `convert_bakta_to_prokka_gff.py`, un programa que los propios autores de Panaroo distribuyen en su repositorio. El conversor se descarga del mismo número de versión del código fuente que el programa instalado (v1.8.0), para que ambas piezas sean compatibles. La conversión descarta las secuencias codificantes que no se pueden traducir, y el sistema registra cuántas se pierden: fueron 5 en total, todas en *A. schindleri*.

La fijación de la versión de Python es la decisión de selección más importante del capítulo, por la siguiente razón: el error que produce su ausencia no se manifiesta durante la instalación sino en la primera ejecución, cuando ya se han descargado 110 GB de base de datos y se ha encolado un trabajo. Fijarla convierte un fallo tardío en una condición verificable en el momento de crear el entorno.

6.2.2 Bases de datos como insumo de referencia

Las bases de datos cumplen en este diseño la función que los insumos cumplen en un proceso físico: son material externo que el sistema consume y del que depende la validez del resultado. La Tabla 6.10 las especifica.

Tabla 6.10: Bases de datos empleadas como insumo de referencia.

Insumo	**Versión**	**Etapa que lo consume**
Base de datos de CheckM2	la que distribuye la herramienta	Calidad genómica
Base de datos de GTDB	R220	Clasificación taxonómica y ANI
Metadatos de GTDB (`bac120_metadata`)	R220	Censo y clasificación de referencias
Base de datos de Bakta (*full*)	v6.0 (24-02-2025)	Anotación
Taxonomía del NCBI (*taxdump*)	descargada el 04-10-2026	F5
NCBI nr y core_nt (remotas)	fecha de la consulta	F5 y F6
NCBI IPG y Datasets API v2 (remotas)	fecha de la consulta	F5b
UniProtKB, vía EBI (remota)	fecha de la consulta	Comparación de F5
Diccionarios propios de hábitat y países	versionados en el repositorio	Clasificación de referencias

La versión del insumo forma parte del resultado. Un genoma clasificado contra R220 puede recibir un nombre distinto contra un release posterior, porque la taxonomía del GTDB se reorganiza entre versiones. Por ese motivo el release se registra en el archivo de versiones de cada ejecución y se declara junto a los resultados.

En la Fase 3 este principio se extiende a las bases remotas. La base de Bakta v6.0 integra a su vez versiones fijas de otras bases, como RefSeq 228, UniProtKB/Swiss-Prot 2025_01 y Pfam 37.2, de modo que basta con registrar su número de versión. Las bases nr y core_nt del NCBI, en cambio, se consultan en línea y cambian a diario. Un gen que hoy no tiene copias conocidas en su especie puede tenerlas mañana, si se deposita un genoma nuevo. Por eso la fecha de cada búsqueda forma parte del resultado y se reporta con él.

Dos insumos de la Fase 3 no son bases de datos externas, sino tablas construidas para este trabajo: un diccionario de expresiones regulares que asigna un hábitat a cada genoma según la fuente de aislamiento declarada, y una tabla que asigna un

continente a cada uno de los 258 países que aparecen en los metadatos. Ambos se versionan junto con el código, porque cambiar una palabra clave cambia la clasificación de las referencias. A ellos se suma la lista de exclusiones manuales de genomas, cuya justificación se presenta en el Capítulo VII.

6.2.3 Entorno de ejecución

El sistema se ejecuta sobre entornos conda independientes, uno por herramienta. La separación responde a un conflicto real de dependencias: Tiara, CheckM2 y GTDB-Tk requieren versiones incompatibles de las mismas bibliotecas, y un entorno único no resuelve.

La selección de canales de paquetes también fue objeto de una decisión. El canal `defaults` de la distribución no compila desde el clúster, lo que produce un fallo de red durante la creación del entorno. El diseño emplea únicamente los canales `conda-forge` y `bioconda`, y los declara de forma explícita en cada llamada de creación. El Código VI.1 muestra la forma en que se implementa esta decisión junto con la fijación de versiones.

LISTING VI.1: Creación del entorno de GTDB-Tk con versión de herramienta y de Python fijadas, y canales declarados de forma explícita (extracto de `02_setup_fase2_khipu.sh`).

```
# Versiones fijadas: GTDB-Tk al release de los datos y Python a
# una serie compatible. --override-channels evita 'defaults'.
$SOLVER create -y -n gtdbtk --override-channels \
    -c conda-forge -c bioconda \
    "gtdbtk=$GTDBTK_VERSION" "python=$PYTHON_VERSION"
```

Para dejar constancia del entorno efectivamente utilizado, el guion de preparación exporta al final un archivo de bloqueo por cada entorno creado, con la lista

completa de paquetes y sus versiones exactas. Esos archivos se versionan junto con el código, en la carpeta `envs/` del repositorio.

La Fase 3 agregó cinco entornos, llamados `ncbi-datasets`, `bakta`, `panaroo`, `iqtree` y `blast`. Los crea el guion `03_setup_fase3_khipu.sh`, con las mismas reglas: solo `conda-forge` y `bioconda`, Python 3.11 y versiones de herramienta fijadas. El entorno de dRep de la Fase 2 se reutilizó tal cual. Al terminar, el guion comprueba que cada entorno responde con su versión, que la base de Bakta es la v6 y que los metadatos de GTDB contienen las columnas que el censo necesita. Esa comprobación detectó un fallo real: el entorno `blast` había quedado creado sin sus programas, y hubo que recrearlo antes de la búsqueda local de la Fase 3.

6.2.4 Plataforma de cómputo

El sistema se ejecuta en el clúster Khipu de la UTEC, bajo el planificador SLURM. Se emplea la partición `standard`, que agrupa los nodos de propósito general, de 32 núcleos y 224 GB de memoria en su mayoría. No se emplean las particiones de GPU, porque ninguna de las herramientas del flujo aprovecha aceleración gráfica, ni la partición de memoria ampliada, a la que la cuenta no tiene acceso.

La arquitectura del clúster impone una separación que el diseño debe respetar: solo el nodo de login tiene acceso a internet, y los nodos de cómputo trabajan sin conexión. Esto obliga a repartir el sistema en dos clases de programas. Los guiones de preparación descargan bases de datos y crean entornos, y se ejecutan de forma interactiva en el login. Los scripts de ejecución ejecutan el análisis y se envían a la cola, sin requerir conexión alguna.

La Fase 3 rompe en parte esta separación, porque una de sus etapas no puede ejecutarse sin conexión: la búsqueda de los genes propios de cada bin en las bases nr y core_nt, que son demasiado grandes para instalarse en el clúster y se consultan en

los servidores del NCBI. Esa etapa se ejecuta en el nodo de login. Como puede durar varias horas, se lanza dentro de una sesión de `tmux`, que sigue corriendo aunque se cierre la conexión SSH. Las demás etapas de la Fase 3 se reparten así: el censo, la descarga, la clasificación y la selección de referencias corren en el login, porque necesitan red y tardan minutos; la desreplicación, la anotación, el pangenoma, los árboles y la búsqueda local se envían a la cola; y la estadística y las figuras se calculan en una estación local con R, a partir de las tablas exportadas del clúster.

6.3 Integración e implementación de los componentes en la solución final

Las etapas descritas no funcionan de forma aislada. Esta sección documenta cómo se encadenan, qué resultado produce cada una, qué resultado de la etapa anterior consume la siguiente y qué mecanismos garantizan que el encadenamiento no se rompa.

6.3.1 Organización del sistema en programas

El sistema se implementa en seis programas, que se agrupan en tres clases según dónde y cuándo se ejecutan. La Tabla 6.11 los describe.

TABLA 6.11: Programas del sistema, clase a la que pertenecen y función que cumplen.

Programa	**Clase**	**Función**
`00_setup_khipu.sh`	Preparación (login)	Crea los entornos de Tiara y CheckM2 y descarga la base de datos de CheckM2
`01_prep_bins.sh`	Preparación (local)	Normaliza el conjunto de bins de entrada y genera la tabla de trazabilidad
`02_setup_fase2_khipu.sh`	Preparación (login)	Crea los entornos de GTDB-Tk y dRep con versiones fijadas y descomprime la base de GTDB R220
`run_fase1.slurm`	script de ejecución (cola)	Ejecuta el filtrado por dominio, la evaluación de calidad y la selección
`run_fase2.slurm`	script de ejecución (cola)	Ejecuta la clasificación taxonómica, la desreplicación y el cálculo de prevalencia
`summarize_phase1.py`, `summarize_phase2.py`	Procesamiento	Convierten las salidas de cada herramienta en las tablas de decisión del flujo y en los reportes legibles

La separación entre script de ejecución y procesamiento es deliberada. El script de ejecución se ocupa de activar entornos, invocar herramientas y verificar condiciones. Los programas de procesamiento contienen la lógica de decisión del flujo, escrita en Python y empleando únicamente la biblioteca estándar. Esta última restricción permite ejecutarlos con el intérprete de cualquiera de los entornos, sin instalar dependencias adicionales.

La Fase 3 se implementa en quince programas, con la misma división entre programas que invocan herramientas y programas que contienen la lógica de decisión, también escritos en Python con la biblioteca estándar. Aparece además una cuarta

clase: la de los programas que ejecutan cálculos en el nodo de login porque necesitan conexión. La Tabla 6.12 los describe en el orden en que se ejecutan.

Tabla 6.12: Programas de la Fase 3, clase a la que pertenecen y función que cumplen, en orden de ejecución.

Programa	**Clase**	**Función**
`03_setup_fase3_khipu.sh`	Preparación (login)	Crea los cinco entornos nuevos, descarga la base de Bakta, el conversor de formato de Panaroo, la taxonomía del NCBI y los metadatos de GTDB
`03_censo_genomas.py`	Ejecución con red (login)	Cuenta los genomas públicos de calidad de cada especie y decide su viabilidad
`04_fetch_refs.sh`	Ejecución con red (login)	Descarga del NCBI todos los genomas que pasan el control de calidad
`04_clasificar_refs.py`	Procesamiento	Verifica las descargas, asigna hábitat, continente y nivel de prioridad, y selecciona las especies y las referencias
`04_drep_refs.slurm`	Ejecución (cola)	Desreplica las referencias de cada especie al 99 % de ANI
`05_bakta_all.slurm`	Ejecución (cola)	Anota los 118 genomas en tres lotes
`06_panaroo.slurm`	Ejecución (cola)	Convierte las anotaciones y construye el pangenoma de cada especie
`06b_iqtree.slurm`	Ejecución (cola)	Infiere el árbol del genoma core de cada especie
`06c_ani_bins.slurm`	Ejecución (cola)	Calcula el ANI de cada bin contra todos los genomas de su especie
`07_particion.py`	Procesamiento	Clasifica las familias en core, shell y cloud y ubica al bin en esa partición
`08_exclusivos_local.slurm`, `08_exclusivos.py`	Ejecución (cola) y procesamiento	Aplica los filtros locales F1 a F4 a los genes candidatos del bin
`08_exclusivos_remoto.sh`	Ejecución con red (login)	Aplica los filtros remotos F5, F5b y F6 contra los servidores del NCBI
`bin/export_fase3.sh`, `figuras/R/f3_*.R`	Procesamiento	Reúne las tablas del clúster y genera la estadística y las figuras

6.3.2 Normalización de la entrada y trazabilidad

La trazabilidad entre cada genoma y su muestra de origen es un requisito del diseño, porque la prevalencia espacial de la Fase 2 se calcula sobre esos resultados. El programa de preparación la establece antes de que empiece el análisis.

Los archivos de origen llevan nombres de la forma `bin-<N>-<muestra>`, que ya codifican la muestra. El programa los copia a una carpeta limpia, descarta los ensamblajes por muestra que no son bins y construye una tabla de correspondencia con la muestra, el número de bin, el número de contigs y la longitud de cada genoma. El Código VI.2 muestra el núcleo de esa operación.

LISTING VI.2: Extracción de la muestra de origen a partir del nombre de archivo y registro en la tabla de trazabilidad (extracto de `01_prep_bins.sh`).

```
# Parseo del nombre: bin-<N>-<muestra>.fasta
core="${bn%.fasta}"          # bin-1-49
sample="${core##*-}"         # 49
rest="${core%-*}"            # bin-1
binn="${rest##*-}"           # 1
nctg=$(grep -c '^>' "$DEST/$bn" || echo 0)
len=$(grep -v '^>' "$DEST/$bn" | tr -d '\n' | wc -c)
printf "%s\t%s\t%s\t%s\t%s\n" \
       "$bn" "$sample" "$binn" "$nctg" "$len" >> "$MAP"
```

El programa verifica al final que el número de genomas procesados sea 97 y emite una advertencia en caso contrario. Esta comprobación protege contra el error más probable de esta etapa, que es tomar como origen una carpeta equivocada.

En la Fase 3 la trazabilidad se extiende a los genomas públicos. Cada genoma se identifica por su accesión del NCBI, en la que el punto se reemplaza por un guion bajo para que el nombre sea válido en todas las herramientas, y los bins conservan

su nombre de origen con la misma regla. Ese identificador se mantiene igual desde la descarga hasta el pangenoma y llega sin cambios a la Fase 4. Cada accesión se pide además con la versión exacta del ensamblaje que lista GTDB (por ejemplo, `.1`), y si esa versión ya no está disponible el genoma no se reemplaza por otra. La razón es que las métricas de calidad con que se seleccionó el genoma corresponden a esa versión y no a otra. Para comprobar que el archivo descargado es el esperado, el sistema compara su longitud total con la que registra GTDB y acepta una diferencia de hasta el 1 %. Este control no es un filtro de calidad, sino una verificación de integridad de la descarga.

6.3.3 Encadenamiento entre etapas

Las etapas se comunican mediante archivos, no mediante memoria compartida. Cada etapa escribe un archivo en disco y la siguiente lo lee. La Tabla 6.13 documenta esa cadena, que es la descripción precisa de cómo la salida de un componente alimenta al siguiente.

Tabla 6.13: Archivos de datos que conectan las etapas del sistema.

Archivo	**Lo produce**	**Lo consume**
`bin_rename_map.tsv`	Preparación	La Fase 2, para asignar cada genoma a su muestra y calcular prevalencia
`tiara_bin_summary.tsv`	Tiara y su resumen	La copia selectiva de bins procariotas hacia la entrada de CheckM2
`quality_report.tsv`	CheckM2	La selección de la Fase 1 y, más adelante, dRep en la Fase 2
`phase1_selection.tsv`	Resumen de la Fase 1	El reporte de la Fase 1. Documenta el motivo de descarte de cada bin
`phase1_selected_genomes/`	Resumen de la Fase 1	La Fase 2 completa. Es su única entrada de secuencias
`genomeInfo.csv`	Resumen de la Fase 2	dRep, para evitar que recalcule la calidad de los genomas
`Cdb.csv`, `Wdb.csv`	dRep	El cálculo de linajes, representantes y prevalencia

Dos elementos de esta cadena resuelven problemas de integración concretos.

El primero es la carpeta de genomas seleccionados. La Fase 2 no recibe una lista de nombres ni un filtro que deba volver a aplicar, sino una carpeta que contiene exactamente los genomas que superaron la Fase 1. De ese modo el criterio de selección se aplica una sola vez, en el lugar donde está definido, y no puede divergir entre fases.

El segundo es el archivo de información de genomas. La herramienta de desreplicación evalúa por omisión la calidad de cada genoma con su propio procedimiento, lo que duplicaría un cálculo ya realizado y podría además descartar genomas que la Fase 1 había aceptado. El diseño evita ambos problemas convirtiendo el reporte de

CheckM2 al formato que la herramienta espera y desactivando sus filtros propios, como muestra el Código VI.3.

LISTING VI.3: Reutilización de la evaluación de calidad de la Fase 1 y desactivación de los filtros propios de dRep (extracto de `run_fase2.slurm`).

```
# genomeInfo.csv a partir de CheckM2 (Fase 1): evita que dRep
# vuelva a estimar completitud y contaminacion.
python "$SCRIPTS_DIR/summarize_phase2.py" genomeinfo \
    --genomes-dir "$DREP_INPUT" --bin-ext "$BIN_EXT" \
    --checkm2 "$CHECKM2_REPORT" \
    --out "$RESULTS/genomeInfo.csv"

# -comp 0 -con 100: desactiva el filtro propio de dRep, ya
# aplicado en la Fase 1 (>70 % compl., <5 % contaminacion).
dRep dereplicate "$DREP_OUT" \
    -g "$DREP_INPUT"/*."$BIN_EXT" \
    -p "$THREADS" \
    -pa "$DREP_PA" -sa "$DREP_SA" \
    --S_algorithm fastANI \
    -comp 0 -con 100 \
    --genomeInfo "$RESULTS/genomeInfo.csv"
```

La Fase 3 conserva el mismo principio de comunicación por archivos. La Tabla 6.14 documenta su cadena.

TABLA 6.14: Archivos de datos que conectan las etapas de la Fase 3.

Archivo	**Lo produce**	**Lo consume**
`phase2_selection.tsv`	Fase 2	El censo, que toma de él la especie GTDB de cada linaje
`phase3_viabilidad.tsv`	Censo	La descarga, que solo pide genomas de especies viables

Tabla 6.14 (continuación)

Archivo	Lo produce	Lo consume
`genomas_ok_<especie>.txt`	Verificación de la descarga	dRep, el filtro F4 y el ANI de los bins: es la lista de todos los genomas válidos de la especie
`genomeInfo.csv`, `extraW.tsv`	Clasificación de referencias	dRep: calidad de cada genoma y peso extra de las cepas tipo y de los aislados de sustrato pétreo o árido
`Wdb.csv`	dRep	La selección, que elige las referencias entre los genomas no redundantes
`bakta_manifest.tsv`	Selección	Bakta: la lista de los 118 genomas que se anotan
GFF3 de Bakta → GFF de Prokka	Bakta y conversor	Panaroo
`gene_presence_absence.csv`	Panaroo	La partición, que recalcula las categorías solo con las referencias
`core_gene_alignment_filtered.aln`	Panaroo	IQ-TREE
`particion_familias.tsv`, `genes_bin.tsv`	Partición	La búsqueda de genes candidatos y, después, la Fase 4
`f5_query.faa`, `f6_query.fna`	Filtros locales	Los filtros remotos: proteínas y contigs que sobrevivieron a F1–F4
`exclusivos_verificados.tsv`	Filtros remotos	El análisis de genes específicos de la cepa y la Fase 4

En esta cadena hay dos puntos que resuelven problemas de integración.

El primero es la partición. Panaroo agrupa en familias los genes de todos los genomas que recibe, incluido el bin, y calcula la frecuencia de cada familia sobre ese conjunto. Ese cálculo no sirve para esta pregunta, porque el bin está incompleto: una familia presente en 48 de las 50 referencias y ausente en el bin quedaría en 48 de 51 genomas, por debajo del 95 %, y pasaría de core a shell solo por la incompletitud del bin. Por la misma razón, una familia presente solo en el bin quedaría como cloud y no como candidata a gen propio de la cepa. El sistema conserva el agrupamiento

de Panaroo, pero recalcula la frecuencia de cada familia solo con las referencias y después ubica al bin dentro de esas categorías. El Código VI.4 muestra ese cálculo.

LISTING VI.4: Frecuencia de cada familia calculada solo con las referencias y ubicación del bin (extracto simplificado de `07_particion.py`).

```
refs = [g for g in genomas if manif[g]["tipo"] == "ref"]
bins = [g for g in genomas if manif[g]["tipo"] == "bin"]
for fam in familias:
    n_ref = sum(1 for g in refs if fam["celdas"][g])
    en_bin = [b for b in bins if fam["celdas"][b]]
    c95 = categoria(n_ref, len(refs), 0.95, 0.15, en_bin)

def categoria(n_ref, n_total, core, cloud, en_bin):
    if n_ref == 0:              # ninguna referencia la tiene
        return "exclusivo" if en_bin else "ninguno"
    f = n_ref / float(n_total)
    if f >= core:  return "core"
    if f >= cloud: return "shell"
    return "cloud"
```

El segundo es la lista completa de genomas válidos de cada especie. El pangenoma usa solo las referencias seleccionadas, pero la búsqueda de los genes propios del bin y el cálculo de su ANI usan esta lista, que incluye los genomas descartados por la desreplicación y por el tope de 50. Separar ambas listas permite que el pangenoma sea manejable sin que la verificación pierda genomas en los que un gen podría estar.

6.3.4 Implementación de la verificación de genes específicos

La identificación de genes propios de cada cepa de la Estela es la etapa de la Fase 3 con más componentes. Un gen candidato es un gen del bin que no tiene equivalente en ninguna referencia del pangenoma, y el sistema lo somete a una cadena de filtros antes de considerarlo propio de la cepa. La Tabla 6.15 resume cómo se implementó cada filtro. Su fundamento y sus resultados se presentan en el Capítulo VII.

Tabla 6.15: Implementación de los filtros de genes específicos de la cepa, en el orden en que se aplican.

Filtro	**Comprobación**	**Dónde se ejecuta**	**Herramienta**
F1	Estructura del gen	Cola, sin red	Anotación de Bakta
F2	Anclaje del contig a la especie	Cola, sin red	Partición de Panaroo
F4	Presencia en otros genomas de la especie	Cola, sin red	`tblastn` [64] contra todos los genomas descargados
F3	Presencia en otros bins de la misma muestra	Cola, sin red	`blastn` contra los demás bins de la muestra
F6	Origen de los contigs huérfanos	Login, servidores del NCBI	`blastn` contra core_nt
F5	Presencia en nr	Login, servidores del NCBI	`blastp` contra nr; linaje con TaxonKit [65]
F5b	Especie de los genomas portadores	Login, servicios del NCBI	IPG y NCBI Datasets [66]

El orden responde al costo. Los filtros locales se ejecutan en segundos y descartan la mayoría de los candidatos, de modo que solo los que sobreviven llegan a los filtros remotos, que pueden tardar horas por búsqueda. Por eso la etapa está partida en dos programas: uno se envía a la cola y deja escritas las consultas para el NCBI, y el otro se ejecuta después en el nodo de login.

La parte remota se implementó contra la interfaz web de BLAST del NCBI y no con la opción `-remote` de BLAST+, que en el clúster quedaba esperando

sin devolver resultados. El programa envía cada consulta con `curl`, guarda el identificador que devuelve el servidor, consulta su estado cada 60 segundos, que es el intervalo mínimo que pide el NCBI, y recupera el resultado con `blast_formatter`. El Código VI.5 muestra el envío.

LISTING VI.5: Envío de una búsqueda a la interfaz web de BLAST del NCBI (extracto simplificado de `08_exclusivos_remoto.sh`).

```
rid="$(curl␣-s␣--max-time␣300␣-X␣POST␣"$BLAST_URL"␣\
␣␣␣␣--data-urlencode␣"CMD=Put"␣\
␣␣␣␣--data-urlencode␣"PROGRAM=$prog"␣\
␣␣␣␣--data-urlencode␣"DATABASE=$db"␣\
␣␣␣␣--data-urlencode␣"EXPECT=$ev"␣\
␣␣␣␣--data-urlencode␣"HITLIST_SIZE=10"␣\
␣␣␣␣--data-urlencode␣"QUERY@$q"␣\
␣␣|␣sed␣-n␣'s/^␣*RID␣=␣*//p'␣|␣head␣-n1)"
# se guarda el RID para reanudar sin reenviar
echo "$rid" > "${out}.rid"
```

6.3.5 Implementación de los scripts de ejecución

Cada script de ejecución declara primero los recursos que solicita al planificador del clúster y después la configuración del análisis. El Código VI.6 reproduce la cabecera de la Fase 1, que materializa el dimensionamiento de la Sección 6.1.3.

LISTING VI.6: Cabecera de solicitud de recursos al planificador (extracto de `run_fase1.slurm`).

```
# Limites de la cuenta: 32 cores, 98 GB RAM, 24 h por trabajo.
#SBATCH --job-name=fase1_estela
#SBATCH --partition=standard
#SBATCH --nodes=1
```

```
#SBATCH --ntasks=1
#SBATCH --cpus-per-task=32
#SBATCH --mem=90G
#SBATCH --time=24:00:00
#SBATCH --output=fase1_%j.out
#SBATCH --error=fase1_%j.err
```

La implementación incorpora tres mecanismos de robustez que conviene documentar porque responden a condiciones propias de esta plataforma.

El primero es el modo de terminación ante error. Los scripts se ejecutan con interrupción ante el primer fallo y con propagación del error a través del *pipeline*, pero sin la opción que aborta ante variables no definidas. Esa opción, que sería deseable, resulta incompatible con el sistema de módulos del clúster, que referencia una variable de entorno sin definirla previamente. El Código VI.7 muestra la solución adoptada y el comentario que la documenta en el propio archivo.

LISTING VI.7: Configuración de terminación ante error, compatible con el sistema de módulos del clúster (extracto de `run_fase1.slurm`).

```
# NO usar 'set -u' (nounset): Lmod referencia LD_PRELOAD sin
# definir y aborta la carga de modulos en Khipu.
set -eo pipefail
export LD_PRELOAD="${LD_PRELOAD:-}"
```

El segundo es un bloque de comprobaciones previas que se ejecuta antes de cualquier cálculo. Verifica que exista la carpeta de bins, que contenga archivos, que la base de datos esté descargada y que el entorno conda haya quedado disponible tras cargar el módulo. Cada comprobación fallida termina el trabajo con un mensaje que indica qué hacer. La finalidad es que un error de configuración se manifieste en los primeros segundos y no después de horas de cola y cómputo.

El tercero es el registro automático de versiones. Antes de empezar, cada script de ejecución escribe un archivo con la fecha, el identificador del trabajo, el nodo asignado, los umbrales efectivos y la versión de cada herramienta consultada al propio programa. Ese archivo acompaña a los resultados y es la evidencia de reproducibilidad que se reporta en el Capítulo VII.

La Fase 3 agregó mecanismos propios, porque dos de sus etapas dependen de condiciones que el sistema no controla.

La primera es el límite de trabajos de la cuenta. La anotación con Bakta se envía como un arreglo de tres tareas, y cada tarea anota las filas $k, k+3, k+6, \ldots$ del manifiesto. Si un trabajo se interrumpe, al reenviarlo se saltan los genomas que ya tienen su anotación completa.

La segunda es la cola del NCBI. Una búsqueda remota puede quedar horas en espera, o el servidor puede cancelarla si supera su límite de tiempo de procesador. El programa remoto responde a ambas situaciones. Guarda el identificador de cada búsqueda, de modo que si se corta la sesión retoma la espera en lugar de reenviar la consulta. Envía las proteínas en lotes de diez, y si el NCBI cancela un lote lo divide y reenvía cada proteína por separado. Una proteína que falla sola queda marcada como «sin resultado», que es distinto de «sin parecidos»: lo primero es una falla técnica y lo segundo, un resultado. Por último, lleva un registro de las proteínas ya consultadas, de modo que si la lista de candidatos cambia solo se envían las nuevas.

A esto se suman comprobaciones entre etapas que detienen el flujo si algo no cuadra. El programa de selección se detiene si dRep no aplicó los pesos de prioridad que se le pasaron. La partición se detiene si Panaroo recibió un genoma que no figura en el manifiesto. Y en cada punto de control de la fase (C0 a C8) se compara el resultado con lo esperado antes de seguir: que cada anotación tenga un número de genes cercano a la mediana de su especie, que cada referencia contenga al menos

el 97 % del genoma core y que cada bin recupere del core un porcentaje cercano a su completitud. Los resultados de esos controles se reportan en el Capítulo VII.

6.3.6 Control de versiones

El código, las tablas de resultados y los archivos de bloqueo de los entornos se mantienen en un repositorio de control de versiones. Los archivos de gran tamaño que no aportan a la reproducibilidad, como el alineamiento concatenado de 230 MB, quedan excluidos de forma explícita y se conservan solo en el almacenamiento local. Esta separación mantiene el repositorio manejable sin perder la capacidad de reconstruir el análisis.

En la Fase 3 el criterio es el mismo. Un programa de exportación reúne en el clúster las tablas, los reportes, los árboles y las anotaciones de los tres bins, y esa selección es la que se copia al repositorio. Quedan fuera los genomas públicos, las anotaciones de las referencias y los alineamientos, que pueden regenerarse a partir de las accesiones y del código.

6.4 Representación gráfica de la solución y su verificación

Esta sección traduce las decisiones de las secciones anteriores a dos representaciones. La primera describe el flujo de datos, es decir, qué transformación sufre la información en cada etapa. La segunda describe la arquitectura de cómputo, es decir, dónde se ejecuta cada pieza y por qué.

6.4.1 Diagrama de flujo del sistema

La Figura 6.1 representa el sistema como una secuencia de operaciones unitarias conectadas por corrientes de datos. Cada bloque corresponde a una etapa de

transformación, cada flecha representa un archivo de los declarados en la Tabla 6.13 y las cifras indican el número de genomas que atraviesa cada punto del flujo.

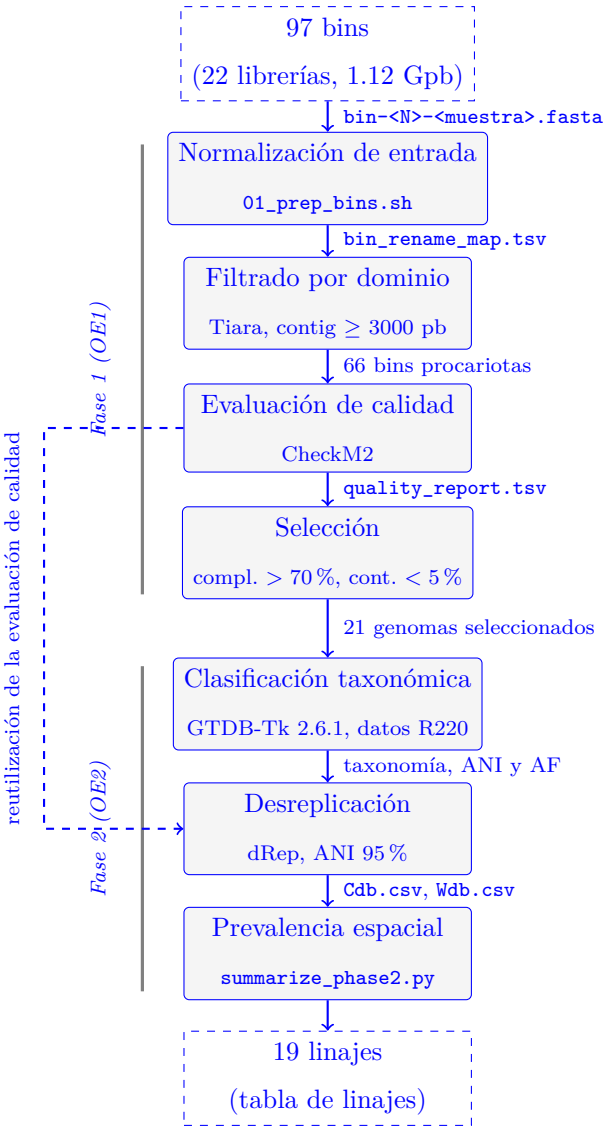


FIGURA 6.1: Diagrama de flujo del sistema implementado. Los bloques continuos representan etapas de transformación y los bloques discontinuos, las corrientes de entrada y salida. Las etiquetas sobre las flechas indican los archivos de datos que conectan las etapas. La flecha discontinua lateral representa la reutilización de la evaluación de calidad de la Fase 1 por parte de la desreplicación de la Fase 2, descrita en la Sección 6.3.3.

El diagrama muestra que el flujo es secuencial, con una única conexión entre

fases: la reutilización de la evaluación de calidad. Esta conexión evita repetir el cálculo de calidad antes de la desreplicación.

La Fase 3 se representa en un diagrama aparte, la Figura 6.2, con las mismas convenciones. A diferencia de las fases anteriores, su flujo no es una sola cadena: después del pangenoma se divide en dos ramas independientes, y una corriente lateral lleva la lista completa de genomas de cada especie desde la descarga hasta la verificación de genes, sin pasar por la desreplicación ni por la selección.

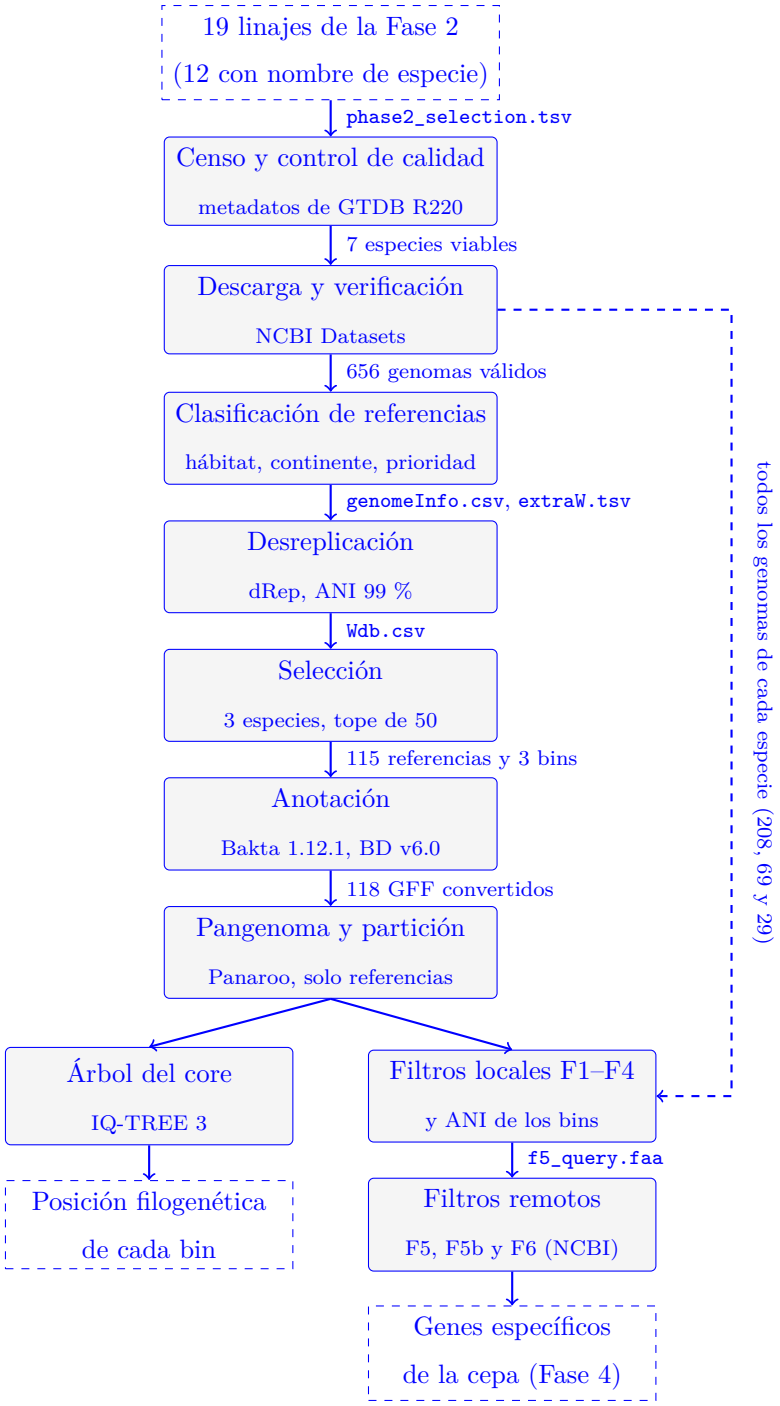


FIGURA 6.2: Diagrama de flujo de la Fase 3. Los bloques continuos representan etapas de transformación y los discontinuos, las corrientes de entrada y salida. Las etiquetas sobre las flechas indican los archivos o las cifras que pasan de una etapa a la siguiente. La flecha discontinua lateral lleva la lista completa de genomas válidos de cada especie hasta la búsqueda local de genes y el cálculo de ANI de los bins, sin pasar por la desreplicación ni por la selección.

El diagrama muestra la decisión de integración más importante de la fase: el pangenoma y la verificación de genes trabajan sobre conjuntos de genomas distintos. El pangenoma usa las referencias seleccionadas, que son pocas y no redundantes, para describir la especie. La verificación usa todos los genomas válidos, porque su objetivo es no pasar por alto ninguna copia de un gen.

6.4.2 Arquitectura de cómputo

La Figura 6.3 representa dónde se ejecuta cada pieza. La división entre el nodo de login y los nodos de cómputo no es un detalle de operación sino una restricción de diseño, porque determina qué programas pueden descargar insumos y cuáles deben encontrarlos ya disponibles. En la Fase 3 la figura agrega dos elementos externos al clúster: los servicios del NCBI, que el nodo de login consulta durante el análisis y no solo durante la preparación, y la estación local donde se generan la estadística y las figuras.

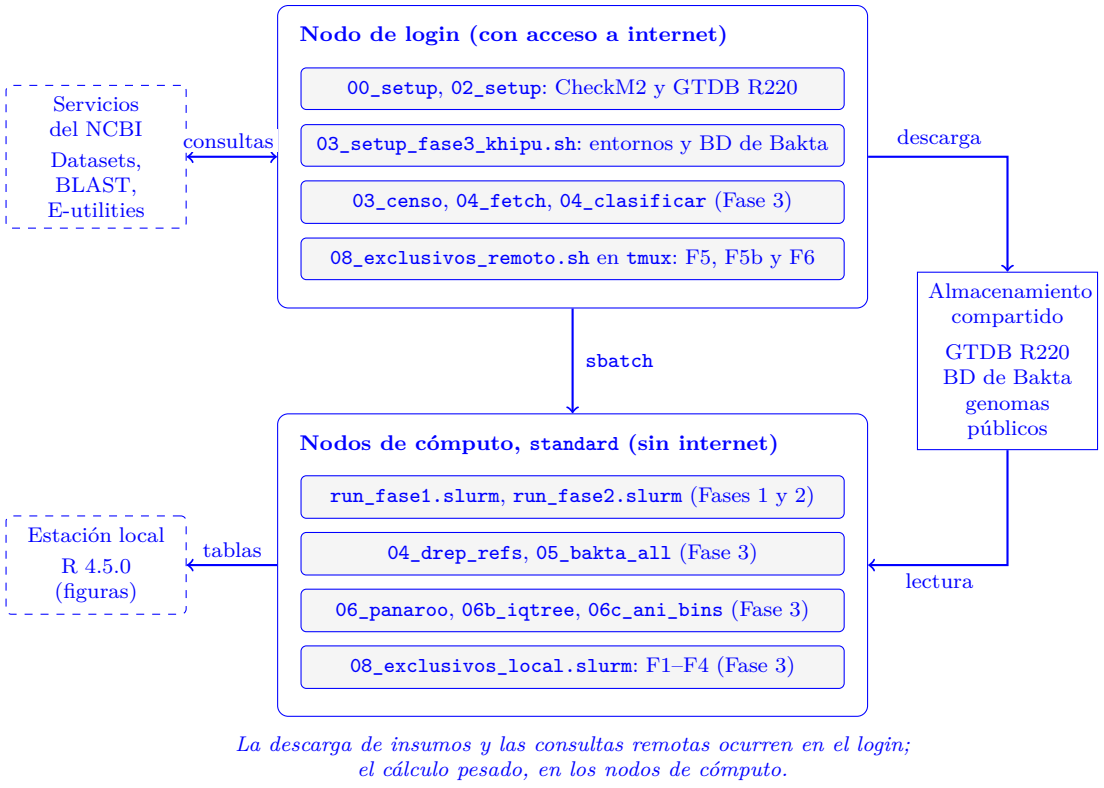


FIGURA 6.3: Arquitectura de cómputo del sistema sobre el clúster Khipu. Los programas de preparación y las etapas que necesitan red (censo, descarga y verificación remota de genes de la Fase 3) se ejecutan en el nodo de login, único con acceso a internet. Los scripts de ejecución se envían a la cola con `sbatch` y corren en nodos de cómputo sin conexión, que solo leen lo que el login dejó en el almacenamiento compartido. Las tablas de resultados se copian a una estación local, donde se calculan la estadística y las figuras.

6.4.3 Verificación de la correspondencia entre el diagrama y la implementación

Las figuras anteriores describen un sistema que existe y que se ejecutó. La correspondencia entre ellas y el código puede comprobarse de forma directa. Cada bloque de la Figura 6.1 corresponde a una invocación identificable dentro de uno de los dos scripts de ejecución de las Fases 1 y 2, y cada bloque de la Figura 6.2, a uno de los programas de la Tabla 6.12, y cada archivo rotulado sobre las flechas corresponde

a un archivo que el sistema escribe en disco y que se conserva en el repositorio junto con los resultados. Las cifras de genomas que atraviesan cada etapa provienen de la ejecución real y coinciden con las que se reportan en el Capítulo VII.

Los guiones completos, con todas sus comprobaciones y mensajes, se presentan en el Anexo correspondiente. Los extractos incluidos en este capítulo recogen las decisiones de diseño relevantes y omiten el código de verificación y de reporte, que no aporta información ingenieril adicional.

CAPÍTULO VII

PRUEBAS Y RESULTADOS

Este capítulo presenta el desempeño del flujo bioinformático diseñado en el Capítulo VI. Primero se define bajo qué condiciones se probó el flujo. Luego se exponen los resultados obtenidos en las Fases 1, 2 y 3, junto con los ajustes de diseño que esos resultados obligaron a realizar. Por último se verifica si la solución cumple las especificaciones técnicas y las restricciones del proyecto.

7.1 Plan de pruebas de la solución

El flujo diseñado no es un cálculo cerrado. Sus resultados dependen de umbrales numéricos que el equipo eligió. Por ese motivo la validación no consiste solo en ejecutar el flujo una vez. Consiste en ejecutarlo con una configuración de referencia y luego comprobar cuánto cambian los resultados si esos umbrales se mueven.

Esta sección define tres cosas. Primero, la configuración de referencia o caso base. Segundo, las variables que se midieron en cada etapa. Tercero, los escenarios alternativos con los que se evaluó la sensibilidad del diseño.

7.1.1 Caso base

El caso base es la configuración con la que se ejecutaron las fases en el clúster Khipu. En las Fases 1 y 2 corresponde a los trabajos SLURM 49286 y 49316. Todos los resultados de la Sección 7.2 provienen de esta configuración, salvo los del

análisis de sensibilidad, que se identifican de forma explícita. La Tabla 7.1 resume los parámetros de las Fases 1 y 2.

TABLA 7.1: Parámetros operativos del caso base con el que se ejecutaron las Fases 1 y 2.

Etapa	**Parámetro**	**Valor**	**Herramienta**
Entrada	Bins de partida	97 (22 librerías)	—
Filtrado de dominio	Longitud mínima de contig	3000 bp	Tiara
Filtrado de dominio	Criterio de decisión	dominio mayoritario	Tiara
Calidad genómica	Completitud	$> 70\,\%$	CheckM2
Calidad genómica	Contaminación	$< 5\,\%$	CheckM2
Clasificación	Base de datos	GTDB R220	GTDB-Tk 2.6.1
Confirmación de especie	ANI	$\geq 95\,\%$	GTDB-Tk (skani)
Confirmación de especie	Fracción alineada (AF)	$\geq 65\,\%$	GTDB-Tk (skani)
Definición de linaje	Umbral primario / secundario	0.90 / 0.95	dRep (fastANI)
Cómputo	Núcleos, memoria, tiempo	32, 90 GB, 24 h	SLURM

Nota. GTDB-Tk 2.6.1 calcula el ANI de confirmación de especie con skani [67]; fastANI solo interviene en la desreplicación con dRep.

El caso base de la Fase 3 se ejecutó entre el 4 y el 8 de octubre de 2026. Sus parámetros se resumen en la Tabla 7.2, y su implementación en la Tabla 6.4 del Capítulo VI. Para la búsqueda de genes específicos, el caso base es la segunda versión del análisis; la primera se documenta como iteración en la Sección 7.2.5.4.

Tabla 7.2: Parámetros del caso base de la Fase 3 y trabajo SLURM en que se ejecutó cada etapa.

Etapa	Parámetro	Valor	Herramienta y trabajo
Censo	Calidad de referencias	$\geq 95\,\%$, $\leq 5\,\%$, ≤ 300 contigs	metadatos GTDB R220
Censo y selección	Genomas por especie	≥ 15 no redundantes	—
Desreplicación	Umbral primario / secundario	0.90 / 0.99	dRep 3.7.1
Selección	Referencias por especie	≤ 50; 3 especies	—
Anotación	Base de datos	v6.0 *full*	Bakta 1.12.1 (54664)
Pangenoma	Modo de limpieza	`moderate`	Panaroo 1.8.0 (54744)
Partición	Core / cloud	$\geq 95\,\%$ / $< 15\,\%$	solo referencias
Árbol	Modelo; soporte	BIC; 1000 UFBoot	IQ-TREE 3.1.3 (54753)
ANI de los bins	Genomas de comparación	todos los válidos	fastANI 1.34 (54890)
Genes específicos	F1–F4, versión 2	ver Tabla 6.4	BLAST+ 2.17.0 (54889)
Genes específicos	F5, F5b y F6, versión 2	nr, core_nt	NCBI, nodo de login

7.1.2 Variables medidas

En cada etapa del flujo se registró un conjunto de variables de respuesta. Estas variables son las que permiten juzgar si la etapa funcionó. La Tabla 7.3 las organiza por etapa.

TABLA 7.3: Variables de respuesta registradas en cada etapa del flujo.

Etapa	**Variables medidas**
Filtrado de dominio	Número de bins retenidos; porcentaje de longitud asignada a cada dominio en cada bin
Calidad genómica	Número de genomas retenidos; completitud y contaminación; motivo de rechazo; número de contigs, N50, tamaño y GC
Clasificación	Número de filos, órdenes y géneros; número de genomas con especie confirmada; ANI y AF frente a la referencia más próxima
Desreplicación	Número de linajes; ANI y cobertura dentro de cada clúster
Prevalencia	Número de muestras distintas en que aparece cada linaje
Censo y descarga	Genomas por especie tras el control de calidad; genomas válidos tras la verificación
Desreplicación	Genomas no redundantes; ANI medio y mínimo entre referencias
Anotación	CDS por genoma frente a la mediana de su especie
Pangenoma	Familias core, shell y cloud; singletons; exponente α
Posición del bin	Genes del bin por categoría; porcentaje del core recuperado
Árbol	Modelo; soporte UFBoot; pariente más cercano y distancia
ANI de los bins	ANI máximo y mediano; correlación con la distancia en el árbol
Genes específicos	Candidatos que sobreviven a cada filtro; origen probable

7.1.3 Escenarios de sensibilidad

Los umbrales del caso base son decisiones de diseño y no constantes físicas. Un umbral distinto habría producido un conjunto de genomas distinto. Para medir esa dependencia se repitió la selección con otros valores y se contó cuántos genomas y cuántos linajes quedaban en cada caso.

Estos escenarios no requirieron volver a ejecutar el flujo en el clúster. Las herramientas del caso base ya entregan, para cada genoma, el valor numérico sobre

el que actúa cada filtro. La selección se recalculó sobre esas tablas de salida. El procedimiento es equivalente porque los filtros son comparaciones directas sobre valores ya calculados. La Tabla 7.4 detalla los escenarios evaluados. Los escenarios E6 a E13 corresponden a la Fase 3. La mayoría también se recalculó sobre tablas ya producidas; solo E8, E10 y E11 exigieron una nueva ejecución.

TABLA 7.4: Escenarios de sensibilidad evaluados sobre los resultados del caso base.

Escenario	**Variable manipulada**	**Valores**	**Variable medida**
E1	Umbral de completitud	50, 60, 70, 80, 90, 95 %	Genomas retenidos
E2	Umbral de contaminación	1, 3, 5, 10 %	Genomas retenidos
E3	Criterio de dominio	mayoría simple; 25 a 90 % de longitud procariota	Bins retenidos
E4	Umbral de ANI de linaje	95, 98, 99, 99.5 %	Linajes definidos
E5	Continuidad del ensamblaje	sin filtro; $\leq$ 300 contigs	Genomas retenidos
E6	Umbral de desreplicación	99, 99.5, 99.9 %	Genomas no redundantes
E7	Umbral del core	90, 95 %	Familias core
E8	Modo de limpieza de Panaroo	moderate, sensitive	Partición, α, candidatos
E9	Genomas en el pangenoma	23 por especie; solo cerrados	α, tamaño del pangenoma
E10	Base de datos de F5	nr, UniProtKB	Genes específicos
E11	Especie del genoma portador	por nombre, por ANI	Genes específicos
E12	Contigs de las referencias	200, 300, 1000	Especies viables
E13	Distancia al borde en F1	0, 50, 100 pb	Candidatos retenidos

7.2 Análisis de los resultados de las pruebas

Esta sección presenta los resultados de las tres fases ejecutadas. Las Secciones 7.2.1, 7.2.2 y 7.2.3 exponen los resultados del caso base. La Sección 7.2.4

evalúa cuánto dependen esos resultados de los umbrales elegidos. La Sección 7.2.5 documenta los ajustes de diseño que los resultados obligaron a realizar.

7.2.1 Resultados de la Fase 1: control de calidad y selección de genomas (OE1)

La Fase 1 se ejecutó en el clúster Khipu mediante el controlador `run_fase1.slurm` (trabajo SLURM 49286), sobre los 97 bins genómicos crudos procedentes de las 22 librerías Illumina que recuperaron material ensamblable (Tabla 5.1). El flujo aplicó dos filtros secuenciales e independientes: primero una discriminación por dominio con Tiara y después una estimación de calidad genómica con CheckM2. El orden no es intercambiable, ya que las métricas de completitud y contaminación de CheckM2 se calculan sobre marcadores procariotas y carecen de sentido en un ensamblaje mayoritariamente eucariota.

7.2.1.1. Depuración secuencial del conjunto de bins

El filtrado por dominio descartó 31 de los 97 bins, cuya mayoría se clasificó como eucariota u organelar. Este resultado era esperable dado el origen de las muestras: una superficie pétrea expuesta a la intemperie acumula material fúngico, algal y vegetal que el ensamblaje por muestra no separa del componente procariota. Casos como `bin-1-55`, con 34.2 Mb repartidos en 247 contigs, corresponden con claridad a un genoma eucariota parcialmente reconstruido y no a un genoma bacteriano contaminado.

Los 66 bins restantes pasaron al control de calidad genómica, donde se aplicó el criterio definido para el OE1: completitud superior al 70 % y contaminación inferior al 5 %. De ellos, 45 fueron rechazados y 21 seleccionados, lo que representa una tasa

de retención del 21.65 % sobre el total crudo inicial. El motivo de los rechazos resulta informativo porque expone dos problemas de naturaleza distinta:

- **18 bins** incumplieron únicamente el criterio de completitud ($\leq 70\,\%$). Se trata de reconstrucciones parciales, atribuibles a baja profundidad de secuenciación o a fragmentación del ensamblaje. Los valores cubren todo el rango, desde reconstrucciones cercanas al umbral, como `bin-1-50` con 62.29 %, hasta fragmentos residuales sin utilidad analítica, como `bin-1-52` con 6.05 %.
- **20 bins** incumplieron únicamente el criterio de contaminación ($\geq 5\,\%$), lo que indica quimerismo: contigs de linajes distintos coagrupados por MetaBAT2 durante el *binning*. La magnitud es en ocasiones considerable, como en `bin-1-60`, con 24.87 %.
- **7 bins** incumplieron ambos criterios de forma simultánea. El caso extremo es `bin-1-58`, con 0.00 % de completitud y 17.71 % de contaminación, un agrupamiento sin correspondencia con ningún genoma real.

Esta diferencia es importante para entender qué se perdió en cada caso. Los 18 bins incompletos corresponden a información que estaba presente en la muestra, pero que no pudo reconstruirse completamente durante el ensamblaje. En cambio, los 20 bins contaminados contienen fragmentos de distintos organismos que fueron agrupados incorrectamente. Este segundo problema es más crítico, porque podría afectar la reconstrucción del genoma accesorio en los análisis posteriores. Por ello, se mantuvo un límite estricto de contaminación del 5 %, mientras que el umbral de completitud se fijó en 70 %.

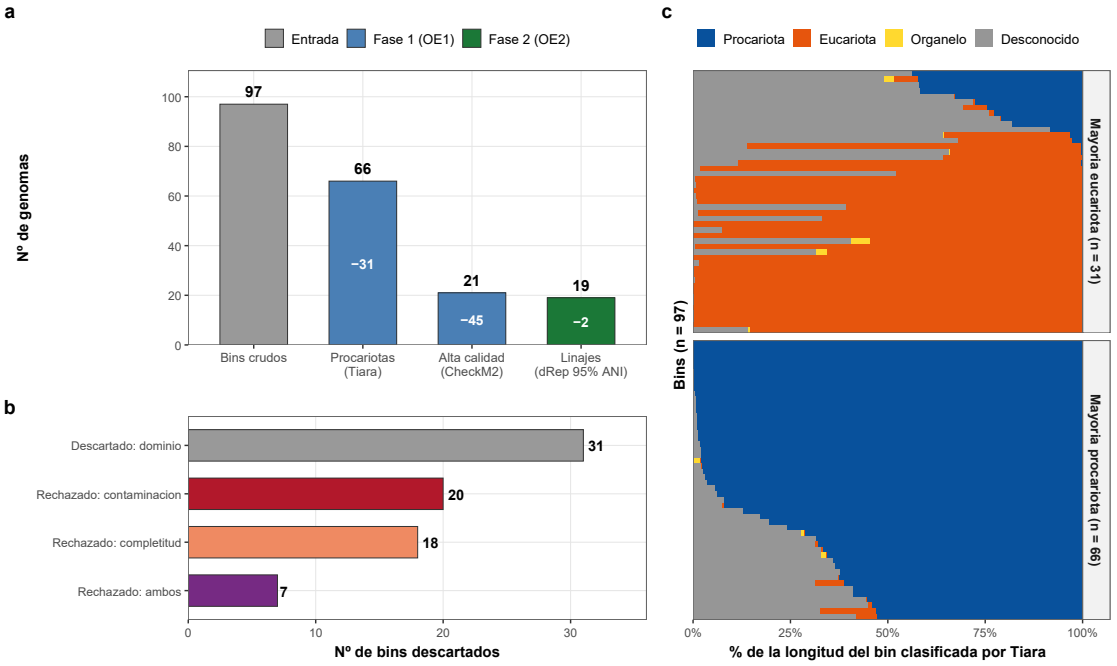


FIGURA 7.1: Embudo de selección de genomas desde los bins crudos hasta los linajes. **(a)** Número de genomas que sobrevive a cada etapa del flujo: 97 bins crudos procedentes de 22 librerías Illumina, 66 con dominio mayoritariamente procariota según Tiara, 21 que superan los umbrales de calidad de CheckM2 (completitud superior al 70 %, contaminación inferior al 5 %) y 19 linajes tras la desreplicación con dRep al 95 % de ANI. Las cifras en blanco indican las pérdidas en cada paso. **(b)** Motivos de descarte de los 76 bins eliminados. **(c)** Composición por dominio de cada uno de los 97 bins según Tiara, expresada como porcentaje de la longitud del bin clasificada en cada categoría; los bins se separan según su dominio mayoritario y se ordenan por la fracción procariota.

La Figura 7.1(c) muestra que la clasificación por dominio no es ambigua en la mayoría de los casos: los bins se concentran en los extremos de la escala, con una fracción procariota cercana al 0 % o al 100 %, y son pocos los que ocupan posiciones intermedias. Esto respalda la decisión de aplicar un criterio de mayoría simple sobre la longitud clasificada en lugar de un umbral más elaborado.

7.2.1.2. Calidad y estructura de los 21 genomas seleccionados

Los 21 genomas retenidos presentan una calidad marcadamente asimétrica respecto del umbral. La mediana de la completitud alcanza el 99.86 %, con 13 genomas por encima del 99 % y 5 con completitud estimada del 100.00 %; solo cuatro quedan por debajo del 80 %. La mediana de la contaminación es del 0.44 %, valor muy por debajo del límite fijado.

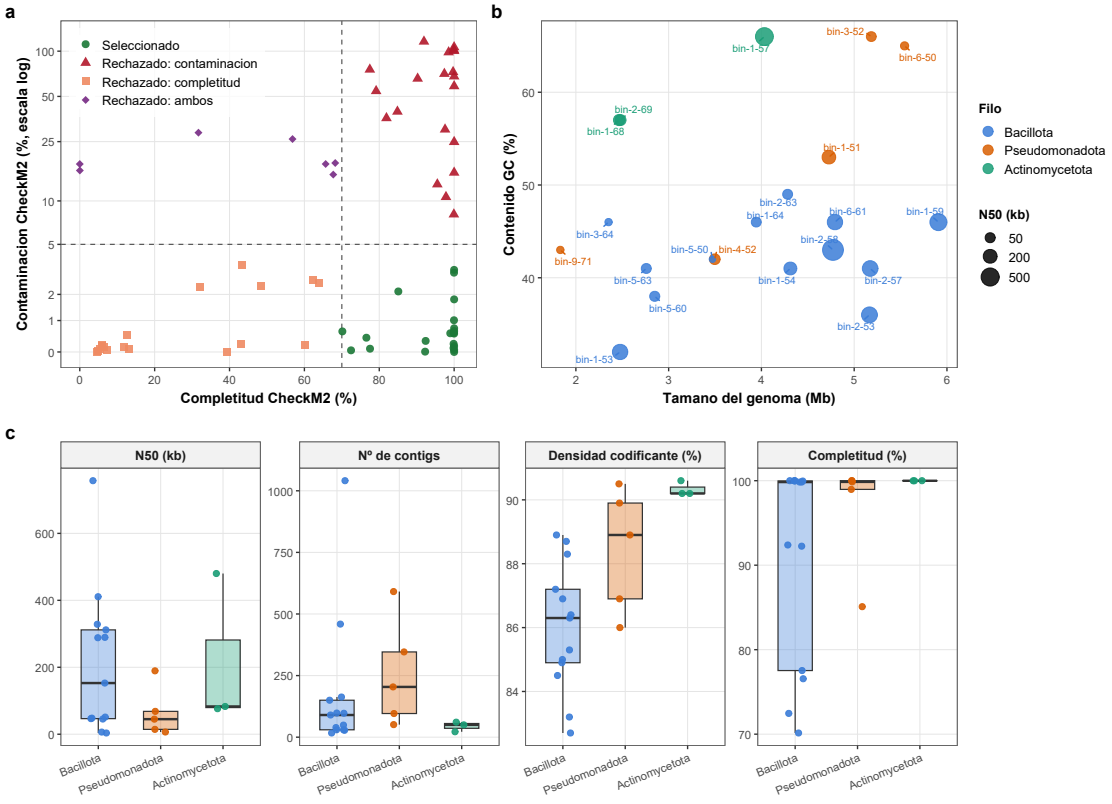


FIGURA 7.2: Calidad y métricas de ensamblaje de los genomas. **(a)** Completitud frente a contaminación (CheckM2) de los 66 bins procariotas. El eje de contaminación usa escala logarítmica ($\log(1+x)$) porque unos pocos bins superan el 60 % y comprimirían la región de interés. Las líneas discontinuas marcan los umbrales del estudio (completitud igual o superior al 70 %, contaminación inferior al 5 %) y la región sombreada, los 21 genomas seleccionados. **(b)** Tamaño del genoma frente a contenido GC de los 21 genomas seleccionados; el tamaño del punto es proporcional al N50 de los contigs y el color indica el filo. **(c)** Distribución de N50, número de contigs, densidad codificante y completitud por filo. Cada punto es un genoma; las cajas muestran mediana y cuartiles.

La Figura 7.2(a) muestra los criterios de contaminación y completitud sobre las distintas poblaciones de bins.

La completitud y la contaminación no describen por completo la utilidad de un genoma para el análisis pangenómico. La continuidad del ensamblaje sí importa, y en esa dimensión el conjunto es heterogéneo: el número de contigs va de 17 a 1041, con mediana de 90. Cuatro genomas superan los 300 contigs (`bin-5-50` con 1041, `bin-6-50` con 591, `bin-3-64` con 459 y `bin-9-71` con 346).

El caso de `bin-5-50` muestra que la calidad y la fragmentación de un genoma son aspectos distintos. Este bin tiene una completitud del 76.56 % y una contaminación del 0.44 %, por lo que cumple los criterios del OE1. Sin embargo, sus 3.47 Mb están divididos en más de mil contigs, con una longitud media de solo 3.3 kb.

CheckM2 le asigna una buena calidad porque evalúa principalmente la presencia de genes marcadores, muchos de los cuales pueden encontrarse completos incluso en contigs pequeños. Por tanto, esta métrica no refleja directamente qué tan continuo está el ensamblaje.

El problema aparece en la Fase 3. Cuando un gen queda cortado entre contigs, puede no coincidir correctamente con su versión completa en los genomas de referencia. Como resultado, el análisis pangenómico puede interpretarlo como un gen diferente y clasificarlo como accesorio o incluso exclusivo de la Estela. Así, una alta fragmentación puede generar falsos genes exclusivos, afectando directamente al OE3. Por esta razón, la Fase 3 incluye controles para identificar y descartar estos casos.

Los tamaños genómicos oscilan entre 1.83 y 5.91 Mb, con mediana de 4.03 Mb, valores compatibles con genomas bacterianos. El extremo inferior corresponde a `bin-9-71` (1.83 Mb), cuya completitud del 85.09 %.

Tabla 7.5: Métricas de ensamblaje y calidad genómica de los 21 MAGs seleccionados (completitud superior al 70 % y contaminación inferior al 5 %).

Bin	**Contigs**	**Longitud (bp)**	**Dominio**	**Completitud (%)**	**Contaminación (%)**
bin-1-51	51	4.727.435	prok	100.00	0.00
bin-1-53	30	2.476.631	prok	99.84	0.12
bin-1-54	49	4.312.038	prok	92.25	0.01
bin-1-57	22	4.032.412	prok	99.99	3.23
bin-1-59	98	5.907.869	prok	99.97	3.07
bin-1-64	163	3.944.265	prok	99.84	0.59
bin-1-68	50	2.465.224	prok	100.00	1.79
bin-2-53	39	5.164.804	prok	99.99	0.57
bin-2-57	28	5.172.263	prok	99.96	1.01
bin-2-58	17	4.771.531	prok	100.00	0.06
bin-2-63	150	4.282.638	prok	92.39	0.34
bin-2-69	61	2.481.071	prok	99.99	0.18
bin-3-52	204	5.184.467	prok	98.97	0.58
bin-3-64	459	2.352.198	prok	70.14	0.64
bin-4-52	96	3.497.259	prok	99.86	0.25
bin-5-50	1041	3.472.002	prok	76.56	0.44
bin-5-60	97	2.849.856	prok	77.53	0.10
bin-5-63	90	2.758.939	prok	72.46	0.05
bin-6-50	591	5.543.214	prok	100.00	0.65
bin-6-61	30	4.792.746	prok	100.00	0.74
bin-9-71	346	1.832.072	prok	85.09	2.13

7.2.1.3. Implicancia para el OE1

El OE1 se cumple. Obtenemos un conjunto de 21 genomas procariotas cuya completitud y pureza permiten la asignación taxonómica y la comparación genómica

posteriores. Por ese motivo descartamos 78.35 % del material de partida. La depuración descarta organismos que estuvieran presentes en la estela pero que no alcanzan la calidad necesaria para los posteriores análisis. Por lo tanto, la diversidad real de la fracción viable es mayor que la que estos 21 genomas representan.

El detalle de todos los 97 bins evaluados, con los motivos específicos para su exclusión, se presenta en el Anexo 7.23.

7.2.2 Resultados de la Fase 2: asignación taxonómica y definición de linajes (OE2)

La Fase 2 se ejecutó en Khipu mediante `run_fase2.slurm` (trabajo SLURM 49316) sobre los 21 genomas seleccionados en la fase anterior. El flujo comprendió la clasificación taxonómica con GTDB-Tk sobre los datos de la versión R220, la confirmación de especie por ANI, la desreplicación en linajes con dRep y el cálculo de la prevalencia espacial de cada linaje.

7.2.2.1. Composición taxonómica de la fracción viable

GTDB-Tk clasificó los 21 genomas dentro de tres filos bacterianos. No se detectó ningún genoma arqueal, lo que resuelve la ambigüedad que Tiara había dejado abierta en la Fase 1 entre bacterias y arqueas. La distribución está dominada por Bacillota, con 13 genomas (62 %), seguido de Pseudomonadota con 5 (24 %) y Actinomycetota con 3 (14 %). Por debajo del filo, la diversidad es alta en relación con el tamaño de la muestra: los 21 genomas se reparten en 11 órdenes y 17 géneros distintos, y solo cuatro géneros aportan más de un genoma.

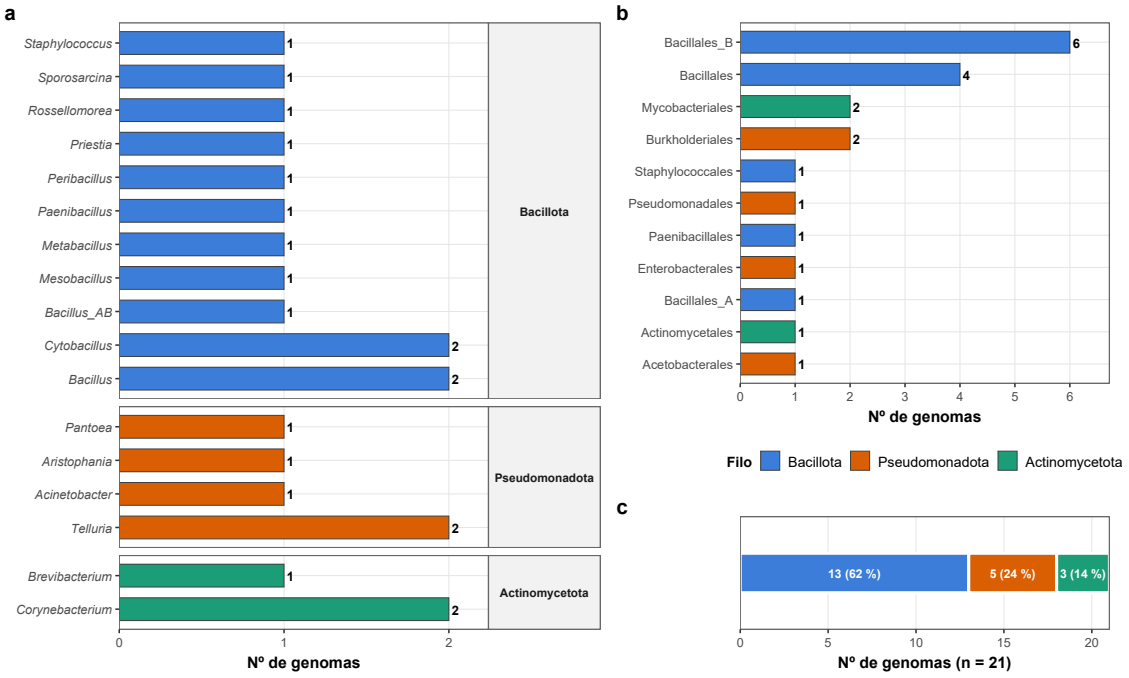


FIGURA 7.3: Composición taxonómica del conjunto de genomas seleccionados. **(a)** Número de genomas por género, agrupados por filo. **(b)** Número de genomas por orden. **(c)** Reparto de los 21 genomas entre los tres filos detectados.

El predominio de Bacillota (Figura 7.3) es coherente con el sustrato y con el método de obtención de la muestra. Buena parte de los géneros recuperados dentro de este filo (*Bacillus*, *Peribacillus*, *Priestia*, *Cytobacillus*, *Metabacillus*, *Rossellomorea*, *Mesobacillus*, *Sporosarcina*, *Paenibacillus*) forma endosporas, una estrategia de resistencia que favorece la supervivencia sobre una superficie pétrea expuesta a desecación, radiación ultravioleta y oscilación térmica [11].

7.2.2.2. Confirmación filogenómica

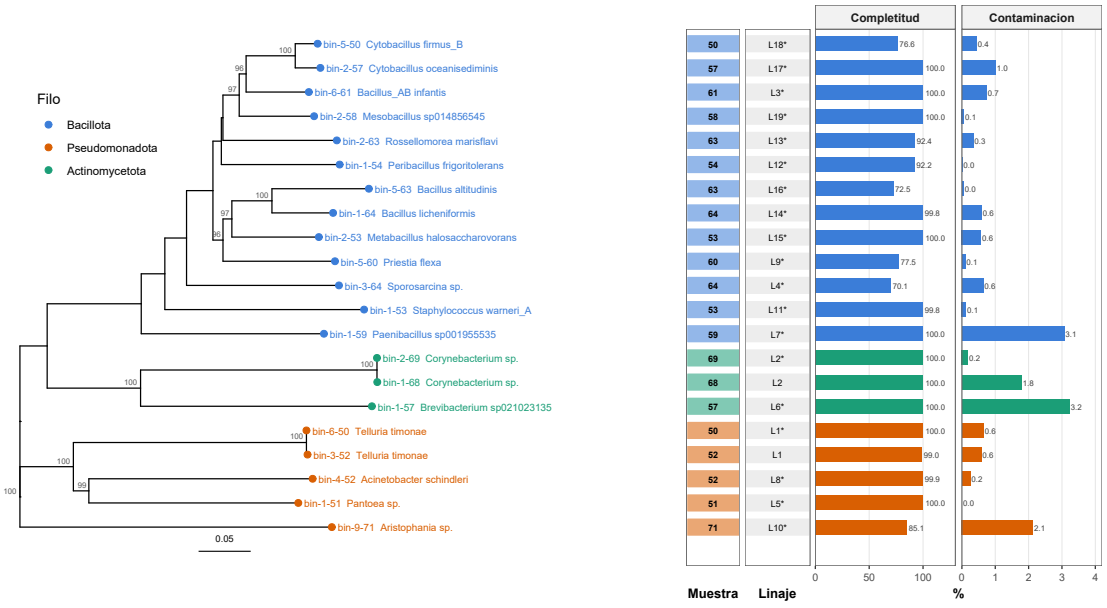


FIGURA 7.4: Árbol filogenómico de los 21 genomas seleccionados con sus metadatos. Árbol de Neighbor-Joining calculado sobre distancias-p a partir del alineamiento concatenado de los 120 marcadores bacterianos de copia única (bac120, 5035 posiciones) generado por GTDB-Tk (datos R220), enraizado en el filo Pseudomonadota. Los números sobre las ramas son valores de soporte de *bootstrap* (500 réplicas); solo se muestran los iguales o superiores al 70 %. Las columnas de la derecha indican, para cada genoma, la muestra de origen, el linaje asignado por dRep (el asterisco marca el genoma representante del linaje) y los valores de completitud y contaminación de CheckM2.

La topología del árbol (Figura 7.4) es congruente con la asignación taxonómica: los tres filos se recuperan como grupos separados y los genomas del mismo género quedan en ramas adyacentes. Los valores de soporte son altos en los nodos que definen la estructura principal, con *bootstrap* del 100 % en la separación de los filos y en los pares congenéricos.

El alcance de este resultado es limitado. El árbol es de distancias y se calculó únicamente sobre los genomas de consulta, sin incorporar genomas de referencia de GTDB, de modo que verifica la coherencia interna del conjunto pero no constituye

una prueba filogenética independiente de la asignación taxonómica. La ubicación de cada genoma entre las cepas de su especie se resolvió en la Fase 3, con un árbol de máxima verosimilitud por especie (Sección 7.2.3.5).

7.2.2.3. Confirmación de especie y candidatos a novedad taxonómica

Se calculó la Identidad Nucleotídica Promedio de cada genoma frente a su referencia GTDB más próxima, aplicando los criterios de confirmación de especie definidos en el Capítulo V (ANI $\geq$ 95 % y fracción alineada $\geq$ 65 %). Dieciséis de los 21 genomas satisfacen ambos criterios, con valores de ANI entre 95.61 % y 99.99 % y mediana de 98.53 %. Doce de los 16 superan el 98 % de ANI, lo que indica correspondencias con especies descritas.

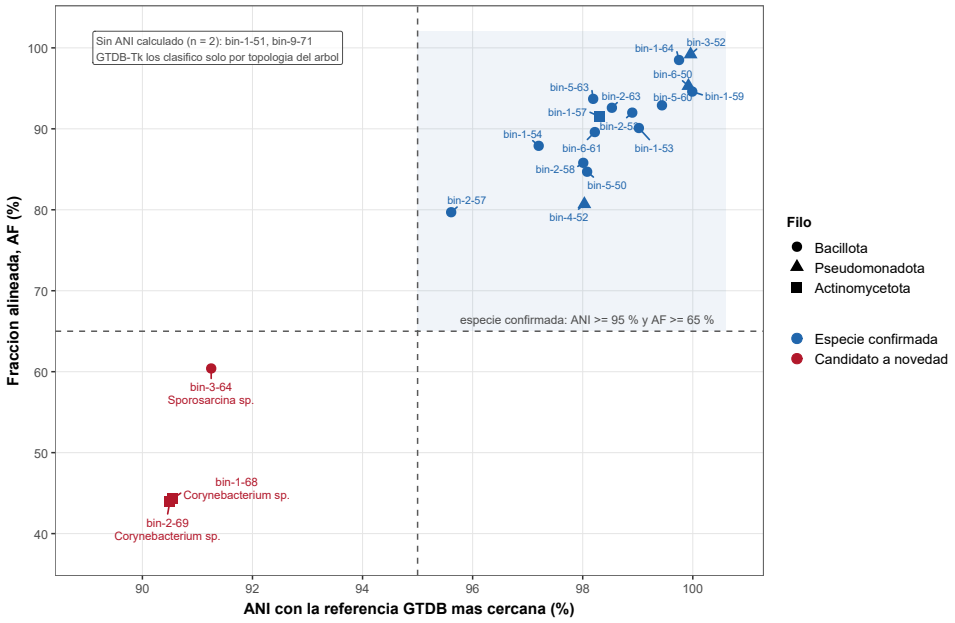


FIGURA 7.5: Evaluación de novedad taxonómica frente a la referencia GTDB más cercana. ANI frente a fracción alineada (AF) de cada genoma respecto de su referencia GTDB más cercana. Las líneas discontinuas marcan los criterios de confirmación de especie (ANI igual o superior al 95 % y AF igual o superior al 65 %). Los 16 genomas del cuadrante sombreado tienen especie confirmada. Dos genomas adicionales (`bin-1-51`, *Pantoea* sp., y `bin-9-71`, *Aristophania* sp.) fueron clasificados únicamente por topología del árbol, sin cálculo de ANI, y no aparecen representados.

Los 5 genomas restantes se distribuyen en dos situaciones distintas (Figura 7.5). Dos de ellos, `bin-1-51` (*Pantoea* sp.) y `bin-9-71` (*Aristophania* sp.), fueron ubicados por GTDB-Tk mediante la topología del árbol de colocación sin que se calculara ANI, de modo que su clasificación se detiene en el rango de género por ausencia de una referencia suficientemente próxima. Por ese motivo, esas secuencias se descartan para la fase 3.

Los otros 3 sí produjeron valores de ANI, pero por debajo del umbral de especie, y constituyen el hallazgo taxonómico más relevante de esta fase. Los dos genomas de *Corynebacterium* sp. (`bin-1-68` y `bin-2-69`) alcanzan un ANI de 90.55 y 90.50 % frente a su referencia más cercana, con fracciones alineadas de apenas

44,3 y 44.0 %. El genoma de *Sporosarcina* sp. (`bin-3-64`) queda en 91.25 % de ANI y 60.4 % de AF. Los tres valores de ANI se encuentran por debajo del umbral de similitud utilizado para la circunscripción de especies en GTDB, lo que indica que ninguno de estos genomas puede asignarse a la misma especie que su referencia más cercana.

En el caso de los *Corynebacterium* la fracción alineada, inferior al 45 %, indica que menos de la mitad del genoma encuentra correspondencia en la referencia. Estos genomas son, por tanto, candidatos a especies no descritas en la versión R220 del GTDB.

Hacemos énfasis en este resultado porque ambos *Corynebacterium* proceden de muestras distintas y presentan completitud del 100 %, de modo que la divergencia observada no es atribuible a una reconstrucción defectuosa.

7.2.2.4. Desreplicación y definición de linajes

La desreplicación con dRep agrupó los 21 genomas en 19 linajes, definidos como clústeres de especie al 95 % de ANI. Solo dos pares colapsaron.

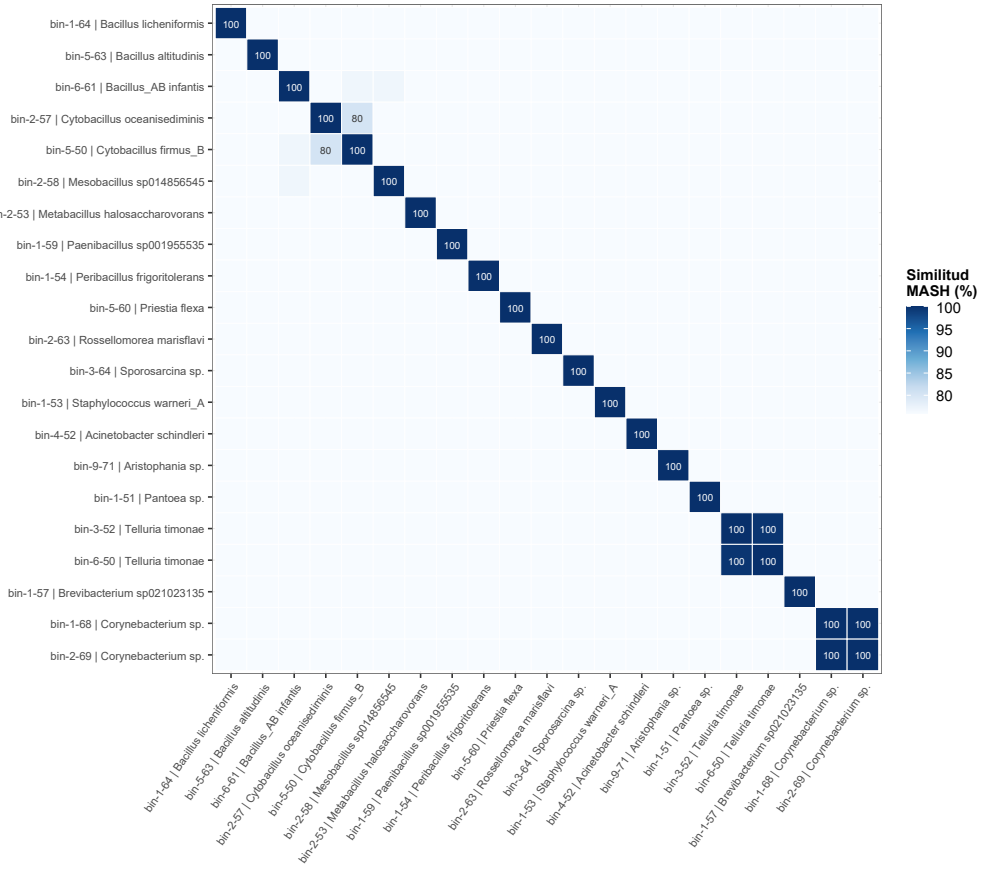


FIGURA 7.6: Matriz de similitud genómica entre los 21 genomas seleccionados. Similitud MASH (100− distancia MASH) entre todas las parejas de genomas, ordenadas por filo y género. Solo dos parejas presentan similitud máxima: los dos *Telluria timonae* (muestras 50 y 52) y los dos *Corynebacterium* sp. (muestras 68 y 69). Nota metodológica: dRep ejecuta fastANI únicamente dentro de cada clúster primario definido por MASH, de modo que no existe una matriz de ANI completa para los 21 genomas; la matriz de todos contra todos disponible es la de MASH.

Las dos parejas sometidas a fastANI dentro de su clúster primario superan el umbral de especie con amplitud: *Corynebacterium* sp. (`bin-1-68` ↔ `bin-2-69`) alcanza 99.96 % de ANI con 97.1 % de cobertura del alineamiento, y *Telluria timonae* (`bin-3-52` ↔ `bin-6-50`), 99.78 % de ANI con 85.2 % de cobertura. Ambas colapsan en un único linaje.

El resto de los genomas resulta mutuamente distante (Figura 7.6), incluido el par de *Cytobacillus* (`bin-5-50` y `bin-2-57`), que pese a compartir género se mantiene como dos linajes separados con una similitud MASH del 80 %. Este es el motivo de que 21 genomas den lugar a 19 linajes y no a un número menor: la redundancia entre muestras es baja, y la mayor parte de lo recuperado corresponde a organismos distintos y no a reconstrucciones repetidas del mismo genoma.

7.2.2.5. Prevalencia espacial de los linajes

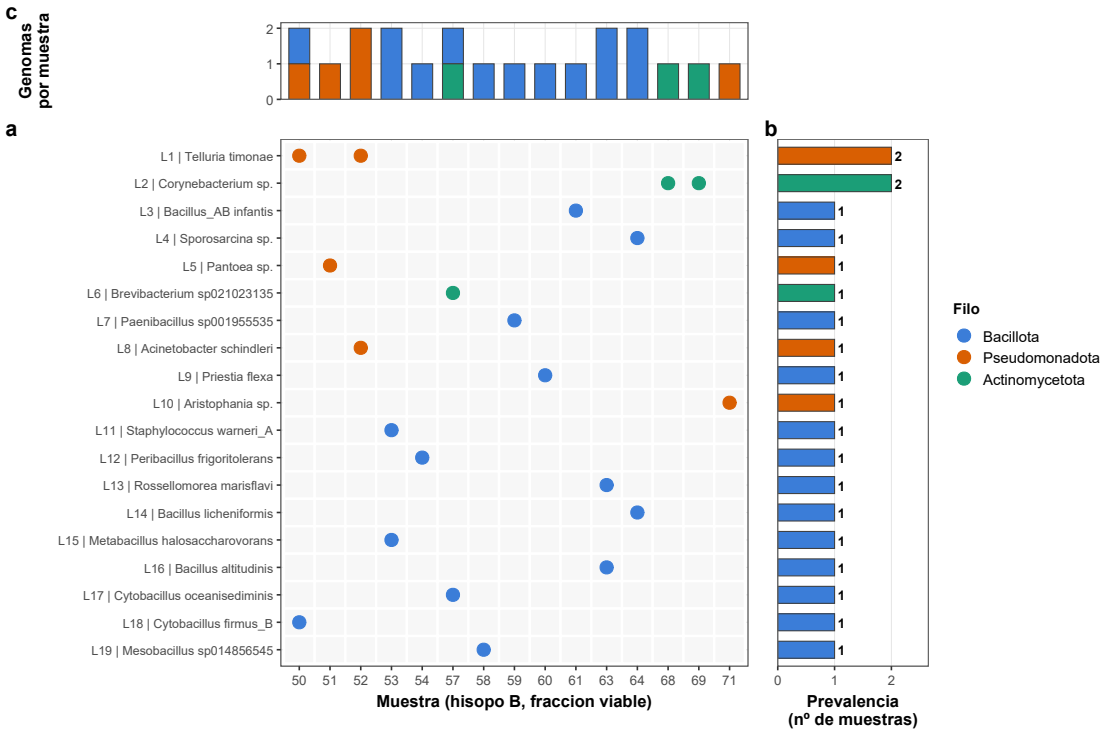


FIGURA 7.7: Prevalencia espacial de los linajes. **(a)** Matriz de presencia de cada linaje (filas, ordenadas por prevalencia descendente) en cada muestra (columnas); el color indica el filo. **(b)** Prevalencia de cada linaje, definida como el número de muestras distintas en que aparece, coloreada por filo. **(c)** Número de genomas de alta calidad recuperados por muestra, coloreado por filo. Limitación: la prevalencia se calcula sobre el número de muestras y no sobre zonas físicas de la estela, porque no se dispone de un mapeo muestra → zona en formato analizable.

La prevalencia espacial resultó baja en todo el conjunto. Diecisiete de los 19 linajes aparecen en una sola muestra, y solo dos alcanzan una prevalencia de dos: L1 (*Telluria timonae*, muestras 50 y 52) y L2 (*Corynebacterium* sp., muestras 68 y 69). Ningún linaje se recuperó en tres o más puntos. Además, de las 22 librerías que produjeron bins, solo 15 aportaron al menos un genoma de alta calidad tras la Fase 1 (Figura 7.7(c)).

Este resultado limita el poder discriminante de la métrica. Con un rango efectivo de apenas dos valores, la prevalencia no permite ordenar los linajes ni separar con seguridad a los colonizadores estables de las detecciones puntuales.

Dos hipotésis resultan compatibles con los datos. La primera es que la comunidad viable de la estela sea genuinamente heterogénea entre muestras, sin un núcleo de organismos compartido. La segunda es que la recuperación de genomas de alta calidad sea limitada, de modo que un linaje presente en varias muestras solo pueda reconstruirse con suficiente calidad en una de ellas.

Los datos disponibles no permiten discriminar entre ambas. La segunda tampoco puede descartarse, dado que el flujo retuvo apenas el 21.65 % de los bins iniciales.

Por esta razón, la prevalencia espacial se reporta aquí como caracterización de la distribución de cada linaje sobre el monumento, pero no se emplea como criterio para decidir qué especies ingresan al análisis pangenómico.

Por ese motivo, el criterio de selección de bins para el pangenoma (fase 3) cambia como se explica en la siguiente sección.

7.2.2.6. Implicancia para el OE2

El OE2 se cumple: los 21 genomas quedan clasificados con resolución de especie en 16 casos y de género en los 5 restantes, y agrupados en 19 linajes operativos que constituyen la unidad de análisis de las fases siguientes.

Dos resultados condicionan el diseño posterior. El primero es la baja redundancia entre muestras: con 19 linajes sobre 21 genomas, y 17 de ellos representados por un único genoma, no es posible construir un pangenoma empleando exclusivamente material de la estela. El análisis pangenómico de la Fase 3 debe apoyarse necesariamente en conjuntos de genomas de referencia públicos. El segundo es la detección de tres candidatos a especies no descritas, entre ellos los dos *Corynebacterium* de completitud íntegra, que por carecer de referencia comparable quedan fuera del análisis pangenómico pero constituyen un hallazgo reportable por sí mismo.

Tabla 7.6: Linajes definidos en la Fase 2, ordenados por prevalencia espacial descendente.

Linaje	Taxonomía (GTDB)	Prev.	Muestras	Representante	Especie conf.
L1	*Telluria timonae*	2	50, 52	bin-6-50	Sí
L2	*Corynebacterium* sp.	2	68, 69	bin-2-69	No
L3	*Bacillus_AB infantis*	1	61	bin-6-61	Sí
L4	*Sporosarcina* sp.	1	64	bin-3-64	No
L5	*Pantoea* sp.	1	51	bin-1-51	—
L6	*Brevibacterium* sp021023135	1	57	bin-1-57	Sí
L7	*Paenibacillus* sp001955535	1	59	bin-1-59	Sí
L8	*Acinetobacter schindleri*	1	52	bin-4-52	Sí
L9	*Priestia flexa*	1	60	bin-5-60	Sí
L10	*Aristophania* sp.	1	71	bin-9-71	—
L11	*Staphylococcus warneri_A*	1	53	bin-1-53	Sí
L12	*Peribacillus frigoritolerans*	1	54	bin-1-54	Sí
L13	*Rossellomorea marisflavi*	1	63	bin-2-63	Sí
L14	*Bacillus licheniformis*	1	64	bin-1-64	Sí
L15	*Metabacillus halosaccharovorans*	1	53	bin-2-53	Sí
L16	*Bacillus altitudinis*	1	63	bin-5-63	Sí
L17	*Cytobacillus oceanisediminis*	1	57	bin-2-57	Sí
L18	*Cytobacillus firmus_B*	1	50	bin-5-50	Sí
L19	*Mesobacillus* sp014856545	1	58	bin-2-58	Sí

Nota. Prev.: prevalencia espacial, número de muestras distintas que aportan al menos un genoma al linaje. Especie conf.: confirmación de especie por ANI igual o superior al 95 % y AF igual o superior al 65 %; el guion indica los linajes clasificados por topología del árbol, sin cálculo de ANI. Los sufijos `_A` y `_B` y los epítetos alfanuméricos del tipo `sp`⟨dígitos⟩ corresponden a la nomenclatura propia del GTDB.

7.2.3 Resultados de la Fase 3: análisis pangenómico comparativo (OE3)

La Fase 3 se ejecutó en Khipu entre el 4 y el 8 de octubre de 2026. Compara cada bin de la Estela con los genomas públicos de su especie para responder tres

preguntas: cómo es el repertorio de genes de la especie, a qué cepa conocida se parece la cepa de la Estela y qué genes tiene esa cepa que ninguna otra cepa conocida de su especie tiene. Las cifras por especie se dan siempre en el orden *Bacillus altitudinis* (L16), *Peribacillus frigoritolerans* (L12) y *Acinetobacter schindleri* (L8).

7.2.3.1. Selección de especies y de genomas de referencia

De los 19 linajes de la Fase 2, solo 12 tienen nombre de especie en GTDB y pudieron someterse al censo de genomas públicos. Quedaron fuera los cuatro linajes que GTDB-Tk clasificó solo hasta género (L2, L4, L5 y L10), que son los candidatos a especies no descritas, y los tres con un nombre provisional de GTDB formado por `sp` y un número (L6, L7 y L19), que no corresponde a un nombre estable en el NCBI.

Para cada uno de los 12 linajes se contaron los genomas públicos que GTDB R220 asigna a su especie y se aplicó el control de calidad de las referencias: completitud de al menos 95 %, contaminación de hasta 5 % y no más de 300 contigs. Se excluyeron además los genomas que el NCBI registra como derivados de un metagenoma, de una muestra ambiental o de una sola célula. Estos genomas excluidos no son los bins de la Estela: son genomas públicos de otros estudios, reconstruidos de la misma forma que los bins. Se excluyeron para que las referencias fueran lo más confiables posible. La asimetría es deliberada: los bins entran al análisis aunque sean MAGs porque son el objeto de estudio, mientras que a las referencias, que sí pueden elegirse, se les exige más. La Tabla 7.7 muestra el resultado de cada paso.

Tabla 7.7: Genomas públicos disponibles para cada especie en cada paso de la selección. Post-QC: genomas que pasan el control de calidad. Válidos: descargados y verificados, sin las exclusiones manuales. No redundantes: tras la desreplicación al 99 % de ANI.

Linaje	Especie (GTDB)	Clúster	MAGs excl.	Post-QC	Válidos	No redund.	Resultado
L16	*Bacillus altitudinis*	217	3	209	208	137	Seleccionada
L12	*Peribacillus frigoritolerans*	82	3	72	69	42	Seleccionada
L8	*Acinetobacter schindleri*	37	8	29	29	23	Seleccionada
L18	*Cytobacillus firmus_B*	18	0	18	18	12	No viable
L11	*Staphylococcus warneri_A*	27	1	24	24	4	No viable
L9	*Priestia flexa*	31	1	29	29	4	No viable
L14	*Bacillus licheniformis*	307	6	279	279	1	No viable
L3	*Bacillus_AB infantis*	12	2	9	—	—	No viable
L1	*Telluria timonae*	8	5	3	—	—	No viable
L13	*Rossellomorea marisflavi*	4	0	4	—	—	No viable
L15	*Metabacillus halosaccharovorans*	4	0	4	—	—	No viable
L17	*Cytobacillus oceanisediminis*	1	0	1	—	—	No viable

Siete especies superaron el umbral de 15 genomas en el censo. El caso de *Telluria timonae* (L1) muestra el efecto del nuevo criterio: es el linaje más prevalente de la Estela, pero solo tiene ocho genomas en GTDB, cinco de ellos MAGs, y queda fuera del pangenoma. El censo debió resolver además dos diferencias de nomenclatura entre GTDB y el NCBI. La especie que GTDB llama *Telluria timonae* se registra en el NCBI como *Massilia timonae*, de modo que una búsqueda por el nombre de GTDB no devuelve ningún genoma. Y los sufijos de GTDB como `_A`, `_B` o `_AB` marcan especies que el NCBI no separa, por lo que el conteo del NCBI para esos nombres sale inflado. Por ambos motivos el censo cuenta los genomas del clúster de especie de GTDB y no los del NCBI.

Los 660 genomas de las siete especies viables se descargaron y los 660 coincidieron en longitud con lo registrado por GTDB. Al revisar los nombres que cada

genoma lleva en el NCBI aparecieron cuatro asignados por GTDB a una de estas especies pero rotulados en el NCBI con un género de otro filo: tres en *P. frigoritolerans* (dos como *Brevibacterium* sp. y uno como *Vibrio vulnificus*) y uno en *B. altitudinis* (como *Micromonospora* sp.). Su calidad según CheckM2 era buena, pero una discrepancia de esa magnitud sugiere un ensamblaje quimérico o contaminado, y se excluyeron. Quedaron 656 genomas válidos.

La desreplicación al 99 % de ANI cambió el orden de las especies. Las bases públicas contienen muchas cepas secuenciadas decenas de veces, y si todas entraran al pangenoma esas cepas pesarían más que las demás. El caso extremo es *Bacillus licheniformis*: sus 279 genomas forman un solo grupo al 99 % de ANI, con un ANI medio de 99.58 % entre ellos. La especie con más genomas públicos resulta ser, en la práctica, un solo clon muy secuenciado, y no sirve para estimar un pangenoma. Tras la desreplicación solo tres especies conservaron al menos 15 genomas no redundantes: *B. altitudinis* (137), *P. frigoritolerans* (42) y *A. schindleri* (23). Como el número de especies viables coincidió con el máximo de tres previsto, el ranking no tuvo que descartar ninguna.

Solo *B. altitudinis* superó el tope de 50 referencias por especie, de modo que solo en ella hubo que elegir. Se incluyeron primero los dos genomas representantes o de cepa tipo de la especie y el único aislado de sustrato pétreo o árido (un residuo minero de Portugal). Los 47 restantes se tomaron por rotación entre hábitats y, dentro de cada hábitat, entre continentes, eligiendo en cada paso el genoma de mejor calidad todavía no elegido. El resultado cubre 10 hábitats y 8 continentes. En *P. frigoritolerans* entraron los 42 genomas no redundantes, dominados por aislados de suelo y plantas (28 de 42) y de Asia y Europa (30 de 42). En *A. schindleri* entraron los 23, de los cuales 11 son aislados clínicos. Ese sesgo viene de las bases públicas, que tienen más cepas de hospital de esta especie, y no de la selección. En total entraron al pangenoma 115 referencias y los 3 bins.

Dos limitaciones de esta clasificación deben tenerse presentes al leer los resultados por hábitat. El 28 % de los 656 genomas no declara su fuente de aislamiento. Y los cinco genomas clasificados como de sustrato pétreo o árido proceden de drenaje minero, sal de mina, arena del desierto, residuo minero y un ánfora romana. Ninguno procede de patrimonio pétreo, porque en las bases públicas no hay aislados de ese origen para estas especies.

7.2.3.2. Anotación de los genomas

Los 118 genomas se anotaron con Bakta, con la misma versión, la misma base de datos y las mismas opciones. El control de la anotación compara el número de secuencias codificantes (CDS) de cada referencia con la mediana de su especie y emite una alerta si se aleja más del 20 %. No hubo ninguna alerta. La Tabla 7.8 compara los bins con sus referencias.

Tabla 7.8: Resultado de la anotación con Bakta. Para las referencias se da la mediana y el rango; para el bin, el valor observado y su proporción respecto de la mediana de CDS de la especie.

Especie	CDS de las referencias	Bin: CDS / contigs / Mpb	Bin / mediana	Completitud del bin
B. altitudinis	3789 (3513–4238)	2738 / 90 / 2.76	72 %	72.5 %
P. frigoritolerans	5337 (5089–6282)	4164 / 49 / 4.31	78 %	92.3 %
A. schindleri	3123 (2781–3552)	3265 / 96 / 3.50	105 %	99.9 %

En *B. altitudinis* y *A. schindleri* el número de genes del bin corresponde a lo que su completitud hace esperar. En *P. frigoritolerans* no: el bin tiene el 78 % de los genes de una cepa típica, aunque su completitud estimada es del 92.3 %. La diferencia tiene una explicación conocida. CheckM2 estima la completitud a partir de genes marcadores conservados, que se reconstruyen con facilidad, mientras que lo que suele perderse al reconstruir un MAG son regiones variables, repetidas o

móviles, es decir, genoma accesorio. La consecuencia práctica, que se repite en toda esta sección, es que la presencia de un gen en el bin es confiable y su ausencia no lo es.

7.2.3.3. Pangenoma de cada especie

El pangenoma de cada especie se construyó con Panaroo y se dividió en tres categorías según la fracción de referencias en que aparece cada familia de genes: core (al menos el 95 %), shell (del 15 al 95 %) y cloud (menos del 15 %). El genoma accesorio es la suma de shell y cloud. El umbral del 95 % corresponde a lo que Roary llama *soft core*, ya que en esa herramienta el core estricto exige el 99 % [44]. La partición se calculó solo con las referencias, por el motivo expuesto en el Capítulo VI. La Tabla 7.9 resume el resultado.

TABLA 7.9: Tamaño y partición del pangenoma de cada especie, calculados solo con las referencias. Singletons: familias presentes en una sola referencia. α: exponente de la ley de Heaps; entre paréntesis, el rango al quitar un genoma cada vez.

Especie	**Ref.**	**Core**	**Shell**	**Cloud**	**Pangenoma**	**Singletons**	α
B. altitudinis	50	3303	847	2909	7059	1546 (22 %)	0.66 (0.64–0.68)
P. frigoritolerans	42	3961	2142	10022	16125	6103 (38 %)	0.57 (0.55–0.58)
A. schindleri	23	2389	1114	4096	7599	2782 (37 %)	0.55 (0.52–0.57)

Las curvas de acumulación de la Figura 7.8 muestran que en las tres especies el pangenoma sigue creciendo con la última referencia añadida. La ley de Heaps resume ese crecimiento con un exponente α: un valor menor que 1 indica un pangenoma abierto, en el que cada genoma nuevo sigue aportando familias [68]. Los tres valores están entre 0.55 y 0.66, de modo que los tres pangenomas son abiertos. El exponente se estimó con 500 permutaciones del orden de los genomas, con el mismo

procedimiento que implementa el paquete micropan [69]. Debe leerse como un resumen estadístico de la muestra de genomas disponible y no como una propiedad fija de la especie [70].

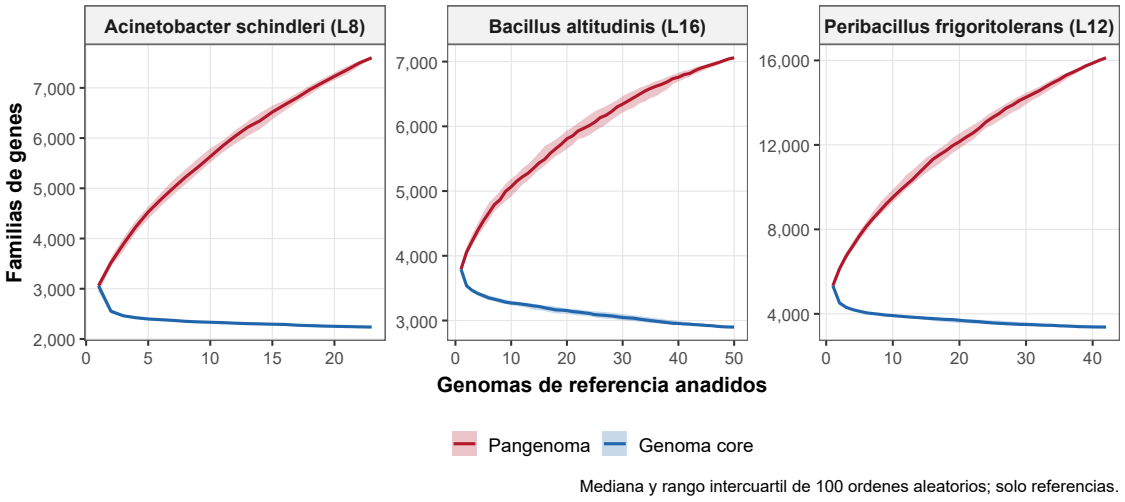


FIGURA 7.8: Curvas de acumulación del pangenoma (rojo) y del genoma core (azul) de cada especie, calculadas solo con las referencias. Cada curva es la mediana de 100 órdenes aleatorios de los genomas y la banda, el rango intercuartil.

P. frigoritolerans tiene un pangenoma mucho mayor que las otras dos especies, con 16 125 familias, y una fracción de singletons del 38 %. Como el tamaño del pangenoma crece con el número de genomas y las tres especies tienen 50, 42 y 23 referencias, se repitió la comparación con submuestras de 23 genomas. El orden se mantuvo: con 23 genomas, el pangenoma de *P. frigoritolerans* reúne unas 12 900 familias, frente a unas 6 000 en *B. altitudinis* y 7 599 en *A. schindleri*. En las tres especies el número de familias por número de genomas que las contienen tiene la forma de U habitual en los pangenomas bacterianos, con muchas familias raras, muchas universales y pocas intermedias [71].

Un pangenoma puede parecer abierto por un artefacto: si los ensamblajes muy fragmentados tuvieran genes partidos, cada fragmento se contaría como una familia nueva. La Figura 7.9 pone a prueba esa posibilidad de tres formas. Primero,

el número de familias únicas de cada referencia no aumenta con el número de contigs de su ensamblaje (panel a): la correlación de Spearman es nula en *B. altitudinis* ($\rho = -0.05$) y en *P. frigoritolerans* ($\rho = -0.08$), y negativa en *A. schindleri* ($\rho = -0.52$, $p = 0.01$), lo contrario de lo que produciría el artefacto. Segundo, α casi no cambia al quitar cualquier genoma, y calculado solo con genomas cerrados da 0.64 y 0.55 en *B. altitudinis* y *A. schindleri* (panel b). En *P. frigoritolerans* sube a 0.74, aunque con solo siete genomas cerrados la estimación es imprecisa: parte de la apertura de esta especie viene de borradores y de dos genomas atípicos, y parte es real, porque la especie tiene linajes muy separados, con un ANI mínimo entre referencias del 95.8 %, cerca del límite de especie. Por eso se reportan ambos valores. Tercero, la proporción de proteínas hipotéticas crece del core (13 a 17 %) al cloud (29 a 45 %), como es habitual, sin que el cloud esté dominado por ellas (panel c). Se concluye que la apertura de los tres pangenomas es real.

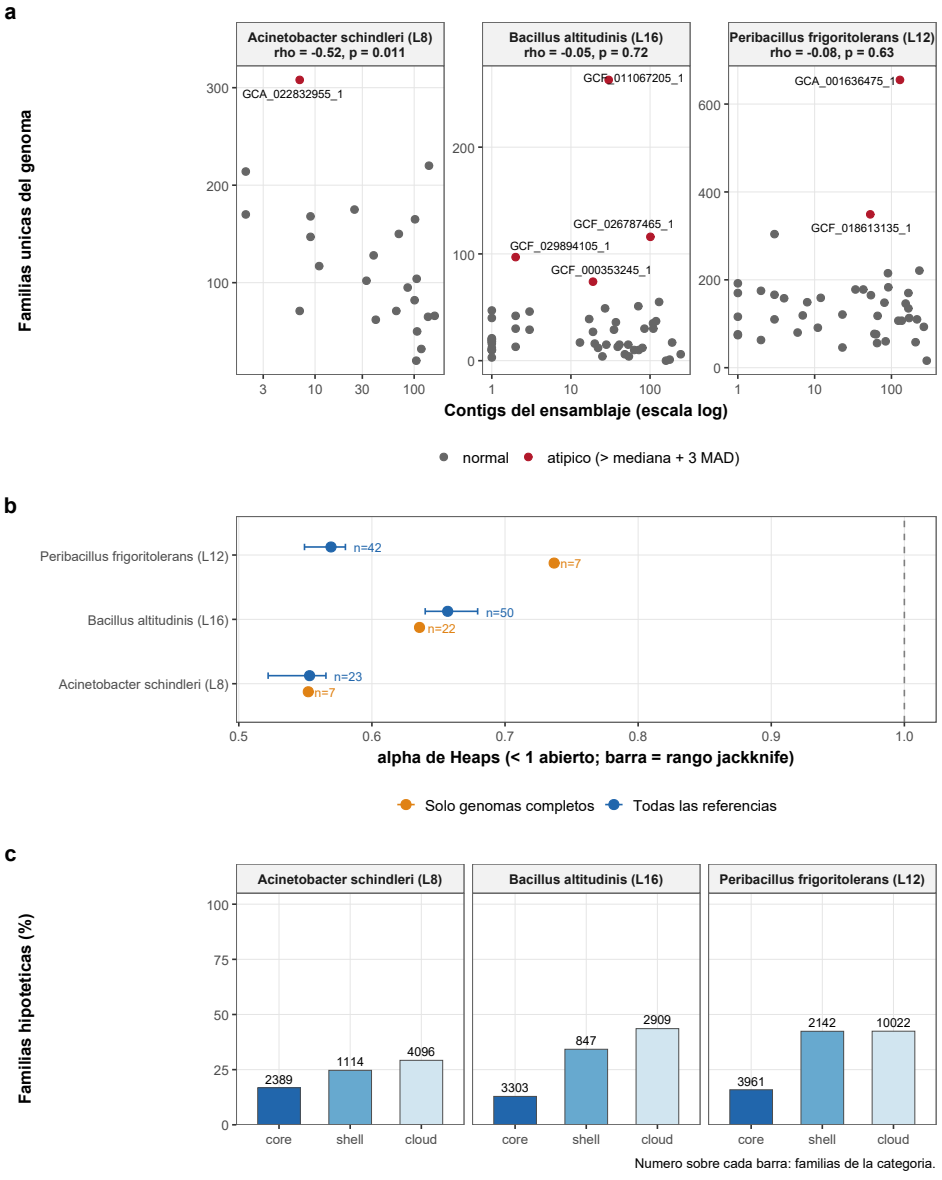


FIGURA 7.9: Diagnóstico de la apertura del pangenoma. **(a)** Familias únicas de cada referencia frente al número de contigs de su ensamblaje; en rojo, los genomas con más familias únicas que la mediana más tres desviaciones absolutas medianas. **(b)** Exponente α de Heaps con todas las referencias (azul; la barra es el rango al quitar un genoma cada vez) y solo con genomas cerrados (naranja). La línea discontinua marca $\alpha = 1$, el límite entre pangenoma abierto y cerrado. **(c)** Porcentaje de familias anotadas como proteína hipotética en cada categoría; el número sobre cada barra es el total de familias de la categoría.

La decisión de calcular la partición sin el bin se evaluó midiendo qué habría

pasado si el bin contara como un genoma más. Con las referencias usadas, el core habría bajado solo 15, 32 y 5 familias (del 0.2 al 0.8 %), porque el bin es un genoma entre 24 y 51. La pérdida de core por incompletitud que describen Li y Yin [72] es importante cuando hay pocos genomas o muchos MAGs: en el piloto, con cuatro genomas, contar el bin hacía caer el core de 3 410 a 2 539 familias. El cambio que sí habría producido contar el bin es que sus familias propias, 14, 34 y 70, habrían pasado a ser cloud y ya no podrían identificarse como candidatas a genes propios de la cepa.

7.2.3.4. Posición de cada bin en el pangenoma de su especie

Una vez definidas las categorías con las referencias, cada gen del bin se ubicó según la categoría de su familia. La Tabla 7.10 y la Figura 7.10 muestran el resultado. La última columna cuenta los genes del bin que Panaroo eliminó durante su limpieza y que, por tanto, no pertenecen a ninguna familia; su origen se explica en la Sección 7.2.5.4.

TABLA 7.10: Genes de cada bin según la categoría de su familia en el pangenoma de las referencias. Candidatos: genes de familias que no aparecen en ninguna referencia.

Bin	Genes	Core	Shell	Cloud	Candidatos	Eliminados	Core recuperado
bin-5-63	2739	2465	213	15	14	32	75.2 %
bin-1-54	4167	3406	520	200	34	7	85.7 %
bin-4-52	3266	2383	345	367	70	101	99.0 %

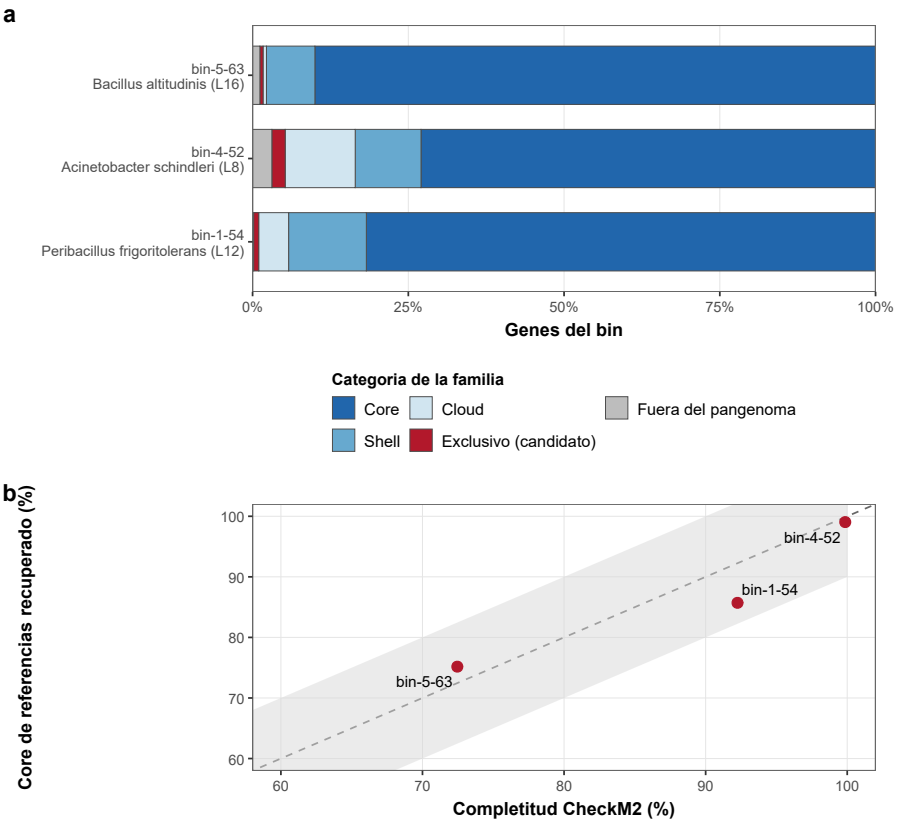


FIGURA 7.10: Posición de cada bin en el pangenoma de su especie. **(a)** Reparto de los genes del bin según la categoría de su familia en el pangenoma de las referencias; «fuera del pangenoma» son los genes que Panaroo eliminó. **(b)** Porcentaje del genoma core de las referencias presente en el bin frente a su completitud según CheckM2. La línea discontinua es la igualdad y la banda gris, un margen de ±10 puntos.

El panel b de la Figura 7.10 es un control de la partición. Si el análisis funciona, cada bin debe contener del core de las referencias un porcentaje parecido a su completitud, porque sus ausencias deberían explicarse solo por lo que le falta al bin. Los tres bins quedan dentro de un margen de 10 puntos. El control equivalente para las referencias exige que cada una contenga al menos el 97 % del core, y solo una no lo cumplió: GCF_018613135.1, de *P. frigoritolerans*, con el 94.6 %. Se mantuvo porque su calidad es alta (100 % de completitud y 0.5 % de contaminación), tiene

un número normal de genes y su ANI medio con las demás cepas es del 96.3 %: es una cepa divergente, no un ensamblaje defectuoso.

Para saber si los bins tienen muchos o pocos genes propios, se comparó su número de candidatos con el número de familias únicas de cada referencia, es decir, las que ninguna otra referencia tiene. Las medianas de las referencias son 18, 120 y 104 familias únicas, y los bins tienen 14, 34 y 70 candidatos, lo que los ubica en los percentiles 34, 2 y 26 de su especie. Cualquier cepa de estas especies tiene genes propios, y los bins de la Estela no tienen más que una cepa típica. Tener genes que ninguna otra cepa comparte no indica por sí mismo una adaptación al ambiente de la Estela.

7.2.3.5. Ubicación filogenética de cada bin

Para cada especie se infirió un árbol de máxima verosimilitud con IQ-TREE 3 [40] sobre el alineamiento concatenado de los genes core, incluido el bin. Los genes core que le faltan al bin quedan como datos faltantes, que el método tolera. La Tabla 7.11 resume los árboles y la posición de cada bin.

Tabla 7.11: Árboles del genoma core de cada especie y posición del bin. Distancia: suma de las ramas entre el bin y su pariente más cercano, en sustituciones por sitio.

	B. altitudinis	***P. frigoritolerans***	***A. schindleri***
Genomas en el árbol	51	43	24
Sitios alineados	2.71 Mpb	3.24 Mpb	2.04 Mpb
Sitios constantes	92.4 %	87.2 %	90.6 %
Sitios informativos	4.9 %	6.2 %	6.1 %
Modelo elegido (BIC)	GTR+F+I+R5	GTR+F+R7	GTR+F+R4
Nodos con UFBoot < 95	18 de 48	2 de 40	0 de 21
Pariente más cercano del bin	GCF_000828455.1	GCA_024160055.1	GCF_025514435.1
Origen del pariente	cereal fermentado, Países Bajos	suelo, Corea del Sur	clínico, EE. UU.
Distancia al pariente	0.016	0.0017	0.013
UFBoot del agrupamiento	100	100	100

Los tres bins se agrupan con su pariente más cercano con soporte máximo. En *B. altitudinis*, el bin y su pariente forman un grupo separado del resto de la especie, y la rama del bin (0.0083) mide casi lo mismo que la de su pariente (0.0077), lo que indica que la incompletitud del bin no alarga su rama. En *P. frigoritolerans* la distancia es de 0.0017 sustituciones por sitio, que equivale a cerca del 99.8 % de identidad en el core: el bin es prácticamente la misma cepa que su pariente (Figura 7.11). En *A. schindleri* el bin cae dentro de un grupo de cepas clínicas, lo que es coherente con el sesgo clínico de las referencias de esa especie.

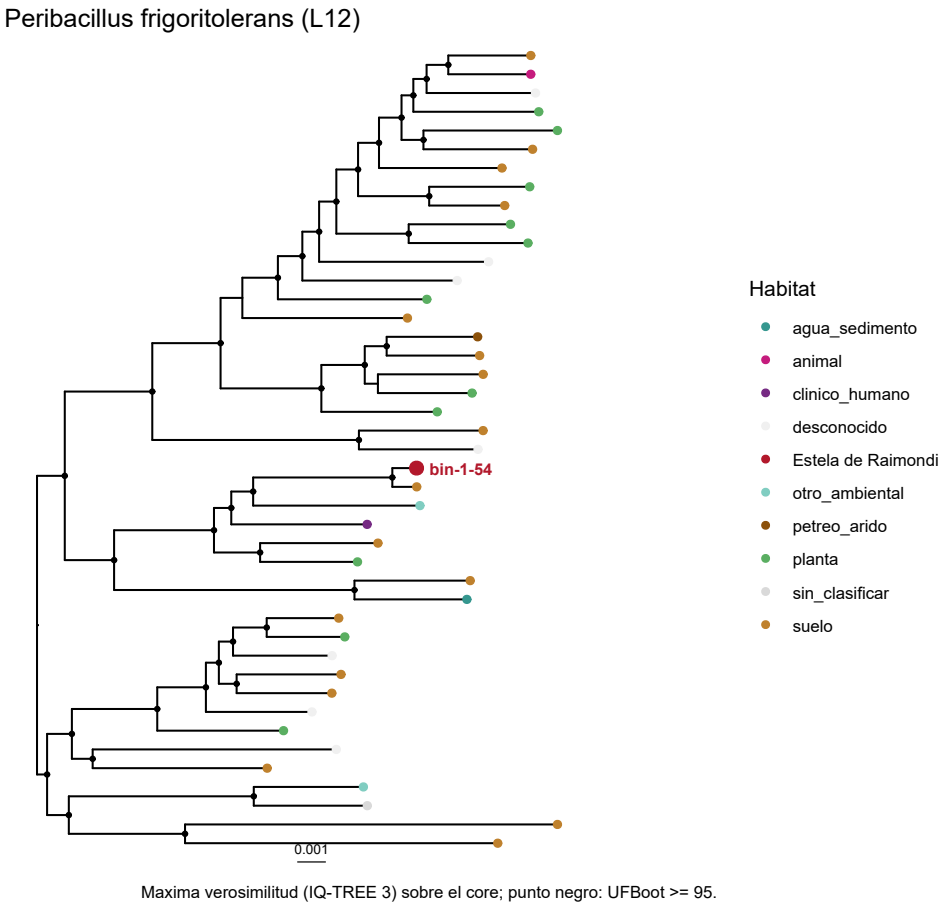


FIGURA 7.11: Árbol de máxima verosimilitud del genoma core de *Peribacillus frigoritolerans* (42 referencias y el bin `bin-1-54`), inferido con IQ-TREE 3. El color de cada punta indica el hábitat de aislamiento de la referencia. Los puntos negros marcan los nodos con UFBoot igual o superior a 95. La raíz se ubicó en el punto medio solo para dibujar el árbol y no representa el ancestro común. Los árboles de las otras dos especies se encuentran en el repositorio del proyecto.

Ningún bin se agrupa con las referencias de sustrato pétreo o árido. El hábitat del pariente más cercano refleja qué cepas se han secuenciado, no el origen del bin, y no debe leerse como una pista sobre la ecología de la cepa en la Estela. La confiabilidad de los árboles es desigual. La posición de cada bin es sólida, pero en *B. altitudinis* 18 de los 48 nodos internos tienen soporte bajo. Las ramas internas de esa especie son muy cortas, porque sus cepas difieren muy poco entre sí, y además

puede haber recombinación, que no se corrigió. Por eso no se hace ninguna afirmación sobre el orden en que se separaron sus cepas.

7.2.3.6. ANI de cada bin y coherencia con el árbol

El árbol usa solo los genes core y solo las referencias seleccionadas. Para contrastarlo se calculó el ANI de cada bin contra todos los genomas válidos de su especie (208, 69 y 29) con fastANI [37]. La Figura 7.12 y la Tabla 7.12 muestran el resultado.

TABLA 7.12: ANI de cada bin contra todos los genomas válidos de su especie. ρ: correlación de Spearman entre el ANI y la distancia en el árbol del core, calculada sobre las referencias del pangenoma.

Bin	**Genomas**	**ANI** $\geq 99\,\%$	**ANI máximo**	**Mediana**	**Genoma más parecido**	ρ
bin-5-63	208	2	99.06 %	98.19 %	GCF_900119345.1	−0.33
bin-1-54	69	8	99.98 %	97.18 %	GCA_900000145.1	−0.90
bin-4-52	29	0	98.39 %	97.12 %	GCF_025514435.1	−0.50

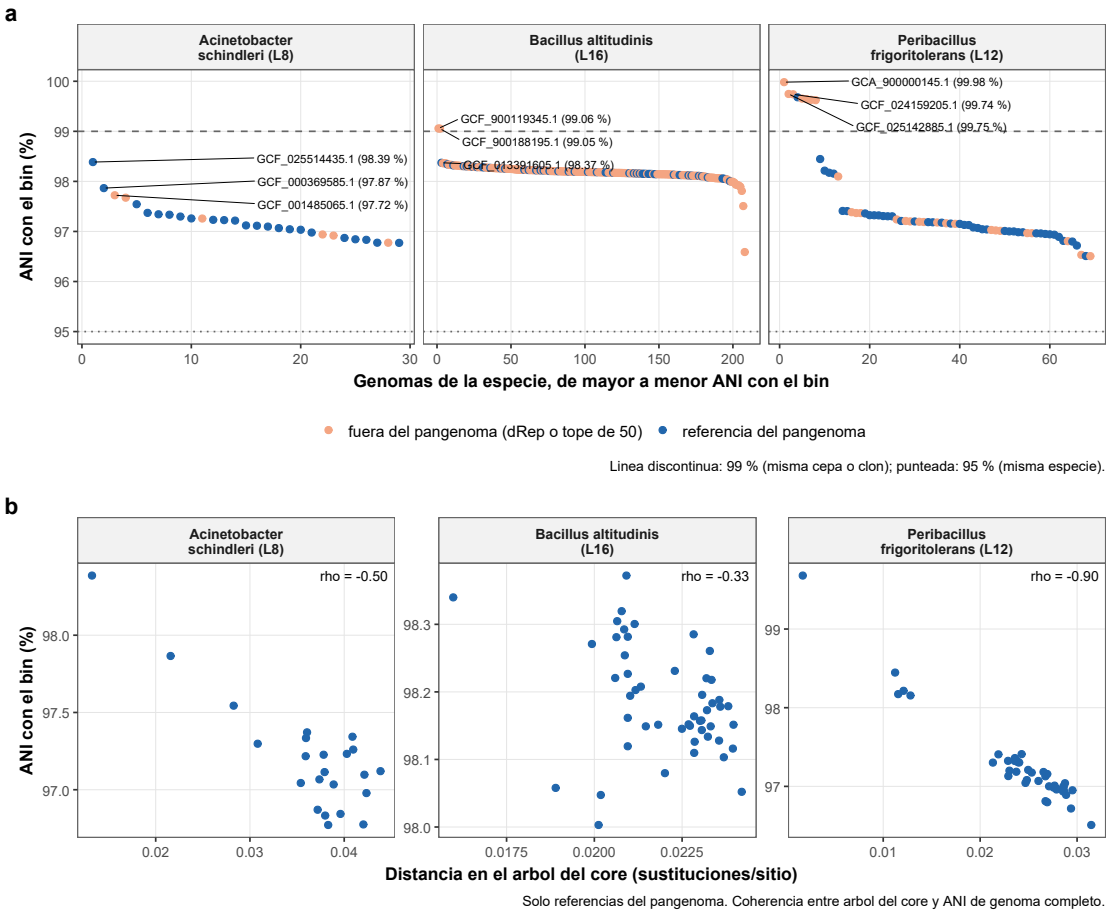


FIGURA 7.12: ANI de cada bin. **(a)** ANI del bin contra cada genoma válido de su especie, ordenados de mayor a menor. En azul, las referencias del pangenoma; en naranja, los genomas que quedaron fuera por la desreplicación o por el tope de 50. La línea discontinua marca el 99 % (misma cepa o clon) y la punteada, el 95 % (misma especie). **(b)** ANI del bin frente a la distancia en el árbol del core, para las referencias del pangenoma.

Los tres bins quedan en situaciones distintas. La cepa de *P. frigoritolerans* de la Estela es prácticamente idéntica a un genoma ya secuenciado (99.98 % de ANI con GCA_900000145.1) y pertenece a un clon de ocho genomas con ANI de al menos 99 % entre sí. Ese clon se ha aislado en cuatro continentes y en seis ambientes distintos: manzana y suelo agrícola en Alemania, semilla en Francia, suelo en Corea del Sur, nieve en la Antártida, y una sala limpia y piel humana en Estados Unidos.

Se trata, por tanto, de un linaje cosmopolita. La cepa de *B. altitudinis* pertenece también a un clon conocido (99.06 %), pero los dos genomas de ese clon quedaron fuera del pangenoma por la desreplicación o por el tope. La cepa de *A. schindleri*, en cambio, no alcanza el 99 % con ningún genoma de su especie: es una cepa distinta de todas las secuenciadas.

El panel b de la Figura 7.12 funciona como control cruzado entre dos métodos independientes: el árbol mide parentesco en los genes core y el ANI, en todo el genoma compartido. Si ambos son coherentes, el ANI debe bajar cuando aumenta la distancia en el árbol. La concordancia fue alta en *P. frigoritolerans* ($\rho = -0.90$) y moderada en *A. schindleri* ($\rho = -0.50$). En *B. altitudinis* fue débil ($\rho = -0.33$), pero no por una contradicción entre métodos. El bin y su pariente forman un grupo aparte, y para llegar desde el bin a cualquier otra referencia hay que recorrer la misma rama larga. Por eso todas las referencias quedan casi a la misma distancia del bin, entre 98.0 y 98.4 % de ANI, y las diferencias que quedan son del orden del error de medición de ambos métodos.

7.2.3.7. Contenido accesorio, parentesco y hábitat

Se comprobó si el genoma accesorio de las referencias se parece más entre cepas emparentadas o entre cepas del mismo hábitat. Para ello se midió la distancia de Jaccard entre los conjuntos de familias accesorias de cada par de genomas, sin contar los singletons. La prueba de Mantel compara esa distancia con la distancia en el árbol, y una PERMANOVA mide qué fracción de las diferencias explica el hábitat, usando solo los hábitats con al menos tres referencias. La Tabla 7.13 muestra el resultado.

Tabla 7.13: Relación del contenido accesorio con el parentesco (prueba de Mantel, 999 permutaciones) y con el hábitat (PERMANOVA, 999 permutaciones). Entre paréntesis, genomas y hábitats incluidos en la PERMANOVA.

Especie	**Mantel: accesorio y árbol**	**PERMANOVA por hábitat**
B. altitudinis	$r = 0.25$, $p = 0.001$	$R^2 = 0.17$, $p \approx 0.35$ (38; 7 hábitats)
P. frigoritolerans	$r = 0.73$, $p = 0.001$	$R^2 = 0.04$, $p \approx 0.3$ (28; 2 hábitats)
A. schindleri	$r = 0.54$, $p = 0.001$	$R^2 = 0.15$, $p \approx 0.06$ (17; 3 hábitats)

En las tres especies las cepas emparentadas comparten más genes accesorios, y el hábitat no agrega una señal detectable. Es el mismo patrón descrito en el grupo *Bacillus pumilus*, al que pertenece *B. altitudinis*, donde el linaje pesó más que el ambiente en la distribución de las cepas [73]. Este resultado tiene poca potencia: hay pocos genomas por hábitat y las categorías de hábitat son gruesas. Que no se detecte un efecto no significa que no exista. Lo que sí permite afirmar es que el pangenoma, por sí solo, no aporta evidencia de adaptación al sustrato pétreo.

7.2.3.8. Genes específicos de la cepa

Se denomina gen específico de la cepa a un gen del bin que no tiene copia, con al menos 80 % de identidad en al menos el 80 % de su longitud, en ningún genoma de su especie depositado en el NCBI a la fecha de la búsqueda ([**pendiente: fecha de la búsqueda remota de la versión 2**]). La definición es deliberadamente estrecha. No implica que el gen sea nuevo para la ciencia, ni que sea una adaptación a la piedra, ni que sea raro en la naturaleza: puede estar idéntico en otra especie del mismo género. Su número depende de cuántos genomas hay de la especie, de qué tan cerca está el pariente secuenciado más próximo, de la completitud del bin y de cuánto ADN móvil intercambia el género.

El punto de partida son los genes candidatos: los genes del bin cuya familia no aparece en ninguna referencia y, desde la segunda versión del análisis, también los genes del bin que Panaroo eliminó (Sección 7.2.5.4). Cada candidato pasa por una cadena de filtros que se aplican de los más baratos a los más costosos. El filtro F1 descarta los genes mal formados: pseudogenes, proteínas de menos de 100 aminoácidos y genes a menos de 100 pb del borde del contig, que suelen estar partidos [74, 75]. El F2 no descarta, sino que clasifica: si el contig del gen no comparte ninguna familia con las referencias, se considera huérfano y se revisa después como posible contaminación [76]. El F4 busca cada proteína con `tblastn` en todos los genomas válidos de la especie y descarta las que aparecen. El F3 busca cada gen en los demás bins de la misma muestra y solo advierte si aparece, porque un gen compartido con otra bacteria de la piedra puede ser ADN intercambiado o un error de reconstrucción. Los filtros remotos completan la cadena: F6 compara los contigs huérfanos con core_nt y descarta los que se parecen más a otro género; F5 busca cada proteína en nr y la descarta si la tiene un organismo de la misma especie; y F5b comprueba la especie de los genomas portadores por su ANI y no por su nombre [77]. La Tabla 7.14 muestra cuántos candidatos sobreviven a cada paso en la versión 2.

Tabla 7.14: Genes candidatos que sobreviven a cada filtro (versión 2). Entre paréntesis, los candidatos que proceden de genes eliminados por Panaroo.

Paso	***B. altitudinis***	***P. frigoritolerans***	***A. schindleri***
Candidatos	46 (32)	41 (7)	171 (101)
Descartados por F1 (cortos / borde / pseudogén)	12 / 9 / 0	12 / 0 / 0	26 / 4 / 4
Pasan F1	25	29	137
Presentes en otro genoma de la especie (F4)	11	28	40
Pasan F4 y van a F5	14	1	97
Contigs huérfanos enviados a F6	6	0	4
Advertencias por otros bins de la muestra (F3)	0	0	0
Descartados por F6, F5 y F5b	**[pendiente]**	**[pendiente]**	**[pendiente]**
Genes específicos de la cepa	**[pendiente]**	**[pendiente]**	**[pendiente]**

El filtro F4 es el que más descarta, y la razón varía según la especie. En *P. frigoritolerans*, 28 de los 29 candidatos que pasaron F1 están en otros genomas de la especie. En la primera versión, 24 de los 26 candidatos que F4 descartó estaban en un solo genoma, GCA_900000145.1, el que tiene 99.98 % de ANI con el bin y que la desreplicación había sacado del pangenoma. En *B. altitudinis*, de los 9 candidatos que F4 descartó en la primera versión, 6 estaban en genomas que no entraron por el tope de 50 y 3 en genomas que sacó la desreplicación. En *A. schindleri*, buena parte estaba en las propias referencias, pero con identidades del 80 al 97 %: eran integrasas, transposasas y proteínas de fago que Panaroo había separado en familias distintas. Sin buscar en todos los genomas de la especie, la lista de candidatos habría quedado inflada por la desreplicación, por el tope y por la forma en que se agrupan los genes móviles.

[pendiente: Resultado de F5, F5b y F6 de la versión 2: número final de genes específicos por especie, su origen probable y las advertencias por identidad casi total.]

La primera versión del análisis, cuya parte remota sí terminó, permite anticipar la naturaleza de estos genes. En ella quedaron 27 genes específicos en *A. schindleri* y ninguno en las otras dos especies. Los 27 están en ocho contigs, agrupados en islas junto a integrasas, transposasas y proteínas de fago. Su mejor parecido en nr está en otras especies de *Acinetobacter* en 24 casos, en un fago en uno, en *Cloacibacterium*, de otro filo, en otro, y en *Thauera* en el último. Dieciséis de ellos tienen al menos 99 % de identidad con una proteína de otra especie. Son, por tanto, ADN móvil adquirido por transferencia horizontal, muchas veces de forma reciente, y no genes originados en la cepa. El mejor parecido indica un origen probable y no identifica al donante [78]. Si alguno de estos genes tiene relevancia para el biodeterioro es una pregunta de la Fase 4.

7.2.3.9. Implicancia para el OE3

El OE3 se cumple para las tres especies con genomas públicos suficientes. Los resultados permiten afirmar lo siguiente:

- Los pangenomas de *B. altitudinis*, *P. frigoritolerans* y *A. schindleri* son abiertos, con un genoma core de 2 389 a 3 961 familias. La apertura se mantiene a igual número de genomas y no se explica por la fragmentación de los ensamblajes.
- Cada cepa de la Estela se ubica con soporte máximo junto a una cepa ya conocida de otro continente y de otro ambiente. Ninguna se agrupa con las cepas de sustrato pétreo o árido.
- La cepa de *P. frigoritolerans* es prácticamente idéntica a una cepa secuenciada y pertenece a un clon cosmopolita; la de *B. altitudinis* pertenece a un clon conocido; la de *A. schindleri* es distinta de todas las secuenciadas.

- El contenido accesorio sigue al parentesco y no al hábitat de aislamiento.
- Las cepas de la Estela no tienen más genes propios que cualquier otra cepa de su especie, y los genes específicos identificados hasta ahora son ADN móvil adquirido de otras especies del mismo género.

Estas afirmaciones tienen límites que conviene repetir. Los bins son MAGs, de modo que la ausencia de un gen no es concluyente, sobre todo en `bin-5-63` (72.5 % de completitud). Las referencias se limitan a GTDB R220, y los genomas depositados después solo se revisan a través de nr. Y la especificidad de un gen es relativa a lo que se ha secuenciado y a la fecha de la consulta. Pasan a la Fase 4 la ubicación de cada gen del bin en el pangenoma (`genes_bin.tsv`) y la lista final de genes específicos.

7.2.4 Sensibilidad de los resultados a los umbrales elegidos

Los resultados anteriores corresponden a una sola configuración. Esta sección responde a una pregunta distinta: cuánto habrían cambiado esos resultados con otros umbrales. La respuesta permite saber si el conjunto de 21 genomas es un resultado estable o el producto de una elección afortunada.

7.2.4.1. Umbrales de calidad genómica

Los escenarios E1 y E2 recalcularon la selección sobre los 66 bins procariotas variando de forma simultánea los dos umbrales de CheckM2. La Tabla 7.15 muestra el resultado.

Tabla 7.15: Número de genomas retenidos sobre los 66 bins procariotas al variar los umbrales de completitud y contaminación. La celda en negrita corresponde al caso base.

Completitud	**Cont.** $< 1\,\%$	**Cont.** $< 3\,\%$	**Cont.** $< 5\,\%$	**Cont.** $< 10\,\%$
$> 50\,\%$	17	22	24	25
$> 60\,\%$	17	22	24	25
$> 70\,\%$	16	19	**21**	22
$> 80\,\%$	12	15	17	18
$> 90\,\%$	12	14	16	17
$> 95\,\%$	10	12	14	15

El conjunto seleccionado resulta poco sensible al umbral de completitud. Bajarlo de 70 a 50 % solo añade tres genomas. Subirlo de 70 a 90 % solo retira cinco. La explicación está en la distribución de la completitud dentro del conjunto retenido, descrita en la Sección 7.2.1: la mediana alcanza el 99.86 % y trece genomas superan el 99 %. La mayoría de los genomas seleccionados está lejos del umbral, de modo que moverlo no los afecta.

El umbral de contaminación pesa más. Entre 1 y 5 % el conjunto pasa de 16 a 21 genomas, y cinco genomas dependen por completo de dónde se ponga ese límite. La contaminación es también el criterio que rechazó más bins en el caso base, con 20 exclusiones por ese solo motivo. En conjunto, la contaminación es el parámetro que gobierna el tamaño final del conjunto, y no la completitud.

Aumentar la contaminación hasta el 10 % habría añadido un solo genoma frente al caso base. Esto indica que el límite del 5 % no está descartando material útil que un criterio algo más permisivo habría recuperado. Entre 5 y 10 % de contaminación casi no hay bins.

7.2.4.2. Criterio de discriminación por dominio

El caso base decide el dominio de cada bin por mayoría simple sobre la longitud clasificada. El escenario E3 reemplazó ese criterio por un umbral explícito sobre la fracción procariota. La Tabla 7.16 compara ambas opciones.

TABLA 7.16: Número de bins retenidos, sobre los 97 de partida, según el criterio de discriminación por dominio.

Criterio	**Bins retenidos**
Mayoría simple (caso base)	66
Fracción procariota $> 25\,\%$	56
Fracción procariota $> 40\,\%$	54
Fracción procariota $> 50\,\%$	50
Fracción procariota $> 60\,\%$	44
Fracción procariota $> 75\,\%$	34
Fracción procariota $> 90\,\%$	30

Este es el punto del flujo más sensible al criterio elegido. La mayoría simple retiene 66 bins, mientras que exigir más de la mitad de la longitud clasificada como procariota retendría 50. La diferencia de 16 bins se explica porque la mayoría simple compara la fracción procariota contra las fracciones eucariota, organelar y desconocida por separado. Un bin con 40 % de longitud procariota, 30 % eucariota y 30 % desconocida tiene mayoría procariota, aunque menos de la mitad de su longitud lo sea.

Hay 22 bins cuya fracción procariota queda entre el 25 y el 75 %. La afirmación de la Sección 7.2.1 sobre la concentración de los bins en los extremos de la escala describe bien la tendencia general, pero este grupo intermedio existe y conviene dimensionarlo.

El efecto sobre el resultado final es menor de lo que sugieren estas cifras. El filtro de calidad de CheckM2 actúa después y elimina de todos modos los bins con mezcla de dominios, porque esa mezcla aparece como contaminación. El criterio de dominio afecta sobre todo al costo de cómputo de la etapa siguiente, ya que determina cuántos bins se someten a CheckM2.

7.2.4.3. Umbral de ANI para la definición de linaje

El escenario E4 varió el umbral de ANI con el que dRep agrupa genomas en linajes. El resultado es que el número de linajes no cambia: se mantiene en 19 para umbrales de 95, 98, 99 y 99.5 % de ANI.

La razón está en los valores observados. Solo dos parejas de genomas fueron comparadas con fastANI dentro de su clúster primario, y ambas presentan identidades muy altas: 99.95 % entre los dos *Corynebacterium* y 99.78 % entre los dos *Telluria timonae*. Ambas parejas siguen colapsando incluso con un umbral del 99.5 %. El resto de los genomas está tan separado que ningún umbral razonable los uniría.

Por lo tanto, la definición de linaje es insensible al umbral dentro de este conjunto. Este resultado refuerza la conclusión de la Sección 7.2.2 sobre la baja redundancia del material recuperado.

7.2.4.4. Continuidad del ensamblaje

El caso base no filtra por número de contigs. El escenario E5 añadió ese filtro para medir su efecto. Aplicar un límite de 300 contigs sobre los 21 genomas seleccionados dejaría 17. Saldrían `bin-5-50` (1041 contigs), `bin-6-50` (591), `bin-3-64` (459) y `bin-9-71` (346).

Este filtro no se aplicó en la Fase 1 por una razón concreta. Los cuatro genomas afectados incluyen a `bin-6-50`, representante del linaje más prevalente, y a `bin-9-71`, único representante de su género. Excluirlos habría reducido la descripción taxonómica de la comunidad, que es el objetivo del OE2, a cambio de una mejora que solo importa en el análisis pangenómico posterior. La decisión fue conservarlos en las Fases 1 y 2 y trasladar el control de continuidad a la etapa donde la fragmentación sí genera un error, tal como se discute en la Sección 7.2.1 a propósito de `bin-5-50`.

7.2.4.5. Umbral de desreplicación de las referencias

El escenario E6 repitió el agrupamiento de las referencias con umbrales del 99, 99.5 y 99.9 % de ANI, a partir de la tabla de ANI que dRep ya había calculado y con el mismo método de agrupamiento. La Tabla 7.17 muestra el número de genomas no redundantes de cada especie.

Tabla 7.17: Genomas no redundantes por especie según el umbral de ANI de la desreplicación. En negrita, el caso base.

Especie	**99 %**	**99.5 %**	**99.9 %**
B. altitudinis	**137**	154	167
P. frigoritolerans	**42**	52	58
A. schindleri	**23**	24	25
C. firmus_B	**12**	17	17
P. flexa	**4**	15	24
S. warneri_A	**4**	8	17
B. licheniformis	**1**	7	125

Las tres especies seleccionadas son las mismas al 99 y al 99.5 %. Al 99.9 % entrarían otras, pero ese umbral está en el límite de resolución de fastANI, que no distingue con fiabilidad diferencias de una décima de punto. Se mantuvo el 99 %, que

es el valor por defecto de dRep para separar cepas [39] y que se había fijado antes de ver los datos. La tabla confirma también que *B. licheniformis* no queda fuera por un umbral demasiado estricto: incluso al 99.5 % sus 279 genomas se reducen a siete. Que su ANI mínimo sea de 98.76 % y aun así forme un solo grupo al 99 % se debe a que dRep agrupa por enlace promedio, es decir, con el ANI medio de cada genoma con el grupo y no con el par más distante.

7.2.4.6. Umbral de contigs de las referencias

El límite de 300 contigs para las referencias es un criterio propio de este trabajo. Es más estricto que el máximo de 1 000 contigs que emplean GTDB y los autores de PPanGGOLiN para admitir un genoma [46, 79], porque aquí la fragmentación de las referencias puede producir genes partidos que se confundirían con genes accesorios. El escenario E12 midió si la viabilidad de las especies depende de ese valor, con límites de 200 y de 1 000 contigs. Con un límite de 200 contigs, *B. altitudinis* pasaría de 209 a 205 genomas tras el control de calidad, *P. frigoritolerans* de 72 a 65 y *A. schindleri* seguiría con 29. Con un límite de 1 000, a cada especie se le sumarían como mucho los genomas que se descartaron por fragmentados, que fueron 3 y 4 en las dos primeras y ninguno en la tercera. En ningún caso cambia qué especies son viables ni cuáles se seleccionan: la que más cerca queda del umbral, *Bacillus_AB infantis*, llegaría como mucho a 10 genomas.

7.2.4.7. Umbral del genoma core

El escenario E7 redujo el umbral del core del 95 al 90 %, lo que en *B. altitudinis* equivale a exigir presencia en 45 de 50 referencias en lugar de 48. El core creció solo 88, 117 y 20 familias, entre el 0.8 y el 3.0 %. Hay pocas familias cerca de la frontera, y el genoma core queda bien definido con cualquiera de los dos umbrales.

7.2.4.8. Modo de limpieza de Panaroo

Panaroo se ejecutó en modo `moderate`. El escenario E8 repitió el pangenoma en modo `sensitive`, que no elimina los genes de borde de contig poco respaldados, con los mismos genomas y la misma partición. La Tabla 7.18 compara ambos modos. Los valores de α de esta tabla se calcularon con un mismo conjunto de permutaciones para los dos modos, y por eso el de *B. altitudinis* difiere en una centésima del de la Tabla 7.9.

Tabla 7.18: Pangenoma de cada especie con los modos de limpieza `moderate` (caso base) y `sensitive`.

Especie	Modo	Core	Shell	Cloud	α	Genes del bin eliminados	Candidatos del bin
B. altitudinis	moderate	3303	847	2909	0.65	32	14
	sensitive	3303	847	3293	0.61	1	45
P. frigoritolerans	moderate	3961	2142	10022	0.57	7	34
	sensitive	3961	2143	12295	0.49	3	38
A. schindleri	moderate	2389	1114	4096	0.55	101	70
	sensitive	2389	1117	5237	0.46	1	171

El core y el shell no cambian, de modo que todo lo dicho sobre el genoma común de cada especie y sobre la posición de los bins es independiente del modo. El cloud crece entre el 13 y el 28 %, casi todo con familias de un solo genoma, que son los genes de borde de contig que el modo `moderate` elimina en las referencias. Con ellos α baja entre 0.04 y 0.09: el pangenoma parece más abierto, pero la conclusión de pangenoma abierto no cambia. El valor de α, en cambio, sí depende del modo, y por eso debe reportarse junto con él. La última columna confirma además la corrección aplicada en la segunda versión de los genes específicos: los candidatos del bin en modo `sensitive` (45, 38 y 171) son prácticamente los mismos que la versión 2 recupera en modo `moderate` (46, 41 y 171).

7.2.4.9. Base de datos y definición de especie en la verificación

Los escenarios E10 y E11 midieron cuánto depende la lista de genes específicos de la base de datos consultada y de cómo se decide que un genoma pertenece a la especie. Ambos se evaluaron sobre la primera versión. Con UniProtKB, consultada a través del EBI, en lugar de nr, habrían pasado como específicos siete genes que nr sí encontró en la especie (uno en *P. frigoritolerans* y seis en *A. schindleri*), porque UniProtKB elimina proteomas redundantes y le faltan muchos genomas de los géneros más secuenciados. Si la especie de cada genoma portador se hubiera decidido por su nombre en el NCBI y no por su ANI, habrían pasado cinco genes más. La lista de genes específicos depende, por tanto, de ambas decisiones, y el resultado oficial es el de nr con la especie decidida por ANI.

7.2.4.10. Distancia mínima al borde del contig

El filtro F1 descarta los genes a menos de 100 pb del borde del contig. Este margen es un criterio propio, basado en que los genes de borde de los ensamblajes en borrador suelen estar partidos [75]. El escenario E13 revisó los 13 candidatos descartados por este motivo en la versión 2: con un margen de 50 pb habrían vuelto 4, y sin margen, los 13. Esos genes tendrían que pasar después por F4 y F5, de modo que el efecto sobre el resultado final está acotado a lo sumo a esas cifras.

7.2.5 Iteraciones de diseño derivadas de los resultados

El diseño del flujo no se mantuvo fijo durante la ejecución. Varios resultados obligaron a modificarlo. Esta sección documenta cada caso siguiendo el ciclo de prueba, evaluación y rediseño.

Conviene precisar en qué consiste cada cambio. El diseño descrito en el Capítulo V es el punto de partida, y las pruebas de este capítulo son precisamente el mecanismo previsto para ponerlo a prueba. En todos los casos siguientes, los cambios se hicieron a partir de resultados obtenidos durante el análisis: un requerimiento de memoria mayor al disponible, una métrica que no permitió diferenciar los linajes, y varios problemas detectados al ejecutar la Fase 3. Para mantener la trazabilidad, se presentan por separado el diseño original, la evidencia que motivó el cambio y el diseño corregido. El Capítulo V conserva el diseño original.

7.2.5.1. Primera iteración: alcance del árbol filogenómico

El diseño inicial contemplaba construir un árbol *de novo* que incluyera los genomas propios junto con el conjunto completo de genomas de referencia del dominio bacteriano de GTDB. La prueba mostró que ese cálculo no cabe en los 98 GB de memoria asignados a la cuenta.

La evaluación de ese fallo distingue dos problemas. El primero es de recursos y no admite solución dentro de la cuota disponible. El segundo es de alcance: el objetivo del OE2 no requiere un árbol del dominio completo, sino verificar la coherencia de las asignaciones taxonómicas.

El rediseño consistió en dos cambios. Para la Fase 2 se calculó un árbol de distancias sobre el alineamiento concatenado de los 120 marcadores, restringido a los nuestros genomas. Ese árbol es el que aparece en la Figura 7.4 y cumple la función de verificación interna. Para la Fase 3, la ubicación de cada bin entre las cepas de su especie se resolvió con un árbol de máxima verosimilitud por especie, inferido con IQ-TREE 3 (versión 3.1.3) [40] sobre el alineamiento del genoma core generado por Panaroo. El modelo de sustitución se eligió con ModelFinder [41] según el criterio BIC y el soporte de las ramas se estimó con 1000 réplicas de UFBoot [42].

En la Fase 3 la pregunta cambia y con ella el método. Ya no se trata de verificar la coherencia de asignaciones entre filos, sino de ubicar una cepa entre otras de su misma especie, que difieren muy poco. Dentro de cada especie entre el 87 y el 92 % de los sitios del alineamiento del core son constantes, y la señal que separa a las cepas está en pocos sitios. Un árbol de distancias como el de Neighbor-Joining [80] resume el alineamiento en una sola distancia por par de genomas y pierde esa información sitio a sitio. La máxima verosimilitud [81] usa cada sitio con un modelo explícito de evolución, que incluye la variación de velocidad entre sitios, y entrega un soporte por rama. Su costo fue de dos a tres horas por especie, asumible dentro de la cuota. El árbol de Neighbor-Joining de la Fase 2 queda, por tanto, como una verificación interna con las limitaciones ya señaladas, y no como la prueba filogenética que preveía la Tabla 5.3.

7.2.5.2. Segunda iteración: criterio de selección de linajes para el pangenoma

El diseño original preveía seleccionar los linajes del análisis pangenómico por prevalencia espacial. La lógica era que un linaje presente en varios puntos del monumento resulta más relevante para el biodeterioro que una detección aislada.

La prueba invalidó ese criterio. Como muestra la Sección 7.2.2, diecisiete de los 19 linajes aparecen en una sola muestra y solo dos alcanzan una prevalencia de dos. Con esa distribución no es posible construir un ranking ni separar bacterias colonizadoras estables de detecciones puntuales.

La evaluación de este resultado identificó además una restricción más básica. Con 19 linajes sobre 21 genomas, y 17 de ellos representados por un único genoma,

el material propio no alcanza para construir ningún pangenoma. El análisis pangenómico depende necesariamente de genomas de referencia públicos, de modo que el criterio de selección debe incorporar la disponibilidad de esas referencias.

El rediseño reemplazó la prevalencia espacial por la disponibilidad genómica pública. Un linaje ingresa al análisis pangenómico si existe para su especie un número suficiente de genomas públicos de calidad adecuada. La ejecución obligó a precisar ese criterio en varios puntos respecto de lo previsto en el Capítulo V, que la Tabla 7.19 resume.

TABLA 7.19: Diferencias entre la Fase 3 descrita en el Capítulo V y la ejecutada.

Aspecto	**Capítulo V**	**Ejecutado**
Criterio de selección	Prevalencia espacial	Disponibilidad de genomas públicos
Umbral de genomas	Aproximadamente diez	15, contados después de la desreplicación
Linajes evaluados	Los seleccionados por prevalencia	Los 12 con nombre de especie en GTDB
Origen de las referencias	RefSeq y GTDB, con prioridad de RefSeq	Clúster de especie de GTDB R220, con ensamblajes de RefSeq y de GenBank
Control de calidad de las referencias	Sin especificar	Completitud $\geq 95\,\%$, contaminación $\leq 5\,\%$, ≤ 300 contigs, solo aislados
Referencias insuficientes	Ampliar al género	No se amplió: una especie sin referencias suficientes queda fuera
Número de referencias	Hasta estabilizar la curva de acumulación	Todas las no redundantes, con un tope de 50
Prioridad en la elección	Cepas latinoamericanas	Sin preferencia regional; prioridad a cepas tipo y a aislados de sustrato pétreo o árido
Exclusiones manuales	No previstas	Cuatro genomas con nombre de otro filo en el NCBI

Cada cambio tiene una razón concreta. El umbral de diez genomas no tenía respaldo bibliográfico, y se elevó a 15, el número mínimo de genomas con que los autores de PPanGGOLiN evaluaron la partición de pangenomas [46]. Se aplica

después de la desreplicación porque la inclusión de genomas filogenéticamente redundantes infla de forma artificial el core y subestima el genoma accesorio, lo que puede llevar a describir como cerrado un pangenoma que en realidad es abierto [70]: quince genomas redundantes no equivalen a quince genomas informativos. El caso de *B. licheniformis*, que pasa de 279 genomas a uno solo, muestra que la precaución era necesaria. Solo se evaluaron los linajes con nombre de especie porque el censo necesita un clúster de especie bien definido. No se amplió al género porque un pangenoma solo distingue con fiabilidad el genoma core del accesorio entre genomas estrechamente emparentados, como se argumentó en el Capítulo V.

El número de referencias no se fijó con la curva de acumulación porque los pangenomas resultaron abiertos, y en un pangenoma abierto la curva no se estabiliza. Se usaron todas las referencias no redundantes, con un tope de 50 para acotar el costo. El tope solo afectó a *B. altitudinis*, y sus efectos se controlaron de dos formas: el exponente α casi no cambia con el número de genomas, y la búsqueda de genes específicos se hizo contra los 208 genomas válidos de la especie y no solo contra los 50 elegidos. La preferencia por cepas latinoamericanas se eliminó por tres razones: el pangenoma debe representar la diversidad global de la especie, solo 19 de los 656 genomas válidos eran latinoamericanos, y la búsqueda de genes específicos ya incluye todos los genomas descargados. Las exclusiones manuales se documentaron en la Sección 7.2.3.1.

La prevalencia espacial se conserva como resultado descriptivo del OE2 y se reporta en la Tabla 7.6, pero deja de cumplir función de criterio de selección.

7.2.5.3. Tercera iteración: herramienta y modo de limpieza del pangenoma

El Capítulo V preveía reconstruir el pangenoma con Panaroo en modo estricto (`strict`) y dejaba PPanGGOLiN como alternativa. Antes de ejecutar se revisó el efecto de ese modo sobre la pregunta de esta fase. El modo estricto elimina de forma agresiva los genes poco respaldados, es decir, los que aparecen en un solo genoma, porque en un pangenoma de aislados suelen ser errores. Pero un gen propio de la cepa de la Estela es, por definición, un gen de un solo genoma, y el modo estricto lo eliminaría antes de poder examinarlo. Se adoptó el modo intermedio, `moderate`, y se descartó PPanGGOLiN para no duplicar el análisis; la ley de Heaps, que PPanGGOLiN calcula de forma nativa, se estimó por separado [69].

La ejecución mostró que el modo `moderate` tampoco era inocuo para esa pregunta, como se explica en la iteración siguiente. Mostró también que la elección del modo no afecta al core ni al shell (Sección 7.2.4.8). Se mantuvo `moderate` porque produce un pangenoma de referencias más limpio, sin fragmentos de borde de contig, y los genes del bin que poda se recuperan por otra vía.

La ejecución obligó además a fijar cómo se calcula la partición. Panaroo agrupa las familias con todos los genomas que recibe, incluido el bin, y en el piloto, con cuatro genomas, contar el bin hacía caer el core de 3 410 a 2 539 familias. Por eso la frecuencia de cada familia se calcula solo con las referencias, como se describe en el Capítulo VI.

7.2.5.4. Cuarta iteración: verificación de genes específicos

El diseño original definía los genes candidatos como las familias del bin ausentes en todas las referencias, y los contrastaba con nr y nt para descartar contaminación. La primera ejecución completa, terminada el 8 de octubre, dejó 2 genes

específicos en *B. altitudinis*, ninguno en *P. frigoritolerans* y 30 en *A. schindleri*. Su revisión detectó dos problemas.

El primero estaba en Panaroo. En el modo `moderate`, Panaroo elimina todo gen situado en el extremo de un contig que aparezca en menos de dos genomas, y repite la poda hacia el interior del contig hasta encontrar un gen compartido [35]. Es un filtro razonable para pangenomas de aislados, pero va en contra de lo que aquí se busca: un gen propio de la cepa está en un solo genoma, y un MAG tiene muchos extremos de contig. En los tres bins Panaroo había eliminado 140 genes, 136 de ellos en tramos continuos desde el borde de un contig. Por la misma razón, el filtro de contigs huérfanos (F6) no había recibido ningún contig: Panaroo ya los había quitado.

El segundo estaba en la forma de decidir la especie. El filtro F5 descartaba un gen si lo tenía un organismo con el nombre de la misma especie en el NCBI. Cinco de los genes considerados específicos estaban, sin embargo, en dos cepas depositadas como *Bacillus* sp. y *Acinetobacter* sp. Según su ANI, calculado por el propio NCBI contra las cepas tipo [77], la primera pertenece a *B. altitudinis* y la segunda a *A. schindleri*. Ambas proceden de rizosfera en China y se publicaron en agosto de 2025, después del release R220 de GTDB.

El rediseño corrigió ambos problemas. Los genes del bin que Panaroo eliminó pasaron a ser también candidatos, sin cambiar el pangenoma de las referencias. Se agregó el filtro F5b, que obtiene todos los genomas que contienen la proteína idéntica y decide la especie de cada uno por su ANI y no por su nombre. Y se agregó una advertencia para los genes cuyo mejor parecido, en otra especie, tiene al menos 99 % de identidad en al menos el 90 % de su longitud, como señal de una posible transferencia reciente. Aplicada solo la corrección por ANI, la primera versión pasa de 2, 0 y 30 genes específicos a 0, 0 y 27. La segunda versión, que incluye además los genes eliminados por Panaroo, eleva los candidatos a 46, 41 y 171 (Tabla 7.14).

7.2.5.5. Quinta iteración: ejecución de la búsqueda remota

El diseño preveía consultar nr y nt con la opción remota de BLAST+. En el clúster esa opción quedaba esperando sin devolver resultados, y se reemplazó por el envío directo a la interfaz web de BLAST del NCBI, descrito en el Capítulo VI. Para los contigs se consultó core_nt, una versión reducida de nt que el NCBI ofrece para búsquedas remotas, en lugar de nt completa. Durante la primera versión la cola del NCBI llegó a demorar hasta siete horas por especie, y se probó como alternativa la búsqueda en UniProtKB a través del EBI. La comparación mostró que no sirve como reemplazo (Sección 7.2.4.9), de modo que el resultado oficial es el de nr. Durante la segunda versión el NCBI canceló una búsqueda por exceder su límite de tiempo de procesador, y el programa se modificó para enviar lotes más pequeños y dividirlos si se cancelan.

7.2.5.6. Sexta iteración: comparación funcional del core y el accesorio

El diseño preveía comparar la función de los genes core y accesorios con las categorías COG. Bakta asigna una categoría COG a solo entre el 4 y el 31 % de los genes, según el genoma, y un número KEGG a una proporción parecida. Con esa cobertura, baja y desigual entre genomas, la comparación no es confiable. La comparación funcional se traslada a la Fase 4, que anota todos los genes con DRAM.

7.3 Verificación del cumplimiento de las especificaciones técnicas

Esta sección dictamina si el desempeño del *pipeline* alcanza los valores comprometidos. Las especificaciones se derivan de los objetivos específicos OE1, OE2

y OE3 y son las que admiten una verificación cuantitativa directa. La Tabla 7.20 cruza cada especificación con su método de verificación y con el resultado obtenido.

Tabla 7.20: Matriz de verificación del cumplimiento de las especificaciones técnicas.

Especificación	**Método de verificación**	**Objetivo**	**Resultado obtenido**	**Cumple**
Fases 1 y 2 (OE1 y OE2)				
Calidad del conjunto final de genomas	CheckM2 sobre cada genoma	Completitud $> 70\,\%$ y contaminación $< 5\,\%$	21 de 21 genomas; mediana de completitud 99.86 % y de contaminación 0.44 %	Sí
Resolución taxonómica de la asignación	GTDB-Tk sobre datos R220, con confirmación por ANI	Asignación al menos a nivel de género	21 de 21 a género; 16 de 21 con especie confirmada (ANI $\geq 95\,\%$, AF $\geq 65\,\%$)	Sí
Trazabilidad entre genoma y muestra de origen	Registro de correspondencia generado en la normalización de nombres	21 de 21 genomas	21 de 21 genomas vinculados a su librería de origen	Sí
Definición de unidades de análisis no redundantes	Desreplicación con dRep al 95 % de ANI	Conjunto sin genomas duplicados	19 linajes sobre 21 genomas; dos parejas colapsadas	Sí
Reproducibilidad de la ejecución	Registro de versiones y control de versiones del código	Versiones de herramientas y bases registradas	Registro de versiones por fase; scripts, resultados y archivos de bloqueo de los entornos versionados en repositorio	Sí
Fase 3 (OE3)				
Especies con pangenoma comparativo	Censo, descarga y desreplicación de genomas públicos	Al menos 15 genomas no redundantes por especie	3 especies, con 137, 42 y 23 genomas no redundantes	Sí
Anotación homogénea	Misma versión, base de datos y opciones de Bakta; control de CDS	Todos los genomas anotados, sin alertas	118 de 118 anotados; 0 alertas	Sí

Tabla 7.20 (continuación)

Especificación	Método de verificación	Objetivo	Resultado obtenido	Cumple
Partición estable del pangenoma	Sensibilidad al umbral del core y al modo de Panaroo	Core estable ante ambos cambios	Core +0.8 a 3.0 % con umbral del 90 %; idéntico entre modos	Sí
Calidad del bin dentro del pangenoma	Core de las referencias recuperado en el bin	A ±10 puntos de su completitud	3 de 3 bins (75.2, 85.7 y 99.0 %)	Sí
Ubicación filogenética del bin	Árbol de máxima verosimilitud por especie	Soporte UFBoot ≥ 95 en el agrupamiento del bin	UFBoot 100 en los 3 bins	Sí
Genes específicos verificados	Filtros F1 a F6 contra todos los genomas de la especie y contra nr	Lista final verificada	Parte local completa; parte remota **[pendiente]**	**[pendiente]**
Selección reproducible	Reglas deterministas y semillas fijas	Mismo resultado al repetir la ejecución	Selección sin azar; semillas fijas en IQ-TREE y R	Sí

7.4 Verificación del cumplimiento de restricciones

Las restricciones son límites que el diseño no podía cruzar, a diferencia de las especificaciones, que son metas de desempeño. La Tabla 7.21 verifica cada una.

Tabla 7.21: Matriz de verificación del cumplimiento de las restricciones del proyecto.

Restricción	Origen	Forma en que el diseño la respeta	Cumple
Cuota de cómputo de 32 núcleos, 98 GB de memoria y 24 h por trabajo	Política de asignación del clúster Khipu	Las Fases 1 y 2 se ejecutaron como trabajos únicos. En la Fase 3, el límite de cinco trabajos enviados obligó a anotar en tres lotes y a enviar los arreglos por tramos o de a una tarea; la memoria de Bakta se ajustó con un piloto. Todos los trabajos terminaron dentro del límite de tiempo. El árbol de referencia completo se reemplazó por árboles focalizados tras exceder la memoria disponible	Sí
Los nodos de cómputo no tienen acceso a internet	Arquitectura del clúster	Las bases de datos de CheckM2, GTDB R220 y Bakta y los genomas públicos se descargaron en el nodo de login antes de cada cálculo. Las únicas etapas que requieren conexión, el censo, la descarga y la búsqueda remota de genes específicos, se ejecutan en el login y no en los nodos de cómputo	Sí
No se dispone de las lecturas crudas de secuenciación	Condición de entrega del material por el centro de secuenciación	El flujo se diseñó para operar sobre bins ya ensamblados. No se recalculan coberturas ni se rehace el ensamblaje ni el *binning*	Sí
El conjunto de muestras es cerrado y no ampliable	Condición de acceso al monumento	El diseño trabaja con las 22 librerías disponibles. Las limitaciones de prevalencia se reportan como tales y no se compensan con muestreo adicional	Sí
Uso exclusivo de software de licencia libre y bases de datos públicas	Restricción presupuestal del proyecto	Todas las herramientas y bases empleadas son de acceso abierto, incluidos los servicios remotos del NCBI	Sí
Dependencia de servicios externos del NCBI	Tamaño de nr y core_nt, que no pueden instalarse en el clúster	La búsqueda remota guarda el identificador de cada consulta, reanuda tras un corte, divide los lotes que el NCBI cancela y distingue «sin resultado» de «sin parecidos». La fecha de consulta se reporta con el resultado	Sí

Tabla 7.21 (continuación)

Restricción	**Origen**	**Forma en que el diseño la respeta**	**Cumple**
Bases públicas con muestreo desigual	Cepas muy secuenciadas y sesgo clínico en algunas especies	Desreplicación al 99 % de ANI, rotación de hábitats en la selección y verificación de genes contra todos los genomas de la especie. El sesgo restante se declara como limitación	Sí

REFERENCIAS BIBLIOGRÁFICAS

[1] A. Cordy-Collins, "Richard l. burger, *Chavín and the Origins of Andean Civilization*. 248 pages, 245 illustrations. london: Thames & hudson, 1992. ISBN 0-500-05069-4, hardback," *Antiquity*, vol. 67, no. 257, pp. 947–948, dec 1993, book review.

[2] R. Hernández Asensio, "Las piedras suplican auxilio. arqueólogos, huaqueros y autoridades locales en chavín de huántar (1870–1945)," *Histórica*, vol. 36, no. 2, pp. 113–138, 2012.

[3] Museo Nacional de Arqueología, Antropología e Historia del Perú, *Los Tesoros del Museo: Colección Lítica*. Lima, Perú: Ministerio de Cultura del Perú, 2015.

[4] T. C. Dakal and S. S. Cameotra, "Microbially induced deterioration of architectural heritages: routes and mechanisms involved," *Environmental Sciences Europe*, vol. 24, p. 36, 2012.

[5] F. Villa, P. S. Stewart, I. Klapper, J. M. Jacob, and F. Cappitelli, "Subaerial biofilms on outdoor stone monuments: changing the perspective toward an ecological framework," *BioScience*, vol. 66, no. 4, pp. 285–294, 2016.

[6] D. G. Alonso-Reyes, F. S. Galván, N. N. Alvarado, M. C. D'Arpino, L. J. Martinez, H. J. Esquivel, C. A. Gallardo, M. J. Silva Manco, and V. H. Albarracín, "Echoes of 1816: microbial footprints in heritage artifacts from Argentina's museum of independence," *Frontiers in Microbiology*, vol. 16, p. 1611832, 2025.

[7] P. J. A. Skipper, L. K. Skipper, and R. A. Dixon, "A metagenomic analysis of the bacterial microbiome of limestone, and the role of associated biofilms in the biodeterioration of heritage stone surfaces," *Scientific Reports*, vol. 12, p. 4877, 2022.

[8] T. Branyšová, K. Demnerová, M. Ďurovič, and H. Stiborová, "Microbial biodeterioration of cultural heritage and identification of the active agents over the last two decades," *Journal of Cultural Heritage*, vol. 55, pp. 245–260, 2022.

[9] M. A. Pita-Galeana, M. Ruhle, L. López-Vázquez, G. de Anda-Jáuregui, and E. Hernández-Lemus, "Computational metagenomics: state of the art," *International Journal of Molecular Sciences*, vol. 26, no. 18, p. 9206, 2025.

[10] P. Tsukayama Cisneros, S. Zurita Macalupú, R. Cristóbal Delgado, A. Ampuero León, Y. Piucón Campos, F. Caballero Salazar, P. Carrasco Zúñiga, and K. Lugo Bardales, "Informe técnico del análisis microbiológico de la Estela Raimondi," Universidad Peruana Cayetano Heredia y Museo Nacional de Arqueología, Antropología e Historia del Perú (MNAAHP), Lima, Perú, Informe técnico interno Orden de Servicio N.º 0006172-2025, 2025.

[11] F. Jroundi, K. Elert, E. Ruiz-Agudo, M. T. González-Muñoz, and C. Rodriguez-Navarro, "Bacterial diversity evolution in Maya plaster and stone following a bio-conservation treatment," *Frontiers in Microbiology*, vol. 11, p. 599144, 2020.

[12] K. Sterflinger and G. Piñar, "Microbial deterioration of cultural heritage and works of art — tilting at windmills?" *Applied Microbiology and Biotechnology*, vol. 97, no. 22, pp. 9637–9646, 2013.

[13] F. Cappitelli, C. Cattò, and F. Villa, "The control of cultural heritage microbial deterioration," *Microorganisms*, vol. 8, no. 10, p. 1542, 2020.

[14] A. Chklovski, D. H. Parks, B. J. Woodcroft, and G. W. Tyson, "CheckM2: a rapid, scalable and accurate tool for assessing microbial genome quality using machine learning," *Nature Methods*, vol. 20, no. 8, pp. 1203–1212, 2023.

[15] P.-A. Chaumeil, A. J. Mussig, P. Hugenholtz, and D. H. Parks, "GTDB-Tk: a toolkit to classify genomes with the Genome Taxonomy Database," *Bioinformatics*, vol. 36, no. 6, pp. 1925–1927, 2020.

[16] H. Suchy, P. Zalar, and M. F. Macedo, "Microbial diversity of biodeteriorated limestone cultural heritage assets identified using molecular approaches—A literature review," *Applied Sciences*, vol. 14, p. 7429, 2024.

[17] Q. Li, B. Zhang, X. Yang, and Q. Ge, "Deterioration-associated microbiome of stone monuments: structure, variation, and assembly," *Applied and Environmental Microbiology*, vol. 84, no. 7, pp. e02 680–17, 2018.

[18] B. Gutarowska, S. Celikkol-Aydin, V. Bonifay, A. Otlewska, E. Aydin, A. L. Oldham, J. I. Brauer, K. E. Duncan, J. Adamiak, J. A. Sunner, and I. B. Beech, "Metabolomic and high-throughput sequencing analysis—modern approach for the assessment of biodeterioration of materials from historic buildings," *Frontiers in Microbiology*, vol. 6, p. 979, 2015.

[19] E. Zanardini, E. May, K. J. Purdy, and J. C. Murrell, "Nutrient cycling potential within microbial communities on culturally important stoneworks," *Environmental Microbiology Reports*, vol. 11, no. 2, pp. 147–154, 2019.

[20] A. A. Gorbushina, "Life on the rocks," *Environmental Microbiology*, vol. 9, no. 10, pp. 2418–2425, 2007.

[21] G. Chimienti, R. Piredda, G. Pepe, I. D. van der Werf, L. Sabbatini, C. Crecchio, P. Ricciuti, A. M. D'Erchia, C. Manzari, G. Pesole *et al.*, "Profile of microbial communities on carbonate stones of the medieval church of San Leonardo di

Siponto (Italy) by Illumina-based deep sequencing," *Applied Microbiology and Biotechnology*, vol. 100, no. 19, pp. 8537–8548, 2016.

[22] X. Ding, W. Lan, J. Wu, Y. Hong, Y. Li, Q. Ge, C. Urzì, Y. Katayama, and J.-D. Gu, "Microbiome and nitrate removal processes by microorganisms on the ancient Preah Vihear temple of cambodia revealed by metagenomics and N-15 isotope analyses," *Applied Microbiology and Biotechnology*, vol. 104, no. 22, pp. 9823–9837, 2020.

[23] X. Ding, W. Lan, and J.-D. Gu, "A review on sampling techniques and analytical methods for microbiota of cultural properties and historical architecture," *Applied Sciences*, vol. 10, no. 22, p. 8099, 2020.

[24] E. Gallego-Cartagena, H. Morillas, and M. Maguregui, "Biodeterioration of built heritage in the context of climate change and atmospheric pollution: Toward transdisciplinary conservation strategies," *Science of The Total Environment*, vol. 1013, p. 181313, 2026.

[25] S. Yadav and D. Purchase, "Biodeterioration of cultural heritage monuments: A review of their deterioration mechanisms and conservation," *International Biodeterioration & Biodegradation*, vol. 201, p. 106066, 2025.

[26] H.-C. Flemming and J. Wingender, "The biofilm matrix," *Nature Reviews Microbiology*, vol. 8, no. 9, pp. 623–633, 2010.

[27] M. Y. Galperin, N. Yutin, Y. I. Wolf, R. Vera Alvarez, and E. V. Koonin, "Conservation and evolution of the sporulation gene set in diverse members of the Firmicutes," *Journal of Bacteriology*, vol. 204, no. 6, pp. e00 079–22, 2022.

[28] D. Li, C.-M. Liu, R. Luo, K. Sadakane, and T.-W. Lam, "MEGAHIT: An ultra-fast single-node solution for large and complex metagenomics assembly via succinct de Bruijn graph," *Bioinformatics*, vol. 31, no. 10, pp. 1674–1676, 2015.

[29] S. Nurk, D. Meleshko, A. Korobeynikov, and P. A. Pevzner, "metaSPAdes: a new versatile metagenomic assembler," *Genome Research*, vol. 27, no. 5, pp. 824–834, 2017.

[30] R. M. Bowers, N. C. Kyrpides, R. Stepanauskas, M. Harmon-Smith, D. Doud, T. B. K. Reddy, F. Schulz, J. Jarett, A. R. Rivers, E. A. Eloe-Fadrosh *et al.*, "Minimum information about a single amplified genome (MISAG) and a metagenome-assembled genome (MIMAG) of bacteria and archaea," *Nature Biotechnology*, vol. 35, no. 8, pp. 725–731, 2017.

[31] D. D. Kang, F. Li, E. Kirton, A. Thomas, R. S. Egan, H. An, and Z. Wang, "MetaBAT 2: an adaptive binning algorithm for robust and efficient genome reconstruction from metagenome assemblies," *PeerJ*, vol. 7, p. e7359, 2019.

[32] C. M. K. Sieber, A. J. Probst, A. Sharrar, B. C. Thomas, M. Hess, S. G. Tringe, and J. F. Banfield, "Recovery of genomes from metagenomes via a dereplication, aggregation and scoring strategy," *Nature Microbiology*, vol. 3, no. 7, pp. 836–843, 2018.

[33] A. M. Eren, Ö. C. Esen, C. Quince, J. H. Vineis, H. G. Morrison, M. L. Sogin, and T. O. Delmont, "Anvi'o: an advanced analysis and visualization platform for 'omics data," *PeerJ*, vol. 3, p. e1319, 2015.

[34] M. Shaffer, M. A. Borton, B. B. McGivern, A. A. Zayed, S. L. La Rosa, L. M. Solden, P. Liu, A. B. Narrowe, J. Rodríguez-Ramos, B. Bolduc *et al.*, "DRAM for distilling microbial metabolism to automate the curation of microbiome function," *Nucleic Acids Research*, vol. 48, no. 16, pp. 8883–8900, 2020.

[35] G. Tonkin-Hill, N. MacAlasdair, C. Ruis, A. Weimann, G. Horesh, J. A. Lees, N. J. Croucher, R. Carter, D. M. Aanensen, S. D. Bentley *et al.*, "Producing polished prokaryotic pangenomes with the Panaroo pipeline," *Genome Biology*, vol. 21, no. 1, p. 180, 2020.

[36] D. H. Parks, M. Imelfort, C. T. Skennerton, P. Hugenholtz, and G. W. Tyson, "CheckM: assessing the quality of microbial genomes recovered from isolates, single cells, and metagenomes," *Genome Research*, vol. 25, no. 7, pp. 1043–1055, 2015.

[37] C. Jain, L. M. Rodriguez-R, A. M. Phillippy, K. T. Konstantinidis, and S. Aluru, "High throughput ANI analysis of 90k prokaryotic genomes reveals clear species boundaries," *Nature Communications*, vol. 9, p. 5114, 2018.

[38] D. H. Parks, M. Chuvochina, C. Rinke, A. J. Mussig, P.-A. Chaumeil, and P. Hugenholtz, "GTDB: an ongoing census of bacterial and archaeal diversity through a phylogenetically consistent, rank normalized and complete genome-based taxonomy," *Nucleic Acids Research*, vol. 50, no. D1, pp. D785–D794, 2022.

[39] M. R. Olm, C. T. Brown, B. Brooks, and J. F. Banfield, "drep: a tool for fast and accurate genomic comparisons that enables improved genome recovery from metagenomes through de-replication," *The ISME Journal*, vol. 11, no. 12, pp. 2864–2868, 2017.

[40] T. K. F. Wong, N. Ly-Trong, H. Ren, P. Demotte, H. Baños, A. J. Roger, E. Susko, C. Bielow, N. De Maio, N. Goldman, M. W. Hahn, M. dos Reis, L. S. Vinh, G. Huttley, R. Lanfear, and B. Q. Minh, "IQ-TREE 3: phylogenomic inference software using complex evolutionary models," *Molecular Biology and Evolution*, vol. 43, no. 5, p. msag117, 2026.

[41] S. Kalyaanamoorthy, B. Q. Minh, T. K. F. Wong, A. von Haeseler, and L. S. Jermiin, "ModelFinder: fast model selection for accurate phylogenetic estimates," *Nature Methods*, vol. 14, no. 6, pp. 587–589, 2017.

[42] D. T. Hoang, O. Chernomor, A. von Haeseler, B. Q. Minh, and L. S. Vinh, "UFBoot2: improving the ultrafast bootstrap approximation," *Molecular Biology and Evolution*, vol. 35, no. 2, pp. 518–522, 2018.

[43] H. Tettelin, V. Masignani, M. J. Cieslewicz, C. Donati, D. Medini, N. L. Ward, S. V. Angiuoli, J. Crabtree, A. L. Jones, A. S. Durkin *et al.*, "Genome analysis of multiple pathogenic isolates of *Streptococcus agalactiae*: implications for the microbial "pan-genome"," *Proceedings of the National Academy of Sciences*, vol. 102, no. 39, pp. 13 950–13 955, 2005.

[44] A. J. Page, C. A. Cummins, M. Hunt, V. K. Wong, S. Reuter, M. T. G. Holden, M. Fookes, D. Falush, J. A. Keane, and J. Parkhill, "Roary: rapid large-scale prokaryote pan genome analysis," *Bioinformatics*, vol. 31, no. 22, pp. 3691–3693, 2015.

[45] S. M. Soucy, J. Huang, and J. P. Gogarten, "Horizontal gene transfer: building the web of life," *Nature Reviews Genetics*, vol. 16, no. 8, pp. 472–482, 2015.

[46] G. Gautreau, A. Bazin, M. Gachet, R. Planel, L. Burlot, M. Dubois, A. Perrin, C. Médigue, A. Calteau, S. Cruveiller *et al.*, "PPanGGOLiN: Depicting microbial diversity via a partitioned pangenome graph," *PLOS Computational Biology*, vol. 16, no. 3, p. e1007732, 2020.

[47] D. Hyatt, G.-L. Chen, P. F. Locascio, M. L. Land, F. W. Larimer, and L. J. Hauser, "Prodigal: prokaryotic gene recognition and translation initiation site identification," *BMC Bioinformatics*, vol. 11, p. 119, 2010.

[48] T. Seemann, "Prokka: rapid prokaryotic genome annotation," *Bioinformatics*, vol. 30, no. 14, pp. 2068–2069, 2014.

[49] O. Schwengers, L. Jelonek, M. A. Dieckmann, S. Beyvers, J. Blom, and A. Goesmann, "Bakta: rapid and standardized annotation of bacterial genomes via

alignment-free sequence identification," *Microbial Genomics*, vol. 7, no. 11, p. 000685, 2021.

[50] M. Kanehisa, M. Furumichi, Y. Sato, M. Kawashima, and M. Ishiguro-Watanabe, "KEGG for taxonomy-based analysis of pathways and genomes," *Nucleic Acids Research*, vol. 51, no. D1, pp. D587–D592, 2023.

[51] B. L. Cantarel, P. M. Coutinho, C. Rancurel, T. Bernard, V. Lombard, and B. Henrissat, "The carbohydrate-active enzymes database (CAZy): an expert resource for glycogenomics," *Nucleic Acids Research*, vol. 37, no. Supplement 1, pp. D233–D238, 2009.

[52] H. Zhang, T. Yohe, L. Huang, S. Entwistle, P. Wu, Z. Yang, P. K. Busk, Y. Xu, and Y. Yin, "dbCAN2: a meta server for automated carbohydrate-active enzyme annotation," *Nucleic Acids Research*, vol. 46, no. W1, pp. W95–W101, 2018.

[53] B. P. Alcock, A. R. Raphenya, T. T. Y. Lau, K. K. Tsang, M. Bouchard, A. Edalatmand, W. Huynh, A.-L. V. Nguyen, A. A. Cheng, S. Liu, S. Y. Min, A. Miroshnichenko, H.-K. Tran, R. E. Werfalli, J. A. Nasir, M. Oloni, D. J. Speicher, A. Florescu, B. Singh, M. Faltyn, A. Hernandez-Koutoucheva, A. N. Sharma, E. Bordeleau, A. C. Pawlowski, H. L. Zubyk, D. Dooley, E. Griffiths, F. Maguire, G. L. Winsor, R. G. Beiko, F. S. L. Brinkman, W. W. L. Hsiao, G. V. Domselaar, and A. G. McArthur, "CARD 2020: antibiotic resistome surveillance with the Comprehensive Antibiotic Resistance Database," *Nucleic Acids Research*, vol. 48, no. D1, pp. D517–D525, 2020.

[54] M. Karlicki, S. Antonowicz, and A. Karnkowska, "Tiara: deep learning-based classification system for eukaryotic sequences," *Bioinformatics*, vol. 38, no. 2, pp. 344–350, 2022.

[55] L. J. U. Pronk and M. H. Medema, "Whokaryote: distinguishing eukaryotic and prokaryotic contigs in metagenomes based on gene structure," *Microbial Genomics*, vol. 8, no. 5, p. mgen000823, 2022.

[56] P. T. West, A. J. Probst, I. V. Grigoriev, B. C. Thomas, and J. F. Banfield, "Genome-reconstruction for eukaryotes from complex natural microbial communities," *Genome Research*, vol. 28, no. 4, pp. 569–580, 2018.

[57] B. Q. Minh, H. A. Schmidt, O. Chernomor, D. Schrempf, M. D. Woodhams, A. von Haeseler, and R. Lanfear, "Iq-tree 2: New models and efficient methods for phylogenetic inference in the genomic era," *Molecular Biology and Evolution*, vol. 37, no. 5, pp. 1530–1534, 2020.

[58] A. A. Elistratova, E. N. Dekhanova, D. R. Kamaldinova, E. I. Shagimardanova, M. R. Sharipova, M. F. Cohen, and I. V. Khilyas, "Extracellular molecular repertoire of xerotolerant actinobacteria colonizing serpentinite rocks," *International Journal of Molecular Sciences*, vol. 27, no. 10, p. 4233, 2026.

[59] D. G. Alonso-Reyes, F. S. Galván, L. R. Portero, N. N. Alvarado, M. E. Farías, M. P. Vazquez, and V. H. Albarracín, "Genomic insights into an andean multiresistant soil actinobacterium of biotechnological interest," *World Journal of Microbiology and Biotechnology*, vol. 37, no. 10, p. 166, 2021.

[60] N. Goosen and G. F. Moolenaar, "Repair of UV damage in bacteria," *DNA Repair*, vol. 7, no. 3, pp. 353–379, 2008.

[61] N. K. Dhami, M. S. Reddy, and A. Mukherjee, "Biomineralization of calcium carbonates and their engineered applications: a review," *Frontiers in Microbiology*, vol. 4, p. 314, 2013.

[62] Q. Li, B. Zhang, X. Yang, and Q. Ge, "Deterioration-associated microbiome of stone monuments: Structure, variation, and assembly," *Applied and Environmental Microbiology*, vol. 84, no. 7, pp. e02 680–17, 2018.

[63] A. Basile, F. P. Riggio, M. Tescari, A. Chebbi, A. Sodo, F. Bartoli, F. Imperi, G. Caneva, and P. Visca, "Metagenome-resolved functional traits of Rubrobacter species implicated in rosy discoloration of ancient frescoes in two Georgian cathedrals," *Science of the Total Environment*, vol. 958, p. 178135, 2025.

[64] C. Camacho, G. Coulouris, V. Avagyan, N. Ma, J. Papadopoulos, K. Bealer, and T. L. Madden, "BLAST+: architecture and applications," *BMC Bioinformatics*, vol. 10, p. 421, 2009.

[65] W. Shen and H. Ren, "TaxonKit: a practical and efficient NCBI taxonomy toolkit," *Journal of Genetics and Genomics*, vol. 48, no. 9, pp. 844–850, 2021.

[66] N. A. O'Leary, E. Cox, J. B. Holmes, W. R. Anderson, R. Falk, V. Hem, M. T. N. Tsuchiya, G. D. Schuler, X. Zhang, J. Torcivia *et al.*, "Exploring and retrieving sequence and metadata for species across the tree of life with NCBI Datasets," *Scientific Data*, vol. 11, p. 732, 2024.

[67] J. Shaw and Y. W. Yu, "Fast and robust metagenomic sequence comparison through sparse chaining with skani," *Nature Methods*, vol. 20, no. 11, pp. 1661–1665, 2023.

[68] H. Tettelin, D. Riley, C. Cattuto, and D. Medini, "Comparative genomics: the bacterial pan-genome," *Current Opinion in Microbiology*, vol. 11, no. 5, pp. 472–477, 2008.

[69] L. Snipen and K. H. Liland, "micropan: an R-package for microbial pan-genomics," *BMC Bioinformatics*, vol. 16, p. 79, 2015.

[70] A. Guerra, "The pangenome: a statistical model, not a fixed biological property," *Bioinformatics Advances*, vol. 6, no. 1, p. vbag069, 2026.

[71] G. Horesh, A. Taylor-Brown, S. McGimpsey, F. Lassalle, J. Corander, E. Heinz, and N. R. Thomson, "Different evolutionary trends form the twilight zone of the bacterial pan-genome," *Microbial Genomics*, vol. 7, no. 9, p. 000670, 2021.

[72] T. Li and Y. Yin, "Critical assessment of pan-genomic analysis of metagenome-assembled genomes," *Briefings in Bioinformatics*, vol. 23, no. 6, p. bbac413, 2022.

[73] X. Fu, L. Gong, Y. Liu, Q. Lai, G. Li, and Z. Shao, "*Bacillus pumilus* group comparative genomics: toward pangenome features, diversity, and marine environmental adaptation," *Frontiers in Microbiology*, vol. 12, p. 571212, 2021.

[74] M. Skovgaard, L. J. Jensen, S. Brunak, D. Ussery, and A. Krogh, "On the total number of genes and their length distribution in complete microbial genomes," *Trends in Genetics*, vol. 17, no. 8, pp. 425–428, 2001.

[75] J. F. Denton, J. Lugo-Martinez, A. E. Tucker, D. R. Schrider, W. C. Warren, and M. W. Hahn, "Extensive error in the number of genes inferred from draft genome assemblies," *PLoS Computational Biology*, vol. 10, no. 12, p. e1003998, 2014.

[76] A. Shaiber and A. M. Eren, "Composite metagenome-assembled genomes reduce the quality of public genome repositories," *mBio*, vol. 10, no. 3, pp. e00 725–19, 2019.

[77] S. Ciufo, S. Kannan, S. Sharma, A. Badretdin, K. Clark, S. Turner, S. Brover, C. L. Schoch, A. Kimchi, and M. DiCuccio, "Using average nucleotide identity to improve taxonomic assignments in prokaryotic genomes at the NCBI," *International Journal of Systematic and Evolutionary Microbiology*, vol. 68, no. 7, pp. 2386–2392, 2018.

[78] M. Ravenhall, N. Škunca, F. Lassalle, and C. Dessimoz, "Inferring horizontal gene transfer," *PLoS Computational Biology*, vol. 11, no. 5, p. e1004095, 2015.

[79] D. H. Parks, M. Chuvochina, C. Rinke, A. J. Mussig, P.-A. Chaumeil, and P. Hugenholtz, "GTDB: an ongoing census of bacterial and archaeal diversity through a phylogenetically consistent, rank normalized and complete genome-based taxonomy," *Nucleic Acids Research*, vol. 50, no. D1, pp. D785–D794, 2022.

[80] N. Saitou and M. Nei, "The neighbor-joining method: a new method for reconstructing phylogenetic trees," *Molecular Biology and Evolution*, vol. 4, no. 4, pp. 406–425, 1987.

[81] J. Felsenstein, "Evolutionary trees from DNA sequences: a maximum likelihood approach," *Journal of Molecular Evolution*, vol. 17, no. 6, pp. 368–376, 1981.

ANEXOS

ANEXO ABET ING 1 - Resolución de problemas

Para filtrar por dominio los MAGs obtenidos se evaluaron las siguientes herramientas:

Tiara: Es una herramienta de clasificación de secuencias metagenómicas basada en *deep learning* que permite separar contigs en categorías como arqueas, bacterias, procariotas, eucariotas, orgánulos y secuencias desconocidas mediante un esquema de dos etapas [54]. Según su publicación original, mostró un rendimiento similar a EukRep para la clasificación de secuencias procariotas, pero superior para secuencias eucariotas, además de requerir menor tiempo de cómputo [54]. Su principal ventaja es que no solo discrimina entre eucariotas y procariotas, sino que también puede identificar ADN organelar, lo que la hace especialmente útil en metagenomas complejos. Sin embargo, al basarse principalmente en patrones de composición de secuencia, puede presentar ambigüedad en linajes evolutivamente inusuales o muy cercanos a eucariotas, por lo que sus resultados deben interpretarse como una clasificación preliminar y no como una asignación taxonómica definitiva.

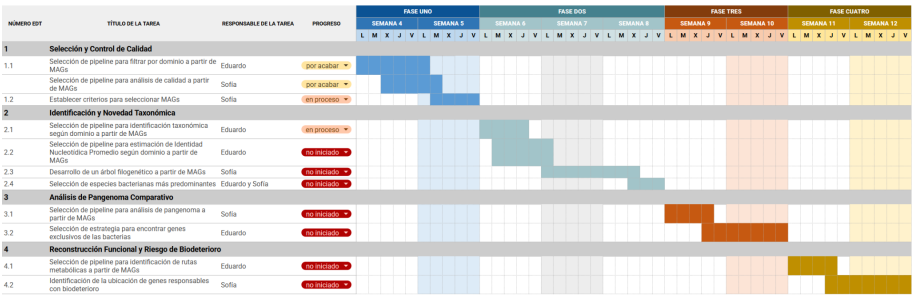
Whokaryote: Es un clasificador diseñado para distinguir contigs eucariotas y procariotas a partir de características de estructura génica, como la densidad génica, la distancia intergénica y la longitud de los genes, utilizando un modelo de *random*

forest [55]. A diferencia de Tiara y EukRep, que dependen sobre todo de frecuencias de *k-mers*, Whokaryote se apoya en diferencias biológicas más interpretables entre ambos dominios. En su artículo, los autores reportan una exactitud cercana al 97 %, indicando además que su desempeño es comparable al de Tiara y EukRep, con la ventaja adicional de aportar una validación independiente basada en otro tipo de señal [55]. Su principal fortaleza es precisamente esa complementariedad metodológica, ya que puede ayudar a confirmar o cuestionar clasificaciones obtenidas por herramientas basadas en composición. Como desventaja, depende de rasgos derivados de genes predichos, por lo que su ejecución es menos directa y puede ser más sensible a la calidad del ensamblado y de la predicción génica subyacente.

EukRep: Es una de las herramientas pioneras para separar secuencias eucariotas de procariotas en ensamblados metagenómicos, utilizando frecuencias de *k-mers* y un clasificador lineal tipo SVM [56]. Su objetivo principal es servir como filtro inicial para recuperar secuencias eucariotas y permitir después el uso de *pipelines* de anotación y análisis específicos para eucariotas. En su publicación original, mostró una exactitud global cercana al 90 % con fragmentos de 3 kb y de aproximadamente 98 % con fragmentos de 20 kb, lo que evidencia un mejor rendimiento en contigs largos [56]. Su ventaja principal es que se trata de una herramienta ampliamente reconocida y adoptada en estudios de recuperación de genomas eucariotas a partir de metagenomas. No obstante, sus limitaciones incluyen un menor desempeño relativo frente a Tiara en la clasificación de eucariotas y la ausencia de una clasificación explícita de secuencias organelares, además de que su precisión puede disminuir en fragmentos más cortos o en ensamblados altamente fragmentados.

ANEXO ABET ING 5 - Trabajo en equipo

En este anexo se presenta la evidencia del trabajo colaborativo desarrollado durante la ejecución del proyecto. Se podrán incluir reuniones de coordinación, distribución de tareas, seguimiento de avances y productos elaborados en conjunto.



NÚMERO EDT	TÍTULO DE LA TAREA	RESPONSABLE DE LA TAREA	PROGRESO
1	**Selección y Control de Calidad**		
1.1	Selección de pipeline para filtrar por dominio a partir de MAGs	Eduardo	por acabar
	Selección de pipeline para análisis de calidad a partir de MAGs	Sofía	por acabar
1.2	Establecer criterios para seleccionar MAGs	Sofía	en proceso
2	**Identificación y Novedad Taxonómica**		
2.1	Selección de pipeline para identificación taxonómica según dominio a partir de MAGs	Eduardo	en proceso
2.2	Selección de pipeline para estimación de Identidad Nucleotídica Promedio según dominio a partir de MAGs	Eduardo	no iniciado
2.3	Desarrollo de un árbol filogenético a partir de MAGs	Sofía	no iniciado
2.4	Selección de especies bacterianas más predominantes	Eduardo y Sofía	no iniciado
3	**Análisis de Pangenoma Comparativo**		
3.1	Selección de pipeline para análisis de pangenoma a partir de MAGs	Sofía	no iniciado
3.2	Selección de estrategia para encontrar genes exclusivos de las bacterias	Eduardo	no iniciado
4	**Reconstrucción Funcional y Riesgo de Biodeterioro**		
4.1	Selección de pipeline para identificación de rutas metabólicas a partir de MAGs	Eduardo	no iniciado
4.2	Identificación de la ubicación de genes responsables con biodeterioro	Sofía	no iniciado

FIGURA 7.13: Diagrama de Gantt del trabajo en equipo durante el desarrollo del proyecto.

ANEXO ABET ING 6 — Experimentación

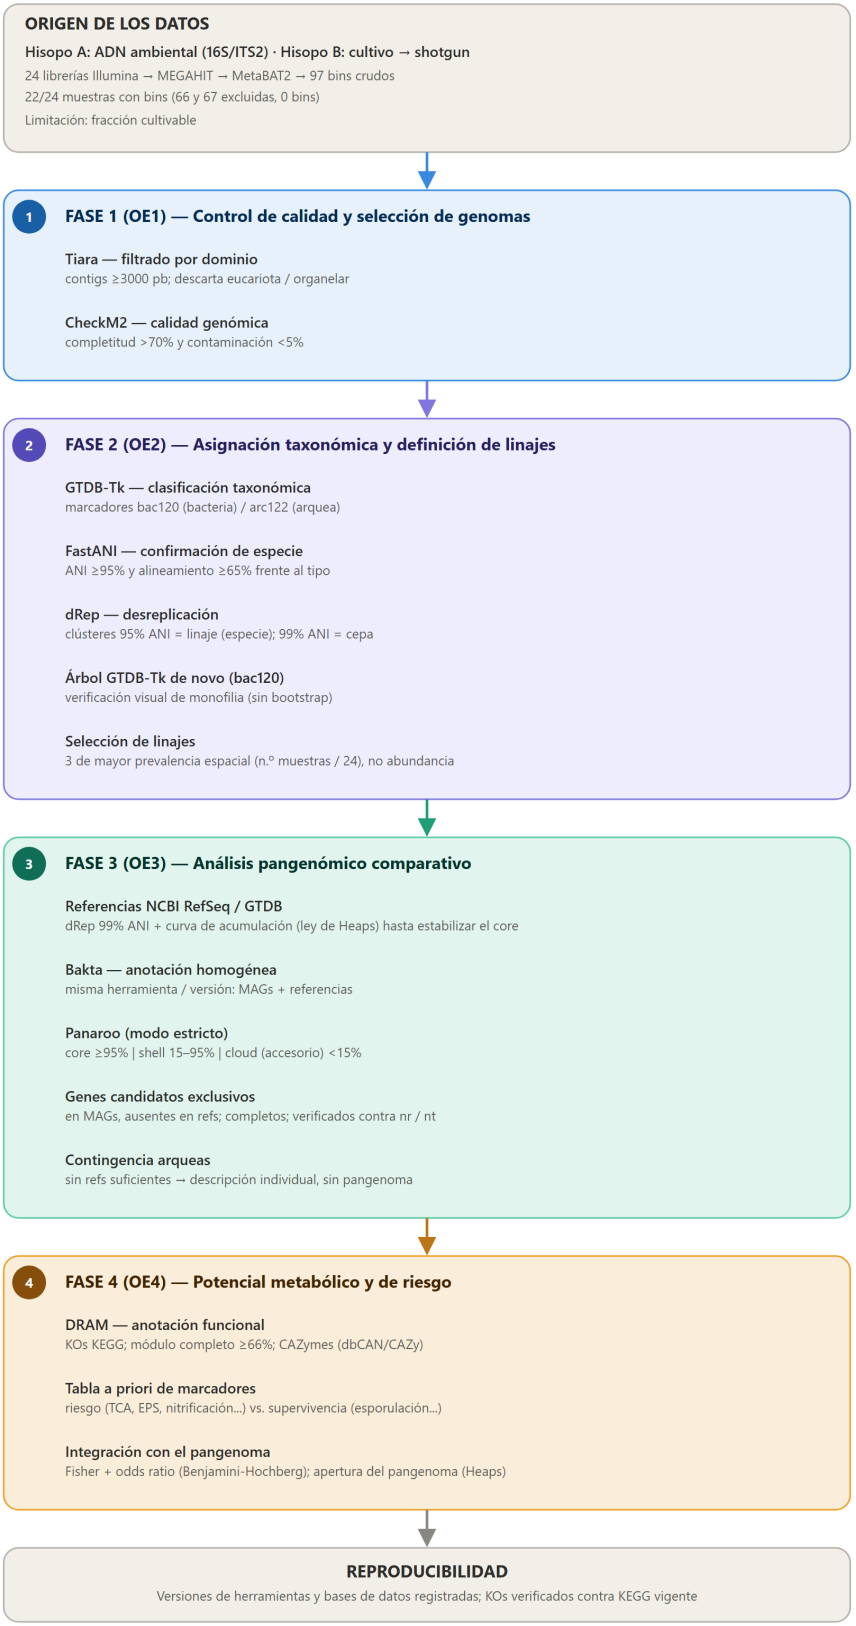


FIGURA 7.14: Flujograma del marco metodológico: cuatro fases consecutivas (OE1 a OE4) desde el origen de los datos metagenómicos hasta la caracterización del potencial metabólico y de riesgo.

ANEXO ABET ING 7 — Aprendizaje continuo

Tabla 7.22: Aprendizaje continuo: fuentes consultadas, contenido aprendido y su aplicación en el documento.

Ref.	**Información o contenido aprendido**	**Aplicación (en el documento)**
[4], [17], [21], [22]	Mecanismos de biodeterioro microbiano de la roca: acidólisis y quelación iónica por ácidos orgánicos de bajo peso molecular, y producción de ácidos nítrico y sulfúrico por bacterias de los ciclos del nitrógeno y del azufre que corroen los minerales. Fundamenta por qué ciertos genes metabólicos implican riesgo material.	Marco Teórico 2.1; Estado del arte; Marco Metodológico
[5], [9], [23], [26]	Marco ecológico de las biopelículas subaéreas en piedra, arquitectura de la matriz de EPS y rol dual biodeterioro/bioprotección, que motiva pasar de la identidad taxonómica al repertorio funcional.	Formulación del problema; Marco Teórico 2.2; Justificación
[9], [30]	Flujo de la metagenómica *shotgun*: ensamblaje *de novo* por grafos de De Bruijn y *binning* por composición de tetranucleótidos y cobertura diferencial para reconstruir MAGs.	Formulación del problema; Marco Teórico 2.3; Marco Metodológico
[14], [30], [36]	Definición de completitud y contaminación mediante genes marcadores de copia única; categorías de calidad MIMAG; estimación por aprendizaje automático (CheckM2) sin asignación taxonómica previa.	Marco Teórico 2.4; Marco Metodológico 4.1.3

Tabla 7.22 – continuación

Ref.	**Información o contenido aprendido**	**Aplicación**
[15], [37], [38], [39]	Clasificación genómica normalizada por divergencia evolutiva (GTDB-Tk/GTDB), delimitación de especie por ANI (umbral del 95 %) y sdereplicación para colapsar genomas redundantes y definir linajes.	Marco Teórico 2.5; Marco Metodológico 4.1.4
[35], [43]	Concepto de pangenoma y partición en genoma núcleo, cubierta y accesorio; la transferencia horizontal como motor de adaptación; corrección de la inflación del accesorio por fragmentación mediante grafos (Panaroo).	Marco Teórico 2.6; Marco Metodológico 4.1.5
[34], [47], [49]	Predicción de ORFs y anotación estandarizada sin alineamiento (Bakta); destilación del metabolismo y cálculo de completitud de módulos/rutas (DRAM) sobre ortólogos KEGG, base para inferir el potencial de biodeterioro.	Marco Teórico 2.7; Marco Metodológico 4.1.6
[54], [55], [56]	Clasificadores de contigs por dominio: aprendizaje profundo sobre composición (Tiara), estructura génica con *random forest* (Whokaryote) y *k-mers* con SVM (EukRep); criterios para seleccionar la herramienta de filtrado.	Marco Metodológico 4.1.3.1; Anexo 1
[1], [2], [3]	Contexto histórico-arqueológico de la Estela de Raimondi: filiación con la cultura Chavín, hallazgo, traslados sucesivos y custodia museística actual.	Introducción (Presentación del proyecto)

7.5 Anexo: Repositorio de GitHub

Link: GitHub

7.6 Anexo: Reporte completo de calidad y selección de bins (Fase 1)

Tabla 7.23: Reporte completo de evaluación y filtrado de bins genómicos (Fase 1).

Bin	Contigs	Long (bp)	Dom.	Comp. (%)	Contam. (%)	Motivo
bin-1-49	87	545.053	euk	–	–	dominio mayoritario: euk
bin-1-50	224	2.609.893	prok	62.29	2.66	completitud $62.29 \leq 70$
bin-1-51	51	4.727.435	prok	100.00	0.00	-
bin-1-52	26	415.732	prok	6.05	0.20	completitud $6.05 \leq 70$
bin-1-53	30	2.476.631	prok	99.84	0.12	-
bin-1-54	49	4.312.038	prok	92.25	0.01	-
bin-1-55	247	34.242.081	euk	–	–	dominio mayoritario: euk
bin-1-56	12	230.366	euk	–	–	dominio mayoritario: euk

Continúa en la siguiente página...

Tabla 7.23 – Continuación de la página anterior

Bin	Contigs	Long (bp)	Dom.	Comp. (%)	Contam. (%)	Motivo
bin-1-57	22	4.032.412	prok	99.99	3.23	-
bin-1-58	4725	12.125.594	unknown	0.00	17.71	completitud 0.00 $\leq$ 70; contamina-cion 17.71 $\geq$ 5
bin-1-59	98	5.907.869	prok	99.97	3.07	-
bin-1-60	302	8.273.570	prok	100.00	24.87	contaminacion 24.87 $\geq$ 5
bin-1-61	448	40.131.343	euk	–	–	dominio mayoritario: euk
bin-1-62	320	7.390.811	prok	99.72	72.67	contaminacion 72.67 $\geq$ 5
bin-1-63	162	65.185.746	prok	84.85	39.63	contaminacion 39.63 $\geq$ 5
bin-1-64	163	3.944.265	prok	99.84	0.59	-
bin-1-65	322	29.636.962	euk	–	–	dominio mayoritario: euk
bin-1-68	50	2.465.224	prok	100.00	1.79	-
bin-1-69	67	251.086	prok	6.60	0.14	completitud 6.60 $\leq$ 70

Continúa en la siguiente página...

Tabla 7.23 – Continuación de la página anterior

Bin	Contigs	Long (bp)	Dom.	Comp. (%)	Contam. (%)	Motivo
bin-1-70	3805	494.251.631	unknown	31.70	28.68	completitud 31.70 $\leq$ 70; contamina-cion 28.68 $\geq$ 5
bin-1-71	37	11.498.934	prok	67.71	15.05	completitud 67.71 $\leq$ 70; contamina-cion 15.05 $\geq$ 5
bin-1-72	16	7.408.652	unknown	5.87	0.19	completitud 5.87 $\leq$ 70
bin-10-71	506	2.845.557	prok	97.57	30.13	contaminacion 30.13 $\geq$ 5
bin-11-71	4161	101.946.556	unknown	65.68	17.72	completitud 65.68 $\leq$ 70; contamina-cion 17.72 $\geq$ 5
bin-12-71	383	1.015.904	unknown	43.42	3.52	completitud 43.42 $\leq$ 70
bin-2-49	134	27.557.437	euk	–	–	dominio mayoritario: euk

Continúa en la siguiente página...

Tabla 7.23 – Continuación de la página anterior

Bin	Contigs	Long (bp)	Dom.	Comp. (%)	Contam. (%)	Motivo
bin-2-50	464	53.406.620	euk	–	–	dominio mayoritario: euk
bin-2-52	270	5.347.688	prok	99.93	8.10	contaminacion $8.10 \geq 5$
bin-2-53	39	5.164.804	prok	99.99	0.57	-
bin-2-54	106	7.273.841	prok	100.00	15.52	contaminacion $15.52 \geq 5$
bin-2-56	816	49.647.189	euk	–	–	dominio mayoritario: euk
bin-2-57	28	5.172.263	prok	99.96	1.01	-
bin-2-58	17	4.771.531	prok	100.00	0.06	-
bin-2-59	424	23.212.147	prok	91.94	115.89	contaminacion $115.89 \geq 5$
bin-2-60	290	10.390.751	prok	100.00	100.33	contaminacion $100.33 \geq 5$
bin-2-61	9	614.253	euk	–	–	dominio mayoritario: euk

Continúa en la siguiente página...

Tabla 7.23 – Continuación de la página anterior

Bin	Contigs	Long (bp)	Dom.	Comp. (%)	Contam. (%)	Motivo
bin-2-62	5	227.679	euk	–	–	dominio mayoritario: euk
bin-2-63	150	4.282.638	prok	92.39	0.34	-
bin-2-64	924	226.083.286	unknown	0.02	16.03	completitud $0.02 \leq 70$; contamina-cion $16.03 \geq 5$
bin-2-65	141	17.056.380	euk	–	–	dominio mayoritario: euk
bin-2-68	70	246.182	prok	4.99	0.03	completitud $4.99 \leq 70$
bin-2-69	61	2.481.071	prok	99.99	0.18	-
bin-2-70	87	278.635	unknown	5.38	0.09	completitud $5.38 \leq 70$
bin-2-71	618	1.368.774	unknown	56.83	26.01	completitud $56.83 \leq 70$; contamina-cion $26.01 \geq 5$
bin-2-72	667	2.485.725	prok	79.16	54.30	contaminacion $54.30 \geq 5$

Continúa en la siguiente página...

Tabla 7.23 – Continuación de la página anterior

Bin	Contigs	Long (bp)	Dom.	Comp. (%)	Contam. (%)	Motivo
bin-3-50	30	2.607.902	unknown	13.03	0.08	completitud $13.03 \leq 70$
bin-3-52	204	5.184.467	prok	98.97	0.58	-
bin-3-53	301	29.244.092	euk	–	–	dominio mayoritario: euk
bin-3-56	160	26.628.065	euk	–	–	dominio mayoritario: euk
bin-3-57	818	25.745.728	euk	–	–	dominio mayoritario: euk
bin-3-58	265	29.647.785	euk	–	–	dominio mayoritario: euk
bin-3-60	959	2.321.293	unknown	39.27	0.00	completitud $39.27 \leq 70$
bin-3-61	50	10.715.439	euk	–	–	dominio mayoritario: euk
bin-3-62	117	449.659	euk	–	–	dominio mayoritario: euk

Continúa en la siguiente página...

Tabla 7.23 – Continuación de la página anterior

Bin	Contigs	Long (bp)	Dom.	Comp. (%)	Contam. (%)	Motivo
bin-3-63	4589	19.740.558	prok	99.91	102.18	contaminacion 102.18 $\geq$ 5
bin-3-64	459	2.352.198	prok	70.14	0.64	-
bin-3-65	5256	27.711.612	euk	–	–	dominio mayoritario: euk
bin-3-70	169	64.261.799	unknown	77.48	75.48	contaminacion 75.48 $\geq$ 5
bin-3-71	3657	12.324.162	prok	97.39	70.70	contaminacion 70.70 $\geq$ 5
bin-3-72	174	16.597.747	prok	98.53	98.35	contaminacion 98.35 $\geq$ 5
bin-4-50	97	1.654.013	prok	43.00	0.23	completitud 43.00 $\leq$ 70
bin-4-52	96	3.497.259	prok	99.86	0.25	-
bin-4-56	122	1.739.035	euk	–	–	dominio mayoritario: euk
bin-4-57	977	39.075.173	euk	–	–	dominio mayoritario: euk

Continúa en la siguiente página...

Tabla 7.23 – Continuación de la página anterior

Bin	Contigs	Long (bp)	Dom.	Comp. (%)	Contam. (%)	Motivo
bin-4-60	4482	25.724.799	euk	–	–	dominio mayoritario: euk
bin-4-61	1610	11.012.084	prok	100.00	58.51	contaminacion $58.51 \geq 5$
bin-4-62	270	79.759.046	prok	90.25	65.70	contaminacion $65.70 \geq 5$
bin-4-63	856	56.508.797	euk	–	–	dominio mayoritario: euk
bin-4-64	428	29.693.972	euk	–	–	dominio mayoritario: euk
bin-4-65	2506	20.150.702	prok	99.99	106.28	contaminacion $106.28 \geq 5$
bin-4-70	484	1.565.460	prok	64.00	2.55	completitud $64.00 \leq 70$
bin-4-71	216	488.562	unknown	32.24	2.32	completitud $32.24 \leq 70$
bin-4-72	72	248.801	prok	4.69	0.01	completitud $4.69 \leq 70$
bin-5-50	1041	3.472.002	prok	76.56	0.44	-

Continúa en la siguiente página...

Tabla 7.23 – Continuación de la página anterior

Bin	Contigs	Long (bp)	Dom.	Comp. (%)	Contam. (%)	Motivo
bin-5-52	1099	3.740.736	prok	95.51	12.95	contaminacion $12.95 \geq 5$
bin-5-56	146	552.204	euk	–	–	dominio mayoritario: euk
bin-5-57	12	224.138	euk	–	–	dominio mayoritario: euk
bin-5-60	97	2.849.856	prok	77.53	0.10	-
bin-5-61	273	5.811.268	prok	97.82	10.64	contaminacion $10.64 \geq 5$
bin-5-62	222	27.886.446	euk	–	–	dominio mayoritario: euk
bin-5-63	90	2.758.939	prok	72.46	0.05	-
bin-5-64	217	39.450.268	prok	100.00	67.99	contaminacion $67.99 \geq 5$
bin-5-65	24	222.213	euk	–	–	dominio mayoritario: euk
bin-5-70	28	2.628.283	unknown	48.48	2.40	completitud $48.48 \leq 70$

Continúa en la siguiente página...

Tabla 7.23 – Continuación de la página anterior

Bin	Contigs	Long (bp)	Dom.	Comp. (%)	Contam. (%)	Motivo
bin-5-71	118	438.388	prok	12.74	0.54	completitud 12.74 $\leq$ 70
bin-6-50	591	5.543.214	prok	100.00	0.65	-
bin-6-56	116	9.578.458	euk	–	–	dominio mayoritario: euk
bin-6-57	126	448.524	euk	–	–	dominio mayoritario: euk
bin-6-61	30	4.792.746	prok	100.00	0.74	-
bin-6-63	21	367.167	euk	–	–	dominio mayoritario: euk
bin-6-64	71	239.057	euk	–	–	dominio mayoritario: euk
bin-6-70	319	48.190.971	unknown	68.24	17.99	completitud 68.24 $\leq$ 70; contamina-cion 17.99 $\geq$ 5
bin-6-71	34	453.921	prok	11.79	0.16	completitud 11.79 $\leq$ 70

Continúa en la siguiente página...

Tabla 7.23 – Continuación de la página anterior

Bin	Contigs	Long (bp)	Dom.	Comp. (%)	Contam. (%)	Motivo
bin-7-64	1246	3.769.741	prok	60.17	0.22	completitud $60.17 \leq 70$
bin-7-71	95	258.968	unknown	7.21	0.05	completitud $7.21 \leq 70$
bin-8-71	908	2.450.575	unknown	81.92	35.87	contaminacion $35.87 \geq 5$
bin-9-71	346	1.832.072	prok	85.09	2.13	-